gebracht.' Hij beoogt en bedrijft dus tekstanalyse, geen contextanalyse. Anders dan Weijers heb ik geen fundamentele bezwaren tegen ideeëngeschiedenis. Zelf zal hij het niet willen horen, maar ik vind dat hij met dit proefschrift een voortreffelijke bijdrage aan deze vorm van geschiedschrijving heeft geleverd.

Wie is er bang voor Shrdlu?

Marc Berg

Recensie van: Harry M. Collins, *Artificial Experts. Social Knowledge and intelligent Machines.* MIT Press, Cambridge, Massachusetts, 1990.

Het volgende is een conversatie met SHRDLU, een gesimuleerde robot. Op het beeldscherm is een tafelblad met gekleurde blokken zichtbaar, die het programma desgewenst verplaatst.

Pick up a big red block.
OK *(Om dit te doen moest eerst een groen blok verplaatst worden).*
Grasp the pyramid.
I DON'T KNOW WHICH PYRAMID YOU MEAN *(Er zijn er twee).*
The red one.
OK.
Build a steeple.
SORRY, I DON'T KNOW THE WORD 'STEEPLE'.
A 'steeple' is a stack of two boxes and a pyramid.
I UNDERSTAND *(SHRDLU voert alsnog de opdracht uit).*
Trade you a football for a big red block.
SORRY I DON'T KNOW THE WORD 'TRADE'.
A 'trade' is a free exchange of property.
SORRY, I DON'T KNOW THE WORD 'FREE'.
Sorry, I thought you were smarter than you are.
SORRY, I DON'T KNOW THE WORD 'SORRY'. (1)

Is het denkbaar dat computers zullen denken en handelen als mensen? Of is 'intelligentie' een uniek menselijk kenmerk, zodat 'artificiële intelligentie' een *contradictio in terminis* is? Deze vragen zijn niet slechts interessant voor techniek-fanaten. Ze raken aan een fundamenteel filosofisch debat: in hoeverre is menselijke kennis *formaliseerbaar,* dat wil zeggen, reduceerbaar tot een set van elementaire gegevens en combinatie-regels? En, hieraan direct gerelateerd: in hoeverre is menselijk gedrag in termen van expliciete regels te analyseren? De ontwikkeling van artificiële intellgentie vormt een intrigerende, *empirische* wending in dit debat. Digitale computers *zijn* immers formele systemen. Indien computers zich intelligent kunnen gedragen, is het filosofische debat beslecht.

Bestaande computers, echter, zijn zelden echt intelligent te noemen. Hubert Dreyfus beargumenteerde in 1972 dat dit komt doordat menselijke expertise voornamelijk niet-formaliseerbare, 'open' domeinen betreft. Zolang het gaat om formaliseerbare, 'gesloten' kennisgebieden, zoals het schakspel, wiskundige theorieën of de 'blokken-wereld' van SHRDLU, kunnen computerprogramma's excelleren. Zodra echter dergelijke domeinen verlaten worden, zodra alledaagse woorden als 'handel', 'ruilen' of 'sorry' relevant worden, faalt de computer. Dreyfus, zich baserend op Wittgenstein en de fenomenologische traditie, stelt dat deze beperking *principieel* is. Buiten formele domeinen is menselijk handelen niet in termen van expliciete regels en definities te vangen: hier hebben

1 Naar John Haugeland, *Artificial Intelligence. The Very Idea.* Cambridge, Massachusetts 1985, pp. 188-190.

eventuele regels altijd een *ceteris paribus* clausule. '[T]hey apply 'everything else being equal', and what 'everything else' and 'equal' means in any specific situation can never be fully spelled out without a regress.' (2) Een digitale computer kan nooit begrijpen wat 'sorry' betekent, omdat deze betekenis ingebed is in onze levensvorm - en deze kan nooit volledig expliciet gemaakt worden.

Bijna twintig jaar nadat Dreyfus deze woorden schreef verschijnt *Artificial Experts,* het nieuwe boek van Harry Collins. Collins, een van de grondleggers van de sociaal constructivistische benadering binnen het wetenschapsonderzoek (3), benadrukt evenals Dreyfus het belang van de discussie rondom artificiële intelligentie. Vanuit Collins' kennissociologisch oogpunt bezien, echter, maakt Dreyfus een fundamentele fout. Dreyfus stelt dat kennis formaliseerbaar is wanneer de realiteit die in deze kennis gerepresenteerd wordt zelf afdoende geordend is. Zijn indeling in 'formaliseerbare' en 'niet-formaliseerbare' kennisgebieden impliceert dus dat 'formaliseerbaarheid' een eigenschap van een objectieve Realiteit is. Als je de recente kennissociologie echter serieus neemt, aldus Collins, zijn ook kennisgebieden als wiskunde en theoretische fysica produkten van sociale interactie. *Alle* kennis is ingebed in sociale praktijken; door representatie geven *wij* vorm aan wat wij als 'realiteit' zien. Collins beargumenteert dan ook dat het *ceteris paribus* argument ook voor de door Dreyfus als 'formeel' betitelde kennis-domeinen opgaat. Iemand die kan rekenen, aldus Collins, geeft als antwoord op de vraag 'hoelang is iemand van 5 voet en 9 inches in centimeters' het antwoord '175 centimeter' en *niet* '175,26 centimeter' of zoiets. 'Kunnen rekenen' houdt volgens Collins ook in dat je weet hoe en wanneer bepaalde afrondingen op hun plaats zijn - en dit is slechts in *ceteris paribus* regels te formuleren. (p.55-56)

Als deze analyse klopt, hoe komt het dan dat we formele systemen als rekenmachines en schaakcomputers überhaupt zinvol kunnen gebruiken? Collins zet hier Dreyfus op zijn kop: 'formaliseerbaarheid' is niet een eigenschap van een objectieve Realiteit maar is een consequentie van *een specifiek type menselijk handelen.* Als we bijvoorbeeld rekenen of schaak spelen *standaardiseren* wij ten dele ons gedrag. Dit is wat Collins *gedrags-specifiek handelen* noemt: handelingen die mensen steeds op dezelfde wijze uitvoeren en die met behulp van ruimtelijke coördinaten en een tijdsas zonder informatieverlies vastgelegd kunnen worden. Typische voorbeelden zijn SHRDLU-achtige activiteiten, lopende band-werk en elementair rekenen-met-de-vingers. Dit type handelen kunnen computers nabootsen, aldus Collins: het is slechts omdat wij sommige activiteiten op een gedrags-specifieke manier uitvoeren dat een computer ons van dienst kan zijn. Ons gedrags-specifiek handelen is en blijft echter altijd ingebed in regulier handelen; wij kunnen slechts formele domeinen creëren bij de gratie van een 'tacit' achtergrond van niet-formaliseerbare praktijken.

Deze analyse heeft consequenties voor de mogelijke rol van expert-systemen (computerprogramma's met expertkennis van een specifiek domein - bijvoorbeeld diagnostische kennis van bepaalde ziekten). Ook expert-kennis is slechts ten dele in gedrags-specifieke regels te expliciteren; ook deze regels zijn altijd ingebed in niet-formaliseerbare, 'tacit knowledge'. Een expert-systeem kan dus slechts zinvol functioneren als de *gebruiker* over deze 'tacit knowledge' beschikt, zodat de formele regels van het expert-systeem begrijpelijk worden. Dat

2 Hubert L. Dreyfus, *What Computers Can't Do.* New York 1979 (2e, gewijzigde druk), p. 57.

3 Harry Collins, *Chabging Order: Replication and Induction in Scientific Practice.* London 1985.

wil zeggen, aldus Collins, dat het vrijwel ondenkbaar is dat expert-systemen esoterische kennis voor leken toegankelijk kunnen maken. Dergelijke systemen moeten dermate veel regels voor de toepassing van eerdere regels bevatten dat een 'combinatorial explosion' (p.95) dreigt: het aantal te programmeren 'als-dan' vertakkingen neemt dusdanig exponentieel toe dat geen computer dat meer aankan.

Collins illustreert deze these aan de hand van een door hem opgezet experiment, waarin getracht wordt een expert-systeem te maken voor de produktie van halfgeleider-kristallen. De rol van de 'tacit knowledge' van de expert wordt al snel duidelijk: aan de hand van alleen tekstboekkennis blijkt het onmogelijk om zelfs maar een zeer globaal systeem op te zetten. Slechts met behulp van langdurige interviews met de expert, waarin zoveel mogelijk praktijk-kennis in regels omgezet wordt, komt uiteindelijk een expert-systeem tot stand. Collins laat echter vervolgens overtuigend zien dat de *praktijk* van de kristalproduktie bij voortduring het expert-systeem onbruikbaar maakt. Om het expert-systeem op te zetten aan de hand van de feitelijke praktijk is volgens Collins echter ook onmogelijk: de overdaad aan pragmatische, opportunistische keuzes en locale eigenaardigheden maakt dit ondenkbaar. Het systeem, CRYSTAL genaamd, blijkt uiteindelijk voor zowel experts als voor beginners weinig bruikbaar: de eersten krijgen slechts triviale of foutieve informatie, de laatsten kunnen met de voor hen te algemene wenken niet uit de voeten.

Collins' *Artificial Experts* eindigt met een normatieve boodschap. De auteur ziet als gevaarlijk bijprodukt van de ontwikkeling van artificiële intelligentie dat wij over onszelf gaan spreken in termen van computers; dat wij menselijke creativiteit voor menselijke gebrekkigheid gaan aanzien. Om deze sluipende identificatie tegen te gaan stelt Collins een strenge 'intelligentie-test voor computers' voor. Een computer, zo stelt hij, is slechts dan intelligent als een kritische interviewer er een lange conversatie mee kan voeren (via toetsenbord en beeldscherm) zonder dat de interviewer kan achterhalen of hier een mens of een computer an het woord is. SHRDLU faalt jammerlijk, maar slagen kan een computer dan ook alleen als hij (?) een deelnemer is geworden aan onze wereld, als hij participeert in onze levensvorm. Dit is moeilijk denkbaar - en tot het zo ver is moeten we computers als niet meer (en niet minder) dan slaafse, onzelfstandige hulpjes beschouwen.

Collins is er wederom in geslaagd een zeer leesbaar en fascinerend boek af te leveren. Hij mengt zich op een originele manier in het al enkele decennia durende artificiële intelligentie debat: terwijl hij Dreyfus' stellingen voor een groot deel onderschrijft, positioneert hij zich op een cruciaal punt recht tegenover hem. Collins wijst erop dat Dreyfus zijn tweedeling in wel en niet formaliseerbare kennisdomeinen ziet als een representatie van een onderscheid in een veronderstelde objectieve Werkelijkheid. Als we de resultaten van het wetenschapsonderzoek na Kuhn serieus nemen, is dit moeilijk meer vol te houden. Formele domeinen zijn niet *gegeven* maar zijn *geconstrueerd;* formaliseerbaarheid is een resultante van standaardisering van ons handelen.

Hoe origineel deze wending ook is, Collins valt mijns inziens in een soortgelijke valkuil als Dreyfus. Waar Dreyfus 'formaliseerbaarheid' tot een objectieve eigenschap van een Wereld-buiten-ons herleidt, reduceert Collins de formaliseerbaarheid van een domein tot een *sociaal* fenomeen. Het moderne wetenschapsonderzoek laat zien waar Dreyfus faalt, maar Collins' reductie is evenmin overtuigend. Dat wiskunde en kristalgroei-kennis produkten van mensen zijn wil nog niet zeggen dat het formaliseer-

baar zijn hiervan te reduceren is tot een sociaal fenomeen. Kristalgroei-kennis is moeilijk formaliseerbaar omdat de experts weinig gedrags-specifiek handelen, maar *ook* omdat de kristal-grondstoffen zich grillig gedragen. De formaliseerbaarheid van bloedziekten-diagnostiek valt of staat met de uniformiteit van het gedrag van zowel de arts als de bloedcellen. Kennis is ingebed in *heterogene* praktijken, die zowel mensen bevatten als grondstoffen, apparaten, enzovoort. (4) Formalisering van dergelijke praktijken vereist *disciplinering* van *alle* elementen. menselijk 'gedrags-specifiek handelen' is slechts één aspect van dit proces, en niet de fundamentele, verklarende categorie die Collins ervan wil maken.

Het meest overtuigende deel van het boek, waar Collins de mogelijkheden en beperkingen van expert-systemen bespreekt, is sterk Dreyfusians. Expert-systemen zijn slechts praktisch toepasbaar als de gebruiker over voldoende achtergrondkennis beschikt. Deze achtergrondkennis is niet uitputtend te expliciteren: eventuele regels hebben hier altijd een ceteris paribus clausule. Het is, uiteindelijk, het unieke, *sociale* karakter van het mens-zijn dat voor computers onnavolgbaar is; het is ook dit karakter dat beschermd moet worden tegen oprukkende computer-metaforen. Collins (net als Dreyfus voor hem) presenteert deze invulling van het mens-zijn als het begin- én eindpunt van zijn analyse. Het is echter de vraag of dit type argumentatie ons nu nog zoveel verder brengt. Collins is bang dat we, door onszelf met computers te vergelijken, zicht verliezen op 'wie we zijn'. (p.224) Maar wat is dat dan? Wat wij als 'mens-zijn' zien is een historisch produkt, waarin, onder meer, hele verzamelingen metaforen (de stoomketel, de telefooncentrale, het leger, de computer) een rol spelen. We kunnen wel langs de zijlijn gaan staan roepen dat wij geen computers zijn, maar is het zo langzamerhand niet veel vruchtbaarder om te onderzoeken *hoe* deze equivalenties worden geconstrueerd en gebruikt, hoe het concept '(artificiële) intelligentie' evolueert, hoe de computer ons bestaan transformeert?

Als we dat gaan doen, als we de discussies uit het 'ons versus zij' keurslijf trekken, dan kunnen we misschien ook meer aandacht krijgen voor het feit dat de computer ons niet zozeer imiteert maar eigen, nieuwe handelingen verricht. In plaats dat we de mogelijkheden en beperkingen van computers steeds met de capaciteiten van mensen vergelijken zouden we ons meer moeten richten op de vraag hoe specifieke computer-toepassingen nieuwe werelden creëren. Het gaat hierbij niet slechts om *standaardisering* van praktijken. Doordat een medisch expert-systeem veelal onderzoeksgegevens en regels gebruikt die artsen nooit zouden gebruiken (en vice versa) creëert het een *andere* praktijk. (5) Het is niet simpelweg een 'minder menselijke' wereld waarin wij terecht gaan komen, een wereld waarin mensen met holle ogen hun ziel en zaligheid in de artificiële handen van een kille, mechanische computer leggen. Dat is, op zijn minst, een te simplistisch en te globaal doembeeld. Computers creëren nieuwe werelden, die steeds op hun eigen merites beoordeeld moeten worden - en waarin het niet noodzakelijkerwijs slecht vertoeven is omdat zij niet weten wat 'sorry' betekent.

4 Gerard de Vries, 'Wittgensteins afscheid van de epistemologie' in: E. Kuyper (red.), *Wittgenstein in meervoud.* Leuven 1991, pp. 17-19.

5 Voor een voorbeeld zie Victor E. van Reijswoud, *Machines at the ITU. How Machines fit into Society.* Doctoraalscriptie Gezondheidswetenschappen. Rijksuniversiteit Limburg 1991.