日本ロボット学会誌 Vol.18 No.2, pp.300 ~ 307, 2000

学術・技術論文

オフィス移動ロボット*Jijo-2*の音声対話システム

松井俊浩[*1] 麻生英樹[*1] John Fry[*2] 浅野太[*1] 本村陽一[*1]
原功[*1] 栗田多喜夫[*1] 速水悟[*1] 山崎信行[*1]

A Speech Dialogue System of the Office Mobile Robot, *Jijo-2*

Toshihiro Matsui[*1], Hideki Asoh[*1], John Fry[*2], Futoshi Asano[*1], Yoichi Motomura[*1],
Isao Hara[*1], Takio Kurita[*1], Satoru Hayamizu[*1] *and* Nobuyuki Yamasaki[*1]

We are developing a mobile robot, called *Jijo-2*, which provides office services, such as answering queries about people's location, route guidance, and delivery tasks. To smoothly *interact* with office people, *Jijo-2* is expected to conduct natural spoken conversation. This paper describes dialogue techniques implemented on our *Jijo-2* office robot, i.e. noise-free voice acquisition system by a microphone array, inference of under-specified referents and zero pronouns using the attentional states, and context-sensitive construction of semantic frames from fragmented utterances. The behavior of the dialogue system integrated with the sound source detection, navigation, and face recognition vision is demonstrated in real dialogue examples in a real office.

Key Words: Spoken Language Dialogue, Mobile Robot, Office Information Service, Microphone Array

1. はじめに

次世代のロボットには，工場でのルーチンワークではなく，オフィスや家庭で柔軟な情報サービスを提供する応用が考えられる．そこでは，時間的に変化する多様な環境に適応し，一般の人々と円滑なコミュニケーションを行う機能が必要になる．

我々は，学習する移動ロボットとして，*Jijo-2*（事情通）ロボットの研究開発を行っている．*Jijo-2*は，オフィスを移動し，人や環境とインタラクションし，人々の居場所を教えたり，道案内をしたり，配達をする，などの作業を目的としている．このようなシステムにおいては，自然なマンマシンインタフェース，特に音声対話の機能が重要な役割を演ずる．この能力は，オフィスユーザーだけでなく，*Jijo-2*自身にとっても必要である．というのは，*Jijo-2*が周囲の人に話しかけることで，学習のためのデータを集めたり，デッドロックから抜け出すことができるからである．これまでに，そのような対話の例として，ロボットが自分の場所がどこかわからなくなると人に場所を尋ね，どちらに行ったらよいかを尋ねる，という対話による地図学習を実装した[1].

次の課題として，*Jijo-2*ロボットのタスクレパートリーを広げるための自然な音声言語対話が必要である．追加すべきオフィス対話として，オフィスメンバーの居場所とスケジュールに関するデータベースへの問い合わせや，電子メールやファックスを依頼する対話を考えた．対話を管理する立場からは，この拡張から少なくとも二つの問題が発生する．

A：語彙を大きくすることによる音声認識性能の低下

B：ある主題に関する複数の発話から意味を合成すること，ときには省略される発話中の単語を補うこと

Aのために，二つの技法を導入した．

1. 雑音の多いオフィス環境下で目的の音声を抽出するためのマルチマイクロフォンアレイ
2. 複数の文法・辞書を用いた音声解析を走らせ，文脈に応じて適当な解釈を選択する

Bの問題は，特に自然な日本語会話にとって重要である．例としてスケジュール登録の発話は，「事情通グループのメンバーである松井は，明日の3時から5時まで本館会議室で会議です.」というように一息で話す文としてはかなりの長さになるので，通常は2，3の短い文に分けて発話されることが多い．音声認識に正しい結果を出させるためにも、適度な長さに区切って発話される方が好ましい．断片的な発話から完全な意味を合成するために，一種のフレーム表現である「対話文脈（*dialogue context*）」を導入した．

ひとたび長い文を短く区切って発話することを許すと，別の問題が生じる．自然な日本語の対話文には，文脈からの類推が可能な場合は，主語，目的語，およびあらゆる種類の代名詞を省略する傾向がある．このような情報不足の発話を理解するために，「注目語状態（*attentional states*）」を導入した．

この論文の主題は，*Jijo-2*オフィスロボットのナビゲーション機能やデータベース接続機能を活用する日本語対話サブシステムの実現にある．本論の各節は，音声を入力し，構文解析を行い，

原稿受付 1999年5月7日

[*1] 電子技術総合研究所RWIセンター
[*2] スタンフォード大学CSLI
[*1] RWI-Center, Electrotechnical Laboratory
[*2] CSLI, Stanford University

意味を抽出して文脈を構成し，必要な行動を取る，という処理の流れに沿って構成されている．

2. *Jijo*-2 ロボットのアーキテクチャ

Jijo-2 は，Nomadic 社の Nomad-200 型移動ロボットを土台にしている（**Fig. 2**）．Nomad-200には，超音波距離センサ（ソナー），赤外線近接距離センサ，バンパー接触センサ，そして走行距離・回転計が搭載されている．内部には，Linux で動作する PC が一台，ホストと通信するための 1.6 [Mbps] 無線イーサネット，約3～4時間分のバッテリーが搭載されている．これに，マイクロフォンアレイ，2台のカラーTV カメラ，音響信号処理用の DSP，日本語音声合成器を追加した．

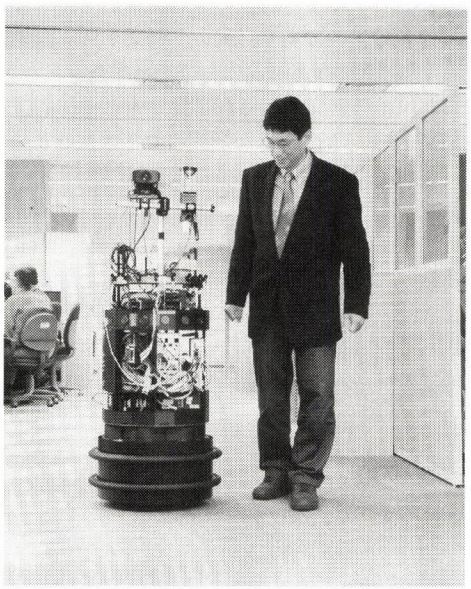


Fig. 1 *Jijo*-2 robot is making a dialogue with a user while it is navigating in an office corridor

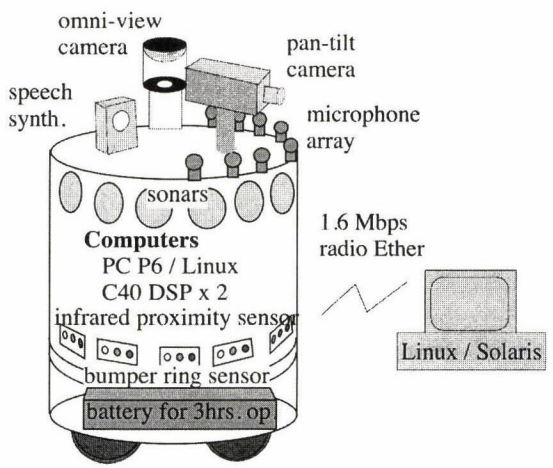


Fig. 2 Hardware configuration of *Jijo*-2

ロボットとリモートのホスト計算機上に，**Fig. 3**に示すようないくつかのソフトウェアモジュールを開発した [1][2][12]．全体は，反射行動層（Reactor）と統合（Integrator）層の二つの層から構成され，実時間性を要求される反射行動層をロボット上に，統合層をリモートホストに実装している．計算量的には，すべてロボット上に実装することが可能であるが，後述するように所在データベースなどへの問い合わせが発生するので，ネットワーク接続機能は必須である．統合層は *EusLisp* [13] で，反射行動層は C で記述している．

各モジュールは，イベント駆動型アーキテクチャに基づいて管理され，TCP を用いた通信を行う．この方式の長所は，複数の行動の並列制御（**Fig. 1**）と，モジュールの交換が容易に行える点にある．

3. 対話システム

3.1 ビームフォーミングを用いた音響入力

パソコンでの音声認識が一般的になりつつあるが，離れた場所で発声された対話文を認識するのには未だに困難がある．*Jijo*-2 が，オフィスで円滑な会話を交わすためには，雑音環境下で1メートル近く離れた場所の発話を捉えるための動的な雑音抑制機能が必要である．

そのために，8本の無指向性マイクロフォンを半周円上に配置したマイクロフォンアレイを適用した．話者からの音声は，おのおののマイクロフォンに異なった遅延時間を伴って到達する．音響信号は AD 変換されて最初の DSP（TI-C44）に送られる．遅延和法 [10] を適用することで，主たる音響信号の方向が計算できる．この指向性を用いて音声だけを拾い上げ，他を周囲雑音として除去する処理を実時間で行う．この方法によって，子音の認識に重要な 1500 ～ 3000 [Hz] の周波数帯域において，約 10 [dB] の雑音が逓減されることを実験で確認した．**Fig. 4**に示すグラフは，三種類の雑音環境下で，本マイクロフォンアレイが単マイク

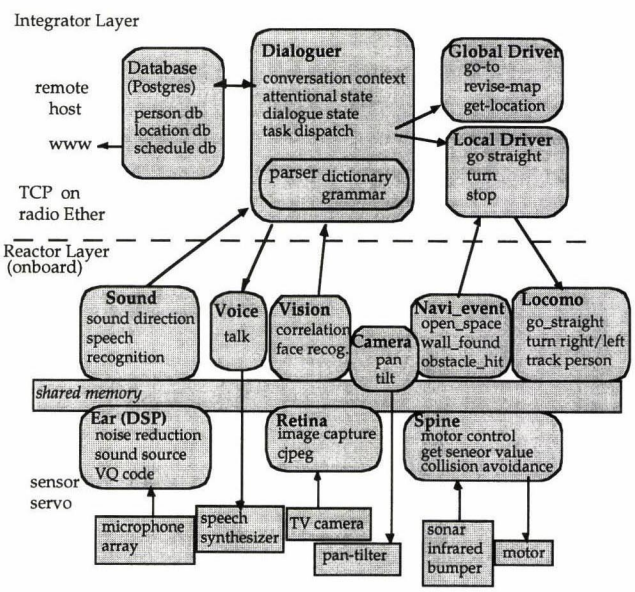


Fig. 3 Organization of software modules of *Jijo*-2

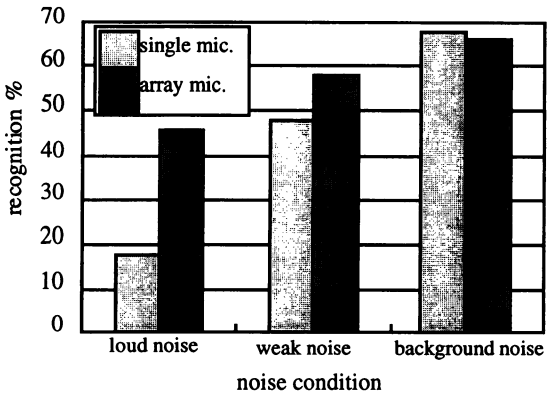


Fig. 4 Speech recognition performance of multi-microphone array in various noise conditions

の場合に比べて良好な音声認識率を示すことを表している.

3.2 日本語音声認識

雑音を取り除いたデジタル音響信号は, DMAで駆動される通信ポートを通じて, 二つ目のDSPに送られる. このDSPは, 周波数分析を行い, 10 [ms] ごとの音韻に対応するVQ (vector quantization) コードを生成する. VQコードは100 [ms] ごとに, Transputer用のOSリンク (シリアル) を通じてPCに送られる.

音声認識には, 電総研で開発された*Ninja*と呼ぶHMMベースの不特定話者連続日本語音声認識システムを用いている [9]. *Ninja*は, 多数の音声資料によりあらかじめ学習された音韻モデルと音韻列で定義された音韻辞書を用いて, 文法を満たす単語の列を探索する. その結果, 「こんにちは」という発話に対して, (hello), 「右に曲がって」に対して (right to turn), 「ここは松井さんの部屋です」に対して (here Matsui s office be), などの語のリストが生成される. 同時に, 認識の確からしさを示す数値, 最初のDSPで計算された音源への方向を表す数値が得られる.

ビームフォーミング, VQコード生成, 辞書・文法照合処理がパイプライン結合されたマルチプロセッサで実行されるので, 認識処理はほぼ実時間で終了する. 最も大きな遅れは, 文の終止を検出するために必要な0.4秒の無音区間である.

ロボットが動いている間は, 三つの*Ninja*が走っている. それぞれの認識プロセスは, 返事文法, 場所文法, 全体文法のうちの一つの文法に対する照合処理を担当する. 統合層の中の対話管理モジュールが, 文脈に応じてある発話に対して一つの*Ninja*を選択する. 発話に「はい」, 「いいえ」のどちらかが想定される場合, 返事文法を使う. 場所あるいは人の名前が期待されるときは, 場所文法を発動する. その他の多くの場合は全体文法を使用する. この方法は, 認識性能を上げるのに有効であることを確認した.

*Ninja*が参照する文法は, 概略次のように記述される.

```
sentence:    greeting
sentence:    imperative
sentence:    declarative
imperative:  action
imperative:  action please
action:      motion
action:      direction to motion
direction:   RIGHT
direction:   LEFT
...
```

RIGHT, LEFTのような終端記号に対応する音韻の列 (ほぼローマ字表記) は, 別の単語定義辞書で与える. 単語総数は約200である. これらの文法規則は, sentenceから終端記号に向かう生成規則であると同時に, 終端記号の列から文を認識するための認識規則でもある. *Ninja*は, 後者の処理を行うが, 結果としてsentenceを返すのではなく, sentenceとして適格であることが証明された終端記号の列を返す. この分析処理をもう一度繰り返すと, 終端記号からsentenceに至るまでの中間記号の構造, すなわちaction, direction, imperativeなどを得ることができる. これらの中間記号は, 文の意味表現の一部となっている.

この考えに従い, 音声認識と同じ辞書を使った構文解析のプログラムを*EusLisp*を使って作成した. これによって意味抽出用の文法を二重に定義する無駄を省くことができる. 今回扱った対話文の文法は比較的単純であり (重文や複文を含まない), 構文解析に送られる単語列はすでに文として適格であることが証明されているので, Lispの構文解析処理はほとんど1秒以内で終わる. Lisp構文解析器は, 次のような形式の意味表現を出力する.

```
(greeting hello)
(imperative     :action turn
                :direction right)
(imperative     :action goto
                :destination matsui
                :via corner)
(interrogative  :person matsui
                :question location)
```

3.3 対話の状態

Fig. 5に示すように, *Jijo*-2の対話管理モジュールは, いくつかの対話状態を持ち, その間を遷移しながら対話を実行する. これらの状態は, *Jijo*-2が反応する発話を状況に応じて限定するために導入した. 例えば, 対話を開始するためには, ユーザーは, まず「こんにちは」によってidleからwaiting状態に遷移させなければならない. confirmation状態では, *Jijo*-2は, 「はい」と「いいえ」(およびそれらの変形) だけを聞く.

この状態遷移は, オフィスにおいてしばしば発生するノイズが, 発話として認識されることによる事故を防ぐために必要である. 例えば, idle状態にあるロボットが周囲の人々の突然の笑い声で動き出すのでは危険である. 状態遷移は, また, 次の音声認識で使用する辞書の選択にも使用される.

「止まれ」, 「取り消して」などのコマンドは, どの状態においても認識される. 明らかに, 「止まれ」は, 安全のために最優先して認識されるべきである. Bernsenらが主張するように, 音声対話システムを実用に供するためには, 「取り消して」, 「何をやっていますか」などの会話自体やシステムに関する語彙を用意しておくことが必要である [3].

3.4 対話の文脈制御

講話などではない通常の対話における人間の一回の発話は, 情報の一部を含むに過ぎない. 例えば, 「曲がって」, は普通に使わ

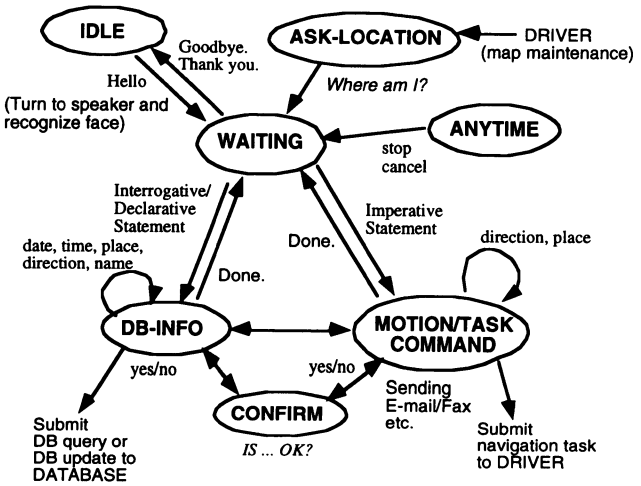


Fig. 5 Dialogue states and transitions

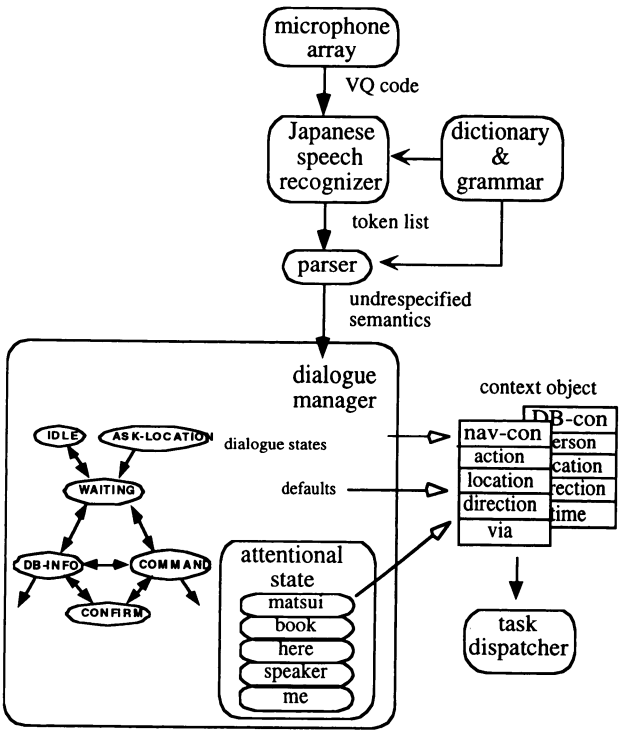


Fig. 6 Flow of speech input processing

れる命令語で，文法的にも適格であるが，ロボットは，これだけではどちらに曲がるべきか理解できない．関連する一連の発話列を管理し，ロボットの行動に必要な意味を形成するために，*dialogue context*（*対話の文脈*）を導入する．

現在，*query-context*，*update-context*，*identification-context*，*navigation-context*，*call-context* など10種類足らずの文脈を定義している．文脈は，いくつかの必須（required）の情報と，任意の（optional）情報を属性値（スロット変数）として保持するような *EusLisp* のオブジェクトとして定義している．例えば，*query-context* は，疑問文が聞こえると生成され，person 名を必須情報として，location，start-time，end-time を任意の属性として持っている．言い換えると，*Jijo-2* は，何かを聞かれるとしたら，人がどこにいるか，ここはどこか，会議などの予定はどこで起こるか，などだと限定している．

会話は，これらの必須属性をすべて獲得するための質問や確認を発しながら進められる．任意の属性は，発話の中で与えられなければ，後述する注目語状態から引いてもよいし，あらかじめ決められたデフォルト値として与えられてもよい．例えば，予定が「外勤」に対しては，目的地（location）が「東京」であることがデフォルト知識として埋め込まれている．

状態遷移ネットワークと文脈の作成は，*EusLisp* 上の Prolog を用いてプログラムされている．

3.5 注目語の管理による属性値推定

一つ一つの発話に関する意味表現は，**Fig. 6** に示す対話管理器（*dialogue manager*）に送られる．*dialogue-manager* は，個人名，もの，できごとなどの注目語を管理している．注目語は，現れた順番や語の意味に応じて相対的な重要度を持つ．この注目語の重要度順列を注目状態（*attentional state*）と呼ぶ．*Jijo-2* では，注目状態には全順序を割り当てている．*dialogue-manager* の機能は，この注目状態を用いて，(1) 不完全指定（under-specified）の入力の処理，(2) 自然な日本語文の生成，を行うことである．その具体的な方法は，[4] で論じたが，ここで概略を述べる．

日本語においては，一般に，文脈から明らかに推定できる場合は，主語，目的語，その他動詞と組み合わされるすべての文節が省略される可能性があり，不完全指定の入力文の問題は深刻である．例えば，「届けて」，は日本語では適格文であるが，対応する英語である“Deliver!”は，目的語を必要とする．このような語の省略は，英語での前方参照代名詞に対応してゼロ代名詞（zero pronoun）と呼ばれる．この例では，「届けて」は，だいたい英語の「(あなたは) これを (彼に) 届けて下さい」([Won't you] deliver this [to him]) に対応する．

ゼロ代名詞の曖昧性を規則的な方法で解消するために，センタリングの手法 [5] に着目した．センタリングは，談話中の対象が重要であればあるほどそれが代名詞で発話されることが多い，という原則に基づいて談話をモデル化し，代名詞の先行詞を予測するために用いられる．センタリングモデルは，ほぼ言語非依存であると言える．主な言語依存パラメータは，談話中の指示物の重要度をランク付けする基準である．我々が対象とする日本語では，**Table 1** に示すような Walker らが提案する順序 [20] を採用した．なお，ランク順は，日本語では，「は」，「が」などの格助詞で示される構文法上の役割で決まり，英語では語順が影響する．日本語ではさらに，話者の立場，話者と対象の関係 (empathy) が取り入れられるべきだとする説がある．

自然に聞こえる対話の実現には，*Jijo-2* 自身が文脈を考慮した発話を生成できなければならない．もしも，ロボットが主題や主語を繰り返したり，イントネーションを無視したり，新規語にアクセントをつけないと，奇妙に聞こえる．例えば，最も高位にある注目語は，改めて発音すべきではない．

Table 1 Walker's salience order of entities

1	Topic (〜は)
2	Empathy (やる、もらうなど)
3	Subject (〜が)
4	Indirect Object (〜に)
5	Direct Object (〜を)
6	Others

4. データベース，移動，視覚との統合的な行動

Jijo-2 は，ナビゲーションや感覚機能を用いてサービスを提供するために対話を行う統合機能ロボットである．文脈オブジェクトの中のすべての必要なスロットが情報を得ると，対話モジュールはそのタスクを実行しようとする．

4.1 データベース問い合わせ・更新

現在の文脈が*query-context* または *update-context*であれば，タスク処理はデータベースモジュールに依頼される．通常は，結果は即座に得られ，対話モジュールは結果を発声する．もし，長い時間がかかる場合には，ユーザーは別の対話を始めることもできる．2節で述べたように、システムは，明確なメインルーチンが存在しないイベント駆動アーキテクチャによって構成されており，複数の行動の並列実行が可能になっているからである．一方，ユーザーとの対話の途中であっても，ロボットがナビゲーション中に自己位置が不明になると，自分の位置を問い合わせる発話を挿入することが起こりうる．

人々の所在とスケジュールを格納するデータベースが，一般的なRDBの一種である*postgres* サーバーを用いて実現されている．このサーバーには，webからの共有アクセスも可能である．したがって，対話によって更新されたユーザーのスケジュールデータが，同時にWebで公開される仕組みとなっている．

4.2 ナビゲーションに関する会話

navigation- または *call-context*では，タスク処理はドライバー（運転士）モジュールに依頼される．タスクが，目的地を指定した移動の場合，ドライバーモジュールは，既に学習済みのトポロジカル地図を用いて移動の計画を立てて実行する．ときには，ドライバーモジュールが，指定された目的地を知らない，あるいはそこに至る経路が見つけられない場合が起こりうる．この場合は，ドライバーモジュールが主体となり，対話モジュールにナビゲーションのインストラクションを得る会話を実行させる．ナビゲーションの実行中に，*Jijo-2*が初めてのランドマーク，例えば「狭い場所から広い場所に出た」イベント，に出くわすことがある．このような場合も，ドライバーモジュールが対話モジュールに場所を確認する対話を依頼することになる．

Jijo-2 は，廊下を走行中にも止まることなく会話を実施できる．対話が，対話モジュールの中だけで処理できる，例えば現在時刻を答えるようなものであれば，ナビゲーションを止めることなく局所的に処理される．別の目的地を指示されれば，その新しい目的地を優先して処理し，最初の目的地は後回しにされる．「止まれ」に対しては，一旦停止して別の会話を行い，「続けて」で前の行動を継続するようにできるが，現在は間違った行動を取り消すことに使う場合が多いので，すべてのタスクをキャンセルする仕様にしている．

4.3 顔認識

*Jijo-2*は，視覚を用いて人を捜し，認識しようとする．*Jijo-2*がwaiting状態にあるときに，「こんにちは」を聞くと，音源の方向を振り向き，肌色探索を開始する．パン・チルト台を動かして人の顔を視角の中央に捉えると，顔認識モジュールを起動する．

顔認識プログラムは，高次局所自己相関特徴によって顔を識別する[11]．視覚モジュールは，顔を105次元の特徴ベクトルとして記憶している．この特徴ベクトルは，同数以上のトレーニング画像から学習的に作成される．得られたサンプル画像から同様の特徴ベクトルを計算し，判別空間におけるトレーニングセットとの距離の最も小さいものを認識候補とする．認識が成功すると，視覚モジュールは，話者の名前を対話モジュールの注目語状態に挿入する．

5. 対 話 の 例

Fig. 7は，人間ユーザーと*Jijo-2*の間で交わされる会話のうち特徴的な二つのパターンを示している．おのおのがロボットにいくつかの行動を起こさせる．

（a）の対話は，単純なロボット動作を指示するものである．*Jijo-2* は，*turn* コマンドで胴体を回転させ，*look-at* コマンドでカメラをパンさせる．どちらも方向を示す語が必要であるが，直前の発話からそれらが補われているのがわかる．

（b）の対話は，「こんにちは」で始まるので，*Jijo-2*は音の方向を向く．ロボットは，顔画像をキャプチャして人を認識する．認識が成功すれば，ロボットは話者の名前を知ることになり，続く対話の中で，話者に対してEmailを送る，などの誤解を避けることに利用することができる．ユーザーが「麻生さんはどこ？」と聞くと，「麻生」が対話の主題に設定され，したがって最も重要な対話の注目語になる．「本館にいます」，という*Jijo-2*の返答は，主語が省略されるべきことがわかった上での不完全指定となる．カレントな主題をゼロ代名詞で表現しているので，この返答はスムーズで自然な日本語である．

次の会話文では，動詞「呼んで」の直接および間接目的語がゼロ代名詞化され，省略されている．この場合，最も顕著な先行詞である「麻生」が，間接目的語としての最適な参照として選択される．

*call-context*は，Emailを麻生に送ることを提案し，確認を取る．続く文でも，不完全指定の発話に適当な先行詞やデフォルトが与えられている．参照語の推定は，日本語対話を自然でスピーディにするだけでなく，よい音声認識性能を上げるためにも役立っている．

6. 性 能 評 価

*Jijo-2*のような，人間的要素が絡んだ統合システムの性能やユーザーインタフェースの適切さを評価するのは容易ではない．主に公平な比較をする環境条件を整えることが難しいために，マ

H:　右を向いて (turn to the right)
R:　*右を向く*
H:　左. ([turn to the] left)
R:　*左を向く*
H:　後ろ. ([turn to the] back)
H:　左を見て. (Look at the left).
R:　*左を見る*
H:　右. (Right)
R:　*右を見る*

(a) Simple motion commands: the same direction keywords can cause different behaviors.

H1(Matsui):　こんにちは。(Hello.)
R:　*音の方向を向き，話者の顔を捉え，認識する.*
　　コンニチハ，マツイサン. (Hello, Matsui.)
H1:　麻生さんはどこ? (Where is Asoh?)
R:　本館ニイマス. ([He is] in the main building.)
H1:　呼んで下さい. (Please call [him].)
R:　麻生サンニ，メールヲオクリマショウカ?
　　(Shall I send E-mail to him?)
H1:　はい. (Yes.)
H1:　本村さんは？([Where is] Motomura ?)
R:　オフィスニイマス. ([He is] in [his] office.)
H1:　連れていって下さい. (Please take me [to his place].)
R:　本村サンノ部屋ニ行キマス.
　　([I'll] go to Motomura's office.)
　　オフィスへの経路を計画し、ナビゲーションする
R:　本村サンノ部屋ニ着キマシタ.
　　([We are] at Motomura's office.)
H2(Motomrua):　食事に行きます.
　　([I'm] going out for lunch.)
R:　本村サンハ、食事デヨロシイデスカ?
　　(Is Motomura going out for lunch ?)
H2:　はい. (Yes.)
R:　スケジュールヲ登録シマス.
　　([I'll] register [the data] to the database.)
H1:　松井も. (Matsui, too.)
R:　松井サンハ，食事デヨロシイデスカ?
　　(Is Matsui going out for lunch ?)
H1:　はい. (Yes.)
R:　スケジュールヲ登録シマス.
　　([I'll] registrate [the data] to the database.)

(b) Zero pronoun filling in navigation and database tasks.

Fig. 7　Sample office dialogues. Words in brackets are predicted. Italics indicate robot's actions

イクロフォンアレイを除くと，定量的な評価を実施していない．そのため，ここでは，数々のデモ実験を通じて得られた定性的な評価を述べる．

Jijo-2 の研究開発を開始して以来，さまざまな見学者に対して50回以上のデモを実施してきた[14]．おのおので，Fig. 7に示したのと同様な会話を行い，ユーザーは同じフロア上のオフィスからオフィスへ道案内された．ほぼ，90%のデモが成功した．平均して20%程度は音源方向の推定に失敗し，同程度の発話が誤って認識された．しかし，ある対話状態で受理する入力文および取りうる行動が限られていることと，大きなタスクには確認が必要なため，悲劇的な状況に陥ることはまれであった．ロボットが誤りを犯したときは，その行動を取り消し，望ましいコマンドを再度与えてリスタートすることができた．

マイクロフォンアレイは，通常のオフィスで周囲雑音を効果的に逓減できることが確認できた．音声認識が失敗するのは，主によどんだ発音や見学者の笑い声のような大きな雑音によることが多い．

7. 関連する研究

ロボットとの対話は，人工知能の分野で古くから研究されてきた題材であり，1960年代のNilssonによるSHAKEYロボット[16]にまで遡る．WinogradのSHRDLU [21]もロボットとの対話の形式を取り，その後の研究に大きな影響を与えた．SHRDLUは，構文解析をうまく利用することで，曖昧さの解消と代名詞の指示語の推定を行った．その成功は，対象領域をブロックの世界に限ったことが大きく影響している．最近では，Torrance [19]が，移動ロボットとの会話を取り上げ，橋本らは，対話機能を備えた人間型ロボットを研究している[7]．柴田らは，自然言語による道案内において，経路の空間的関係を用いて曖昧さを解消する方法を提案している[17]．Horswillは，SHRDLU型の言語処理と実時間ビジョンを統合したシステムを提案している[8]．これらの最近の成果は，自然言語を人間と対話するためのツールとして用いており，言語学的な成果，または談話理論の適用には関心が薄い．

武田らは，構造的なオントロジに立脚した移動ロボットの対話システムを標準的なマルチエージェントとして実現しようとしている[18]．実ロボットではなく，コンピュータグラフィックスを使ったエージェントとの対話の試みもなされている[6][15]．

これらの成果と比較して我々のシステムの新規性は，移動ロボットの行動，およびデータベースの問い合わせ・更新を対話文によって制御し，オフィスにおける有用な情報サービスを提供できるようにしている点，ならびに実オフィス環境において，自然な音声対話の質と頑健性を向上させている点にある．

8. 結論と将来の課題

移動ロボットが，広い範囲のオフィスタスクレパートリをカバーする自然な日本語対話を実現するために，1）マイクロフォンアレイ，2）複数辞書，3）対話文脈，4）注目語の管理，の四つの手法を導入した．1と2は，実環境での実験によって，雑音環境下での音声認識の性能向上に効果があることを確認した．3と4は，数種類のタスクに対して，断片的な対話文から意味フレームを構成することを可能にした．これらは，音声認識器の負担を軽減し，対話を日本語として自然にするためにも効果的であった．

これらの技術に基づき，対話によるトポロジカル地図の学習に加えて，道案内対話とデータベース対話が可能になった．真に知的な人工知能システムの創造には，さまざまな種類の情報ソースを統合的に利用する必要がある．音源方向検出器と顔認識を対話と統合することで，より密なユーザーとのインタラクションが可能になったと考える[14]．

今後は，複数話者との対話，視覚情報を利用した場所の同定，環境音の認識，より長い距離のナビゲーション，豊富なタスクレパートリなどに向けた研究を継続する計画である．

謝辞　本研究は，通商産業省，RWCプロジェクトの一環とし

て電子技術総合研究所RWIセンターで実施した．同プロジェクト，同センターで研究推進に当たられた方々，ならびに本研究に熱心な関心を寄せていただいた方々に感謝いたします．

参 考 文 献

[1] H. Asoh, Y. Motomura, T. Matsui, S. Hayamizu and I. Hara: "Combining Probabilistic Map and Dialogue for Robust Life-Long Office Navigation," In Proc. of 1996 IEEE/RSJ International Conference on Intelligent Robots and Systems, pp.807-812, 1996.

[2] H. Asoh, I. Hara and T. Matsui: "Dynamic Structured Multi-Agent Architecture for Controlling Office-Conversant Mobile Robot," In Proc. of 1998 IEEE International Conference on Robotics and Automation (ICRA'98), pp.1552-1557, 1998.

[3] N. O. Bernsen, H. Dybkjoer and L. Dybkjoer: "What Should Your Speech System Say," IEEE COMPUTER, vol.30, no.12, pp.25-30, 1998.

[4] J. Fry, H. Asoh and T. Matsui: "Natural Dialogue with the *Jijo*-2 Office Robot," In Proc. of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS'98), pp.1278-1283, 1998.

[5] B. Grosz, A. Joshi and S. Weinstein: "Centering: A Framework for Modelling the Local Coherence of Discourse," Computational Linguistics, vol.21, no.2, pp.203-225, 1995.

[6] O. Hasegawa, K. Itou, T. Kurita, S. Hayamizu, K. Tanaka, K. Yamamoto and N. Otsu: "Active Agent Oriented Multimodal Interface System," In Proc. of the Fourteenth International Conference on Artificial Intelligence, pp.82-87, 1993.

[7] S. Hashimoto et al: "Humanoid Robot -Development of an Information Assistant Robot Hadaly," In Proc. of the 6th IEEE International Workshop on Robot and Human Communication, RO-MAN'97, 1997.

[8] I. Horswill: "Integrating Vision and Natural Language without Central Models," In Proc. of the AAAI Fall Symposium on Embodied Language and Action, Cambridge, 1995.

[9] K. Itou, S. Hayamizu, K. Tanaka and H. Tanaka: "System Design, Data Collection and Evaluation of a Speech Dialogue System," IEICE Transactions on Information and Systems, E76-D, pp.121-127, 1993.

[10] D. H. Johnson and D. E. Dugeon: Array Signal Processing. Prentice Hall, Englewood Clifs, NJ, 1993.

[11] T. Kurita et al: "Scale and Rotation Invariant Recognition Method Using Higher-Order Local Autocorrelation Features of Log-Polar Images," In Proc. of the third Asian Conference on Computer Vision, vol.II, pp.89-96, 1998.

[12] T. Matsui, H. Asoh and I. Hara: "An Event-Driven Architecture for Controlling Behaviors of the Office Conversant Mobile Robot *Jijo*-2," In Proc. of the IEEE International Conference on Robotics and Automation (ICRA'97), pp.3367-3371, 1997.

[13] T. Matsui and I. Hara: EusLisp Reference Manual Ver. 8.00, Technical Report, ETL-TR-95-2, Electrotechnical Laboratory, 1995.

[14] T. Matsui and *Jijo*-2 Group: *Jijo*-2 Project Web home pages, http://www.etl.go.jp/~7440/, 1999.

[15] 長尾 確："マルチモーダルインタフェースとエージェント"，人工知能学会誌，vol.11, pp.32-40, 1996.

[16] N. Nilsson: "A Mobile Automaton: an Application of Artificial Intelligence Techniques," In Proc. of the First International Joint Conference on Artificial Intelligence, pp.509-520, 1969.

[17] 柴田，芦田，角所，北橋："移動ロボットによる言語的経路指示理解のための記号情報とパターン情報の対応付け"，人工知能学会誌，vol.13, pp.221-230, 1998.

[18] 武田，小林，松原，西田："人間・ロボット間のユビキタス・インタラクション環境"，人工知能学会全国大会（第11回）論文集，pp.441-444, 1997.

[19] M. Torrance: "Natural Communication with Robots," Masters Thesis, Massatusetts Institute of Technology, 1994.

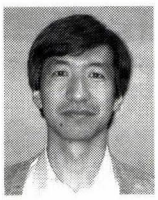
[20] M. Walker, M. Iida, and S. Cote: "Japanese Discourse and the Process of Centering," Computational Linguistics, vol.20, no.2, pp.193-233, 1994.

[21] T. Winograd: Understanding Natural Language. Academic Press, 1972.



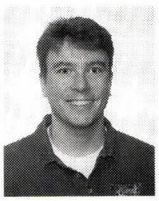
松井俊浩（Toshihiro Matsui）

1956年10月30日生．1980年東京大学計数工学科卒業，1982年同大学大学院情報工学修士，電子技術総合研究所入所．ロボットプログラミングシステムの研究に従事．*Jijo*-2のアーキテクチャ，対話システムを担当．工学博士．日本ロボット学会，計測自動制御学会，ISRR，元岡記念会，工業技術院などから論文賞／研究賞受賞．1991年から1999年にかけて米国スタンフォード大学，マサチューセッツ工科大学，オーストラリア国立大学客員研究員．情報処理学会，ACM，IEEE会員．（日本ロボット学会正会員）



麻生英樹（Hideki Asoh）

1958年11月19日生．1981年東京大学工学部計数工学科卒業．1983年東京大学大学院工学系研究科情報工学専攻修士課程修了．同年電子技術総合研究所に入所．1990年、情報科学部主任研究官．1993～94ドイツ国立情報処理研究所（GMD）客員研究員．知的学習システムの実現に関する研究に従事．地図学習を担当．人工知能学会，日本神経回路学会，電子情報通信学会，行動計量学会各会員．



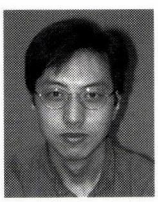
John Fry

1966年10月3日生．1990年カリフォルニア大学ロスアンジェルス校言語科学科卒業，1993年よりスタンフォード大学CSLI博士課程在籍．1994～1998年にNSF Summer Institute，科学技術庁COE特別研究員などで電総研に滞在．講話解析，対話システムを担当．



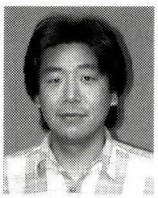
浅野 太（Futoshi Asano）

1962年10月13日生．1986年東北大学電気工学科卒業，1991年同大学大学院博士課程電気および通信専攻修了．1995年まで，同大学電気通信研究所助手，1993年ペンシルバニア州立大学客員研究員．1995年より電子技術総合研究所研究員．アレイ信号処理などの研究に従事．ビームフォーミングを用いた音響入力を担当．



本村陽一（Yoichi Motomura）

1967年8月26日生．1991年電気通信大学通信工学科卒業．1993年同大学大学院電子情報学専攻修士課程修了．同年電子技術総合研究所に入所．1999年アムステルダム大学招聘研究員．人工知能学会研究奨励賞など受賞．電子情報通信学会，日本神経回路学会，人工知能学会，認知科学会各会員．実環境からの知識獲得，確率推論・学習，位置推定などを担当．



原　功（Isao Hara）

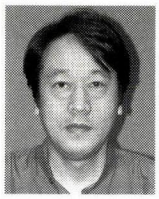
1965年5月20日生．1993年九州大学大学院工学研究科電気工学専攻修了．博士（工学）．同年電子技術総合研究所入所，現在に至る．自律移動ロボットのナビゲーション等の研究に従事．主にビジュアルナビゲーション，反射行動モジュールの開発を担当．

（日本ロボット学会正会員）



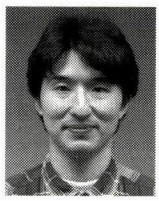
栗田多喜夫（Takio Kurita）

1958年4月18日生．1981年名古屋工業大学電子工学科卒業，電子技術総合研究所入所．統計的手法の応用に関する研究に従事．顔画像の認識を担当．工学博士．日本行動計量学会優秀賞，情報処理学会Best Author賞／論文賞，画像センシングシンポジウム優秀論文賞，IARPMVA Most Infuluential Paper of the Decade Award受賞．1990～91年カナダNRC招聘研究員．電子情報通信学会，日本行動計量学会，情報処理学会，日本神経回路学会，IEEE会員．



速水　悟（Satoru Hayamizu）

1956年3月2日生．1978年東京大学工学部卒業，1981年同大学大学院修士課程修了，同年電子技術総合研究所入所．音声認識，音声対話，人工物との対話に関する研究に従事．音声認識の信号処理，音韻モデルを担当．1989～90年カーネギーメロン大学，1994年LIMSI/CNRS客員研究員．工学博士．電子情報通信学会，日本音響学会，言語処理学会，日本機械学会，IEEE，ESCA各会員．



山崎信行（Nobuyuki Yamasaki）

1966年5月1日生．1991年慶應義塾大学理工学部物理学科卒業，1996年同大学大学院理工学研究科計算機科学専攻博士課程修了．同年電子技術総合研究所入所．1998年10月慶應義塾大学理工学部情報工学科助手．現在，電子技術総合研究所COE特別研究員及び科学技術振興事業団さきがけ研究21研究員を兼務．実時間通信機能を備えたULSIの研究に従事．*Jijo*-2ロボットのハードウェア関係を担当．

（日本ロボット学会正会員）