Cognitive Studies, **24**(1), 16-22. (March 2017)

■特集 — 新しい計算論が切り拓く認知科学の展開　　招待論文

人と機械の言語獲得

海野 裕也

Despite recent artificial intelligence technologies achieved prominent results, machines cannot behave like humans yet. I compare the ability of humans' language acquisition with natural language processing by machine learning technologies, taking learning of word embedding vectors as an example. And I introduce some notable researches which may fill in the gap, one-shot learnig, memory models and language game tasks. Although these researches have just begun, it will be important for artificial intelligence to aquire human intelligence.

Keywords: language acquisition（言語獲得）, natural language processing（自然言語処理）, word-embedding（単語埋め込みベクトル）, one-shot learning, memory model（ワンショット学習，記憶のモデル）, language game（言語ゲーム）

1. はじめに

人工知能が世間で話題になって久しい．深層学習を始めとした機械学習技術が注目され，クイズや囲碁といった特定の領域で大きな成果を見せている．では，こうした人工知能は人間のように物事を学んでいるのだろうか．人間固有の知的な活動の一つとしての，言語に目を向けてみる．言葉を扱う人工知能の分野は，自然言語処理という名前で知られている．近年の深層学習の技術の発展によって，言葉の意味を扱おうとする研究が増えてきたものの，自由に言葉を操る機械が出現しているわけではない．本稿では自然言語処理技術や機械学習技術による近年の研究動向を紹介し，機械学習による言語の獲得と人間の言語の獲得の比較し，それらを埋める新しい研究課題に関して概観する．

2. 単語の分散表現の獲得

自然言語処理の分野で近年最も発達した技術の一つが，埋め込みベクトルの学習である．埋め込みベクトルとは，各単語ごとにその単語の「意味」を表現する多次元ベクトルを割り当てたものである．意味を割り当てるとは，「りんご」と「みかん」，あるいは「ペン」と「筆」のように，意味の近そうな単語に近いベクトルを割り当てるということだ．ベクトルの近さの尺度として，2 つのベクトル v_1 と v_2 のコサイン類似度 $v_1^\top v_2/\|v_1\|\|v_2\|$ によってベクトルの近さを測ることが多い．

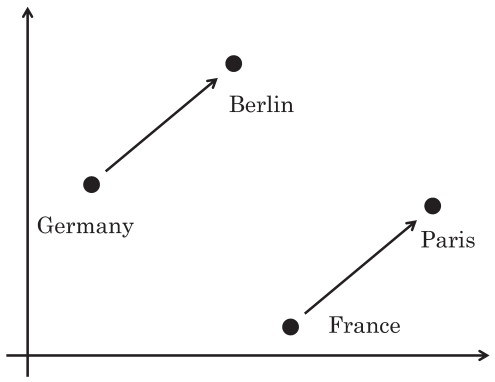


図 1　Skip-gram モデルによる単語ベクトルの類推．

契機になったのが Skip-gram モデル (Mikolov, Sutskever, Chen, Corrado, & Dean, 2013) の登場である．ベクトルの類似性で単語の類似性を表現す

Language Acquisition for Humans and Machines, by Yuya Unno (Preferred Networks, inc.).

るだけであれば，既存の潜在意味解析の研究などでも見られたが (Deerwester, Dumais, Furnas, Landauer, & Harshman, 1990)，特徴的なのは意味の合成ができたことである．例えば，“Berlin” のベクトルから “Germany” のベクトルを引き，“France” のベクトルを足すと，“Paris” のベクトルに近くなることがわかった（図 1）．すなわち，

$$v_{\text{Berlin}} - v_{\text{Germany}} + v_{\text{France}} \approx v_{\text{Paris}}$$

が成り立ったのである．これは，$v_{\text{Berlin}} - v_{\text{Germany}}$ が「国名に対する首都」を表す差分のベクトルになり，ここに v_{France} を足すことでその首都である “Paris” が求まる，かのように振る舞うのである．この現象は，言語に依存せずに安定して確認された．こうした性質は，加法構成性と呼ばれ，既存の手法との類似性が発見されたり (Levy, & Goldberg, 2014)，なぜ成り立つのかという理論的な研究が進み，今でも盛んに研究されている．さらに，異なる言語間で得られるベクトルに類似性が認められるなど (Mikolov, & Quoc V. Le, 2013)，多くの不思議な性質が明らかになった．いち早く著者がプログラムを公開[1)]し，非常に高速に動作することもあって大きな流行となった．

それでは単語の埋め込みベクトルを獲得できたということをもって，機械が人間のように単語の意味を獲得したということがいえるのだろうか．先に結論を言ってしまえば，埋め込みベクトルの学習の進展は大きなものであったものの，未だ機械と人間の言語に対する扱いは大きく異る．以降，機械学習技術について俯瞰しつつ，人間の言葉の獲得と機械の言葉の獲得，あるいは言葉の処理を比較していき，またこれらのギャップを埋めるような新たな研究について解説していきたい．

3. 機械学習による言語処理

近年の自然言語処理の技術は，Skip-gram モデルの学習を含めて，機械学習を利用した手法が中心的になっている．機械学習は蓄積したデータを利用することで，賢くなるアルゴリズム全般を指す．特に規則を陽に書き下して適用することで知的な処理を行う，ルールベースな手法と対比されることが多い．少なくとも 90 年台には機械学習が自然言語処理に適用され，2000 年台以降は最も中心的なアプローチとなっている．

多くの機械学習手法は，学習対象となるデータをよく説明する表現を，統計的に推定するという方法が取られる．まず，対象のデータを上手く表現できそうなモデルを立てる．次に学習データをこのモデルに当てはめて，対象の目的関数を最小化させるような最適化問題に帰着させる．この最適化問題は，目的関数の勾配を計算して逐次的にパラメータを更新することで局所解を得ることで，当てはまりの良いパラメータを得ることができる．

例で説明しよう．あるメール（文）が迷惑メールかそうでないかの判定をしたいとする．このとき，N 個の文 $X = \{x_1, \ldots, x_N\}$ が与えられるとする．それぞれの文 x_i に対して，迷惑メールであれば $y_i = 1$ そうでなければ $y_i = -1$ なる $Y = \{y_1, \ldots, y_N\}$ が同時に与えられるとする．このデータを利用して，なるべく $f(x_i) = y_i$ となるような関数 f を得たい．そうすれば，迷惑メールか否か不明な x' が与えられたときに，$f(x')$ を計算することで判断に利用できるからである．これが機械学習，特に分類学習の目的である．

ここで

$$l(x, y) = -yf(x)$$

という関数 l を考える．仮に $f(x_i) = y_i$ を満たしていれば，$l(x_i, y_i) = -y_i^2 \leq 0$ が成り立つ．そこで l の総和

$$L(X, Y) = \sum_{i=1}^{N} l(x_i, y_i)$$

がなるべく小さくなるような f を探すことができれば，入力 x に対する出力 y をうまく予想する関数 f が求まりそうである．そこで f がパラメータ θ を持つ関数として，f の最適なパラメータ

$$\tilde{\theta} = \operatorname*{argmin}_{\theta} L_\theta(X, Y) = \operatorname*{argmin}_{\theta} \sum_{i=1}^{N} -y_i f_\theta(x_i)$$

を求めることにしよう．対象の関数を最小化するようなパラメータを求めることは，最適化問題と呼ばれる．つまり $L_\theta(X, Y)$ を最小化する，最適化問題を解くことによって，学習ができることになる．このように，機械学習の多くの手法は，最適化問題に帰着することによって学習を行うのである．

この最適化は閉じた式で解くことはできない．そ

1) https://code.google.com/archive/p/word2vec/

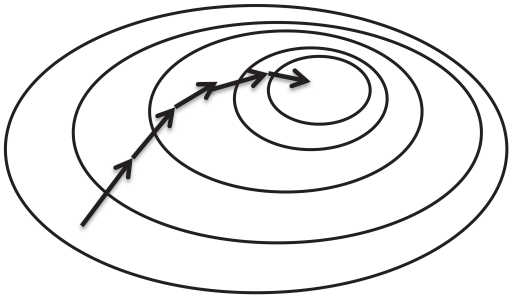


図 2 最急降下法による最適化の例.

のため，反復計算することによって解く方法を利用する．特に目的関数 L をパラメータで微分した勾配を利用した勾配法が用いられることが多い．パラメータ θ に，勾配 $\nabla_\theta L$ の定数倍を引くことで更新する手法は，最急降下法と呼ばれる．図 2 に最急降下法のイメージを示す．この図は，パラメータ θ に対する L の値の等高線を示している．勾配の方向は等高線に直行した方向を示すため，勾配方向にパラメータを更新すると徐々に山を下っていくように最適点に近づいていく．こうした手法は，今日の機械学習手法の礎となっている．例えばサポートベクトルマシンや近年流行のニューラルネットワーク，また Skip-gram の学習などは，多くの場合上記の枠組みで学習される．大きくまとめると，解きたい問題を表現するよう目的関数を設計し，目的関数の勾配によって反復的にパラメータを更新することによって，その最小化問題を解くということを行うのである．

3.1 Skip-gram モデルの学習

Skip-gram モデルによる埋め込みベクトルの計算過程は決して難しくない．大雑把に説明すれば，単語の出現を周囲の単語のみから予測するようなモデルを作り，既存のデータによって学習を行う．文長 T の文書 $S = \{w_1, \ldots, w_T\}$ が与えられたとする．単語 w の D 次元の埋め込みベクトルを $V(w) \in \mathbb{R}^D$ とする．同様に $V'(w) \in \mathbb{R}^D$ の D 次元ベクトルを用意する．V と V' は語彙数 M としたときに $D \times M$ 次元の行列であり，各列が 1 つの単語の埋め込みベクトルと考えればよい．窓幅 $c(\approx 5)$ が与えられたときに，以下の関数

$$\frac{1}{T}\sum_{t=1}^{T}\sum_{-c\leq j\leq c, j\neq 0}\log f(w_{t+j}, w_t)$$

が最小となるようなベクトルを求める．ただし，

$$f(w_l, w_r) = \frac{\exp\left(V(w_l)^\top V'(w_r)\right)}{\sum_w \exp\left(V(w)^\top V'(w_r)\right)}$$

である．これは，先程説明した勾配法などを利用することで最適な V のパラメータを求めることができる．この各 $V(w)$ が各単語 w の埋め込みベクトルとなる．この目的関数は極めて簡単であり，そのことも Skip-gram モデルの衝撃の一つであった．

前置きが長くなったが，勾配法を含む反復計算による学習を持って,「人間の学習」を比喩するのにはいささか疑問がある．反復計算による学習は，何度も細かく内部パラメータを更新することを繰り返す．そのため学習時には何度も同じデータを読み直し，パラメータは細かく何度も修正される．一方で人間が言葉を学ぶ過程はもっと素早い．特に 1〜2 才児に見られる語彙爆発と呼ばれる現象では，何度も反復すること無く 1 日に幾つもの単語を次々に覚えていく．加えて，一度聞いただけの単語であっても，即座に対象の概念と結びつける即時マッピングという現象も広く知られている．これらからは，反復的にパラメータの更新を行う機械学習とは異なる性質を持っていることが伺える．このように比較してみると，両者の間には学習の過程に大きな差があるように感じられる．より人間の言語獲得に近い傾向のある技術はないか．通常の機械学習手法とは異なる手法や設定について，ここから見ていこう．

4. ワンショット学習

一般的な機械学習の手法は，たくさんのデータを使って，何度もステップを経て，じわじわと体得するように振る舞う．これは一回見ただけで言葉を覚えるような，人間の言葉の獲得とは似ていない．一方で，一度しかデータを見ないで学習を行うことができるのかという課題はワンショット学習と呼ばれており，近年研究が進んでいる．

文字認識の例で考えよう．たった一件の文字を見ただけで，同じ文字を判別できるだろうか．図 3 の左の文字と同じ文字を右側から探してみて欲しい．もちろん正解は左から 2 番目の文字である．しか



図 3 未知の文字の判別の例.

し，何に基づいて判断するのだろうか．形状という点で言えば，同じ字体の左から 3 番目の「天」の方が似ているように見える．加えて，正解の「夫」は右払いが点になっていて，隙間すらある．一見簡単に見えるが，機械にこの問題を解かせるのは非常に難しい．先程説明した教師ありの機械学習で特定の文字を判別できるようにするには，それぞれの文字の画像を沢山用意し，他の文字との差を学習する必要がある．ところが図 3 のように，初めて見る文字でも人間はその他の文字から分別できる．このようにたった一つの事例だけで，他のデータを分類させる課題を，ワンショット学習と呼ぶ．この設定は，先に述べた即時マッピングの現象とも類似性がある．

ワンショット学習は，従来の機械学習の流暢とは真逆の設定になっている．機械学習の課題設定ではたくさんの教師情報によって設計された最適化問題を解くことで，教師情報と類似の情報を処理できるようになる．しかし，ワンショット学習では教師情報が 1 つしかないため，類似の情報を引き出すのが難しい．そこで代わりに，教師情報のついていない，学習対象以外の文字データはたくさんある，という仮定を置く．つまり，その他の文字データから「文字そのものはどういうものなのか」，あるいは「文字を分別するには一般的にどのような特徴を見れば良いのか」という個別の文字以外の，ある種の常識のような情報を獲得させることが重要になる．図 3 の例ではも,「右払いは点で書くことがある」ということを知っていれば，字形の差異を無視して判別できるだろう．最近の研究では，深層学習を応用することによって高い精度を達成したことも報告されている (Vinyals, Blundell, Lillicrap, Kavukcuoglu, & Wierstra, 2016).

ワンショット学習のように，直接解きたい問題とは異なるが，非常に関連の深いデータを利用した学習手法というのはこれまでも研究されてきた．教師情報のついたデータとついていないデータから学習する，半教師あり学習．異なる課題に対する教師情報がついたデータを組み合わせることで学習する，マルチタスク学習．同じ課題だが，異なる分野の情報に対して適用する，転移学習．いずれの設定でも，異なる種別の情報から普遍的な情報を抜き出し，他の課題の解決に活かすという点では類似している．ワンショット学習は特に半教師あり学習の，極めて極端な例とみることもできるだろう．

5. 記憶のモデル化

先に説明した機械学習の目的は，与えられたデータから未知のデータを説明する汎化した関数を得ることにある．これは一方で，情報の細部を「記憶」することとは目的が異なり，どちらかと言うと汎化された技能を「体得」することに近い．では逆に，対象の情報を記憶する仕組みはできないか．近年の深層学習の研究では，かなり複雑な構造を持つ目的関数にしても，微分可能な関数で構成すれば最適化できることが示されてきた．そのため，より意図をもって目的関数をモデル化して学習させる研究が増えてきている．その中でも記憶を直接読み書きするような関数を設計して，記憶をモデル化する研究が増えている．

記憶ネットワーク (Weston, Chopra, & Bordes, 2015) はそうした研究の一つである．外部から得た情報を記憶として保持し，質問に応じてどの記憶情報を利用するか選択して応答を行うことをモデル化した手法である．記憶ネットワークは以下の 4 つのモジュールからなる．

I: 入力特徴変換 入力情報を内部の表現形式に変換する．

G: 一般化 変換された表現形式を使って内部の記憶状態を更新する．

O: 出力特徴変換 記憶状態と外からの質問によって出力情報を生成する．

R: 応答生成 出力情報から，返答や行動といった具体的な操作に変換する．

記憶ネットワークに対する入力は，文などからなる複数の情報源と，質問文のような問い合わせである．複数の情報源を I モジュールで内部表現に変換し，G モジュールで新規の情報として内部の記憶に追記する．記憶に対して問い合わせが与えられたら O モジュールにより必要な記憶を呼び出し，R モジュールで返答を生成し，例えば自然文として返答を行う．

それぞれのモジュールをどのように構成するかが

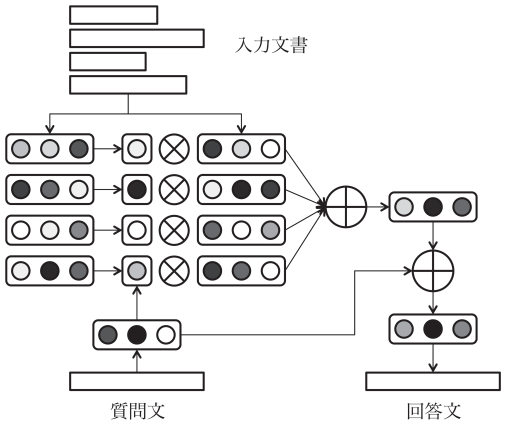


図 4 記憶ネットワークの模式図.

工夫のしどころだが，Sukhbaatar, Szlam, Weston, & Fergus (2015) は全てのモジュールを微分可能な関数で構成することで，全体の操作を単一の機械学習の枠組みで学習させている．全体像を図 4 で示している．厳密な説明は避けるが，I では情報源の文を単語の埋め込みベクトルの和で固定長のベクトルに変換し，G では単に固定長ベクトルを複数並べる．すなわち，ベクトルの集合を記憶として扱う．O では，問い合わせに対しても同様に固定長のベクトルを作り，各記憶のベクトルとの類似度から，どの記憶を引き出すかの重みを決定する．この重みで，記憶ベクトルの重み付き平均を取ったベクトルを返答情報とする．最後に R では，できた返答情報のベクトルから返答文を生成する（実験では単語を選択する）.

以上のステップは全て微分可能な関数の形で計算している．つまり全体では，情報源の文集合と，問い合わせ文を入力とし，返答文を出力とする，単一の巨大な微分可能な関数の形でかけるのである．そのため，機械学習の枠組みで入力情報・問い合わせ・返答の 3 つ組に対して，なるべく正解率が高くなるような最適化を行うことができる．近年の深層学習の研究では，このような複合的なプロセス全体を単一のモデルでモデル化して，入出力情報を使って一気に学習することが増えている．このようなやり方は，end-to-end と呼ばれている．従来このような複雑な問題は，個別の部分問題に分解して，それぞれに独立に学習データを用意して最適化することが多かった．例えば，どの記憶を参照すると返答できるのかのヒントとなる情報を付与して，参照する仕組み単体を学習させて，そこから答えを導くところもそれとは別に学習させる．End-to-end のやり方の場合，こうした中間的なデータは直接学習せず，システム全体の入力と出力のみを与えて，その中間段階でどのような部分課題を解くべきかを含めて学習させるのである．このような複雑なモデルであっても，学習がうまくできるようになってきたとも言えるだろう．しかし一連のステップは非常に複雑になっているため，Sukhbaatar et al. (2015) の実験では機械的に作った簡単なデータで実験を行っている．これはまだ，現実の質問を高精度に解けているわけではない.

同じように記憶の読み書きをモデル化する手法は他にも提案されている (Graves, Wayne, & Danihelka, 2014; Kumar, Irsoy, Ondruska, Iyyer, Bradbury, Gulrajani, Zhong, Paulus, & Socher, 2016)．いずれも，微分可能な関数の組み合わせによって記憶の更新と読み出しを表現し，end-to-end で学習を行う．しかし，十分に記憶や，それに基づく思考がモデル化されているとは言い難い．例えば先の記憶ネットワーク上では，各記憶は完全に別々の単一のベクトルとして表現されている．類似の記憶を汎化させるような仕組みや，連続的に起こる出来事を適度な粒度で参照することはできていない．もちろん記憶ネットワークの 4 つの各モジュールを洗練させることでこれらの欠点を克服する可能性はあるだろうから，今後発展が期待される分野であろう.

6. 言語獲得に関わる研究

ここまで見てきた研究は，いずれも言語だけで表現できるタスクを学習させる研究であった．しかし，人間の子供が言葉を獲得する過程を考えると，言葉によるタスクだけを解くことによって言葉を覚えているようには見えない．現実世界に対する操作と，それに対する周囲の人間との言葉のやり取りによって言葉を獲得している．このような，ある種の試行錯誤を通じて得た経験をもとに，機械学習の技術を適用することで言葉を獲得させることに焦点を当てた研究がここ数年出てきている.

まず，Wang, Liang, & Manning (2016) は SHRDLURN という，言葉を使ったゲームによる実験を提案している．これは Winograd の SHRDLU

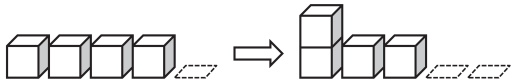


図 5 SHRDLURN の初期状態と終了状態の例.

のもじりであろう. SHRDLURN では, 一列に並んだ色の付いた積み木を操作する. 人間のプレイヤーは, 図 5 のように, 積み木の初期状態 s と最終状態 t が与えられ, システムには s のみが与えられる. プレイヤーは s から t にするために必要な指示を自然文でシステムに与える. 例えば, 図 5 の例の場合「一番右のブロックを一番左の上に置く」といった内容である. プレイヤーはどのように説明してもよい. そのため,「左から 4 つ目を取り除き, 1 つ目の上に 1 個追加する」という様に説明することもあるだろう. システムは与えられた指示に従って, 現在のシステムが適切と考える操作を行い, 次の状態を提示する. 何も学習していない状態では, 指示に関する一切の情報が与えられていないため, システムはほとんどランダムな動作を行うだろう. プレイヤーは意図通りの状態に変化したら, 正解であることをシステムに伝え, 次の操作の指示を与える. 意図通りに変化しなかったら, 間違えであることをシステムに伝える. システムは, このプレイヤーの反応を元に学習を行い, プレイヤーの指示と取るべき行動の規則を学習することを繰り返す. この学習を繰り返す過程で, 人間の指示に対応する操作を, 試行錯誤しながら学習していくという寸法である.

この実験が巧妙なのは, 人間には一切指示の出し方に関する制約を与えていないのだ. 人によっては英語で指示を出すし, 別の言語で指示を出す人もいる. 場合によってはコマンドのような, 独自の言語を作成して, それによって指示を出すこともある. システムはこれらの一切の仮定をおかずに, 処理を行う必要がある.

同時期に提案された, Bisk, Marcu, & Wong (2016a) や Bisk, Yuret, & Marcu (2016b) の研究も同様にブロックを移動させるものだが, より難易度は高いゲームになっている. ブロックは 2 次元のボード上に置かれ, 各ブロックには数種類の絵のいずれかが書かれている. Wang et al. (2016) ら同様, システムはブロックを動かす指示を自然文で受けて, それに従って操作を行う. しかし, ブロックが 2 次元上に配置され, 単純に場所の指定が難しくなっている. さらに, ブロックは色ではなく絵柄で区別されたり, あるいは絵柄が無く場所を説明する文による指示, 例えば「一番右下のブロックの直上にあるブロック」のように, 複数のブロックの関係性を用いて説明する必要のある指示も含まれる. いずれの研究も, まだ課題が提案されてシンプルな手法で解答を試みたという段階で, これからよりタスクは複雑になり研究は本格化していくだろう.

記憶の研究でも, 言語獲得の研究でも, 未だ機械が人間のように言語を体得するのは難しい. 現実の人間と同じような身体と言葉を持った機械を作り, 言語を獲得させるには至っていない. タスクを簡素化させることが現状では必要であろう. 記憶ネットワークのときに用いられたタスクは, 文を機械的に生成していたため, 人間が実際に扱う言語の多様性からは大きな乖離があった. 利用される語彙も, 表現される現象も極めて限定的であった. ここで紹介した二つのタスクも, 積み木しか存在せず, 移動させるなどの極めて少ない操作しか存在しない限定的な世界ではある. しかし, そこに対する指示の文は生身の人間が与えており, 人による曖昧性や, 多様な表現をシステムは受けることになる. また文の中には,「左から二番目」といった積み木間の関係を含む表現や,「一つおきに」といった積み木全体に関わるような表現も含まれることが容易に起こる. まさに子供の積み木遊びを大人が手伝っているような感覚のタスクではあるが, そこには言葉によるやり取りの難しさが多く含まれている.

近年の自然言語処理の研究の中には, これらの研究に限らず, 新しいタスク設定を行う研究が増えている. 背景にはクラウドソーシングを利用して, 大規模なデータを安価に作成することができるようのなったことや, 深層学習を始めとした技術が end-to-end の学習を容易ににさせて, 様々なタスクに対する実験が行いやすくなったことなども原因しているのであろう. 今後も言語の獲得を直接指向した研究は増えていくことが予想される.

7. まとめ

ここまで, 機械学習による自然言語処理の技術を中心に, 人間の言語の獲得と, 機械の言語の獲得の差異を埋めることに寄与しそうな研究を幾つか見てきた. 深層学習の登場で, 自然言語処理の中でも意

味を扱う研究が，従来よりも盛んに行われるようになってきた．一方で，深層学習を始めとする機械学習の技術はまだ発展途上である．特に人間の学習や記憶の仕組みと比べると個別のタスクにより特化しており，人間の柔軟な思考や知性を再現しているとは言い難い．

これらを埋める可能性がある技術として，3つの研究を見てきた．ワンショット学習は，人間の即時マッピングとも取れる，最小限の情報による学習を可能にする．記憶のモデル化は，物事を記憶しそれに対する問い合わせをモデル化している．言語獲得の研究では，自然文での指示内容と操作の結びつきを学習している．いずれの研究も，これまでの特定のタスク指向的な研究というよりは，人間の知能の模倣を目指すような傾向が見られる．これらの研究が進めば，人間と同じような知的作業を行える可能性もあり，注目していきたい．

文　献

Bisk, Y., Marcu, D., & Wong, W. (2016a). Towards a Dataset for Human Computer Communication via Grounded Language Acquisition. *Proceedings of the AAAI 2016 Workshop on Symbiotic Cognitive Systems*.

Bisk, Y., Yuret, D., & Marcu, D. (2016b). Natural Language Communication with Robots. Proceedings of the 15th Annual Conference of the North American Chapter of the Association for Computational Linguistics.

Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K., & Harshman, R. (1990). Indexing by latent semantic analysis. *JOURNAL OF THE AMERICAN SOCIETY FOR INFORMATION SCIENCE*, **41** (6), 391–407.

Graves, A., Wayne, G., & Danihelka, I. (2014). Neural Turing Machines.. arxiv:1410.5401.

Kumar, A., Irsoy, O., Ondruska, P., Iyyer, M., Bradbury, J., Gulrajani, I., Zhong, V., Paulus, R., & Socher, R. (2016). Ask Me Anything: Dynamic Memory Networks for Natural Language Processing. Proceedings of The 33rd International Conference on Machine Learning, 1378–1387.

Levy, O., & Goldberg, Y. (2014). Neural Word Embedding as Implicit Matrix Factorization. *Advances in Neural Information Processing Systems*, **27**, 2177–2185.

Mikolov, T., & Quoc V. Le, I. S. (2013). Exploiting Similarities among Languages for Machine Translation.. arxiv:1309.4168.

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed Representations of Words and Phrases and their Compositionality. *Advances in Neural Information Processing Systems*, **26**, 3111–3119.

Sukhbaatar, S., Szlam, A., Weston, J., & Fergus, R. (2015). End-To-End Memory Networks. *Advances in Neural Information Processing Systems*, **28**, 2440–2448.

Vinyals, O., Blundell, C., Lillicrap, T., Kavukcuoglu, K., & Wierstra, D. (2016). Matching Networks for One Shot Learning. *Advances in Neural Information Processing Systems*, **29**, 3630–3638.

Wang, I. S., Liang, P., & Manning, D. C. (2016). Learning Language Games through Interaction. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, 2368–2378.

Weston, J., Chopra, S., & Bordes, A. (2015). Memory Networks. *International Conference on Learning Representations (ICLR)*.

(Received 25 Dec. 2016)



海野　裕也

昭和 58 年生．平成 20 年東京大学大学院情報理工学系研究科修士課程修了．同年日本アイ・ビー・エム株式会社入社．平成 23 年株式会社 Preferred Infrastructure 入社．平成 26 年株式会社 Preferred Networks 入社．現在同社知的情報処理事業部事業部長．機械学習を用いた自然言語処理の研究と開発に従事．オープンソースの深層学習フレームワーク，Chainer の開発者の一人．著書に「オンライン機械学習」（共著，講談社）．言語処理学会会員．