Universitat d'Alacant
Universidad de Alicante

Esta tesis doctoral contiene un índice que enlaza a cada uno de los capítulos de la misma.
Existen asimismo botones de retorno al índice al principio y final de cada uno de los capítulos.

Ir directamente al índice

Para una correcta visualización del texto es necesaria la versión de Adobe Acrobat Reader 7.0 o posteriores

Aquesta tesi doctoral conté un índex que enllaça a cadascun dels capítols. Existeixen així mateix botons de retorn a l'index al principi i final de cadascun deis capítols .

Anar directament a l'index

Per a una correcta visualització del text és necessària la versió d' Adobe Acrobat Reader 7.0 o posteriors.

Departamento de Filología Inglesa
Universidad de Alicante

UNIVERSITAT D'ALACANT
COMISSIÓ DE DOCTORAT
28-3-94
ENTRADA Núm. 216
EIXIDA Núm.

Tesis Doctoral

presentada por

Celia Rico Pérez

dirigida por

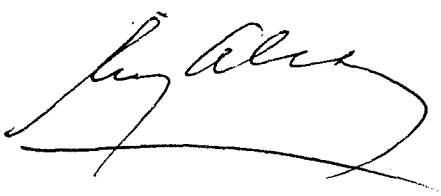
Dr. D. Enrique Alcaraz Varó

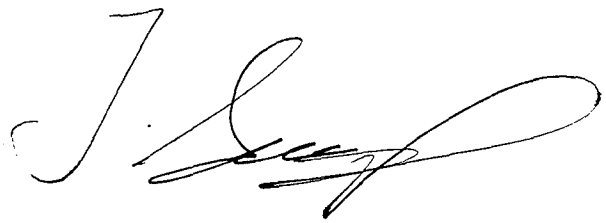
y

Dr. D. José Simón Granda

APROXIMACIÓN ESTADÍSTICO-ALGEBRAICA AL PROBLEMA DE LA RESOLUCIÓN DE LA ANÁFORA EN EL DISCURSO

V°B°
Los Directores





Fdo. Dr. D. Enrique Alcaraz Varó

Fdo. Dr. D. José Simón Granda



Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Universitat d'Alacant
Universidad de Alicante

A Manuel y Mª Luisa,
mis padres

Universitat d'Alacant
Universidad de Alicante

INDICE

Agradecimientos i

Capítulo 1. Introducción y organización de la tesis.

1. El problema. 1
2. La perspectiva adoptada. 5
3. La hipótesis y los objetivos. 9
4. El procedimiento metodológico. 12

Capítulo 2. La anáfora. Definición de conceptos.

1. Introducción. 15
2. Definición de conceptos. 16
   - 2.1. La anáfora discursiva. 16
   - 2.2. Referente y antecedente. 17
   - 2.3. Expresión anafórica y expresión referencial. 19
3. Clasificación de los fenómenos anafóricos. 20
4. El antecedente y la accesibilidad. 24
   - 4.1. La distancia. 24
   - 4.2. La prominencia. 25
   - 4.3. La competencia. 26
   - 4.4. La unidad. 27
5. El tipo de relación anafórica. 28
   - 5.1. La anáfora morfosintáctica. 28
   - 5.2. La anáfora semántica. 31
   - 5.3. La anáfora pragmática. 36
6. Función cohesiva de las diferentes relaciones anafóricas. 37
   - 6.1. La coespecificación. 37
   - 6.2. La sustitución y la elipsis. 39
   - 6.3. La cohesión léxica. 40
   - 6.4. La conjunción. 40
7. Expresiones anafóricas tratadas en este estudio. 41
8. Conclusiones. 43

Capítulo 3. Anáfora y lingüística computacional.

1. Introducción. 44
2. Aproximaciones tradicionales. 46
2.1. ELIZA 48
2.2. SHRDLU. 51
2.3. LSNLIS. 54
2.4. Charniak. 57
2.5. Wilks. 60
2.6. Hobbs. 64
3. Aproximaciones de tipo «democrático». 66
3.1. Alshawi. 67
3.2. Carbonell y Brown. 70
3.3. Rich y LuperFoy. 76
4. Aproximaciones de tipo «consultivo». 79
4.1. La teoría del foco discursivo. 79
4.2. Foco discursivo y foco agente. 81
4.3. Los centros focales. 82
4.4. La estructura de atenciones del discurso. 84
5. Sistemas que adoptan el enfoque «consultivo». 85
5.1. Brennan, Friedman y Pollard. 85
5.2. SPAR. 88
5.3. CLE. 92
6. Conclusiones. 96

Capítulo 4. Análisis de las relaciones anafóricas contenidas en un corpus.

1. Introducción. 98
2. Criterios generales para la selección de un corpus. 100
3. El corpus seleccionado. 101
4. Selección de la muestra. 103
5. Análisis de los datos. 105
6. Fuentes de información necesarias para la identificación de antecedentes. 107
7. Información gramatical. 108
8. Información sintáctica. 111
9. Información semántica. 114
10.Información pragmática. 116
10.1. Rasgo de distancia. 117
10.2 Rasgo de competencia. 120
10.3 Rasgo de prominencia. 123
10.4. Rasgo de unidad. 125

Universitat d'Alacant
Universidad de Alicante

11.Información sobre el tipo de expresión anfórica. 127
12. Conclusiones. 130

Capítulo 5. Coordinación de múltiples fuentes de información.

1. Introducción. 132
2. La estrategia de identificación de antecedentes anafóricos. 133
3. Selección de la estrategia: el producto escalar. 135
4. Aplicación del producto escalar. 141
5. Los atributos anafóricos. 143
6. Asignación de valores numéricos a los atributos anafóricos. 154
7. Los vectores asociados a entidades discursivas y expresiones anafóricas. 161
8. Identificación de antecedentes mediante el producto escalar. 165
9. Conclusiones. 195

Capítulo 6. Automatización del proceso de identificación de antecedentes.

1. Introducción. 196
2. Estructura general. 197
3. Los módulos de análisis morfológico y sintáctico. 199
4. Identificación de unidades de análisis. 207
5. Extracción de información semántica. 208
6. Asignación de rasgos pragmáticos. 211
7. Identificación de relaciones anafóricas. 212
8. Conclusiones. 215

Capítulo 7. Evaluación del producto escalar como estrategia de identificación de antecedentes.

1. Introducción. 217
2. Estudio y justificación de la aproximación computacional adoptada. 219
3. Alcance lingüístico. 221
4. Precisión. 222
   4.1. Selección del antecedente por concordancia gramatical. 223
   4.2. Selección del antecedente por posiciones sintácticas paralelas. 226

Universitat d'Alacant
Universidad de Alicante

4.3. Selección del antecedente
por consistencia semántica. 231
4.4. Selección del antecedente
por rasgos pragmáticos de distancia. 234
5. Dificultad en la valoración de los datos. 238
6. Sencillez de las estructuras y
mecanismos empleados. 239
7. Poder explicativo. 239
8. Limitaciones. 240
9. Actualización y ampliación. 241

Conclusiones. 242

Bibliografía. 248

Apéndice 1. Ejemplo de un texto extraído del corpus. 259

Apéndice 2. Ejemplo de un texto con las unidades identificadas. 271

Apéndice 3. Listado del programa. 278

Universitat d'Alacant
Universidad de Alicante

Universitat d'Alacant
Universidad de Alicante

AGRADECIMIENTOS

Mis primeras palabras de agradecimiento son para mis directores de tesis: el Dr. Enrique Alcaraz Varó, profesor de la Universidad de Alicante, y el Dr. José Simón Granda, profesor de la Universidad de Alcalá de Henares. Su apoyo ha sido constante, y al igual que unos padres guían a sus hijos en los primeros pasos por el mundo, el Dr. Alcaraz y el Dr. Simón me han indicado siempre los caminos acertados en el campo de la investigación.

Quiero reconocer asimismo la contribución a mi tesis de dos entidades: la Caja de Ahorros del Mediterráneo y el British Council. En 1989 obtuve una beca de estudios de ambos organismos, gracias a la cual pude iniciar mis estudios en lingüística computacional en Inglaterra y descubrir, entonces, una curiosidad científica por la lengua.

Por otra parte, debo agraceder igualmente al British Council la bolsa de viaje que me concedió en 1991 para continuar mi consulta bibliográfica en el UMIST de Manchester.

También en cuestiones bibliográficas debo dar las gracias a Yolanda Sánchez Mateo, compañera del departamento de Filología Inglesa y coordinadora del CEDOCAM, y a Beth Robb, de PeopleSoft, quien me consiguió algunos de los libros que componen mi bibliografía.

Agradezco los comentarios acertados de Miguel Angel Campos Pardillos, compañero también del departamento de Filología Inglesa, y las oportunas sugerencias del Dr. Gabriel Amores Carredano, de la Universidad de Sevilla, así como de Antonio Sánchez Valderrábanos, de WordPerfect Development.

Reconozco la simpatía e interés de José Segundo Álvarez, Carmen Payá y Mª José Ruiz, de la comisión de doctorado, para responder a todas mis preguntas sobre créditos, impresos y demás asuntos administrativos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Volver al índice/Tornar a l'índex

En los aspectos prácticos de esta tesis me han ayudado mis hermanos, Héctor, Graziella y Manuel, con largas horas dedicadas, entre risas, a la estadística, el diseño gráfico y las pizzas de las doce de la noche.

Para Manuel Martínez López y Mª Carmen Martínez Segura quiero reservar una mención especial porque todo el capítulo cuarto se lo debo a ellos y a la cesión de su casa en la playa durante la primavera de 1993, donde pude encontrar la necesaria soledad para reflexionar sobre mi trabajo.

No quiero concluir mis agradecimientos sin mencionar a mis padres y mi abuela, quienes, más que nadie, han tenido que soportar mis cambios de humor y mis angustias, y a cambio me han ofrecido siempre una sonrisa.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 1.
Introducción y organización de la tesis.

1. El problema.

En los orígenes de todo trabajo de investigación está presente el deseo intenso de dar respuesta a un problema o asunto específico que el investigador ha considerado lo suficientemente cautivador como para dedicarle su esfuerzo y horas de estudio. A veces, el problema se plantea como la necesidad de dar explicación a algún aspecto concreto que todavía no ha sido abordado por la comunidad científica. En otras ocasiones, se trata de arrojar luz desde nuevas perspectivas sobre cuestiones ya explicadas con anterioridad. En cualquier caso, y con independencia del tipo de problema al que se enfrenta el estudioso, es realmente cierto que siempre existe un motivo esencial que estimula al investigador a acometer la tarea (Alcaraz, 1990: 162).

En el caso de la tesis que presento, el estímulo investigador surge de la observación de fenómenos lingüísticos como el que citaré a continuación, así como de la necesidad de aportar nuevos datos explicativos en torno a estos mismos fenómenos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Observemos, así pues, el siguiente ejemplo:

> Pain shout up Curt's arm clear to the shoulder, but Jess seemed hardly aware that *he* had been hit.

Aparece en esta oración un pronombre, *he*, que podemos asociar, sin dificultad, al nombre *Curt*, es decir, que es *Curt* quien ha recibido un golpe y *Jess* quien no se ha dado cuenta de ello.

Sin embargo, cuando a esta misma oración le añadimos un nuevo contexto, la interpretación puede ya no ser la misma:

> Curt drove home a solid left to Jess' mid section. It was like hitting a sack of salt. Pain shout up Curt's arm clear to the shoulder, but Jess seemed hardly aware that *he* had been hit.

Es evidente que al insertar la oración dentro de un contexto concreto el nombre asociado a *he* ya no es *Curt* sino *Jess*, esto es, que la persona que ha recibido el golpe y que parece no darse cuenta de ello es el propio *Jess*.

Como es de suponer, el ejemplo citado no es más que una pequeña ilustración del incontable número de oraciones en las que la correcta interpretación de un pronombre depende directamente del contexto en el cual aparece dicho pronombre. El problema que se plantea entonces, ante el examen de enunciados como el expuesto, es determinar con exactitud la importancia de las diferentes fuentes de información lingüística que se distribuyen a lo largo del discurso y que intervienen en la interpretación de pronombres y otras expresiones que tienen la misma función asociativa

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

o de referencia. En otras palabras, se trata de explorar el efecto que la información morfológica, sintáctica, semántica y pragmática tiene en la comprensión de lo que denominaremos relaciones anafóricas o relaciones de referencia a otras partes del discurso.

Después de todo lo dicho, se pone de manifiesto que el objeto central de estudio de la presente investigación serán las citadas relaciones anafóricas. Como mostraremos a continuación, es la anáfora un fenómeno lingüístico central en todo proceso comunicativo. En efecto, sea como manifestación oral o como manifestación escrita, la comunicación humana se sirve de mecanismos que facilitan la referencia al mundo, al propio texto, a objetos, a personas, a situaciones o a acciones mencionadas a lo largo del intercambio comunicativo. Por ejemplo, si a lo largo de una conversación con un amigo éste dice: «Te recomiendo *este libro*, es muy interesante», y con un gesto señala el libro que tiene entre sus manos, se construye una relación de referencia al mundo real mediante el uso de la expresión *este libro*. Asimismo, es posible establecer una referencia a una parte de un texto escrito, como muestra el ejemplo siguiente: «Pedro estaba hojeando *Alicia en el país de las maravillas* cuando se encontró a Marta por el pasillo. Sin esperar al saludo, Pedró le recomendó a Marta la lectura de *este libro*.»

Con respecto a lo anterior, es necesario precisar que el establecimiento de relaciones de referencia o relaciones anafóricas puede llevarse a cabo de muy diferentes formas, esto es, que no existe un único modo de crear referencias. Así pues, podemos fácilmente comprobar que los mecanismos empleados en las relaciones anafóricas abarcan desde formas lingüísticas relativamente simples hasta formas lingüísticas de gran

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

complejidad y poder descriptivo. A este respecto, comparemos, a modo de ilustración, los mecanismos de refencia usados en los textos T1 y T2[1]:

T1 Susana se ha comprado *un seiscientos de segunda mano.* Pilar le recomendó que no *lo* comprara.

T2 Susana se ha comprado *un seiscientos de segunda mano.* Pilar le recomendó que no comprara *ese coche tan viejo.*

Es evidente que en T1 la relación anafórica se construye entre el sintagma nominal *un seiscientos de segunda mano* y el pronombre *lo*. Por otra parte, observamos que en T2 se crea una relación similar entre el mismo sintagma nominal, *un seiscientos de segunda mano*, y otro sintagma nominal, *ese coche tan viejo*. Como vemos, la complejidad y la carga descriptiva del sintagma que en T2 actúa como vehículo para construir la referencia es mucho mayor que la que posee el pronombre *lo* en T1, pero la referencia a *un seiscientos de segunda mano* sigue manteniéndose en ambos casos.

Llegamos, así pues, a la conclusión de que, independientemente de la forma lingüística empleada para construir la referencia, el fenómeno lingüístico con el que nos enfrentamos es siempre el mismo, la **anáfora**. En este punto, se hace imprescindible que ofrezcamos una primera definición de anáfora, que será ampliada más adelante. De esta forma, definiremos la anáfora, de manera general, como la relación de referencia que se establece entre una forma lingüística y un objeto, una persona o

[1] Los textos que presentamos como ejemplo están numerados a lo largo de esta tesis con una T, que consideramos como la abreviatura de «texto», y un número, que permite identificar cada ejemplo del resto.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

una situación que ya han sido mencionados de manera implícita o explícita con anterioridad durante el proceso comunicativo y que llamaremos antecedente[2].

Universitat d'Alacant
Universidad de Alicante

2. La perspectiva adoptada.

Una vez conocido el objeto de nuestra investigación, es preciso que centremos nuestra atención en la definición del marco teórico o paradigma en el cual se apoya el problema que vamos a tratar, ya que el mismo problema, analizado desde perspectivas diferentes, produce diferentes resultados. En el caso de la anáfora, los estudios realizados son muy numerosos y cada uno ha tratado aspectos diferentes con la intención de ofrecer un modelo claro que explicase las relaciones anafóricas. En este sentido, existen teorías de la anáfora en sintaxis, semántica, pragmática y también en psicolingüística, filosofía del lenguaje y lógica. Esto es así debido a que los procesos que intervienen en el establecimiento de relaciones anafóricas abarcan un amplio espectro de las ciencias humanísticas. Así, por ejemplo, en psicolingüística se llevan a cabo experimentos para descubrir la manera en que los interlocutores consiguen crear y comprender las referencias anafóricas en el proceso comunicativo (Marslen-Wilson y Komisarjevsky Tyler, 1982) o cuáles son los mecanismos que actúan en la selección de determinadas anáforas (Gernsbacher, 1989); en filosofía del lenguaje se proponen teorías que explican cómo una anáfora puede llegar a establecer una relación con el mundo real a través de la referencia a un antecedente (Donnellan, 1978); y en lógica se crean

[2] Existen casi tantas definiciones de anáfora como teorías que se ocupan del fenómeno. Reconocemos que esta definición no se ajusta a los postulados de ningún marco teórico concreto pero es nuestra intención mantener la anáfora dentro de un marco muy general hasta que determinemos, más tarde, el paradigma de nuestra investigación.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

gramáticas que tratan la anáfora, entre otros problemas lingüísticos (Dowty *et al*, 1981).

Universitat d'Alacant
Universidad de Alicante

Sin embargo, la anáfora no es un fenómeno nuevo que se haya descubierto en este siglo. Si nos remontamos a la Grecia clásica encontraremos las primeras aproximaciones conocidas al problema. En efecto, en las gramáticas griegas podemos situar los orígenes de la investigación sobre la anáfora y, como veremos, la perspectiva que adoptan con respecto a esta cuestión está en consonancia con el acercamiento teórico que seguiremos en nuestra investigación.

En las citadas gramáticas, la anáfora se considera como una noción relacionada con la clasificacion de las partes del discurso (Bosch, 1983: 3), es decir, que constituye un elemento más del discurso. Cabe destacar dentro de esta concepción discursiva, la propuesta de Dionisio de Tracia, para quien la anáfora está ligada a la parte del discurso denominada *syndemos*, que se caracteriza por su función de mantener unido el hilo de coherencia del pensamiento y de llenar los vacíos durante su interpretacion. Por otra parte, podemos citar la escuela de los Estoicos, para quienes la anáfora cumple la misma función de creación y conservación del mismo hilo discursivo (Robins, 1951: 29).

Finalmente, no debemos olvidar el primer tratado sobre los pronombres, *Pery Antonymias*, escrito por Apolonio Díscolo, donde se clasifica la anáfora como *deutera gnosis* (conocimiento de algo percibido y recordado con anterioridad) frente al *prote gnosis* (conocimiento de cosas o seres vivos no percibidos anteriormente) (Bosch, 6).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La definición de anáfora que dan las citadas gramáticas de la Grecia clásica nos ayudará a centrar el marco de nuestra investigación y así, tomaremos como punto de partida para nuestro estudio la idea de que la anáfora es un fenómeno lingüístico básicamente discursivo y, por tanto, el paradigma de estudio será, en nuestro caso, la pragmática[3].

Con frecuencia se ha privado a la anáfora de su dimensión discursiva y su estudio ha quedado reducido, en muchas ocasiones, al marco de la oración. Este es el caso, entre otros, de las primeras propuestas de la gramática transformacional (Chomsky, 1965) donde la anáfora se considera como una especie de sustitución sintagmática. A pesar de que la idea de la sustitución ha sido abandonada en versiones posteriores de la citada teoría (Reinhart, 1983; Chomsky, 1981), se mantienen los conceptos de reglas y restricciones sintácticas para explicar este fenómeno lingüístico.

Sin embargo, como quedará demostrado a lo largo de nuestro estudio, la anáfora es un fenómeno eminentemente discursivo ya que (a) es el propio discurso el que proporciona y distribuye en diferentes enunciados la información necesaria para interpretar las relaciones anafóricas, y (b) mantener la coherencia discursiva es uno de los principales objetivos de las anáfora. Para ilustrar nuestras palabras analizaremos, a continuación, el texto T3:

[3] La pragmática es un paradigma de investigación «cuyo *status* no está claro y perfectamente definido en el momento actual» (Alcaraz, 1990: 111). Prueba de ello son las múltiples definiciones que existen de esta disciplina (Levinson,1983). Queremos subrayar que el concepto de pragmática al que nos acogemos es el que define el discurso como una entidad global dotada de cohesión y coherencia, y estudia los diferentes aspectos de la estructura del discurso y el contexto que intervienen en la interpretación del enunciado.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T3 I worked with my uncle, who ran one of those antique shops in New Orleans' Vieux Carre, the old French Quarter. *The arrangement* I had with him was to work four hours a day. The rest of the time I devoted to painting or to those other activities a young and healthy man just out of college finds interesting. I had a one-room studio which overlooked an ancient courtyard filled with flowers and plants, blooming everlastingly in the southern sun. I had come to New Orleans two years earlier after graduating college. When my uncle offered me *a part-time job* which would take care of my normal expenses and give me time to paint I accepted. *The arrangement* turned out to be excellent.

En primer lugar, podemos comprobar que las relaciones anafóricas que se establecen entre los grupos nominales *the arrangement* y *a part-time job* son posibles gracias a la presencia en el discurso de determinadas fuentes de información, que permiten saber que *the arrangement* consiste, en este caso, en *to work four hours a day*. Para llegar a esta conclusión es imprescindible que el lector sepa que trabajar cuatro horas es trabajar a tiempo parcial y, sólo así, puede establecerse la referencia de *a part-time job* a *the arrangement*.

En segundo lugar, observamos que, gracias al empleo de relaciones anafóricas, surgen vínculos de unión entre diferentes partes del texto, los cuales hacen que éste se constituya como una unidad de sentido cerrada. Esta idea de la función discursiva de la anáfora queda sucintamente esbozada aquí, puesto que será desarrollada en mayor profundidad en los capítulos siguientes.

Después de todo lo dicho, podemos concluir que, ciertamente, la anáfora es un fenómeno discursivo y como tal será tratado en nuestra

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

investigación. Consecuentemente, el marco de partida de nuestro estudio será la pragmática ya que es dentro de esta perspectiva donde se considera el lenguaje como discurso.

Universitat d'Alacant
Universidad de Alicante

3. La hipótesis y los objetivos.

Ya conocemos el problema que vamos a tratar, la anáfora, así como el paradigma en el cual enmarcamos nuestra investigación, la pragmática. Debemos hacer mención en este momento a la hipótesis sobre la que construimos nuestro proyecto investigador.

A este respecto, diremos que nuestra hipótesis de trabajo se concreta dentro de un área de estudio relativamente nueva, la lingüística computacional, cuyo objetivo básico es tratar la información lingüística mediante métodos informáticos a fin de faciliar el tratamiento automático del lenguaje natural. En palabras de Meya y Huber (1986) «el objetivo de la lingüística computacional es comprender cómo se comunica el ser humano y luego crear modelos y sistemas que capaciten a los ordenadores para poder simular un comportamiento inteligente» (12).

Dentro de la aproximación computacional, el problema que plantea la anáfora es conseguir la identificación de antecedentes de los pronombres y otras expresiones anafóricas de manera automática. Para llegar a esta automatización del proceso de localización de antecedentes, es imprescindible que la información que se utilice en el proceso sea accesible también de modo automático, es decir, que puedan ser codificados sin intervención humana los conocimientos que proceden de aspectos morfológicos, sintácticos, semánticos y pragmáticos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Con relación a lo anterior, podemos afirmar que nos encontramos ante un problema ciertamente complejo. Pensemos, por ejemplo, en la ambigüedad que nos plantea el texto T4:

T4 Susana invitó a cenar a Pilar.
Ella quería contarle el problema que había tenido con el coche.

En T4 los antecedentes posibles del pronombre *ella* son dos: Susana y Pilar. Normalmente el ser humano identifica *Susana* como antecedente de *ella* y esto es posible porque dispone de toda la información necesaria para ello: sabe que debe existir una concordancia entre el género, número y persona de la expresión anafórica y el antecedente; identifica *Susana* como entidad prominente; y presupone que cuando una persona invita a otra es por alguna razón y en este caso, la razón es poder contar un problema. Pues bien, suponiendo que para las personas la referencia anafórica en T4 esté clara[4] se plantea el siguiente problema: ¿cómo es posible llegar a codificar toda la información que normalmente emplea el ser humano de manera inconsciente para que pueda ser utilizada de manera automática en la identificacion de antecedentes?

En respuesta a la pregunta anteriormente formulada, construimos la siguiente hipótesis: puede llevarse a cabo un tratamiento de los problemas que plantea la identificación de los antecedentes anafóricos en el discurso si, para ello, se emplean modelos de inspiración vectorial[5].

[4] Es posible que para algunos hablantes la referencia sea diferente.

[5] Como veremos en el capítulo quinto, el modelo que proponemos toma del cálculo vectorial la noción de vector, concepto utilizado en física y matemáticas, que se define como un segmento orientado que queda definido por su magnitud, dirección y sentido AB;

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La enunciación de esta hipótesis presupone el reconocimiento de los siguientes puntos:

a) Los tipos de información lingüística que intervienen en la identificación de antecedentes anafóricos se distribuyen a lo largo de todo el discurso y, por tanto, no puede excluirse una aproximación discursiva al problema.

b) Toda la información lingüística actúa por igual en la localización de los antecedentes, es decir, no puede darse prominencia a ninguna fuente lingüística por encima de otras. Este supuesto implica que no podemos predecir la influencia que tendrá cada fuente de información en la selección de antecedentes. En este sentido, intentaremos demostrar más adelante la imposibilidad de afirmar que, por ejemplo, la información morfológica sobre la concordancia de número entre el antecedente y la expresión anafórica sea un factor de mayor peso que la información pragmática sobre la posición prominente de un antecedente.

c) La construcción de un modelo de inspiración vectorial permite, por una parte, tratar la información lingüística en los términos de igualdad deseados y, por otra, coordinar en un único patrón toda la información contenida en el discurso.

Con el fin de probar nuestra hipótesis marcamos el siguiente objetivo: conseguir crear un mecanismo de identificación automática de

A origen y B extremo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

antecedentes anafóricos que utilice, por igual, información morfológica, sintáctica, semántica y pragmática, empleando, para ello, un modelo de inspiración vectorial.

Universitat d'Alacant
Universidad de Alicante

4. El procedimiento metodológico.

Para llevar a cabo nuestro objetivo y probar nuestra hipótesis nos serviremos de la metodología pragmática discursiva, orientada a construir una aplicación computacional (recordemos que, por una parte, el discurso ha sido definido como unidad básica para nuestro análisis y por otra, enmarcamos la investigación dentro de la perspectiva de la lingüística computacional).

El plan de trabajo sobre el que construimos toda nuestra investigación es el siguiente:

1- Formulación de una tipología de la anáfora discursiva con el fin de conocer en profundidad el fenómeno lingüístico con el que vamos a tratar, su importancia en el establecimiento y mantenimiento de relaciones discursivas y cualquier otro dato que pueda aportar información teórica relevante sobre el objeto de nuestro estudio.

A estos efectos, expondremos en el capítulo 2 todos los presupuestos teóricos en los que nos basamos, así como todas las definiciones de la terminología usada en esta investigación. Del mismo modo, desarrollaremos en este capítulo una clasificación de la anáfora teniendo en cuenta los tipos de antecedente, los tipos posibles de relación anafórica y la función discursiva de la misma. Finalmente,

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

aludiremos a las expresiones anafóricas concretas que se examinarán en este estudio.

Universitat d'Alacant
Universidad de Alicante

2- Estudio y análisis crítico de las aproximaciones más relevantes al problema de la anáfora en lingüística computacional. Examinaremos con una visión crítica los sistemas y algoritmos desarrollados desde lo que podemos considerar los primeros tiempos de la lingüística computacional hasta las últimas propuestas de los años 90. Con este recorrido casi histórico pretendemos: (a) ofrecer una visión de conjunto de las investigaciones más importantes sobre la anáfora y (b) componer el marco general en el que se incluye nuestra investigación. El capítulo 3 está dedicado a este estudio.

3- Análisis empírico de las relaciones anafóricas contenidas en un corpus de textos para conocer, con datos, el comportamiento real de la anáfora en el discurso, así como los tipos de información lingüística que intervienen en la localización de antecedentes. Una vez efectuado el análisis, podremos sacar una serie de conclusiones que utilizaremos en la construcción de la estrategia de identificación de antecedentes. Dicho análisis se expone con detalle en el capítulo 4.

4- Creación de la estrategia de identificación de antecedentes empleando un modelo vectorial. La construcción de ésta se apoya en el empleo de notación vectorial para la codificación de las fuentes de información localizadas en la fase 3 de la investigación. Una vez diseñada la estrategia, experimentaremos de manera manual con relaciones anafóricas reales para decidir sobre su adecuación al

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

tratamiento del problema que nos ocupa. En el capítulo 5 mostraremos con detalle la técnica empleada.

5- Ejecución de la estrategia propuesta. En el capítulo 6, una vez comprobada la eficacia del método de identificación de antecedentes, procederemos a llevarlo a la práctica en un programa informático que muestre que es posible automatizar todo el proceso de localización de antecedentes.

6- Evaluación de la aproximación adoptada en esta investigación y extracción de conclusiones sobre el trabajo realizado. El capítulo 7 contiene los resultados de esta última fase.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 2.
La anáfora. Definición de conceptos.

1. Introducción.

Como señalamos en el capítulo primero, los estudios sobre la anáfora son muy numerosos y las perspectivas que éstos adoptan son también muy variadas. Ante tal número de diferentes aproximaciones al problema de la identificación de antecedentes anafóricos es imprescindible delimitar con claridad el marco teórico en el que centramos la presente investigación para poder ofrecer así una definición inequívoca de este fenómeno lingüístico.

Con este fin, expondremos en el apartado 2 las bases teóricas sobre las que trabajamos y justificaremos la necesidad de tomar como punto de partida las propuestas de la lingüística supraoracional, que considera la anáfora en su dimensión discursiva. Partiendo de este punto de vista, definiremos los conceptos básicos que utilizamos a lo largo del presente estudio y propondremos en el apartado 3 una clasificación de los tipos de anáfora que responde también a la concepción discursiva adoptada. Las secciones 4, 5 y 6 desarrollan en profundidad esta clasificación. El último apartado especifica el tipo de anáfora que hemos seleccionado para realizar nuestra investigación.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2. Definición de conceptos.

Los conceptos básicos con los que vamos a tratar son los siguientes: anáfora discursiva, referente y antecedente, expresión anafórica y expresión referencial. Todos ellos quedarán definidos a continuación.

2.1. La anáfora discursiva.

La definición de anáfora que nos interesa en este estudio es la que se desprende de los postulados básicos de la lingüística supraoracional. Desde esta perspectiva la anáfora es un fenómeno que no puede restringirse a la definición que propone la lingüística oracional, según la cual la anáfora es «el sintagma nominal cuya referencia está determinada necesariamente dentro de la oración sin poder tener referencia independiente» (Horrocks, 1987: 108). Esta definición es claramente insuficiente cuando el objetivo de nuestra investigación es realizar un procesamiento automático del lenguaje natural, donde la oración no es un elemento aislado, sino un componente más dentro de una unidad mayor, el discurso.

Si adoptamos este punto de vista y tomamos el texto como unidad discursiva, la anáfora adquiere una dimensión más amplia y se sitúa más allá de los límites establecidos por la sintaxis. No es únicamente una referencia abreviada a una entidad previamente mencionada en la oración, ya que existe una relación muy estrecha entre la anáfora y el discurso. En efecto, ésta desempeña siempre una función relevante en la interpretación de los enunciados que componen el discurso y en el establecimiento del mismo como entidad global (Alcaraz, 1990: 135). La anáfora en el discurso actúa como mecanismo de cohesión textual y contribuye a la conservación

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

de un foco de interés previamente establecido mediante las entidades discursivas, las cuales crean unos puntos de atención en el discurso que son confirmados y consolidados gracias a las expresiones anafóricas. Así pues, la anáfora sólo puede comprenderse si pensamos en ella como en un elemento que ayuda a que el discurso sea una unidad de sentido cerrada, puesto que crea una serie de vínculos de unión entre diferentes partes del texto. Estos nexos de unión se concretan en el empleo de expresiones anafóricas (pronombres, sinónimos, demostrativos, paráfrasis...) que dependen de entidades previamente mencionadas.

Podemos afirmar, en suma, que la definición de anáfora que proponemos en este estudio está ligada a un fenómeno básicamente pragmático, la cohesión textual, y por lo tanto, al establecimiento y consolidación del discurso y las entidades que en él aparecen[1].

2.2. Referente y antecedente.

Los términos referente y antecedente se utilizan en lingüística computacional, con relación al estudio de las relaciones anafóricas, para diferenciar entre la representación mental de los objetos evocados por el texto (referente), y la representación lingüística que éstos toman en el mismo (antecedente). Autores como Sidner (1983) y Webber (1986) proponen esta distinción, y rechazan la definición tradicional según la cual, el proceso de interpretación anafórica trata de encontrar el antecedente sin

[1] En este sentido es muy interesante la propuesta que hace Levinson (1987), quien desarrolla un modelo pragmático de interpretación de la anáfora tomando como base el Principio de Cooperación de Grice (1975). Dentro de este principio, las máximas de Cantidad y Modalidad actúan en la interpretación de fenómenos anafóricos y permiten reducir las reglas sintácticas de Control y Ligamiento a una dimensión pragmática.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

entrar en consideraciones de tipo cognitivo.

Universitat d'Alacant Universidad de Alicante

Los mencionados estudios proponen un modelo computacional en el que la distinción entre referente y antecedente, en los términos propuestos, surge de la necesidad de representar el discurso mediante representaciones abstractas que definan las relaciones cognitivas entre los objetos y los elementos evocados en la mente de los participantes en el discurso. Así lo confirma Allen (1987) cuando apunta que «in computational systems, where there is a knowledge representation, reference generally considers the relationships of phrases to terms in the knowledge representation» (335).

En el modelo que ofrecemos en el presente trabajo, no es nuestra intención crear esta representación mental o abstracta del mundo. Sin embargo, sí mantendremos la distinción entre referente y antecedente, ya que servirá como punto de partida para definir el concepto de relación anafórica.

Así pues, definiremos ésta como la relación que se da únicamente entre entidades lingüísticas, es decir, entidades cuya referencia puede localizarse dentro del propio texto.

Como podemos suponer, esta definición excluye la exófora, es decir, cualquier relación de tipo extralingüístico como la que se podría plantear con la referencia «ésta» en el enunciado *Mamá quiero ésta*, si enmarcáramos esta oración dentro de un contexto en el que un niño le pide a su madre una bicicleta que está en un escaparate.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El hecho de eliminar de nuestra investigación las relaciones exofóricas responde a la propia naturaleza del presente estudio, que se centra, por una parte, en el análisis empírico de datos observables y, por otra, en el desarrollo de un modelo computacional para el tratamiento de la anáfora que excluye representaciones abstractas del mundo. Esto es así porque solamente es posible obtener datos cuantitativos sobre las relaciones anafóricas si el antecedente y la expresión anafórica son directamente observables en el texto. En cualquier caso asumimos que en última instancia los antecedentes son siempre unidades mentales, aunque no desarrollemos un modelo del mundo.

2.3. Expresión anafórica y expresión referencial.

Si tomamos como punto de partida la distinción entre antecedente y reconocemos que el marco de estudio es el texto, podremos distinguir dos tipos de expresiones:

a- Expresiones anafóricas. Son aquéllas cuyo antecedente se puede calcular[2] dentro del texto porque éste existe en el universo lingüístico.

b- Expresiones referenciales. Son aquéllas cuyo antecedente no puede calcularse dentro del texto porque éste existe en el universo extralingüístico.

[2] El hecho de que un antecedente sea calculable se define como la facultad de éste para ser expresado con valores numéricos y, como se mostrará en el capítulo 5, poder establecer relaciones anafóricas en virtud de una operación matemática.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Podemos decir, por tanto, que las expresiones anafóricas tienen un antecedente calculable, mientras que las expresiones referenciales tienen un antecedente que no es calculable. Así, por ejemplo, consideramos como una expresión referencial cualquier entidad que aparezca por primera vez en el texto ya que, en esta primera mención, el antecedente pertenece todavía al mundo de las representaciones mentales. Sin embargo, las menciones posteriores de la misma entidad son expresiones anafóricas porque su antecedente es una unidad lingüística localizable en el discurso. Esto es precisamente lo que ocurre en el Texto 1:

T1 *The boy with fair hair* lowered himself down the last few feet of rock... He had taken off his school sweater. (7,1)[3]

En T1 la entidad discursiva *the boy with fair hair* es una expresión referencial al ser la primera vez que aparece en el discurso. Sin embargo, las referencias posteriores a esta misma entidad discursiva se consideran referencias anafóricas porque el antecedente puede localizarse dentro del mismo texto.

3. Clasificación de los fenómenos anafóricos.

En general, la clasificación de cualquier fenómeno debe garantizar «que tanto el punto de vista aplicado, como el reconocimiento y la orientación que se siga, no son simples éxitos individuales sino verdaderos logros científicos, de forma que será tanto más adecuada científicamente cuanto

[3] Los ejemplos de este capítulo están tomados de la novela de W. Golding *Lord of the Flies* (Faber & Faber, edición de 1982). Los números que aparecen después del ejemplo corresponden a la página y la línea del texto.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

más amplia sea su respuesta a exigencias e intereses teóricos generales» (Alcaraz, 1990: 72). Así es como las diferentes disciplinas llegan a desarrollar diferentes criterios de clasificación, según la naturaleza de los fenómenos observados y la finalidad para la cual se construyen las clasificaciones.

El marco teórico sobre el que construimos la clasificación de los fenómenos anafóricos en el presente estudio es, como vimos en el apartado 2.1, la lingüística supraoracional. La finalidad de dicha clasificación es delimitar claramente el tipo de fenómeno con el que vamos a trabajar. Por tanto, ésta debe aportar información sobre (a) los posibles tipos de relación anafórica que pueden establecerse, (b) sobre los tipos de antecedente y cómo pueden influir en la elección de la expresión anafórica, (c) sobre las diferentes formas que tiene la lengua para construir expresiones anafóricas y, por último, (d) sobre la manera en que las relaciones anafóricas contribuyen a mantener la cohesión en el discurso.

Con este fin, elaboramos, a continuación, una clasificación que conjuga diferentes aspectos del mismo fenómeno y aporta información acerca de:

a) El tipo de antecedente. Tomamos como punto de partida la ordenación que hace de los antecedentes Ariel (1990) dentro de la teoría de la accesibilidad y analizamos en el apartado 4 la influencia que el criterio de la accesibilidad tiene en la elección de las expresiones anafóricas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

b) El tipo de relación anafórica. En este caso, adoptamos la clasificación de los fenómenos anafóricos propuesta por Cornish (1986) desde una perspectiva discursiva y que desarrollamos en el apartado 5.

c) La función cohesiva de las relaciones anafóricas. Extraemos esta información de las propuestas de Halliday & Hasan (1976) y la veremos en el apartado 6.

Mostramos en la figura 1 cómo se relaciona toda esta información. En esta figura comprobamos que hay tres tipos de relación anafórica: la anáfora morfosintáctica, la anáfora semántica y la anáfora pragmática. Los tres se ordenan en una escala que va desde la máxima a la mínima accesibilidad y cumplen, además, una función cohesiva determinada.

En los apartados que siguen a continuación desarrollaremos con detalle las ideas esbozadas en la figura 1.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Accesibilidad del antecedente	**Las relaciones anafóricas**	**Función cohesiva**
Máxima accesibilidad		
	<u>Anáfora morfosintáctica</u>	
	- Nominal:	Coespecificación[4]
	referencia a un nombre referencia a un SN	Sustitución y elipsis nominal
	- Verbal:	
	referencia a un verbo referencia a un SV	Sustitución y elipsis verbal
	- Oracional	Sustitución oracional
	<u>Anáfora semántica</u>	
	- Sinonimia	
	- Hiperonimia	Cohesión léxica
	- Anáfora contextual	
	<u>Anáfora pragmática</u>	
Mínima accesibilidad		

Fig. 1

[4] El término propuesto por Halliday y Hasan es *reference* (referencia) pero preferimos adoptar el término «coespecificación», siguiendo a Carter (1987) para designar este tipo de cohesión, ya que «referencia» es un término que utilizamos en este estudio con un significado diferente (ver apartado 2.2.).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

4. El antecedente y la accesibilidad.

Ariel (1990) define la *accesibilidad* como el factor que permite determinar la facilidad o dificultad con la que se accede al antecedente de una expresión anfórica concreta (14). La accesibilidad de un antecedente corresponde, según Ariel, a diferentes estados en la memoria, «where material may be extremely salient, i.e. highly activated, or, viceversa, unactivated or fading away» (16). El grado de accesibilidad de un antecedente se determina mediante la aplicación de cuatro parámetros básicos: distancia, prominencia, competencia y unidad. Veamos, a continuación, cómo se definen éstos.

4.1. La distancia.

Para medir la distancia que existe entre un antecedente y la expresión anafórica que a él se refiere, tomamos como punto de referencia el número de oraciones que hay desde la expresión anafórica hasta su antecedente[5]. Así, por ejemplo en T2:

T2 *Piggy* could think. *He* could go step by step inside that fat head of his.
(85,19)

la distancia entre la expresión anafórica *he* y su antecedente *Piggy* es de una oración.

[5] Como veremos en el capítulo 5 al hablar de los atributos anafóricos necesarios para la localización de los antecedentes (apartado 5), es necesario incluir en el parámetro de distancia no sólo la distancia oracional sino también la distancia clausal si queremos dar cuenta también de las restricciones que imponen las condiciones de ligamiento sobre el empleo de pronombres en la oración (Chomsky, 1981).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El parámetro de distancia es similar al que Brown (1983) llama *lookback* y que utiliza para contar el número de oraciones que hay desde una expresión anafórica hasta la oración más cercana que contenga un antecedente para esta expresión.

Según el parámetro de distancia, un antecedente será más accesible cuanto menor sea el espacio que lo separa de su expresión anafórica, siendo, entonces, la distancia mínima la propia oración y la distancia máxima la oración en la que comienza el texto.

4.2. La prominencia.

Este parámetro permite distinguir los antecedentes que se encuentran en posición temática de aquéllos que no aparecen en esta posición. Gracias al parámetro de prominencia pueden clasificarse como antecedentes de gran accesibilidad todos aquellos que se encuentren en posición temática. De este modo, un antecedente que muestre un alto grado de prominencia se localizará con más facilidad que otro cuya prominencia sea baja.

A modo de ilustración, examinaremos el ejemplo siguiente:

T3 *Jack* spoke.
'Give me a drink.'
Henry brought him a shell and he drank, watching *Piggy* and *Ralph* over the jagged rim. Power lay in the brown swell of his forearms; authority sat on his shoulder and chattered in his ear like an ape.
(165, 21)

En T3 hay varias entidades discursivas que podrían ser antecedente de *his*, pero sólo una tiene mayor prominencia que las demás, *Jack*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Gracias a este alto grado de prominencia las expresiones anafóricas que se introducen a lo largo del texto identifican *Jack* como antecedente.

4.3. La competencia.

Este parámetro analiza el número de entidades discursivas que compiten por ser antecedente de la expresión anafórica, de manera que cuantas más entidades discursivas aparezcan en el texto, más difícil será localizar el antecedente correcto.

Este problema puede solucionarse si empleamos una expresión anafórica de gran carga léxica que ayude a determinar el antecedente con facilidad. Así ocurre, por ejemplo, en T4:

> T4 *Ralph* dived into the pool. A couple of littuns were playing at the edge, trying to extract comfort from a wetness warmer than blood. *Piggy* took off his glasses, stepped primly into the water and then put them on again. Ralph came to the surface.
> (162, 25)

En este texto, existe competencia entre dos entidades discursivas: *Ralph* y *Piggy*. Si queremos crear una referencia anafórica a una de las dos entidades, no podremos utilizar un pronombre porque entonces la referencia sería ambigua. Por tanto, usaremos el pronombre *Ralph* en la oración *Ralph came to the surfacce*, en lugar del pronombre *he*, que llevaría a confusión.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

4.4. La unidad.

Desde la perspectiva psicolingüística con que este parámetro se ha estudiado normalmente[6], la unidad entre una expresión anafórica y su antecedente depende de que el mismo esté «within vs. without the same frame / world / point of view / segment or paragraph as the anaphor» (Ariel 29). Por tanto, si ambos están en el mismo párrafo consideramos que su grado de unidad es mayor que si están en párrafos diferentes, de modo que su grado de accesibilidad es mayor.

Una vez descritos los cuatro parámetros que intervienen en la asignación del grado de accesibilidad a una expresión anafórica, queda por analizar la influencia que éstos tienen en la elección de una expresión anafórica determinada. Esta influencia puede expresarse del siguiente modo:

1) En aquellos casos en los que el antecedente es muy accesible, es decir, el antecedente es una entidad altamente activada en la memoria, la expresión anafórica que generalmente se emplea es, como podemos ver en la figura 1, una anáfora de tipo morfosintáctico en cualquiera de sus variantes nominal, verbal u oracional. Esto ocurre así porque el antecedente tiene suficiente peso por sí mismo como para que su identificación no sea problemática. En estos casos la expresión anafórica típica es el pronombre, como vimos en T2.

[6] P. Clancy (1980) estudia el efecto que la estructura discursiva tiene en la elección de expresiones anafóricas y referenciales.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En este ejemplo la entidad más accesible es *Piggy* ya que (a) se encuentra a una distancia mínima, (b) es una entidad prominente por estar en posición temática, (c) no tiene competencia de ningún otro antecedente y (d) se encuentra dentro del mismo párrafo que su expresión anafórica.

2) Cuando el antecedente tiene una accesibilidad baja, la expresión anafórica es normalmente de tipo semántico (véase Fig.1), ya que éstas son las expresiones que tienen mayor carga léxica y aportan mayor información sobre el antecedente. Así ocurría, por ejemplo, en T4 con la competencia de dos entidades por una única referencia.

5. El tipo de relación anafórica.

Cornish (1986) toma el discurso como punto de partida para elaborar una tipología de las relaciones anafóricas. Desde esta perspectiva, el único límite que existe a la hora de establecer dichas relaciones es el que marque el propio discurso, con lo cual confirmamos la idea expuesta anteriormente de que la anáfora es un instrumento de cohesión discursiva (135).

Los tipos de anáfora que define Cornish se organizan en función de la relación que puede existir entre el antecedente y la expresión anafórica dentro del discurso. Esta relación puede ser morfosintáctica, semántica o pragmática.

5.1.Anáfora morfosintáctica.

Las tres manifestaciones de la anáfora morfosintáctica son las siguientes: la anáfora nominal, la anáfora verbal y la anáfora oracional.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

a) Anáfora nominal.

La referencia en este caso puede ser tanto a un nombre como a un sintagma nominal y la expresión anafórica mediante la cual se construye esta referencia es un pronombre.

Veamos a continuación dos ejemplos de anáfora nominal, el primero con referencia a un nombre, y el segundo con referencia a un sintagma nominal.

T5 *This cry* was echoed by *another.* (7.8)

T6 *The boy with fair hair* lowered himself down the last few feet of rock... *He* had taken off his school sweater. (7.1)

En ambos ejemplos el pronombre actúa como núcleo del sintagma nominal en el que aparece, sustituyendo en T5 a un nombre (*cry*) y en T6 a todo un sintagma nominal (*the boy with fair hair*).

b) Anáfora verbal.

Este tipo de anáfora se construye en inglés, mediante el llamado «gapping» o eliminación del verbo, así como mediante la utilización de un pro-verbo del tipo «*do*». La anáfora verbal puede referirse bien a un verbo bien a una frase verbal.

En T7 y T8 aparecen ejemplos de referencia a un verbo y a un sintagma verbal respectivamente.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T7 Some of them *must have got out*. They *must have*, mustn't they?.
(8.9)

En T7 la anáfora verbal se construye mediante la construcción *must have*, donde claramente falta el verbo principal. Este verbo es el que aparece en el enunciado que precede a la anáfora, *must have got out* y que constituye su antecedente. Este es un caso de «gapping», donde el verbo principal *got out* no aparece explícito.

T8 Someone's *got to go across the island and tell Piggy we'll be back after dark.*
I'll *do* if you like.
(110.2)

En T8 *do* es la expresión anafórica y su antecedente es la frase verbal «*has got to go across the island and tell Piggy we'll be back after dark.*»

c) Anáfora oracional.

La anáfora oracional se construye mediante una expresión anafórica cuyo antecedente es toda una oración anterior.

T9 "*Aren't there any grown-ups at all?*"
"I don't think *so*."
(8.14)

Con respecto a la relación que existe entre la anáfora morfosintáctica, en sus tres manifestaciones, y el grado de accesibilidad del antecedente (véase apartado 4), podemos afirmar que sólo cuando este último es muy accesible, puede emplearse la anáfora morfosintáctica sin

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

peligro de perder la referencia al antecedente correcto en el discurso.

Universitat d'Alacant
Universidad de Alicante

Supongamos, por ejemplo, que tenemos una oración donde existe un antecedente cuyo grado de accesibilidad es bajo, es decir, que no está en posición temática y donde la competencia con otros antecedentes es elevada. Si utilizáramos una anáfora de tipo morfosintáctico se perdería la referencia. Esto es lo que ocurriría si modificáramos T4 del siguiente modo:

> T4b *Ralph* dived into the pool. A couple of littuns were playing at the edge, trying to extract comfort from a wetness warmer than blood. *Piggy* took off his glasses, stepped primly into the water and then put them on again. *He* came to the surface.

El pronombre *he* cambia la referencia de *Ralhp* a *Piggy* de manera que la identificación del antecedente es errónea con respecto al texto original.

5.2. Anáfora semántica

Existen relaciones anafóricas que sólo pueden explicarse acudiendo a criterios semánticos. Son, según Cornish, las anáforas semánticas. Entre ellas destacamos la sinonimia, la hiperonimia y la anáfora contextual.

a) Sinonimia.

La construcción de relaciones anafóricas a través de la sinonimia es posible cuando existen dos o más equivalentes semánticos que pueden intercambiarse, sin que este cambio introduzca entidades extrañas al lector. El equivalente semántico hace la función de

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

anáfora, mientras que el término sustituido es el antecedente. Los términos empleados para una y otro son, por tanto, totalmente intercambiables.

Mostramos a continuación un ejemplo:

T10 He took off his *glasses* and held them out to Ralph, blinking and smiling, and then started to wipe them against his grubby wind-breaker... He smeared the sweat from his cheeks and quickly adjusted the *spectacles* on his nose.
(9.27)

En T10, los términos *glasses* y *spectacles* son totalmente intercambiables, con lo cual, la utilización de *spectacles* al final del párrafo es natural y no introduce ningún elemento extraño al lector.

b) Hiperonimia.

Al igual que es posible establecer relaciones anafóricas mediante sinónimos, también pueden utilizarse hiperónimos para crear lazos antecedente-anáfora.

T11 'Then I'll give him the *conch*'
'Conch?'
'That's what this *shell*'s called'
(36.22)

En T11 se establece una relación de hiperonimia entre *shell*, definido como *hard outer covering of some animals*, y *conch*, *shellfish with a large spiral shell*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

c) Anáfora contextual.

La anáfora contextual supone el uso de una expresión anafórica que conecta con una idea o un hecho que se infiere de una parte del texto anterior. Este tipo de anáfora muestra uno de los mayores grados de cohesión textual, ya que la relación antecedente-anáfora es muy estrecha y sólo puede comprenderse en el conjunto del contexto.

El antecedente en este tipo de anáfora puede ser una única entidad, implícita o explícita, puede ser también toda una idea evocada por el texto, o surgir de una presuposición. En cualquier caso, sólo a través del conocimiento y comprensión global del texto podemos interpretar la relación anafórica.

Veamos, en primer lugar, un ejemplo en el que se crea una relación anafórica entre elementos que no están explícitos en el texto.

T12 He wiped his *glasses* and adjusted them on his button nose. *The frame* had made a deep, pink «V» on *the bridge.*
(11.12)

En T12, la interpretación de la referencia anafórica de *the frame*, y *the bridge*, exige que el lector conozca las partes que componen unas gafas. Sólo si sabemos que las gafas tienen montura (*frame*) y caballete (*bridge*), podemos inferir correctamente que los elementos que componen la expresión anafórica tienen como antecedente *glasses*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los ejemplos que mostramos a continuación construyen la referencia anafórica tomando como antecedente no una única entidad, sino toda una idea evocada por el texto.

T13 *I expect we'll want to know all their names*, said the fat boy, *and make a list. We ought to have a meeting.*
Ralph did not take *the hint* so the fat boy was forced to continue.
(11.22)

En T13 la expresión anafórica es *the hint*, que tiene como antecedente toda la frase anterior *I expect we'll want to know their names, and make a list. We ought to have a meeting.* Es el propio contexto el que fuerza esta interpretación anafórica ya que fuera de él no existiría ninguna relación entre ambos.

Algo similar ocurre en T14.

T14 'Piggy'
Piggy grinned reluctantly, pleased despite himself at even *this much recognition.*
(12.12)

En este ejemplo, la relación entre *Piggy* y *this much recognition* sólo puede entenderse si previamente el autor nos ha indicado que únicamente los amigos de Piggy le llaman así. Es ésta, por tanto, una señal de acercamiento. El antecedente de *This much recognition* no es el enunciado *Piggy*, sino lo que éste presupone, la señal de acercamiento.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Veamos, por último, otro ejemplo de anáfora contextual, donde el antecedente es un elemento explícito en el discurso y la expresión anafórica introduce más información acerca del antecedente.

T15 There are *pigs* on the island.
All three of them tried to convey the sense of *the pink live thing struggling in the creepers.*
(36.1)

La referencia anafórica a *pigs* aporta información acumulada a lo largo del texto. En pasajes anteriores los tres niños se habían enfrentado a unos cerdos y los habían visto luchar entre las lianas. Ahora es posible referirse a ellos ampliando en la expresión anafórica la información que da el antecedente.

Con respecto a la relación que existe entre el grado de accesibilidad del antecedente y la anáfora de tipo semántico, comprobamos que ante antecedentes poco accesibles, la expresión anafórica preferida es la citada anáfora semántica. En efecto, los antecedentes de los ejemplos propuestos no están siempre explícitos en el discurso y, por tanto, son antecedentes muy poco accesibles.

Como hemos visto, sólo podemos recuperar la referencia a un antecedente de estas características mediante el empleo de una anáfora semántica. Desde el punto de vista de la cohesión textual este tipo de anáfora exige para su comprensión un alto grado de cohesión y coherencia discursivas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5.3.Anáfora pragmática

Universitat d'Alacant
Universidad de Alicante

En este tipo de anáfora, la relación antecedente-anáfora no depende de factores contextuales, sino que, independientemente del contexto, el lector es capaz de identificar el antecedente de la anáfora. Esto es posible gracias al conocimiento pragmático presupuesto por el discurso.

Algunos ejemplos aparecen en T16 y T17:

T16 *'Whee-oh'*
'Wacco!'
'Bong!'
'Doink'
...The shouting died down

T17 *'It's like in a book'*
'Treasure Island -
'Swallows and Amazons -
'Coral Islands -

En los ejemplos anteriores, se hace imprescindible poseer el conocimiento pragmático que ayuda a interpretar la interjecciones de T16 como gritos (*shouting*) y los títulos en T17 como libros (*book*). Si el conocimiento del mundo no incluyera los títulos de T17 como libros, la referencia anafórica se perdería.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

6. Función cohesiva de las diferentes relaciones anafóricas.

Universitat d'Alacant
Universidad de Alicante

Halliday y Hasan (1976) proponen una clasificación de los fenómenos anafóricos que nos sirve para descubrir la función cohesiva que tienen los diferentes tipos de relaciones anafóricas. Ya apuntamos en el apartado 2.1 que la anáfora que nos interesa es la que amplía su campo de referencia a todo el discurso, sin restringirse al marco de la oración. Mostramos también entonces cómo la anáfora es un instrumento lingüístico que contribuye a mantener el discurso como una unidad de sentido completa gracias a la creación de vínculos de unión entre diferentes partes del texto. En este sentido precisamente cobra mayor importancia el estudio de la función cohesiva de las relaciones anafóricas.

Halliday y Hasan distinguen cinco tipos de cohesión: la co-especificación, la sustitución, la elipsis, la cohesión léxica y la conjunción.

6.1. La coespecificación.

La construcción de la cohesión discursiva mediante la coespecificación supone la utilización de determinadas expresiones que mantienen una relación de identidad con otras expresiones previamente introducidas en el discurso.

Tal como afirman Halliday y Hasan, la coespecificación «lies in the continuity of reference, whereby the same thing enters into the discourse a second time» (31). Este tipo de cohesión es el que se da en la anáfora morfosintáctica (apartado 5.1), donde una pro-forma con poca carga léxica debe tomar su significado del antecedente con el cual coespecifica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La coespecificación puede manifestarse de tres formas:

a) Coespecificación personal.
Se construye mediante el uso de pronombres personales, reflexivos y posesivos. Supone identidad entre el antecedente y la expresión anafórica.

T18 *Piggy* hauled *himself* up.
(15.20)

En este ejemplo el pronombre reflexivo *himself* mantiene una relación de identidad con su antecedente *Piggy*.

b) Coespecificación demostrativa.
Se construye mediante el uso de los demostrativos *this, that, these y those*, los adverbios *here, there* y *then*. En este caso se identifican el antecedente y la expresión anafórica dentro de una escala de proximidad, donde lo más próximo es *this* y lo más lejano es *that*[7].

Halliday y Hasan incluyen el artículo *the* dentro de la coespecificación demostrativa aunque nosotros lo discutiremos dentro de la cohesión léxica ya que normalmente introduce un sintagma nominal cuyo núcleo mantiene con su antecedente una relación de tipo semántico más que morfosintáctico.

[7] La escala de proximidad sobre la que ordenan *this* y *that* engloba aspectos temporales y espaciales, así como el grado de proximidad con el hablante y el interlocutor (Joly, 1989).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

c) Coespecificación comparativa.

Se construye mediante el uso de adjetivos y adverbios como *same, identical, such....*

Con respecto a la relación que existe entre la coespecificación como mecanismo de cohesión y los tipos de anáfora definidos por Cornish vemos que sólo la anáfora morfosintáctica cumple la función cohesiva de coespecificación porque se construye mediante pro-formas que toman su especificación del antecedente.

6.2. La sustitución y la elipsis.

La sustitución como mecanismo de cohesión consiste en reemplazar una palabra por otra dentro de una relación que se mantiene en el nivel gramatical. En la sustitución, la palabra sustituida tiene la misma función gramatical que la palabra a la cual sustituye. Las diferentes clases de sustitución se definen por tipos gramaticales, de manera que existen tres tipos de sustitución: la sustitución nominal, la verbal y la clausal.

En la tipología de Cornish, estas tres clases corresponden a la anáfora morfosintáctica nominal, verbal y clausal.

Con respecto a la elipsis como mecanismo cohesión podemos afirmar que ésta se encuentra próxima a la sustitución ya que se trata de «substitution by zero» (Halliday y Hasan: 142).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

6.3. La cohesión léxica.

Este tipo de cohesión se construye mediante la selección léxica de determinadas palabras que mantienen entre sí algún tipo de relación semántica. Corresponde, en la terminología de Cornish, a la anáfora semántica. Normalmente se introduce el artículo *the* para construir un sintagma nominal, de modo que la estructura *the + nombre* constituye la expresión anafórica. Una alternativa al artículo son los demostrativos.

6.4. La conjunción.

Halliday y Hasan definen la conjunción como «a specification of the way in which what is to follow is systematically connected to what has gone before» (226). La conjunción es un mecanismo cohesivo que no puede definirse como anafórico ya que, a diferencia de lo que ocurre con la coespecificación, la sustitución, la elipsis y la cohesión léxica, los vínculos que crea la conjunción no son vínculos de referencia entre un antecedente y una expresión anafórica, sino que construye una relación de tipo estructural entre varios elementos lingüísticos. Tomemos, por ejemplo, el siguiente texto:

> T19 He was searching his mind for simple words so that even the littluns would understand what the assembly was about. *Later* perhaps, practised debaters would use their whole art to twist the meeting: *but* now the subject of the debate must be laid out clearly.
> (86,14)

En este ejemplo la función cohesiva que cumplen *later* y *but* es la de conectar un enunciado con otro, pero no puede hablarse de relación

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

anafórica en el sentido definido en nuestro estudio.

Universitat d'Alacant
Universidad de Alicante

7. Expresiones anafóricas tratadas en presente investigación.

Las relaciones anafóricas analizaremos son aquellas que se sitúan en los dos extremos de la escala de accesibilidad (ver Fig.1), es decir, la anáfora morfosintáctica en su variante nominal y la anáfora semántica. La anáfora que Cornish denomina pragmática queda excluida de este estudio porque, tal como apuntamos en el apartado 2.3, necesitamos analizar relaciones anafóricas que sean calculables en los términos definidos en esta investigación. La anáfora pragmática, por otra parte, necesita para la localización de su antecedente que se construya una representación del mundo y este tipo de representación queda fuera de nuestros objetivos.

Así pues, las relaciones anafóricas que estudiamos son las siguientes:

a) Descripción definida: denominamos así a la anáfora semántica construida mediante un sintagma nominal introducido por el artículo *the*.

T20 "Let him have *the conch*".
At last Ralph induced him to hold *the shell*. (39.4)

b) Descripción con demostrativo: recibe este nombre la anáfora semántica construida mediante un sintagma nominal introducido por un demostrativo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T21 ...a great platform of pink granite thrust up uncompromisingly through the forest... Ralph hauled himself on to *this platform*.
(12,21)

c) Anáfora morfosintáctica construida mediante el uso de pronombres personales.

T22 The twins stood with the pig... *They* seemed to share one wide, ecstatic grin.
(75,16)

d) Anáfora morfosintáctica construida mediante el uso de pronombres posesivos.

Como veremos en el capítulo cuarto, estos tipos de anáfora serán objeto de un estudio exhaustivo dentro de un corpus de textos con el objeto de (a) determinar las fuentes de información lingüística que intervienen en la creación de relaciones anafóricas y (b) crear patrones de comportamiento de las relaciones anafóricas para poder construir una estrategia de identificación de antecedentes utilizando un modelo vectorial como el descrito en el capítulo 5.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

8. Conclusiones.

Hemos podido comprobar a lo largo de este capítulo que la anáfora, considerada como elemento discursivo, adquiere una complejidad aún mayor si cabe que la que muestran los estudios de sintaxis. Los aspectos que deben tenerse en cuenta para explicar la anáfora discursiva engloban, como hemos visto, desde la morfosintaxis hasta la pragmática. Así mismo, es necesario describir el papel que desempeña el antecedente en la selección de las expresiones anafóricas según el grado de accesibilidad que aquél tenga en el discurso. Por último, no debe olvidarse que la anáfora es también un mecanismo de cohesión textual y como tal cumple diferentes funciones en sus distintas manifestaciones. Todos estos aspectos de la anáfora han sido expuestos en este capítulo y han contribuido a sentar las bases teóricas sobre las que construímos nuestra investigación.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 3.
Anáfora y Lingüística Computacional.

1. Introducción.

Indicamos en el capítulo primero que el enfoque general de nuestra investigación es básicamente computacional, esto es, que asumimos una orientación informática en el planteamiento del problema, el desarrollo del trabajo y la propuesta de soluciones. Recordemos, asimismo, que el objetivo central de la presente tesis es facilitar un tratamiento automático de la identificación de antecedentes anafóricos.

Consecuentemente, antes de acometer la tarea que nos hemos propuesto, debemos examinar con una visión crítica los modelos, sistemas y algoritmos que la lingüística computacional ha producido, a fin de obtener una perspectiva global que siente las bases del presente trabajo.

Así pues, analizaremos en este capítulo las principales aproximaciones computacionales al problema de la anáfora. En este sentido, estudiaremos, en primer lugar, los enfoques denominados «tradicionales», esto es, aquellos desarrollados durante los primeros años de la lingüística computacional. Estos modelos han sido bautizados como «tradicionales» por autores como Hirst (1981) para aludir al hecho de que pertenecen a una primera generación de investigaciones en el tratamiento

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

del lenguaje natural y, por tanto, no hacen uso de ninguna de las técnicas informáticas o las teorías lingüísticas desarrolladas en los últimos años.

En segundo lugar, centraremos nuestra atención en el examen de los modelos computacionales más recientes ya que consideramos que incorporan técnicas de identificación de antecedentes que serán de gran ayuda para el desarrollo del presente trabajo de investigación.

Dividiremos, a su vez, los modelos de este segundo grupo en dos tipos, utilizando para ello las propuestas de Carter (1990). Este autor clasifica las aproximaciones computacionales al problema de la anáfora en función del enfoque que adoptan. Así, define dos tipos de enfoque: (a) el enfoque «democrático» (*democratic*) y (b) el enfoque «consultivo» (*consultative*).

Como podremos comprobar más tarde, en las aproximaciones de tipo «democrático» todas la fuentes de conocimiento tienen asignado el mismo papel en la selección del antecedente anafórico, es decir, que aquellas unidades lingüísticas o entidades conceptuales que pueden ser susceptibles de convertirse en antecedente pueden surgir, por igual, de aportaciones de la información morfológica, de la información sintáctica, de la información semántica o de la información pragmática.

Con respecto a las aproximaciones de tipo «consultivo», veremos que únicamente una fuente de información está capacitada para proponer antecedentes y que la función del resto de fuentes de información es confirmar o rechazar los antecedentes propuestos. Se trata, por tanto, de un enfoque basado en la consulta a varias fuentes de conocimiento con el

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

fin de ratificar la selección que ha propuesto con anterioridad otra fuente de información.

Universitat d'Alacant
Universidad de Alicante

2. Aproximaciones «tradicionales».

A la vista de las investigaciones llevadas a cabo en el tratamiento automático del lenguaje natural a lo largo de la última década, no es difícil aceptar la denominación de «tradicional» referida a las primeras aproximaciones computacionales realizadas en torno a de los años sesenta y setenta. En el caso del tratamiento automático de la anáfora, como en muchos otros problemas lingüísticos, el hecho de que las técnicas computacionales fueran todavía limitadas condiciona, en gran medida, el tipo de acercamiento que se desarrolla.

En efecto, los primeros sistemas y algoritmos construidos para la identificación de antecedentes aprovecharon al máximo el potencial informático y teórico de que disponían pero aún así hay ciertas limitaciones que es necesario reconocer. En primer lugar, restringen la búsqueda de antecedentes al conjunto de entidades explícitamente mencionadas en el texto, con lo cual no tratan los antecedentes que surgen por referencia implícita. En segundo lugar, los métodos que emplean tienden a centrar la búsqueda de posibles antecedentes a aquellos encontrados dentro de la misma oración.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para ilustrar la importancia del tratamiento de ambos aspectos, supongamos, por ejemplo, que debemos encontrar el antecedente a la expresión *este problema* en el siguiente texto:

T1 Susana tuvo anoche una pelea con Pilar por el asunto del coche.
Este problema se complica cada vez más.

Como puede comprobarse, el empleo de la expresión *una pelea* introduce en el discurso la posibilidad implícita de que exista un problema entre Susana y Pilar. Pues bien, si queremos identificar correctamente el antecedente de *este problema* en la segunda parte del texto, debemos tener en cuenta esta posibilidad de referencia implícita ya que, de otro modo, la localización del antecedente no puede efectuarse. Así ocurre, por ejemplo, si modificamos T1 para convertirlo en T2:

T2 Susana estuvo anoche hablando con su madre.
Este problema se complica cada vez más.

En T2, a diferencia de lo que ocurre en T1, no existe ningún antecedente posible para la expresión *este problema* porque la oración anterior no introduce ninguna entidad que pueda asociarse con un problema. Para comprender la referencia de *este problema* sería necesario suponer que para Susana constituye un problema el hablar con su madre. Sin embargo, no se ofrecen datos en el texto que permitan deducir esta referencia implícita por lo cual la interpretación de la expresión anafórica se pierde.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

A modo de conclusión podemos afirmar, entonces, que los enfoques de corte «tradicional» ofrecen soluciones parciales al problema de la identificación de antecedentes ya que hay gran número de casos que no pueden tratar.

Entre las aproximaciones que responden a las características aquí esbozadas centraremos nuestra atención en las siguientes: el programa ELIZA, construido por Weizenbaum a mediados de los años 60; SHRDLU, sistema desarrollado por Winograd en 1972; LSNLIS (Lunar Sciences Natural Language Information System) construido por Woods, Kaplan y Nash-Webber en 1972 y conocido también como LUNAR; el sistema creado por Charniak en 1972; el sistema de traducción construido por Wilks en 1975; y el algoritmo desarrollado por Hobbs en 1976.

2.1. ELIZA.

Este es uno de los primeros programas escritos para simular el comportamiento humano y quizá uno de los más conocidos. ELIZA, creado por Weizenbaum, es capaz de imitar a un psiquiatra que dialoga con su paciente. En efecto, la principal característica que define ELIZA es la asombrosa forma en que imita una conversación con un psiquiatra, y ésta parece tan real que el usuario se ve envuelto rápidamente en un diálogo con la máquina, que le responde con aparente naturalidad y precisión. Veamos, a continuación, un ejemplo del tipo de conversación que podemos tener con ELIZA.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Usuario: Men are all alike.
Eliza: In what way.
Usuario: They are always bugging us about something or other.
Eliza: Can you think of a specific example?
Usuario: Well, my boyfriend made me come here.
Eliza: Your boyfriend made you come here.
Usuario: He says I'm depressed much of the time.
Eliza: I'm sorry to hear you are depressed.
Usuario: It's true, I am unhappy.
Eliza: Do you think coming here will help you not to be unhappy?
(Allen, 1987: 3)

El realismo que ELIZA consigue es tal que el interlocutor cree que está dialogando con un ser inteligente puesto que no descubre ninguna reacción errónea e incluso llega a pensar que el programa comprende sus problemas y quiere ayudarle. Sin embargo, el programa no contiene ningún módulo ni rutina que sea capaz de entender de manera inteligente lo que el usuario dice, únicamente aparenta comprenderlo.

La técnica sobre la que se construye ELIZA es simple, consiste en el emparejado de estructuras o *pattern-matching*. Según esta técnica, una cadena de símbolos se reconoce como una estructura siempre que exista en el programa otra estructura similar que marca la pauta para su análisis. Por ejemplo, si queremos que la cadena *men are all alike* sea aceptada, necesitamos un patrón parecido que pueda emparejarse con la cadena, esto es, que contenga algunas de las siguientes palabras: *men*, o *are*, *all*, *alike*. Una vez que la cadena está emparejada, el programa podrá activar las rutinas necesarias para generar sus respuestas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Con el fin de ilustrar el funcionamiento de ELIZA mostramos dos rutinas del programa:

Universitat d'Alacant
Universidad de Alicante

Patrón	Respuesta
?X are you ?Y	Would you prefer if I weren't ?Y?
?X are ?Y	What if they were not ?Y?

De acuerdo con estas reglas, si el usuario le dice a ELIZA *men are all alike*, el programa emparejará este enunciado con el patrón *?X are ?Y* y contestará *What if they were not all alike?*

Por lo que respecta al tratamiento de las relaciones anafóricas, ELIZA sólo contiene unas pocas reglas para construir algunas referencias a lo largo del diálogo. En los experimentos que hemos realizado con el programa hemos podido comprobar que las únicas ocasiones en que utiliza una anáfora son las siguientes:

a) Cuando el usuario utilliza los pronombres *you* o *I*. Al contestar, ELIZA emplea el pronombre *I* o *you*, respectivamente.

b) Cuando el usuario utiliza una cadena que empareja con el patrón *?X are ?Y*. En su contestación ELIZA sustituye *X* por *they*. Sin embargo si *X* es algún miembro de la familia, por ejemplo, *my brother*, el programa utilizará el patrón que identifica a este miembro con el rasgo «familia» y generará la respuesta *Tell me more about your family*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para concluir diremos que ELIZA es un experimento muy interesante ya que consigue crear la ilusión de ser una máquina inteligente, pero que para el problema que nos ocupa, esto es, las relaciones anafóricas, los datos que puede ofrecer son mínimos.

2.2. SHRDLU.

SHRDLU es un sistema interactivo, construido por T. Winograd en 1972, que permite al usuario entablar un diálogo con el ordenador para obtener información acerca de determinadas cuestiones (*Question Answering System*). Los diálogos que el usuario puede mantener con el programa SHRDLU giran en torno a un campo temático concreto: el mundo de las figuras geométricas y las posiciones, formas y colores que éstas pueden tomar.

En efecto, Winograd construyó en SHRDLU un universo móvil de formas geométricas (pirámides, bloques, cajas...) que el usuario puede manipular a su antojo. Así, por ejemplo, el programa acepta instrucciones para mover una pirámide grande de color rojo y colocarla sobre un bloque pequeño verde. A cada nueva orden, SHRDLU muestra en la pantalla una imagen gráfica del estado de cosas.

Junto a la facultad de aceptar instrucciones y de ejecutarlas, SHRDLU es capaz también de contestar a preguntas formuladas por el usuario acerca del universo geométrico que construye, preguntas que pueden llegar a ser tan complejas como la que se muestra a continuación:

T3 Is there anything which is bigger than every pyramid
but is not as wide as the thing that supports it?

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Como puede suponerse, SHRDLU marcó toda una época en el tratamiento automático del lenguaje natural ya que gracias a este sistema, los científicos pudieron demostrar que era realmente posible crear programas informáticos que comprendiesen y simulasen la comunicación humana. En este sentido, este sistema mostró que podía construirse una aplicación informática que interpretase correctamente preguntas, órdenes y explicaciones, que aprendiese nuevos conceptos y, lo más importante, que fuera capaz de aplicar razonamientos para crear inferencias.

Con respecto a su diseño, no entraremos aquí en la descripción detallada de los módulos que componen el programa, baste decir que éstos son básicamente tres: un analizador sintáctico o *parser*, un analizador semántico y un módulo que incorpora técnicas de razonamiento que permite resolver las cuestiones más complejas[1].

Dedicaremos mayor atención, no obstante, al tipo de tratamiento que SHRDLU hace de las relaciones anafóricas. El método empleado para identificar antecedentes se basa principalmente en la heurística, esto es, utiliza razonamiento inductivo sobre ejemplos encontrados anteriormente para resolver los casos de anáfora que se plantean. Durante el procesamiento de cada una de las órdenes que recibe del usuario, SHRDLU va almacenando en un «pila» (*stack*) todos los grupos nominales que encuentra. Cuando aparece en el diálogo una referencia anafórica que debe resolver, considera como posibles antecedentes los grupos nominales almacenados en esta pila y trata de localizar el antecedente correcto

[1] El lector interesado en el estudio de los módulos que componen SHRDLU encontrará una aproximación introductoria en Tennant (1981) y un análisis más profundo en Winograd (1986).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

aplicando, como hemos apuntado, métodos heurísticos.

Universitat d'Alacant
Universidad de Alicante

De este modo, al recorrer la pila de posibles candidatos en busca del antecedente, SHRDLU comprueba la posibilidad de referencia basándose en las características sintácticas y semánticas exigidas por la expresión anafórica. Así pues, no selecciona como válido el primer antecedente que encuentra sino que comprueba todas las posibilidades y determina la más probable en función de los casos anteriormente resueltos.

Mediante la aplicación de este método, SHRDLU consigue tratar correctamente relaciones anafóricas en las que la anáfora es parte de su propio antecedente:

T4 A block which is bigger than anything which supports *it*.

También consigue asignar una relación anafórica entre dos pronombres idénticos que aparezcan en la misma oración o en oraciones consecutivas:

T5 Put the green box on the table. When *it* is there, stack up a pyramid on top of *it*.

Es capaz, asimismo, de encontrar el antecedente a preguntas del tipo:

T6 Why did you do *it*?

que hacen referencia directa a una acción realizada anteriormente.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2.3. LSNLIS.

El sistema LSNLIS (*Lunar Sciences Natural Language Information System*), más conocido como LUNAR, fue desarrollado en 1972 por el equipo investigador compuesto por W. Woods, R. Kaplan y B. Nash-Webber con el fin de construir un interface en lenguaje natural para una base de datos que contenía datos mineralógicos de las piedras traídas de la luna por la expedición Apolo-11.

LUNAR responde a las preguntas y órdenes del usuario sobre la composición química de las muestras lunares y ofrece listados, resultados de análisis y grupos de muestras seleccionados. Reproducimos, a continuación, algunas de las preguntas más típicas:

T7 What is the average modal plagioclase concentration for lunar samples that contain rubidium?.

T8 Do any breccias contain aluminium?.

Existen en LUNAR tres componentes básicos que procesan el lenguaje natural. Estos tres módulos son: un analizador sintáctico, un módulo de interpretación semántica y un último módulo encargado de la gestión de la base de datos. Los dos primeros componentes se utilizan para la comprensión de las preguntas y órdenes del usuario, mientras que el tercer componente ejecuta las órdenes en la base de datos.

Con respecto al tratamiento de las relaciones anafóricas, LUNAR procede del siguiente modo: cada vez que aparece una entidad en el discurso, LUNAR la archiva en el directorio discursivo (*discourse*

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

directory); las entidades archivadas en este directorio se codifican junto a sus respectivas representaciones sintácticas y sus interpretaciones semánticas, de manera que toda esta información esté disponible cuando sea necesario. Así pues, cada vez que LUNAR encuentra una expresión anafórica se lleva a cabo una búsqueda en el directorio discursivo con el fin de encontrar el antecedente correcto.

Para poder decidir si un antecedente corresponde a una determinada expresión anafórica, LUNAR emplea diferentes tipos de reglas. En este sentido, el tipo de regla que se aplica depende del tipo de anáfora que deba resolverse. Los tipos de anáfora que distingue LUNAR son dos: anáfora parcial y anáfora completa.

La anáfora parcial se caracteriza por el empleo de un pronombre que se refiere a una parte de un sintagma nominal aparecido con anteriodad. Así, por ejemplo, en el texto que mostramos a continuación, el pronombre *them* tiene como antecedente *all analyses of sample 10046*, esto es, una parte del sintagma nominal completo *all analyses for sample 10046 for hydrogen*:

T9 a Give me all analyses of sample 10046 for hydrogen.

T9 b Give me *them* for oxygen.

Para encontrar el antecedente correcto a las anáforas parciales, LUNAR efectúa una búsqueda entre todos los grupos nominales que han sido mencionados anteriormente, e intenta localizar aquél que tenga una estructura sintáctica y semántica paralela a la expresión anafórica empleada. Esto es lo que ocurre en casos como el siguiente:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T10 a What is the silicon content of each volcanic sample ?

T10 b What is *its* magnesium concentration?

El segundo tipo de anáfora que reconoce LUNAR, las anáforas completas, reciben un tratamiento diferente. En estos casos la estrategia empleada depende de si la anáfora se construye mediante demostrativo o mediante un pronombre. Cuando se emplea el primer tipo, es decir, si la expresión anafórica la constituye un sintagma nominal introducido por un demostrativo, el método aplicado consiste en buscar un sintagma nominal cuyo nombre sea el mismo que acompaña al demostrativo. Para ilustrar este tipo de búsqueda mostramos el siguiente texto:

T11 a Do any breccias contain aluminium?.

T11 b What are *those breccias*?.

Como vemos, en la segunda oración aparece el sintagma nominal *those breccias* que construye una relación anafórica con el nombre *breccias* de la oración anterior.

En el caso de que la anáfora se construya mediante un pronombre, la estrategia seguida consiste en utilizar la información semántica codificada en las reglas del sistema. Así, por ejemplo, si queremos localizar el antecedente del pronombre *them* en T12a y T12b, necesitaremos que el módulo semántico de LUNAR encuentre un antecedente cuyos rasgos semánticos respondan a los requisitos semánticos de la regla BE IN.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T12 a How much titanium is in type B rocks?

T12 b How much silicon is in *them*?

En T12b aparece la construcción *is in* que LUNAR identifica mediante la regla BE IN. Esta regla establece que los rasgos semánticos del complemento deben responder a la definición de SAMPLE. Entre los posibles antecedentes, sólo el grupo nominal *type B rocks* contiene estos rasgos semánticos.

2.4. Charniak.

El sistema desarrollado por Charniak (1972) tiene como objetivo principal estudiar el tipo de inferencias sobre el mundo real que son necesarias para hacer comprender al ordenador pequeñas historias, contestar a preguntas sobre estas historias y resolver problemas de ambigüedad anafórica. Así, por ejemplo, ante una historia como la que mostramos a continuación, el sistema diseñado por Charniak es capaz de hacer razonamientos y contestar a las cuestiones que le son planteadas:

T13 Janet needed some money. She got her piggybank (PB) and started to shake it. Finally some money came out.

Con relación al tipo de razonamientos que el sistema es capaz de resolver, presentamos las siguientes preguntas a modo de ilustración:

T14 Why did Janet get the PB?

T15 Did Janet get the money?

T16 Why was the PB shaken?

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para poder realizar inferencias y razonamientos, el sistema emplea un método esencialmente heurístico. La estrategia se basa en la aplicación de los llamados *demons* o rutinas que codifican hechos sobre el mundo, que deben ser satisfechos para llegar a la comprensión del texto. Estos *demons* se van activando a medida que se va procesando la historia y van apareciendo conceptos nuevos. Así, por ejemplo, si la historia que se va a procesar es la siguiente:

T17 One afternoon Jack was outside playing ball with Bill. Bill looked up and noticed that the sky was getting dark. 'I think we should stop' said Bill. 'We will get wet if we keep playing.'

el sistema necesita una regla del tipo:

If 'it is (or will be) raining' and
if 'person P is outside'
then 'P will get wet'

para poder comprender la historia. Así pues, una vez localizada esta regla o *demon*, el sistema intentará establecer las conexiones necesarias entre los hechos que ocurren en la historia para poder interpretarla y obtener las inferencias adecuadas.

Además de la comprensión de historias y razonamientos que hemos mencionado antes, el sistema puede también resolver casos de ambigüedad entre varios antecedentes de una expresión anafórica. La estrategia que se sigue para identificar el antecedente correcto podría resumirse del siguiente modo: en primer lugar, construye una lista de posibles antecedentes de la expresión anafórica; a continuación, si se comprueba que esta lista contiene un único candidato, éste se acepta como

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

antecedente; en el caso de que la lista contenga más de un posible antecedente, entonces la expresión anafórica se representa como una variable y se aplican diferentes *demons* con esta variable a la lista de antecedentes; finalmente, la variable que representa a la expresión anafórica quedará ligada a aquel antecedente que sea válido para el *demon* que contiene la variable.

Supongamos, por ejemplo, que nos encontramos con un texto como el siguiente:

T18 Janet put some money on the sink. Mother said, 'If you leave the money there *it* may fall in the drain. Let's find your piggybank.'

Para encontrar el antecedente del pronombre *it*, el sistema consulta la lista de posibles antecedentes. En esta lista aparecen los candidatos *money* y *sink*. Estamos, por tanto, ante un caso de posible ambigüedad. El modo de decidir entre ambos candidatos es, como hemos apuntado, convertir la expresión anafórica en una variable e incluirla dentro del *demon* que represente la información *it may fall in the drain*. Este *demon* se aplica a los dos candidatos y obtenemos, así, una interpretación para *money*: «*some money* may fall in the drain»; y otra para *the sink*: «*the sink* may fall in the drain». Como es evidente, únicamente es correcta la interpretación de *money*.

Las desventajas de un tratamiento como el que propone Charniak se centran fundamentalmente en el hecho de que a la hora de aplicar varios *demons* para resolver una relación anafórica siempre tiene preferencia aquel que se haya empleado antes. Normalmente este tipo de

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

tratamiento no produce resultados correctos.

Universitat d'Alacant
Universidad de Alicante

2.5. Wilks.

Y. Wilks (1975) construye un sistema de traducción del inglés al francés en el que implementa su teoría de la semántica de preferencias (*preference semantics*). Como mostraremos a continuación, esta teoría utiliza primitivos y patrones semánticos para interpretar las palabras en sus contextos.

La teoría de las preferencias semánticas tiene su punto de partida en la concepción del texto como un conjunto de bloques semánticos (*semantic blocks*). De este modo, el texto se convierte en una unidad semántica que no necesita la sintaxis para su análisis.

Cada bloque semántico o texto está compuesto por plantillas (*templates*), las cuales se unen mediante patrones (*paraplates*) y reglas de inferencia de sentido común (*common sense inference rules*). El vínculo de unión entre estos tres elementos lo constituyen las fórmulas.

A fin de delimitar con claridad suficiente el significado de los constituyentes del bloque semántico, veamos una a una sus definiciones y algunos ejemplos:

a) Elementos: son aproximadamente 70 primitivos semánticos que se emplean para expresar entidades, estados, cualidades y acciones, así como para construir fórmulas. Algunos ejemplos de elementos son los siguientes:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El elemento MAN representa al ser humano.
El elemento THING representa a los objetos.
El elemento STUFF representa a las sustancias.

Los elementos se emplean en la construcción de fórmulas.

b) Fórmulas: son construcciones que expresan el significado de las palabras. Por ejemplo, la fórmula

(FLOW STUFF)

expresa la idea de líquido.

c) Plantillas: son un conjunto de fórmulas que se conectan mediante secuencias del tipo AGENT, ACTION, OBJECT. Un ejemplo de plantilla sería:

KIND MAN HOW CAUSE KIND MAN

aplicado a la oración:

small men sometimes father big sons

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

d) Patrones: son estructuras que se utilizan para unir dos plantillas y así codificar información sobre las preposiciones y las conjunciones.

Una vez esbozados los principales puntos que constituyen la base de la teoría de las preferencias semánticas, centraremos nuestra atención en el modo en que el sistema desarrollado por Y. Wilks consigue identificar las relaciones anafóricas.

En este sentido, la localización de antecedentes se lleva a cabo mediante tres mecanismos diferentes:

1) Aplicación de las plantillas y patrones. Por este método se resuelven refencias como la que se cita a continuación:

T19 Give the bananas to the monkeys although *they* are not ripe, because *they* are very hungry.

Para identificar los antecedentes correspondientes al primer y segundo *they*, basta con explorar las fórmulas de los adjetivo *ripe* y *hungry* y comprobar que el primero se aplica a entidades del reino vegetal, mientras que el segundo necesita entidades animadas. Así, se identifican correctamente los antecedentes.

2) *Extracción*. Cuando las plantillas y los patrones son insuficientes para localizar el antecedente correcto se utiliza un mecanismo que Wilks denomina *extracción*. Este método consiste en la construcción de nuevas plantillas semánticas que de alguna manera están implícitas en las plantillas que ya existen. Por ejemplo, en la oración

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

siguiente:

T20 John drank the whisky from a glass, and *it* felt warm in his stomach.

Para identificar *whisky* como antecedente de *it*, Wilks propone que se extraiga de la fórmula que representa a *drink* las inferencias de que existe una sustancia líquida que se encuentra dentro de una entidad animada y, por tanto, es necesario localizar esta sustancia líquida (*whisky*) y esta entidad animada (*John*).

3) *Common Sense Inference Rules* (reglas de inferencia de sentido común). Este tercer mecanismo de resolución anafórica se aplica cuando ninguno de los métodos anteriores consigue localizar el antecedente. Supone el empleo de reglas de inferencia sobre el mundo real que van más allá de las definiciones y significados codificados en las fórmulas.

Las reglas de inferencia se utilizan en casos como el que mostramos a continuación:

T21 John left the window open and drank the wine on the table. *It* was good.

La regla que se aplica sería la siguiente: «if an animate being causes a real object to move into him/her/irself, then that animate being may judge that real object» (Carter, 1987: 169), y así llegar a identificar *wine* como antecedente de *it*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Wilks apunta, por último, que en el caso de que ninguno de los tres métodos descritos consiga identificar el antecedente, entonces es necesario seleccionar el antecedente por defecto, lo cual, en palabras de Wilks, equivale a suponer que todavía se está hablando de lo mismo que se había hablado hasta ese momento (Wilks, 1986). Esta presuposición es similar al concepto de foco del discurso o entidad focalizada que veremos en el apartado 4, pero Wilks no llega a profundizar en este aspecto dentro de su teoría. Para autores como Hirst (1981) el hecho de que el concepto de foco discursivo no haya sido desarrollado con mayor amplitud constituye una carencia importante, ya que es fuente de errores en la selección de antecedentes.

2.6. Hobbs.

A diferencia de los autores examinados hasta ahora, Hobbs (1976) no construye un sistema con una aplicación práctica específica, sino que desarrolla un algoritmo, es decir, una serie de pasos que deben seguirse para poder encontrar los antecedentes correctos a un pronombre. A este respecto, Hobbs propone como solución al problema de la identificación de antecedentes un algoritmo basado en un enfoque sintáctico.

Este enfoque sintáctico consiste en recorrer el árbol que representa la estructura de superficie de una oración y buscar a lo largo del mismo los sintagmas nominales que por su concordancia de género y número puedan ser antecedentes. Una vez que se encuentra el primer sintagma nominal que cumple estos requisitos, éste se acepta como antecedente. Puede pensarse que este es un algoritmo bastante simple pero las pruebas

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

realizadas muestran que funciona en gran número de casos[2].

El orden que sigue el algoritmo para atraversar el árbol sintáctico analiza, en primer lugar, la última oración que aparece en el texto y, una vez que está dentro de ella, recorre el árbol de izquierda a derecha y examina primero los nodos que están a un mismo nivel, para pasar después a un nivel más profundo (*breath-first*).

Según Walker (1989) el orden en que se buscan los antecedentes implica el establecimiento de un orden de prominencia de los mismos, ya que si primero se considera como antecedente el sujeto y, a continuación, el objeto directo y el indirecto, el algoritmo está asignando, de modo implícito, mayor prominencia a estas posiciones sintácticas.

Con relación a este punto, podemos afirmar, por tanto, que el algoritmo incorpora a modo de procedimiento o subrutinas, las preferencias por posiciones prominentes, esto es, que detalla con precisión el modo de alcanzar los antecedentes más destacados.

En opinión de algunos autores, el algoritmo de identificación de antecedentes propuesto por Hobbs es demasiado simple (Carter, 1990). Sin embargo, debemos reconocer que a pesar de realizar un acercamiento poco sofisticado al problema ha servido de punto de partida para investigaciones posteriores.

[2] No nos detendremos aquí en la exposición de los datos estadísticos extraídos de las numerosas pruebas a que ha sido sometido el algoritmo de Hobbs. Puede consultarse, sin embargo, Hobbs (1979) y Walker (1989).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Entre las principales críticas que recibe el algoritmo diseñado por Hobbs mencionaremos las siguientes. En primer lugar, no llega a realizar una interpretación del texto y, por tanto, no puede tener en cuenta las referencias del texto a entidades implícitas.

En segundo lugar, el orden impuesto en la búsqueda obliga a agotar todas las posibilidades dentro de una oración antes de pasar a la inmediatamente anterior y con ello, impide el acceso directo a los antecedentes que no están en la misma oración que la expresión anafórica.

Finalmente, existe el problema de que para que el algoritmo pueda ser aplicado, Hobbs asume una serie de módulos como, por ejemplo, uno que recupere sintácticamente el texto omitido o que construya el árbol sintáctico correcto para todas las oraciones.

En nuestra opinión, no podemos decir que éste último punto sea un un defecto del algoritmo puesto que Hobbs no pretende construir todo un sistema de interpretación anafórica sino únicamente establecer los pasos necesarios para que esta interpretación sea posible.

3. Aproximaciones de tipo «democrático».

Mencionamos en la introducción que la característica que diferencia los enfoques «democrático» y «consultivo» de las llamadas aproximaciones «tradicionales» es que los dos primeros reconocen la necesidad de incorporar diferentes fuentes de conocimiento para el tratamiento de las relaciones anafóricas, y así contar en el mismo modelo con conocimiento sintáctico, semántico y discursivo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Del mismo modo, podemos también diferenciar entre el enfoque «democrático» y el «consultivo» en función del tipo de tratamiento que dan a toda esta información. En el caso de las aproximaciones democráticas, la característica que las define consiste básicamente en que conceden la misma importancia a todas las fuentes de conocimiento que intervienen en la identificación de antecedentes anafóricos. En efecto, como se mostrará a continuación, no existe en las estrategias de tipo «democrático» ninguna fuente de información que tenga mayor prominencia sobre las otras a la hora de proponer y seleccionar antecedentes.

Las estrategias que analizaremos son las siguientes: Alshawi (1987), Carbonell y Brown (1988) y Rich y LuperFoy (1988).

3.1. Alshawi.

El sistema de resolución de anáfora construído por Alshawi (1987) se basa en dos mecanismos fundamentales: el de memoria (*memory mechanism*) y el contextual (*context mechanism*). El primero consigue un acceso rápido a los nodos de una red semántica, mientras que el segundo señala la información más relevante en el texto.

Ambos mecanismos se utilizan no sólo para la identificación de antecedentes sino también para resolver ambigüedades, generar enunciados a partir de un texto y almacenar éstos en una base de datos.

Veamos, en primer lugar, cómo actúa el mecanismo de memoria. Su función principal consiste en almacenar información a medida que el sistema analiza un texto y tenerla disponible cuando sea necesario, es

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

decir, que se comporta como la «memoria» del sistema.

Universitat d'Alacant
Universidad de Alicante

Para poder llevar a cabo su tarea, la memoria emplea una serie de reglas semánticas formales que se definen mediante dos tipos de función (*ref* y *rel*) y dos tipos de afirmación (*specialisation* y *corresponds*).

La función *ref* establece una *ref*erencia entre una entidad y el conjunto de objetos del mundo que ésta representa. Por ejemplo, la regla *ref(COMPUTER)* crea la referencia entre la entidad *computer* y los objetos del mundo real que corresponden a ella.

La función *rel* establece una *rel*ación entre un par de entidades y el conjunto de pares de objetos que corresponden a éste en el mundo real. Por ejemplo, la regla *rel(DATA/PROCESSING,COMPUTER)* une las entidades *data processing* y *computer* y da cuenta de la relación que existe entre ambas.

En cuanto a los dos tipos de afirmación, *specialisation* y *corresponds*, la primera de ellas indica la referencia de un subconjunto a un conjunto mayor, mientras que la última expone la relación que existe entre un par de entidades y otro par de entidades correspondientes a un conjunto mayor. Por ejemplo, en la afirmación *(specialisation: COMPUTER of MACHINE)* se establece una referencia entre *computer* como un subconjunto de *machine*. En el caso de una afirmación como *(corresponds: DATA/PROCESSING to COMPUTER as MACHINE/ACTIVITY to MACHINE)*, se establece una relación entre el par *DATA/PROCESSING to COMPUTER* como un subconjunto del par *MACHINE/ACTIVITY to MACHINE*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Una vez que hemos expuesto brevemente cómo funciona el mecanismo de memoria, veamos ahora en qué consiste el mecanismo contextual.

Alshawi define en su sistema siete factores contextuales (*context factors*) que se aplican al texto a medida que éste se analiza y que constituyen la esencia del mecanismo contextual.

Los factores son los siguientes:

1- Factor que señala la oración más reciente en el texto.
2- Factor que indica qué párrafo es el más reciente.
3- Factor que indica la relevancia del sujeto en las oraciones construídas con el verbo *be* (*be-clauses*) y las oraciones de pasiva. Alshawi denomina este factor «énfasis sintáctico» (*syntactic emphasis).*
4- Factor que indica el camino o «historia» que han seguido las operaciones del mecanismo de memoria. Éste es, en palabras de Alshawi, el *processing history factor.*
5- Factor que señala el uso de deixis[3].
6- Factor de asociación entre nodos semánticos cuyos vecinos hayan sido activados anteriormente.
7- Factor que asocia un enunciado creado en la base de datos con todas las entidades correspondientes.

[3] La deixis, que en su sentido etimológico significa «señalar», sirve para dirigir la atención del receptor desde un interés pre-existente a otro nuevo (Alcaraz, 1990: 135).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Cada factor consiste en un grupo de entidades a las que se asocia un valor numérico que determina su peso o importancia en el conjunto del texto.

Para localizar un antecedente en una relación anafórica, se lleva a cabo una búsqueda entre todas las entidades cuyo peso supere un umbral determinado. Si sólo existe una entidad que supere este umbral, se aceptará ésta como antecedente. En cambio, si son varias las entidades propuestas, se tomará como antecedente aquella cuyo peso sea mayor.

3.2. Carbonell y Brown.

A diferencia de lo que ocurre en las aproximaciones «tradicionales», Carbonell y Brown reconocen la necesidad de tratar la anáfora en toda su amplitud como un fenómeno en el que intervienen muchas y diferentes fuentes de información. De esta concepción surge la necesidad de integrar todas las fuentes de información lingüística en una única estrategia.

En palabras de Carbonell y Brown «syntactic information plays a central role in establishing appropriate references for intrasentential anaphora. But semantic and pragmatic information is absolutely required for intersentential anaphora» (96). Y así, la base de toda su teoría es que «anaphor resolution is not a monolitic autonomous process; it requires access and integration of all the knowledge sources necessary for dialog and text interpretation. These linguistic knowledge sources are brought to bear as constraints or preferences encoded as multiple resolution strategies» (96).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los citados autores toman como punto de partida esta definición y construyen una estrategia de identificación de antecedentes que combina múltiples fuentes de conocimiento en un único modelo. Estas fuentes corresponden a diferentes tipos de conocimiento, que Carbonell y Brown dividen en dos tipos: restricciones y preferencias. A cada una de las restricciones y preferencias se le asocia una regla de identificación diferente.

Como veremos, las restricciones sirven para eliminar candidatos mientras que el papel de las preferencias es facilitar la selección del antecedente correcto indicando qué candidatos se consideran mejores que otros.

Las *restricciones* que actúan en la identificación de antecedentes son las siguientes:

a) Restricciones de número, género y caso. La regla que formulan Carbonell y Brown establece que deben eliminarse como posibles antecedentes todos los candidatos que no cumplan las restricciones de número, género y caso impuestas por la expresión anfórica. Así ocurre, por ejemplo, en el siguiente texto:

T22 John and Mary went shopping. *He* bought a steak.

En este texto, existen dos antecedentes posibles: *Mary* y *John*. Sin embargo, tras la aplicación de la restricción de género, número y caso *Mary* queda eliminado como posible antecedente. Por tanto, sólo queda *John* como único candidato y se selecciona como antecedente.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

b) Restricciones semánticas. Este tipo de restricciones se utiliza para eliminar todas aquellas entidades discursivas cuyos rasgos semánticos no concuerden con las restricciones semánticas exigidas por la expresión anafórica. Por ejemplo, en la oración:

T23 John took the cake from the table and ate *it*.

el verbo *to eat* impone en su objeto directo la restricción de una entidad comestible. Como los posibles antecedentes son dos: *cake* y *table*, y de ellos sólo *cake* es comestible, eliminaremos *table* en virtud de la restricción semántica.

c) Restricciones impuestas por la acción que se realiza en la oración. La estrategia empleada establece que deben eliminarse todos aquellos posibles antecedentes que violan algunas de las condiciones exigidas por la acción en la cual se inserta la anáfora. Consideremos, por ejemplo, el siguiente texto:

T24 John gave Tom an apple. He ate the apple.

En esta oración el verbo *to give* impone la condición de que la persona que da algo a alguien deja de poseer ese algo. Si el antecedente del pronombre *he* fuera *John* se crearía un conflicto entre la condición del verbo *to give* y la del verbo *to eat*, que establece que para que alguien coma algo es necesario que ese alguien posea ese algo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Con respecto a las *preferencias*, Carbonell y Brown apuntan las siguientes:

a) Preferencias de la expresión anafórica por aquellos candidatos que se encuentren en posiciones paralelas. Las posiciones paralelas pueden ser sintácticas, semánticas y pragmáticas.

Consideramos posiciones sintácticas paralelas, aquellas en las que el antecedente y la expresión anafórica desempeñan la misma función sintáctica aunque la unidad lingüística que las representa sea distinta. Por ejemplo, son posiciones sintáctica paralelas las que unen el pronombre *it* con su antecedente *the dog* en el texto:

T25 The robot gave *the dog* a bone. John also gave *it* some water.

De igual modo, son también posiciones sintácticas paralelas las que ayudan a identificar *the robot* como antecedente de *it* en:

T26 *The robot* gave the dog a bone. *It* also gave John some water.

Con respecto a la preferencia por posiciones semánticas paralelas, definiremos éstas como las relaciones que se dan entre una expresión anafórica y un antecedente que comparten la misma categoría semántica, aunque se manifiesten en diferentes posiciones sintácticas en la oración. Así, en el ejemplo que mostramos a continuación, la expresión anafórica *him* y su antecedente *Peter*

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

comparten el rasgo semántico de receptor, con lo cual se consiguen eliminar el resto de posibles antecedentes.

Universitat d'Alacant
Universidad de Alicante

T27 John carried the box of papers from Bill to Peter.
He also sent him Mary's books.

El último tipo de preferencia por posiciones paralelas es la que Carbonell y Brown denominan «posición pragmática». Según Carbonell y Brown la preferencia pragmática obliga a seleccionar como antecedente el que ayude a mantener la cohesión discursiva. Un antecedente que cumpla esta condición se prefiere antes que otro que rompa el curso natural del texto.

Mostramos a continuación un ejemplo de lo expuesto:

T28 Mary drove from the park to the club.
Peter went there too.

Como vemos, la primera parte del discurso crea una acción de movimiento del parque al club. En la segunda oración debemos interpretar *there* como refiriéndose a *the club* si queremos mantener la cohesión discursiva.

b) Preferencias por posiciones topicalizadas. En esta regla de preferencia se establece que debe darse mayor prioridad a los posibles antecedentes que se encuentren en posiciones temáticas. Así ocurre, por ejemplo, en el caso de las oraciones truncadas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T29 It was Mary who told Jane to go to New York.
Why did she do it?.

En este texto, la entidad *Mary* está en posición temática y, por tanto, se prefiere como antecedente de *she*.

c) Preferencia en el orden de búsqueda por los antecedentes que se encuentren en la misma oración que la expresión anafórica.

Todas estas restricciones y preferencias se ponen en práctica dentro de un único modelo de identificación de antecedentes, el cual se enmarca en el contexto del proyecto *Universal Parser* desarrollado en la Universidad de Carnegie Mellon. En este entorno se crea el módulo de tratamiento de las relaciones anafóricas, que actúa después del análisis sintáctico y semántico.

Los pasos que sigue el sistema para identificar los antecedentes son los siguientes: (a) considera como posibles antecedentes todos los sintagmas nominales que hayan aparecido con anterioridad, (b) aplica sobre ellos las restricciones, y elimina así todos los candidatos que no las cumplan, (c) sobre los candidatos que quedan aplica las preferencias.

Como resultado, cada candidato tendrá asignado un «peso» o valor correspondiente a la relevancia que le otorga cada preferencia determinada. Por último, el sistema selecciona como antecedente el que mayor peso haya obtenido.

La propuesta de Carbonell y Brown es muy interesante porque reconoce la necesidad de utilizar diferentes tipos de conocimiento dentro

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

de una misma estrategia. Como vemos, esta aproximación es típicamente democrática por cuanto ninguna fuente de conocimiento tiene mayor importancia que otras, ni existe una que proponga candidatos al resto, ya que éstos surgen tras la aplicación de todas las restricciones y preferencias.

3.3. Rich y LuperFoy.

Rich y LuperFoy (1988) afirman, al igual que apuntan Carbonell y Brown, que no puede construirse una teoría única sobre la resolución de la anáfora, sino que si se quiere llevar a cabo un tratamiento completo de este fenómeno lingüístico, deben crearse diferentes teorías para explicar los diferentes problemas y aspectos que componen el tratamiento de la anáfora.

En este sentido, la estrategia que construyen Rich y LuperFoy se basa en la creación de diferentes módulos que corresponden, a su vez, a diferentes teorías de la anáfora. Así, consiguen que cada uno de estos módulos aborde un aspecto diferente de la identificación de antecedentes. Esta estrategia se lleva a la práctica en *LUCY*, un sistema de comprensión de textos.

Rich y LuperFoy aseguran la independencia entre los diferentes módulos gracias a la utilización de la llamada arquitectura de pizarra *(blackboard)*[4]. Este tipo de arquitectura ha sido utilizada sobre todo en

[4] Para ilustrar el funcionamiento de la arquitectura de pizarra imaginemos, por ejemplo, un grupo de especialistas dedicados a resolver un problema determinado. Todos ellos están reunidos ante una pizarra con el objetivo de comunicarse sus conocimientos y buscar una solución al problema. Por turnos, cada uno escribe en la pizarra su contribución de modo que el siguiente especialista pueda utilizarla y añadir nuevos datos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

reconocimiento de habla, y se caracteriza porque utiliza diversas fuentes de información para proponer y evaluar diferentes hipótesis (Erman *et al*, 1981). Junto a los citados módulos independientes, Rich y LuperFoy construyen un módulo superior, *the handler* («controlador») que coordina las propuestas e intercambios entre todos los módulos.

Como ya hemos apuntado, cada módulo pone en práctica un aspecto distinto de la anáfora e impone, asimismo, una serie de restricciones en la selección de candidatos. Por esta razón, los módulos reciben el nombre de «fuentes de restricción» (*constraint sources*) o CS.

Cada CS tiene cuatro tipos de funciones, que enumeramos a continuación:

1- «Modelado» (*modeller).* Es la función que mantiene el modelo de interpretación creado por el CS. Supongamos, por ejemplo, que el módulo activo es el que contiene información sobre el discurso. Pues bien, para poder aplicar las restricciones sobre los posibles antecedentes, se construye un modelo de interpretación discursiva que permanece activo mientras es necesario.

Este proceso continúa hasta que el problema está resuelto o ninguno de los especialistas puede añadir más información.

En una arquitectura de pizarra, el papel de los especialistas lo desempeñan una serie de programas independientes, denominados fuentes de conocimiento (*knowledge sources*) y la estructura global que coordina toda la información es precisamente la pizarra (Velthuijsen, 1993).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2- «Exhibición de restricciones» (*constraint poster*). Esta función establece todas las restricciones que interactúan en la identificación de antecedentes asegurando así que la interpretación será correcta.

3- «Formulación de hipótesis» (*proposer*). Esta función se encarga de proponer una lista de candidatos a antecedente, mediante la asociación de una puntuación a cada uno de ellos en función de los resultados obtenidos tras aplicar las restricciones.

4- «Evaluación» (*evaluator*) . Evalúa los antecedentes propuestos por la función anterior.

La aplicación de los módulos de restricción o CS se efectúa después de completar el análisis semántico, siguiendo el siguiente orden: (a) tras el análisis sintáctico y semántico se actualiza la estructura discursiva, (b) se activan las funciones del *modeller* y el *constraint poster*, (c) se activa, a continuación, el *anaphor handler* que, a su vez, llama al *proposer* y al *evaluator*. El resultado es una lista de posibles antecedentes ordenados según la puntuación obtenida tras la aplicación de los CS. La selección final del antecedente se efectúa en función de la puntuación obtenida por cada candidato tras aplicar todas las restricciones.

Como podemos suponer, resulta fundamental para el desarrollo de esta estrategia el diseño de un método eficaz que asigne puntuaciones a cada candidato. Rich y LuperFoy emplean una función que calcula la media entre la puntuación absoluta que otorga cada CS a cada candidato (esta puntuación se sitúa entre -5 y +5) y el índice de confianza o seguridad de que el antecedente elegido es correcto (entre 0 y 1).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

4. Aproximaciones de tipo «consultivo».

Universitat d'Alacant
Universidad de Alicante

Como ya mencionamos anteriormente, las aproximaciones computacionales que adoptan un enfoque «consultivo» se caracterizan porque seleccionan el antecedente gracias a la información recogida por una única fuente que normalmente suele ser el foco discursivo. Una vez que éste ha propuesto un antecedente, se consultarán otros tipos de conocimiento con el fin de recoger información suficiente para confirmar o rechazar dicho antecedente.

Dada la importancia que el foco del discurso tiene en las aproximaciones consultivas, pensamos que es adecuado presentar la teoría que da origen a la noción computacional de foco discursivo y ver cómo ha ido evolucionando a través de sucesivas versiones. Así pues, expondremos, a continuación, los puntos fundamentales de esta teoría y analizaremos después el modo en que estas ideas se han llevado a la práctica.

4.1. La teoría del foco discursivo.

En las investigaciones realizadas en este campo dentro de la lingüística computacional se ha experimentado con una amplia gama de representaciones y algoritmos con el fin de estudiar la estructura del discurso. El modelo más destacado es el desarrollado por Grosz (1977, 1983, 1986), quien propone la identificación del foco del discurso como clave para descubrir su estructura organizativa.

La teoría del foco del discurso ha sufrido diferentes modificaciones desde que Grosz (1977) hiciera su primera propuesta en su artículo «The

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

representation and use of focus in a system for understanding dialogs». Los puntos básicos de este modelo son los conceptos de *foco* y *proceso de focalización*, que, como mostraremos a continuación, tienen un papel central en el tratamiento de las referencias y las frases nominales anafóricas[5].

En el mencionado artículo, Grosz presenta los principios fundamentales de la teoría del foco del discurso y construye un modelo de focalización basado en tres mecanismos:

1- Representación del foco explícito. Se utiliza para localizar los elementos de mayor relieve en el discurso, los cuales quedarán almacenados en los «espacios focales».

2- Representación del foco implícito. Contiene información sobre conceptos asociados con el elemento que está focalizado en ese momento.

3- Cambio de foco. Su función es actualizar los elementos contenidos en los espacios focales a medida que avanza el discurso.

Por lo que respecta a las referencias anafóricas, la representación de la estructura del discurso creada mediante los tres mecanismos facilita la localización de los antecedentes, al disponer en cada momento de un espacio focal de donde extraer la información necesaria.

[5] La mayoría de las investigaciones sobre la anáfora se han centrado en las frases nominales, dejando abandonadas, en cierto modo, las expresiones verbales. En inglés, algunos autores han tratado las formas verbales anafóricas(Robinson 1981, Webber 1988), pero falta aún una visión general que estudie este fenómeno.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

De este modo, la interpretación de las frases nominales anafóricas se construye gracias a la selección de las entidades que están focalizadas en ese momento. Así, además de predecir el referente, los mecanismos de focalización limitan la búsqueda a las entidades relacionadas con elementos focalizados, dejando en segundo término otras entidades menos accesibles.

4.2. Foco discursivo y foco agente

La primera modificación a la teoría del foco esbozada por Grosz, la introduce Sidner (1979, 1983) al añadir las nociones de foco discursivo y foco agente. Estos dos conceptos corresponden ambos a entidades mencionadas en el enunciado que son focalizadas debido a la estructura sintáctica y a las relaciones temáticas de la oración. Por ejemplo, en la oración «Juan sacó el perro a pasear», *Juan* es el foco agente y *el perro* el foco discursivo.

Esta distinción entre ambos tipos de foco es importante porque, como veremos, ayuda a identificar los antecedentes de los pronombres. En efecto, la interpretación de la anáfora nominal es posible, según Sidner, gracias a la aplicación de un algoritmo que podríamos resumir del siguiente modo: «cuando el pronombre que se está interpretando se encuentra en una posición temático que no es la de agente, seleccionamos el foco discursivo como antecedente; si el pronombre está en posición de agente, se tomará como antecedente el foco agente».

Gracias a la aplicación de esta regla, Sidner trata ejemplos como el siguiente:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T30 Alfred and Zohar liked to play basketball.
They played it everyday.

En T30, *Alfred* y *Zohar* son el foco agente, mientras que *basketball* es el foco discursivo. Si seguimos la regla, podemos asignar correctamente el pronombre *they* (posición de agente) a *Alfred* y *Zohar* (foco agente). De igual modo, relacionaremos *it* con el foco discursivo *basketball.*

Junto a esta regla básica, Sidner reconoce la necesidad de aplicar restricciones sintácticas, semánticas y pragmáticas, que pueden impedir la selección de un antecedente aunque la regla lo haya identificado como tal. Así ocurre, por ejemplo, en T31:

T31 Alfred and Zohar liked to play basketball.
After their game, Alfred and Zohar had ice cream cones.
The boys thought they tasted really good.

El pronombre *they* no puede relacionarse con *basketball* porque las restricciones sintácticas y semánticas lo impiden. Seleccionamos, entonces, el siguiente foco discursivo, esto es, *ice cream cones.*

4.3. Los centros focales

Grosz, Joshi y Weinstein (1983) presentan una mecanismo de resolución de la anáfora que contrasta, en algunos aspectos, con el algoritmo de Sidner.

Según estos autores, la regla básica de interpretación anafórica está

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

basada en un proceso de identificación de lo que ellos denominan centros focales, los cuales vienen a sustituir a las nociones de foco discursivo y foco agente.

Veamos cómo operan los centros focales: existe para cada enunciado del discurso un centro focal que mira hacia atrás (*backward centre o Cb*) y un conjunto de centros focales que miran hacia delante (*forward centre o Cf*); el Cb une el enunciado al discurso precedente, mientras que el Cf proporciona un conjunto de entidades a las que pueden hacer referencia los enunciados siguientes.

El proceso de identificación de antecedentes, que estos autores denominan *centering*, consiste en comprobar si el centro del enunciado que se está procesando es el mismo que el centro del enunciado anterior, en cuyo caso, se empleará un pronombre.

Con esta fórmula tan simple, Grosz, Joshi y Weinstein afirman que es posible resolver la interpretación de los pronombres sin necesidad de recurrir al foco agente y foco discursivo propuestos por Sidner. Sin embargo, la regla de «centralización» restringe únicamente la selección de palabras en un enunciado, pero no la localización del antecedente correcto del pronombre. Tal como señala Carter (1987) la teoría del centro focal es criticable en este punto.

Así pues, si bien es cierto que la «centralización» permite el uso de un pronombre para sustituir a una entidad que ya está en foco, la regla no predice, sin embargo, el antecedente correcto del pronombre. Veamos cómo actuaría esta regla en el ejemplo que mostramos (Carter, 1987:117):

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T32 I haven't seen Jeff for several days.
Carl thinks he's studying for his exams.
He thinks he studies too much.

Según la teoría de la «centralización», el pronombre *he* en el tercer enunciado está empleado correctamente ya que sustituye al centro de la oración anterior, *Carl*. Sin embargo, por lo que respecta a su interpretación, la regla no aporta ninguna solución, ya que podría tener a *Carl* o a *Jeff* como antecedentes.

4.4. La estructura de atenciones del discurso

Grosz y Sidner (1986) consiguen unir todas las teorías desarrolladas anteriormente, gracias a la definición de unos principios generales sobre la estructura del discurso.

En el nuevo modelo, la estructura básica del discurso consta de tres componentes:

1- Estructura lingüística de la oración. El análisis lingüístico de la oración ayuda a localizar ciertos marcadores lingüísticos o *cue phrases* a partir de las cuales se produce un cambio de foco en el discurso. Este cambio impide cualquier referencia anafórica a una entidad anafórica previa al cambio.

2- Estructura de intenciones. Determina la finalidad del discurso (*discourse purpose*). Todo discurso tiene una finalidad propia que lo diferencia de otros discursos y junto a ésta, existen una serie de

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

«finalidades secundarias» que se distribuyen a lo largo del discurso y contribuyen al cumplimiento de la finalidad principal.

3- Estructura de atenciones. Es una abstracción del foco de atención de los participantes en el discurso a medida que éste se desarrolla. Como podemos suponer, se trata de una estructura dinámica que cambia y se actualiza durante el transcurso del discurso.

Con estos tres elementos, Grosz y Sidner construyen la estructura discursiva y la organizan en espaciones focales y pilas donde se almacena la información. De este modo, restringe la búsqueda de antecedentes a los que estén dentro de los espacios focales.

5. Sistemas que adoptan el enfoque «consultivo».

Entre los sistemas que utilizan un enfoque «consultivo» para llevar a cabo la identificación de antecedentes anafóricos analizaremos los siguientes: Brennan, Friedman y Pollard (1987), SPAR (Carter, 1987), CLE (Alshawi, 1992).

5.1. Brennan, Friedman y Pollard.

Brennan, Friedman y Pollard (1987) diseñan e implementan un algoritmo en la línea de las propuestas apuntadas por Grosz, Joshi y Weinstein. Este algoritmo construye y actualiza la estructura discursiva, al mismo tiempo que ayuda a localizar los antecedentes anafóricos. Añade, asimismo, algunas extensiones a las propuestas anteriores, de modo que puedan tratarse mayor número de casos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Brennan *et al* llevan sus ideas a la práctica con el desarrollo de un sistema que sirve de interface a una base de datos. Los módulos encargados del tratamiento de las relaciones anafóricas y la gestión de la estructura discursiva son el procesador semántico (*semantic processor*) y el procesador pragmático (*pragmatic processor*). La función del procesador semántico consiste en construir representaciones de las oraciones y pasarlas al procesador pragmático.

Con respecto a las expresiones anafóricas, el procesador semántico anota éstas con información sintáctica, información sobre concordancia e información sobre su función gramatical.

Como ya hemos mencionado, la característica fundamental del algoritmo construido por Brennan *et al* es que realiza una ampliación sobre las propuestas de Grosz *et al* de modo que podrán tratar correctamente un mayor número de casos. Esta ampliación se concreta básicamente en la construcción de una nueva regla que haga posible el cambio de foco discursivo en más ocasiones de las que preve la regla diseñada por Grosz *et al* (Brennan *et al*: 157).

Por lo que respecta a la implementación del proceso de identificación de antecedentes, éste se lleva a cabo en tres fases consecutivas.

La primera fase consiste en localizar todas las expresiones anafóricas que se encuentren en la oración y ordenarlas según su posición sintáctica, con el sujeto de la oración en primer lugar. Gracias a esta ordenación se establecen preferencias en la selección de candidatos y, una vez ordenadas todas las expresiones anafóricas se construyen todas las

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

combinaciones posibles del centro focal que mira hacia atrás (*backward looking centre*) o Cb y el centro focal que mira adelante (*forward looking centre*) o Cf (véase apartado 4.3).

A continuación, la segunda fase aplica una serie de filtros que eliminan como posibles antecedentes todas aquellas combinaciones de Cb y Cf que contradigan las reglas de indexación entre antecedente y expresión anafórica.

Finalmente, la fase tercera clasifica cada par Cb, Cf en función del tipo de transición que se da en el paso de una oración a otra. Así, por ejemplo, si el foco del discurso continúa siendo el mismo, los pronombres que aparezcan tendrán como antecedente este foco discursivo. Si, por el contrario, se detecta un cambio en el foco del discurso, tendrá preferencia como candidato a antecedente aquel par Cb, Cf que señale precisamente este cambio y, por tanto, las expresiones anafóricas que se hayan empleado considerarán el nuevo foco del discurso como antecedente preferido.

A fin de ilustrar todo lo expuesto, examinaremos cómo se desarrolla todo el proceso en el texto T33:

T33 Brennan drives an Alfa Romeo.
She drives too fast.
Friedman races her on weekends.
She often beats her.
(Brennan *et al*: 157)

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En la primera oración de T33 el Cb es *Brennan* y el Cf es también *Brennan*. En la segunda oración el Cb y el Cf siguen siendo los mismos y, por tanto, el foco del discurso sigue siendo *Brennan*. Como no se ha producido ningún cambio en el foco, el pronombre *she* tiene como antecedente la entidad *Brennan*.

En la tercera oración del texto T33 el Cb es *Brennan* pero el Cf cambia a *Friedman*, esto es, hay un cambio de foco, que influye en la selección del antecedente de *she* en la cuarta oración y hace que *Friedman* desplace a *Brennan*.

Como podemos comprobar por lo expuesto, la estrategia diseñada por Brennan *et al* considera el foco discursivo como fuente principal de información y así, los antecedentes elegidos son los propuestos por el foco del discurso. Sin embargo, esta estrategia no tiene en cuenta la incorporación de otras fuentes de conocimiento tales como la información semántica, el conocimiento del mundo o restricciones sintácticas que podrían rechazar el antecedente preferido por el foco discursivo.

En este sentido, Brennan *et al* reconocen esta deficiencia y señalan que es una fuente de investigación futura.

5.2. SPAR (Shallow Processing Anaphor Resolver).

El desarrollo del sistema SPAR (Carter, 1987) obedece al deseo de comprobar la hipótesis de que no es necesario efectuar un tratamiento demasiado profundo del lenguaje para obtener resultados correctos en la resolución de ambigüedades. Carter propone esta aproximación y afirma

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

que incluso es posible limitar la cantidad de conocimiento del mundo necesaria para tratar computacionalmente el lenguaje, siempre que la información estrictamente lingüística esté suficientemente fundada.

Los módulos que componen SPAR están basados en los trabajos previos de Boguraev (1979), Sidner (1983) y Wilks (1975). Con todos ellos, Carter construye un módulo de análisis sintáctico y semántico que parte del analizador diseñado por Boguraev, otro módulo que incorpora reglas de gestión y actualización de la estructura del foco del discurso basado en las reglas de Sidner y, por último, un módulo que aplica reglas de inferencia sobre el mundo similares a las utilizadas por Wilks en su teoría de preferencias semánticas.

Como es de suponer, Carter amplía y modifica algunas de las reglas y estrategias incorporadas en los citados módulos para conseguir una mayor eficacia en la identificación de los antecedentes y así conseguir que con el mínimo conocimiento sobre inferencias del mundo real sea posible resolver las referencias de las expresiones anafóricas.

El problema que se plantea en SPAR es cómo coordinar todos los módulos para que la información que cada uno de ellos aporta se aplique de manera correcta, en el orden correcto e interactúe adecuadamente con el resto de fuentes de información. A este respecto, conviene recordar que el enfoque adoptado por Carter se encuadra dentro de las aproximaciones consultivas y, por tanto, supone la primacía de una fuente de información que señala preferencias por determinados antecedentes.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La fuente de información que cumple esta función es la que se deriva de la estructura del discurso y la localización del foco discursivo. En efecto, los candidatos a antecedente son seleccionados tras la aplicación de las reglas contenidas en el módulo de gestión del discurso, mientras que la función del resto de reglas es confirmar o rechazar estos candidatos pero nunca proponer uno nuevo.

Con el fin de coordinar todos los componentes de SPAR, Carter organiza el tratamiento de la información en una serie de etapas consecutivas.

Estas etapas son las siguientes:

1- Aplicación de los módulos sintáctico y semántico. Estos módulos están basados, como ya hemos apuntado, en los módulos de análisis construidos por Boguraev. Estos módulos consisten en un *Augmented Transition Network*[6] y en un diccionario que contiene la entradas léxicas.

2- Aplicación del módulo de gestión discursiva. La información contenida en este módulo se concreta en reglas sobre la focalización de las entidades discursivas. Estas reglas indicarán preferencias por unos candidatos a antecedente sobre otros. Carter implementa la

[6] Un ATN es un conjunto de redes (*networks*) que representa las diferentes categorías sintácticas. Cada una de estas redes está formada por una serie de estados conectados entre sí por medio de arcos. Gracias a estos arcos podremos saber si una oración es gramatical ya que sólo si el ATN consigue llegar desde el principio al final de la red atravesando los arcos, la oración será gramatical. El ATN cuenta además con una serie de registros donde se almacena la información sobre los arcos que ya se han atravesado.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

reglas de Sidner (véase apartado 4.2) pero añade un nuevo concepto a las propuestas de Sidner, la «preferencia débil» (*weak preference*).

En efecto, Carter señala la necesidad de distinguir entre una preferencia débil y otra fuerte para poder tratar ejemplos como el que se muestra a continuación:

T34 a The monkey picked a banana.
The elephant ate it.

T34 b The monkey picked a banana.
The elephant attacked it.

En ambos casos hay un antecedente que tiene mayor preferencia sobre el otro para ser antecedente del pronombre *it*. Para el primer ejemplo será *a banana*, mientras que para el segundo será *the monkey*. Si al procesar la oración *The monkey picked a banana* dejáramos que las reglas de focalización impusieran una preferencia fuerte sobre uno de los dos candidatos (*monkey* o *banana*) siempre existiría la posibilidad de que el candidato propuesto fuera el erróneo. La solución, tal como apunta Carter, es permitir que la preferencia sea débil y dejar que otros módulos de SPAR tomen la decisión final sobre qué candidato es el correcto.

3- Aplicación de reglas de concordancia sintáctica y restricciones semánticas.

4- Aplicación de reglas de restricción sintáctica para la localización del antecedente de un pronombre.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5- Reglas de inferencia, tomadas de la teoría desarrollada por Wilks (1975) (véase apartado 2.4). Las reglas de inferencia se aplican sólo cuando todavía existen relaciones anafóricas ambiguas tras la fase cuarta. El objetivo es utilizar las reglas de inferencia sobre el mundo cuando se han agotado todas las posibilidades de las fuentes de información anteriores.

6- Aplicación de reglas heurísticas. En el caso extremo de que tras las reglas de inferencia el antecedente no haya podido ser localizado, se aplicarán reglas heurísticas.

Mediante una estrategia consultiva como la descrita, Carter consigue resolver problemas de ambigüedad entre antecedentes, decidir entre varios candidatos a antecedente dentro de la misma oración así como permitir la interacción de varias fuentes de conocimiento. Los resultados que obtiene son satisfactorios ya que Carter obtiene un porcentaje del 93% en la identificación de los antecedentes correspondientes a 242 pronombres (Carter, 237).

5.3. CLE (Core Language Engine).

El proyecto CLE (Alshawi, 1992) ha sido desarrollado en el SRI International Artificial Intelligence Centre y el Cambridge University Computer Laboratory con el objetivo de construir un mecanismo de aplicación general que permita traducir enunciados del lenguaje natural a representaciones lógicas de sus significados. En este sentido, el CLE se concibe como una herramienta para el tratamiento del lenguaje natural que puede ser utilizada como un componente más en la construcción de

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

sistemas interactivos.

Para asegurar su independencia así como la posibilidad de hacerlo extensible a diferentes aplicaciones, el CLE ha sido diseñado con una estructura completamente modular, de manera que cada módulo tiene una función claramente definida dentro del proceso general de traducción a las formas lógicas. Este proceso se concreta básicamente en dos fases: análisis e interpretación.

La fase de análisis contiene los módulos léxico, sintáctico y semántico y genera como resultado las llamadas «fórmula *quasi* lógicas» (*Quasi Logical Forms*) o QLF. En cuanto a la fase de interpretación, ésta contiene los módulos que aplican el conocimiento del contexto para obtener finalmente las formas lógicas (LF), que representan los posibles significados de los enunciados.

Como es lógico suponer, una herramienta como CLE, que genera interpretaciones del lenguaje, debe incorporar un mecanismo que se ocupe de las relaciones anafóricas y resuelva el problema de asignarles antecedentes. En este sentido, el CLE sigue una estrategia muy concreta.

En primer lugar, CLE toma todas aquellas QLF que tengan expresiones anafóricas sin resolver y aplica una serie de reglas de referencia (*reference resolution rules*) que propondrán diferentes candidatos a antecedente. Cada una de las reglas de referencia especifica el modo en que puede ser localizado el antecedente, en función del tipo de expresión anafórica que aparece en la QLF.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Así, por ejemplo, para localizar el antecedente de *him* en una oración como *Mary expected him to introduce himself*, tomaríamos primero la QLF sin resolver:

```
a_term(t=ref,p=pro,l=him,n=sing,a=[mary]>,X,[male,X])
```

Esta QLF indica que *him* es una expresión anafórica (*a_term*) que necesita una referencia (*t=ref*); que *him* es un pronombre no reflexivo (*p=pro*) cuyo número es singular (*n=sing*); y que *mary* es un antecedente posible dentro de la oración (*a=[mary]*). Existe además la restricción de que el antecedente tiene que ser masculino (*[male,X]*).

Una vez que se ha construido la QLF, el paso siguiente es, como hemos apuntado, aplicar las reglas de referencia, las cuales se utilizan según un orden de preferencia, que para los pronombres es el siguiente:

```
refrule(a_term(<t=ref,p=pro,l=i>,_,_),
          hearer_speaker_ref).

refrule(a_term(<t=ref,p=pro>,_,_),
          intra_sentential).

refrule(a_term(<t=ref,p=pro>,_,_),
          inter_sentential).
```

El orden que se establece en este ejemplo especifica que tiene preferencia la referencia *hearer_speaker* cuando el pronombre es *I*, y que los antecedentes de tipo *intra_sentential* se consideran antes que los *inter_sentential* (Alshawi: 194).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Las reglas de referencia en CLE mantienen su independencia con respecto al algoritmo y, por tanto, la ampliación de las reglas a otras lenguas puede realizarse sin necesidad de cambiar el algoritmo de resolución. Esta aproximación contrasta con propuestas como la de Hobbs (1976) y Carter (1987), donde el algoritmo y las reglas forman un todo, sin posibilidad de separarlos.

Cuando las reglas han sido aplicadas a la QLF se obtiene como resultado una lista de posibles candidatos, codificados como «formas lógicas casi resueltas» (*Resolved Quasi Logical Form*) o RQLF. Estas RQLF entran entonces en la siguiente fase, donde se comprueba si aquellos son aceptables o no como antecedentes. Así, el objetivo principal de esta fase consiste en verificar si los candidatos propuestos cumplen una serie de restricciones que puedan afectar la selección del antecedente correcto.

Las restricciones que incorpora el CLE son fundamentalmente tres: restricciones de ordenación (*sortal constraints*), que evitan interpretaciones erróneas e incoherentes en el contexto del enunciado; restricciones de ligamiento (*binding constraints*), que consideran los casos de cuantificación universal; y restricciones de configuración (*configurational constraints*), que tratan con el problema de la referencia de los reflexivos y no reflexivos.

Por último, si la RQLF propuesta por las reglas de referencia no consigue pasar los tests con las restricciones, entonces se generarán otras posibilidades para resolver la QLF; en el caso de que estas otras propuestas tampoco cumplan las condiciones restrictivas, será necesario considerar otras QLF para el enunciado. Una vez que una RQLF es aceptada como antecedente, el CLE actualiza su modelo discursivo y las

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

entidades discursivas que lo componen.

Universitat d'Alacant
Universidad de Alicante

6. Conclusiones.

Hemos visto a lo largo de este capítulo las principales aproximaciones computacionales al problema del tratamiento de la anáfora. Dividimos éstas en «tradicionales», «democráticas» y «consultivas». Para cada uno de estos tipos esbozamos una serie de características generales y mostramos los modelos más representativos de cada aproximación.

La cuestión que queda por resolver ahora es decidir qué estrategia nos parece más adecuada para nuestros propósitos y justificar nuestra decisión. En general, todas las estrategias aquí expuestas ofrecen algún aspecto interesante que debe tenerse en cuenta, así como desventajas que también debemos considerar.

En el caso de las aproximaciones «tradicionales», el principal inconveniente que detectamos surge del hecho de limitar la búsqueda de antecedentes a la oración así como de emplear únicamente conocimiento de tipo sintáctico para la localización del antecedente.

Los enfoques «consultivo» y «democrático» sí reconocen, sin embargo, la necesidad de incorporar diferentes fuentes de información y, por ello pensamos que aportan soluciones más reales al problema de las referencias anafóricas. En el caso de las aproximaciones consultivas, hemos visto que existe siempre una fuente de información principal que propone los candidatos, mientras que en las aproximaciones democráticas todas las fuentes de conocimiento interactúan por igual.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

En nuestra opinión, el tratamiento «democrático» de la información lingüística se ajusta de manera más adecuada al tipo de problema que plantea la localización de antecedentes anafóricos. Para comprobar si esto es efectivamente así, analizaremos en el capítulo siguiente una serie de relaciones anafóricas contenidas en un corpus de textos y volveremos a discutir entonces acerca de las estrategias «consultiva» y «democrática».

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 4.
Análisis de las relaciones anafóricas contenidas en un corpus de textos

1. Introducción.

En el capítulo anterior vimos cómo los enfoques computacionales más recientes reconocen la necesidad de considerar diferentes fuentes de información lingüística para la identificación de antecedentes anafóricos. En este sentido, las posturas adoptadas se dividen, como ya expusimos, en «democráticas» y «consultivas». El problema ahora es decidir qué aproximación nos parece más adecuada para nuestros propósitos, esto es, si consideramos necesario conceder mayor importancia a una fuente sobre otra o, por el contrario, pensamos que todas las fuentes de información actúan de igual manera.

A fin de encontrar una respuesta a esta cuestión, llevamos a cabo en este capítulo un análisis empírico de las relaciones anafóricas contenidas en un corpus, que nos ayudará a delimitar la incidencia de cada fuente de conocimiento en la selección de antecedentes y decidir, entonces, entre una aproximación «democrática» o una «consultiva».

El estudio del corpus que aquí presentamos se encuadra dentro de las últimas corrientes de investigación en lingüística. En efecto, desde hace

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

algunos años han renacido con ímpetu los estudios lingüísticos basados en un corpus, y han aportado resultados muy interesantes y clarificadores sobre la lengua. En efecto, gracias al análisis de corpus, los investigadores han extraído datos empíricos y han examinado aspectos cuantitativos y probabilísticos de la lengua para crear modelos lingüísticos.

En lingüística computacional, el tratamiento de corpus de textos se ha convertido en una aproximación que aporta soluciones a algunos de los problemas más complicados. En el caso de la anáfora, este tipo de estudio abre nuevos caminos al proporcionar datos significativos acerca de las relaciones antecedente-expresión anafórica.

El estudio de corpus que se presenta en este capítulo tiene básicamente dos objetivos: en primer lugar, delimitar el tipo de conocimiento pertinente para la identificación de antecedentes en las relaciones anafóricas; y en segundo lugar, descubrir cómo y en qué medida actúa cada uno de los tipos de conocimiento identificados. La hipótesis sobre la que trabajamos es la concepción de que cada fuente de información lingüística ofrece sólo datos parciales ya que, como veremos, la asignación del antecedente correcto a una expresión anafórica únicamente puede llevarse a efecto mediante la integración de múltiples fuentes de conocimiento en una única estrategia.

Este estudio pretende, por tanto, servir de punto de partida para la creación de un modelo de interpretación de las relaciones anafóricas que coordine todas estas fuentes de información.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para poder llevar a cabo este tipo de análisis necesitamos contar, en primer lugar, con un corpus de donde obtener los datos; en segundo lugar, debemos delimitar claramente el problema que estudiaremos en el corpus; y, por último, tendremos que concretar el tipo de información que extraeremos del mismo.

2. Criterios generales para la selección de un corpus.

Tal como afirman S. Atkins, J.Clear y N. Ostler (1992), un corpus consiste en un repertorio de textos compilados según unos criterios explícitos, tan perfectamente equilibrado que constituye por sí mismo un modelo a escala de los aspectos lingüísticos que el investigador quiere examinar(5).

Para nuestro estudio, podemos pensar en el corpus como en un conjunto de datos empíricos que presentan información sobre cómo se establecen los vínculos que unen una expresión anafórica concreta a su antecedente.

Las características que debe tener todo corpus son las siguientes:

a) Cohesión y coherencia: los textos que componen el corpus deben mantener la estabilidad conceptual y la trabazón morfosintáctica en sus oraciones y párrafos (Alcaraz, 1990: 121).

b) Clausura: el corpus debe constituir una unidad en sí mismo, es decir, debe tener un principio y un final.

c) Homogeneidad.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

d) Neutralidad: los textos no deben reflejar el estilo particular de un autor, sino que deben ser una muestra imparcial de la lengua.

e) Representatividad: el corpus debe reproducir un modelo lingüístico.

3. El corpus seleccionado.

El corpus que hemos seleccionado para realizar nuestro estudio es *SUSANNE*, desarrollado por G. Sampson (1993) en la Universidad de Sussex con el objetivo básico de desarrollar una taxonomía exhaustiva y un esquema de anotaciones de la gramática del inglés.

El sistema de anotaciones que diseña G. Sampson representa todos los aspectos de la gramática y la sintaxis del inglés y especifica con tal detalle las categorías y los límites entre éstas, que el corpus anotado puede ser utilizado de manera general por diferentes investigadores con diferentes objetivos. De este modo, *SUSANNE* ofrece un esquema de categorías suficientemente práctico, que puede ser utilizado sin peligro de generar ambigüedades.

En cuanto a los datos, *SUSANNE* es un corpus de 128.000 palabras extraídas del *Brown Corpus of American English*(Kucera y Francis, 1967) y organizadas en 64 archivos. Los textos que componen *SUSANNE* se agrupan en torno a las siguientes categorías: artículos de prensa, biografías y memorias, textos científicos y técnicos, literatura.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Cada línea de *SUSANNE* contiene seis campos, separados por un tabulador. Los campos contienen la siguiente información:

1 referencia
2 status
3 etiqueta correspondiente a la palabra
4 la palabra
5 el lema
6 el análisis

En la línea de referencia hay 9 bites, correspondientes a:

- el nombre del archivo (bytes 1 a 3)
- dos puntos (byte 4)
- los números correspondientes a la línea del corpus original (Brown Corpus) donde aparece la palabra (bytes 5 a 8)
- letra minúscula que diferencia palabras sucesivas que en el corpus original estaban en la misma línea (último byte)

Mostramos a continuación un ejemplo donde puede observarse esta organización por campos:

A20:1620p - AT the the [Ns.
A20:1620q - NP1m Dwight Dwight .
A20:1630a - NN1c reformatory reformatory .

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

A20 es el nombre del archivo donde puede encontrarse este texto. *1620* es la línea del corpus original donde se encuentra la palabra en cuestión. *p* diferencia las palabras *the* y *Dwight*, que están en la misma línea en el Brown Corpus pero en *SUSANNE* pertenecen a líneas diferentes. *AT* es el cógigo que indica que *the* es artículo. *[Ns.* indica una frase nominal en singular.

4. Selección de la muestra.

La muestra utilizada para el análisis consiste en una selección de 8 textos extraídos del total de 64 textos que componen el corpus. Nuestra selección pretende ser una muestra representativa de los 4 tipos de texto de *SUSANNE*, ya que en ella hemos incluído dos artículos de prensa(textos A01 y A020), dos biografías y memorias (textos G04 y G03), dos textos científicos (J02 y J06), y dos textos literarios (N07 y N04).

El promedio de páginas por texto es de 45, de las cuales escogimos nuevamente dos grupos de 9 páginas cada uno. De este modo, conseguimos 16 subtextos que representan el conjunto del corpus *SUSANNE*. En la Tabla I mostramos un esquema con la numeración correspondiente a los textos elegidos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Artículos de prensa
Texto A01-1
Líneas A01:0010a a A01:0370g
Texto A01-2
Líneas A01:0370h a A01:0740d
Texto A20-1
Líneas a20:0640c a A20:1020e
Texto A20-2
Líneas A20:1610f a A20:1870m
Biografías y memorias
Texto G04-1
Líneas G04:0010a a G04:0430p
Texto G04-2
Líneas G04:0806d a G04:1220d
Texto G03-1
Líneas G03:0230e a G03:0640m
Texto G03-2
Líneas G03:1250q a G03:1650p
Textos científicos
Texto J02-1
Líneas J02:0540k a J02:0970d
Texto J02-2
Líneas J02:1270g a J02:1700m
Texto J06-1
Líneas J06:0640n a J06:1080k
Texto J06-2
Líneas J06:1530m a J06:1830m
Textos literarios
Texto N12-1
Líneas N12:0240c a N12:0590e
Texto N12-2
Líneas N12:1180a a N12:1400k
Texto N15-1
Líneas N15:0010a a N15:0230k
Texto N15-2
Líneas N15:0280m a N15:0570h

Tabla I

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5. Análisis de los datos.

Universitat d'Alacant
Universidad de Alicante

Una vez que hemos seleccionado las muestras de donde extraeremos la información, llevamos a cabo el análisis estadístico en las siguientes etapas:

1- Identificación. Se trata de localizar en cada texto las siguientes unidades de análisis: párrafos, oraciones, entidades discursivas y expresiones anafóricas. La identificación de unidades es automática gracias a que el corpus incluye las anotaciones sintácticas que facilitan la búsqueda. Así, por ejemplo, un párrafo se identifica por el código **<minbrk>**, una oración por **YF** (punto final) y una frase nominal por estar encerrada entre **[N...N]**. Mostramos en el Apéndice 1 un ejemplo de texto con las unidades de análisis identificadas.

Veamos algunos ejemplos:

- un párrafo:

N07:1210q - YB **<minbrk>** - [Oh.Oh]

- una oración:

N07:1210p - **YF** +. - .O]

- frase nominal:

N07:1230r - APPGm his his **[N**s.
N07:1240a - JJ tender tender .
N07:1240b - NN1n care care **.N**s]P:u]S+]S]

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2- Numeración. Asignamos un número a cada uno de los elementos que intervienen en la relación anafórica.

Universitat d'Alacant
Universidad de Alicante

Veamos un ejemplo de texto numerado y preparado para el análisis:

Número frase	**Entidades introducidas**	**Referencia a**
21	21.1. he	(20.1.)
	21.2. Kruger's men	(2.1.)
22	22.1. he	(21.1.)
	22.2. them	(21.2.)
	22.3. everything	
	22.4. you	(16.1.)
	22.5. him	(22.1.)
23	23.1. He	(22.5.)
	23.2. your ranch	(22.4.)

En el Apéndice 2 mostramos un ejemplo de un texto con las unidades identificadas y numeradas.

3- Establecimiento de las relaciones entre expresiones anafóricas y antecedentes.

4- Estudio de la frecuencia con que aparecen en el texto cada una de las expresiones anafóricas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5- Recogida de datos con el fin de establecer la pertinencia de cada una de las fuentes de información en cada expresión anafórica.

En esta etapa del análisis, estudiamos la influencia que cada parámetro de información tiene en cada expresión anafórica y en la creación de las relaciones anáfora-antecedente.

6- Extracción de conclusiones sobre la incidencia de diferentes fuentes de información en el establecimiento de relaciones anafóricas.

6. Fuentes de información necesarias para la identificación de antecedentes.

Para determinar los criterios mínimos necesarios para identificar los antecedentes anafóricos restringimos los conocimientos necesarios a los que provienen de fuentes lingüísticas. Así pues, la información que analizamos para cada expresión anafórica y su posible antecedente es la siguiente:

a) Información sobre rasgos gramaticales: estudiamos el género, número y persona tanto del antecedente como de la expresión anafórica.

b) Información sobre rasgos sintácticos: codificamos la función que antecedente y anáfora tienen en la oración.

c) Información sobre rasgos semánticos: analizamos las posibles relaciones semánticas entre antecedente y expresión anafórica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

d) Información sobre rasgos pragmáticos[1]. En este punto estudiaremos los siguientes rasgos:

- La distancia desde la expresión anafórica al antecedente.
- La competencia o número de candidatos a antecedente.
- La prominencia del antecedente en el texto.
- La unidad o localización del antecedente y la expresión anafórica dentro de un mismo párrafo.

e) Información sobre el tipo de expresión anafórica.

Analizaremos, a continuación, cada una de las fuentes de información que intervienen en el establecimiento de las relaciones anafóricas. Veremos asimismo, cómo influye cada fuente y extraeremos reglas generales de comportamiento. De igual modo, mostraremos que los valores que estas fuentes asignan a los potenciales antecedentes no pueden considerarse absolutos ni totalmente definitivos.

7. Información gramatical.

La información gramatical extraída de cada una de las expresiones anafóricas y sus antecedentes indica que, como regla general, toda expresión anafórica debe mostrar concordancia en género, número y persona con su antecedente. Existen, sin embargo, algunos casos en los que la concordancia no se mantiene:

[1] Como puede comprobarse en el capítulo 2, apartado 4, estos rasgos están tomados de M. Ariel (1990), quien los utiliza para desarrollar la teoría de la accesibilidad sobre los antecedentes anafóricos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

a) Cuando se emplean nombres colectivos. Dada su naturaleza, éstos pueden aceptar una referencia en singular o en plural. Por ejemplo, en el texto T1a, el pronombre *they* tiene su antecedente en el nombre colectivo *tribe* y designa a los miembros del conjunto. En T1b, el antecedente de *it* es también *tribe*, pero esta vez designa al conjunto en su totalidad.

T1 a The tribe had been walking for two hours.
They were tired.

T1 b The tribe had been walking for two hours.
It was tired.

b) Cuando se utiliza como expresión anafórica un sintagma nominal que implica generalización con respecto al antecedente. Ocurre entonces, que el antecedente tiene el rasgo singular y la expresión anafórica el de plural:

T2 It was possible to make estimates of the quantum yield by observing the extent of reduction of a uranyl oxalate actinometer solution illuminated for a known time in *a typical reaction cell*... When *typical reaction cells* to which 0.3 of an atmosphere of oxygen had been added were illuminated, chlorine and phosgene were produced. [J06:1530n - J06:1630e][2]

[2] Esta numeración corresponde a la línea del corpus de donde se ha extraído el ejemplo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En T2, el número de la expresión anafórica *typical reaction cells* es plural, mientras que el número del antecedente *typical reaction cell* es singular.

c) Cuando se construye una relación anafórica con un grupo que actúa como antecedente de un individuo. En estos casos, el número del antecedente es plural y el de la expresión anafórica singular. Este es, por ejemplo, el tipo de relación que se da entre *reaction tubes* y *each tube* en el texto T3:

> T3 The contents of the manifold for liquid phase experiments were then mixed by shaking, redistributed to *the reaction tubes*, frozen down, and *each tube* was then sealed off. [J06:0740h - J06:0760n]

d) Cuando la suma de varios antecedentes en singular da como resultado una expresión anafórica en plural. En T4, *Greg, Todman, Banjo Ferguson and Walters* forman un único antecedente de la expresión en plural *them*.

> T4 A weapons carrier took *Greg, Todman, Banjo, Ferguson and Walters* the two miles from the bivouac area to the strip. It was a rough long ride through the mud and the pot holes. The sky glowered down at *them*.[N15:0110e - N15:0140t]

Como muestran todos los ejemplos expuestos, la formulación de una regla para la identificación de antecedentes debe dar cuenta no sólo de los casos generales donde antecedente y expresión anafórica comparten rasgos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

de género, número y persona, sino también de la posibilidad de que no exista tal concordancia.

Universitat d'Alacant
Universidad de Alicante

8. Información sintáctica.

La identificación de la función sintáctica que antecedente y expresión anafórica tienen en la oración nos servirá para:

a) Señalar posiciones prominentes en el discurso.
b) Analizar el papel que tienen las estructuras paralelas en la identificación de antecedentes.

Con respecto al punto (a), veremos en el apartado 10.3 la influencia que ejercen determinadas funciones sintácticas para marcar posiciones prominentes y ayudar así a identificar el antecedente. Comprobaremos entonces, cómo la función sintáctica del antecedente y la expresión anafórica resuelve, con frecuencia, la ambigüedad entre varios antecedentes.

En relación al punto (b), esto es, el papel que pueden tener las estructuras paralelas, ilustraremos la influencia de este parámetro mediante el análisis del texto T5:

T5 *Their gait* is impossible to convey in words. *It* has nothing of the proud stride of the trained runner. *It* is not a lope. *It* is not done with style or verve.
[G04:0180d - G04:0200h]

La posición del antecedente *their gait* y la de la anáfora *it* es la misma,

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

sujeto, y contribuye, por tanto, a una identificación inequívoca de la relación que existe entre ambos.

A veces, sin embargo, el empleo de las estructuras paralelas en la identificación de antecedentes no aporta información concluyente. Veamos, por ejemplo, el enunciado T6a.

T6a There was also *a dog*. Its ribs showed, it was a yellow nondescript color, it suffered from a variety of sores, hair had scabbed off its body in patches.
It lay with its head on its paws.
[G04:1020j - G04:1050j]

En T6a, los antedentes posibles de la expresión anafórica *it* pueden ser: *dog, color, hair, body*. Podríamos recurrir a diferentes tipos de información para eliminar cada uno de los candidatos erróneos, pero la información más inmediata es la que considera que *it* sólo puede tener como antecedente a *dog* puesto que las posiciones de sujeto de las oraciones anteriores están ocupadas por el mismo tipo de expresión anafórica (*it*) y su antecedente es el mismo (*dog*).

Sólo una posición de sujeto no está ocupada por el pronombre *it* y ésta se encuentra en la frase *hair had scabbed off its body in patches*, donde *hair* introduce una nueva entidad en posición de sujeto.

Existen, sin embargo, otras fuentes de información que refuerzan la elección de *dog* como antecedente por encima de *hair*. Las fuentes de información que apuntan hacia *dog* como candidato ideal son por una parte la posición temática de *dog* y , por otra, la información semántica que se

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

desprende de la mención de *head* (cabeza) y *paws* (patas).

Sería posible, de todos modos, deshacer la influencia de las mencionadas fuentes y forzar una referencia a *hair*, si cambiáramos el tipo de información semántica:

T6b It lay scattered about on the ground in tufts.

En este texto, *tufts* (mechones) introduce un tipo de información semántica que fuerza la reinterpretación de la expresión anafórica *it* y asigna como antecedente *hair*.

En cualquier caso, no debemos olvidar que la relación que los hablantes nativos[3] identifican como la más natural es la que se establece entre el pronombre *it* y *dog*.

Una vez analizados algunos de los ejemplos más característicos, podemos concluir que la regla que dé cuenta de la influencia de la estructura sintáctica de las oraciones que contienen el antecedente y la expresión anafórica debe considerar siempre que los candidatos seleccionados necesitan la confirmación de otras fuentes de información, y que nunca debe señalar valores absolutos porque, como hemos visto, pueden llevar a resultados erróneos.

[3] Agradecemos, en este sentido, la colaboración del profesor Bryn Moody del departamento de inglés de la Universidad de Alicante, quien actuó como informante en los casos más problemáticos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

9. Información semántica.

Universitat d'Alacant
Universidad de Alicante

Consideramos como regla general que siempre debe existir *consistencia semántica* en la relación anafórica. Definimos tres tipos de consistencia semántica:

a) Consistencia entre el antecedente y la expresión anafórica.
b) Consistencia entre el verbo y la expresión anafórica.
c) Consistencia dentro de la oración en la que se encuentra la expresión anafórica.

En el primer caso, la consistencia semántica entre antecedente y expresión anafórica se mantiene mediante el empleo de sinónimos, hiperónimos, relaciones del todo a una parte, del grupo al individuo y de generalización. Este tipo de consistencia semántica se manifiesta normalmente en aquellas expresiones anafóricas que tienen mayor carga léxica (descripciones definidas y descripciones introducidas por un demostrativo):

T7 *Reverend Jason* got an Indian, the Canadians the other. I saw *the clergyman* kneel for a moment.
[N04:1440i - N04:1450p]

La consistencia entre el verbo y la expresión anafórica supone que ésta última debe obedecer siempre las restricciones semánticas impuestas por el verbo. Mostramos, a continuación, un ejemplo claro del efecto que el cambio de un verbo puede tener en la asignación de antecedentes:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T8a The jury recommended that Fulton legislators act to have these laws studied and revised to the end of modernizing and improving *them*. [A01:0150g - A01:0170c]

En T8a, la identificación de *these laws* como antecedente de *them* se hace gracias a la necesidad de mantener la consistencia semántica con los verbos *improve* (mejorar) y *modernize* (modernizar). Por el contrario, si en lugar de estos dos verbos, introducimos el verbo *fulfil* (cumplir) y construimos la oración como:

T8b The jury recommended that Fulton legislators act to have these laws studied and revised to the end of fulfilling the task assigned to *them*.

el antecedente del pronombre debe ser entonces *Fulton legislators*.

Veamos ahora qué ocurre con respecto a la consistencia semántica dentro de la oración que contiene a la expresión anafórica. Este tipo de consistencia es la más compleja porque utiliza el conocimiento del mundo para poder identificar el antecedente.

Así, por ejemplo, en T9 sólo podemos identificar como antecedente de la expresión *its operating procedures* (procedimientos operativos) a *the court* (el tribunal) si sabemos que *the jury* (el jurado) no tiene *operating procedures*.

T9 The jury said it found the court has incorporated into its operating procedures... [A01:0460a - A01:0470c]

De cualquier modo, las relaciones anafóricas identificadas en el

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

corpus en las que el criterio semántico de inferencia es el definitivo para identificar el antecedente son muy poco numerosas (alrededor de un 6% del total de expresiones analizadas).

Por último, señalaremos que la influencia de la regla de consistencia semántica es definitiva para la selección inequívoca del antecente en una gran mayoría de casos, sobre todo cuando la expresión anafórica tiene gran carga léxica.

Sin embargo, es posible neutralizar la consistencia semántica de modo que no aporte ninguna información concluyente. Es entonces cuando deben actuar otras fuentes de información.

T10 The arc started to strike the anode holder instead of the porous graphite plug and that *it* became highly unstable.
[J02:1290k - J02:1310f]

En T10 los posibles antecedentes de *it* son *arc*, *anode holder* y *porous graphite plug*. Los tres candidatos mantienen consistencia semántica con la expresión anafórica por lo que no es éste un criterio que ofrezca una solución definitiva para este ejemplo. La única clave que podríamos tener sería considerar la posición temática de *arc*.

10. Información pragmática.

Los rasgos pragmáticos que estudiamos en el corpus son cuatro: distancia, competencia, prominencia y unidad.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

10.1. Rasgo de distancia.

Este criterio se basa en la distancia que existe entre la expresión anafórica y el antecedente con el cual se establece la relación anafórica. Para medir aquélla, contaremos el número de oraciones que separan la expresión anafórica de su antecedente. En la Tabla II podemos ver la distribución de las expresiones anafóricas según la distancia a la que se encuentra el antecedente.

Distancia	*Expresión anafórica*			
	Descripción definida	Descripción demostrativo	Pronombre personal	Pronombre posesivo
0	6.3%	4.4%	30.8%	**63.1%**
1	39.4%	**75.5%**	**46.8%**	27.8%
2	10%	13.3%	5.9%	3.2%
3	**44.1%**	6.6%	16.3%	5.7%
TOTAL	99.8%	99.8%	99.8%	99.8%

0 = el antecedente se encuentra en la misma oración,
1 = el antecedente se encuentra una oración antes,
2 = el antecedente se encuentra dos oraciones antes,
3 = el antecedente se encuentra más de dos oraciones antes

Tabla II

En el gráfico 1 representamos gráficamente estos datos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

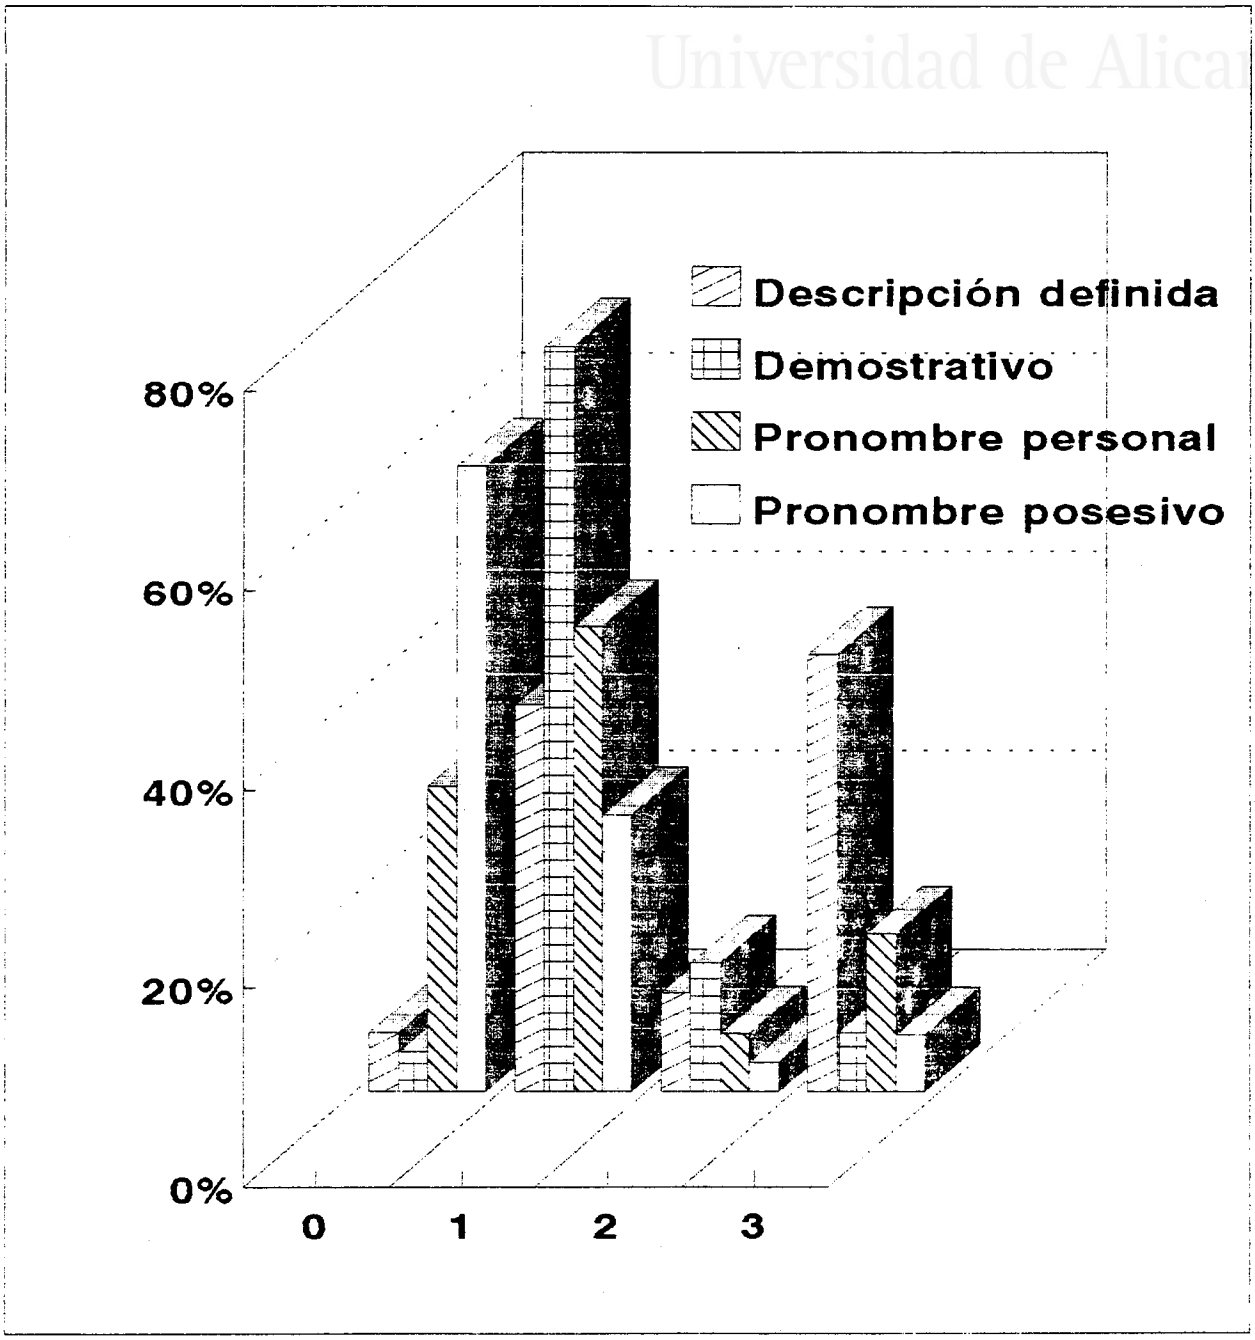


Gráfico 1

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Como podemos observar, las expresiones anafóricas que admiten mayor distancia con su antecedente son las descripciones definidas (44.1% casos con valor 3), seguidas de las descripciones introducidas por un demostrativo (75.5% casos con valor 1), los pronombres personales (46.8% casos con valor 1) y, por ultimo, los pronombres prosesivos (63.1% casos con valor 0).

El hecho de que descripciones definidas y descripciones con demostrativo permitan mayor distancia con su antecedente se debe a que son precisamente estas expresiones anafóricas las que tienen mayor carga léxica, esto es, comparten más rasgos con su antecedente y, por tanto, éste se identifica con más facilidad.

La conclusión que podemos extraer a la vista de los datos, es que mientras los pronombres permiten, en general, muy poca distancia con su antecedente, las descripciones admiten hasta más de dos frases de distancia. Podemos considerar, entonces, que el rasgo de distancia es un mecanismo de control que impide que el antecedente de una expresión anafórica se busque más lejos de lo que realmente le corresponde.

Ocurre, sin embargo, que en un porcentaje relativamente elevado de casos (16.3%) los pronombres personales identifican su antecedente a más de dos oraciones de distancia. Esto es posible cuando entre la expresión anafórica y el antecedente no se encuentra ningún otro antecedente que pueda competir[4].

[4] Veremos en el siguiente apartado la influencia del criterio de competencia.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Conviene recordar que la distancia, al igual que el resto de los criterios de identificación aquí expuestos, no ofrece nunca valores absolutos para identificar antecedentes y que su papel es siempre relativo con respecto a otros criterios que puedan ejercer mayor influencia. Lo que sí es cierto, es que la distancia evita, en muchas ocasiones, realizar una búsqueda demasiado exhaustiva.

10.2. Rasgo de competencia.

Como vimos en el capítulo segundo, apartado 4.3, el criterio de competencia permite decidir sobre el comportamiento de las expresiones anafóricas dependiendo de si tienen un único antecedente, dos antecedentes o más de dos antecedentes. Según Ariel (1990), el empleo de ciertas expresiones anafóricas está condicionado por la existencia en el discurso de un único candidato a antecedente frente a otras expresiones empleadas cuando los candidatos son varios.

Cuando existe un único antecedente, éste es altamente accesible para la expresión anafórica y, por tanto, puede emplearse como medio de referencia anafórica una expresión con poca carga léxica, como sería, por ejemplo, un pronombre. En el caso de que los antecedentes fueran varios, la expresión anafórica debe tener rasgos más marcados para que la identificación del antecedente correcto sea posible.

En el corpus analizado esta regla efectivamente se cumple y diferencia pronombres y descripciones definidas en función de su comportamiento con respecto al criterio de competencia (Tabla III).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Competencia	*Expresión anafórica*			
	Descripción definida	Descripción demostrativo	Pronombre personal	Pronombre posesivo
1	5.9%	31.1%	**88.4%**	**94.2%**
2	10.5%	13.3%	6.4%	4.1%
3	**83.6%**	**55.5%**	5.2%	1.6%
TOTAL	100%	99.9%	100%	99.9%

1 = existe un único antecedente posible
2 = existen dos posibles antecedentes
3 = existen más de dos antecedentes posibles

Tabla III

Comprobaremos más tarde que el rasgo de competencia actúa junto al rasgo de distancia y permite asignar antecedentes en los casos más simples, como, por ejemplo, en T11.

T11 *She* had been sentenced to 180 years in prison, but former Gov. Stratton commuted *her term* to 75 years.
[A20:1660e - A20:1670m]

En este texto, el único antecedente posible de *her term* es *she* ya que no existe ningún otro antecedente que pueda competir con él.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

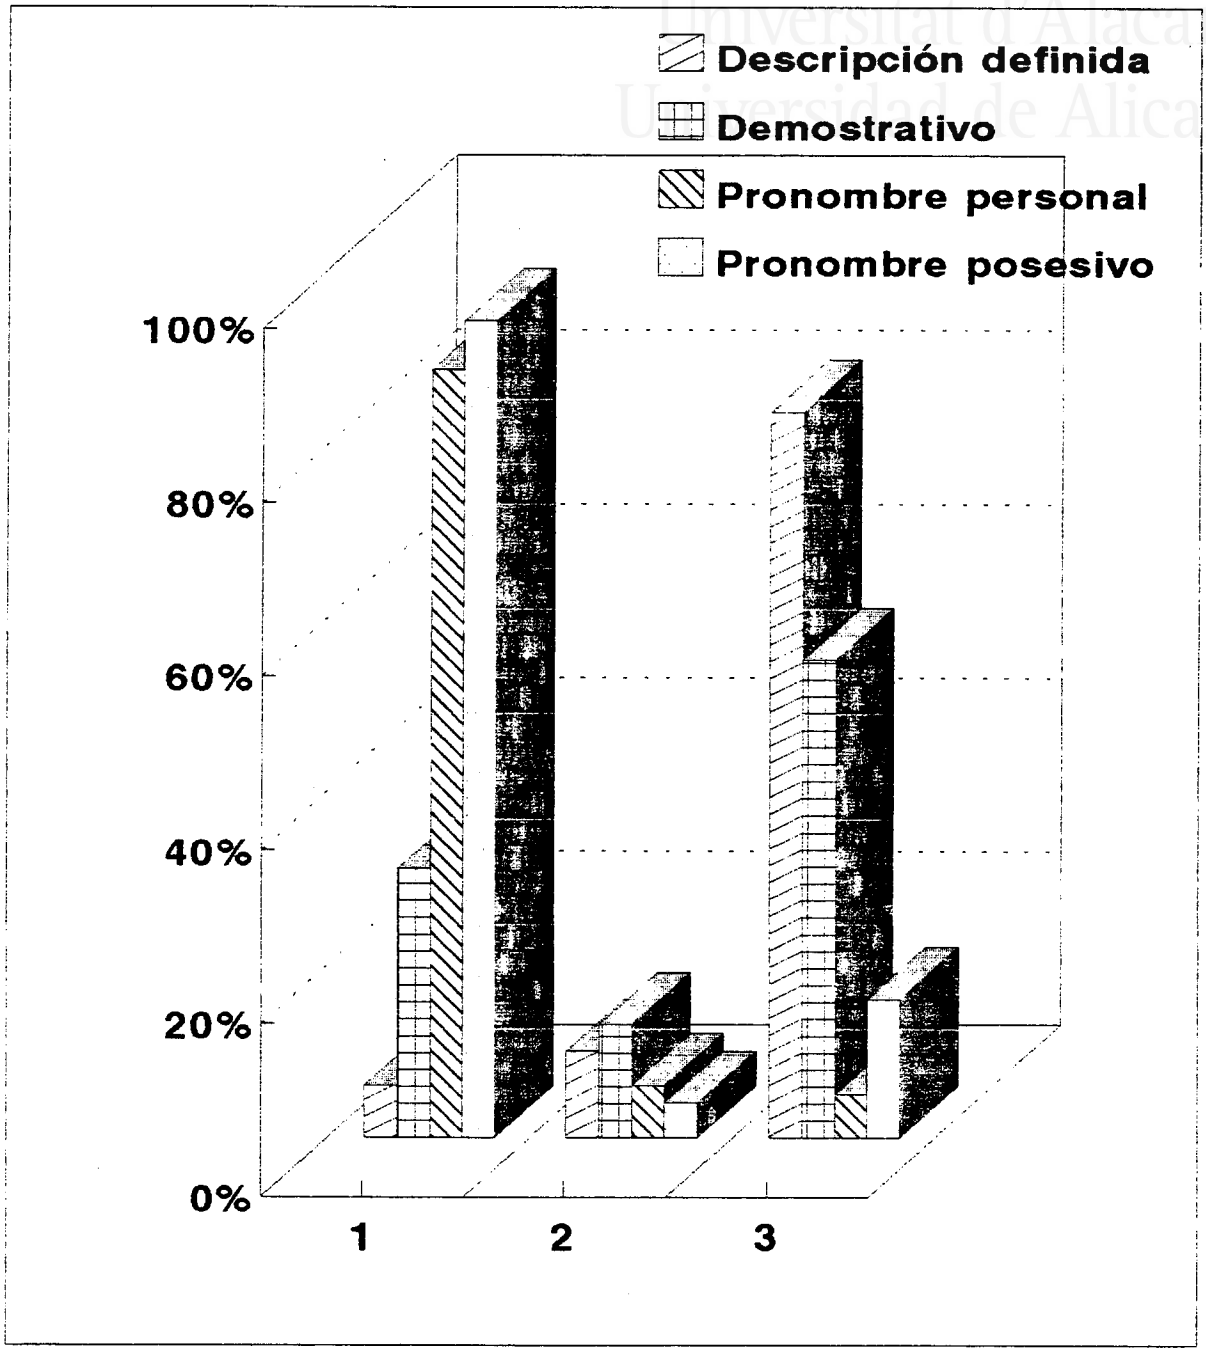


Gráfico 2

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

10.3. Rasgo de prominencia.

Mencionábamos en el apartado 8, la importancia que tiene en la identificación de antecedentes el análisis de las posiciones prominentes de las entidades discursivas.

La asignación del rasgo de prominencia a una entidad se realiza dependiendo de dos factores:

a) La función sintáctica que la entidad tenga en la oración.
b) La repetición que la entidad muestre a lo largo del texto.

Las funciones sintácticas que marcan mayor prominencia en inglés se ordenan del siguiente modo: en primer lugar el sujeto, a continuación el objeto directo y el objeto indirecto, y en último lugar los circunstanciales y los complementos regidos por el verbo.

Con respecto al criterio de repetición o recurrencia, apuntaremos que en muchas ocasiones es este criterio el que permite la identificación de un antecedente que, a pesar de no estar en posición sintáctica prominente, consigue, por repetición, hacerse prominente:

T12 ... he knew Donovan would keep his back to *the strip*... Greg rumbled down *the rough metal strip*... and the clean roar of the engine that took him off *the rough strip*... *the metal strip* they had taken off from... [N15:0330a - N15:0480m]

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En T12, desde la primera mención de *the strip* hasta la última hay once oraciones y dos párrafos de distancia y aún así es posible identificar la última mención con la primera, precisamente gracias a la repetición de la entidad a lo largo del texto.

Universitat d'Alacant
Universidad de Alicante

La regla general sobre el rasgo de prominencia predice que las expresiones anafóricas encuentran su antecedente en posiciones prominentes siempre que los criterios de concordancia gramatical y consistencia semántica lo confirmen. Así ocurre en T13, donde la regla de prominencia selecciona correctamente *this temperature* como antecedente de *it* a pesar de que los antecedentes posibles son tres: *environmental temperature*, *anode holder* y *radiation*.

T13 *This temperature* was taken as environmental temperature to which the anode holder was exposed as far as radiation is concerned. *It* is sufficiently small compared with the surface temperature of the anode holder.[J02:1610c - J02:1690a]

Sin embargo, como hemos visto en otros casos, la regla tiene una aplicación relativa y necesita la confirmación de otras fuentes de información, que incluso pueden rechazar el candidato propuesto por el rasgo de prominencia.

T14 The mean temperature of this region was approximated by the temperature measured halfways between the edge of *the hot spot* and the rim of the plug. The mean temperature of the surface was then computed according to the following relation: <formula> where x is the fraction of the plug area covered by *the hot spot*. [J02:1410h - J02:1470f]

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En este ejemplo, la posición prominente es rechazada como antecedente en favor de otra menos prominente debido al criterio de consistencia semántica entre antecedente y expresión anafórica.

Universitat d'Alacant
Universidad de Alicante

10.4. Rasgo de unidad.

Recordemos que el criterio de unidad determina el efecto que la estructura discursiva tiene en la elección de las expresiones anafóricas.

En el análisis del corpus realizado en la presente investigación, el criterio de unidad se reveló como poco importante ya que, tal como se muestra en la Tabla IV y el gráfico 3, la mayoría de las expresiones anafóricas se agrupan dentro de los valores 0 (el antecedente se encuentra en el mismo párrafo) y 1 (el antecedente se encuentra en el párrafo anterior).

Unidad	*Expresión anafórica*			
	Descripción definida	Descripción demostrativo	Pronombre personal	Pronombre posesivo
0	**60.5%**	**73.3%**	**73.9%**	**91%**
1	26.5%	22.2%	23.9%	8.1%
2	4.6%	4.4%	0.7%	0%
3	8.4%	0%	1.5%	0.8%
TOTAL	100%	99.9%	100%	99.9%

0 = el antecedente se encuentra en el mismo párrafo,
1 = el antecedente se encuentra en el párrafo anterior,
2 = el antecedente se encuentra dos párrafos antes,
3 = el antecedente se encuentra más de dos párrafos antes

Tabla IV

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

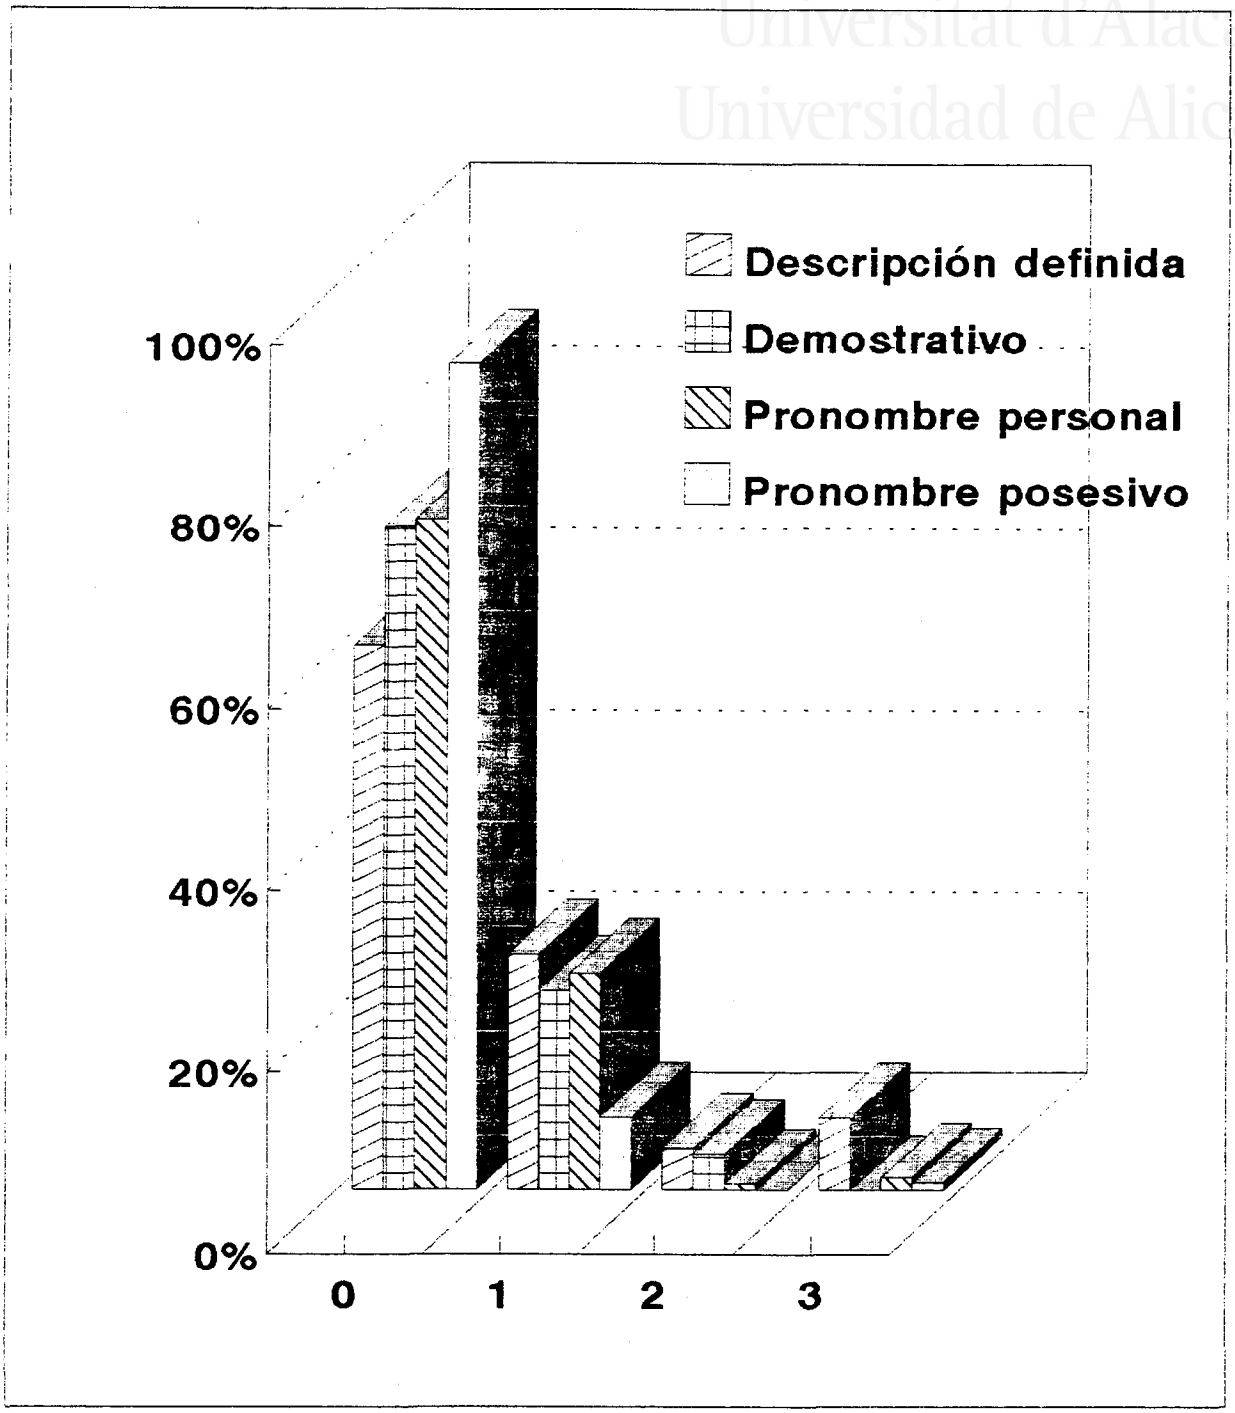


Gráfico 3

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

11. Información sobre el tipo de expresión anafórica.

Analizamos, a continuación, la relación que existe entre el tipo de expresión anafórica utilizada y la incidencia de las fuentes de información. Es importante conocer esta relación porque según el tipo de expresión anafórica que estemos tratando, la información necesaria para la identificación del antecedente será también diferente.

Mostramos en el gráfico 4 el grado de incidencia de cada una de las fuentes de información según la expresión anafórica con que tratemos.

Como podemos observar, existe una clara distribución del tipo de información entre descripciones y pronombres. Para las descripciones, el criterio que mayor incidencia tiene es el semántico y dentro de él, la sinonimia. En los pronombres, el criterio con mayor incidencia es la distancia, seguido de la información que aporta el rasgo de prominencia.

La influencia de la información semántica en la identificación de antecedentes de las descripciones se explica precisamente por las condiciones en las que se usan este tipo de expresiones anafóricas. Las condiciones son las siguientes:

a) Si hay más de un posible antecedente.
b) Si hay distancia excesiva entre antecedente y anáfora.
c) Si la posición del antecedente no es prominente y no ha tenido ningún refuerzo a lo largo del discurso.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En todos estos casos, la identificación del antecedente es más problemática y sólo la utilización del criterio de consistencia semántica permite seleccionar el antecedente correcto.

Universitat d'Alacant
Universidad de Alicante

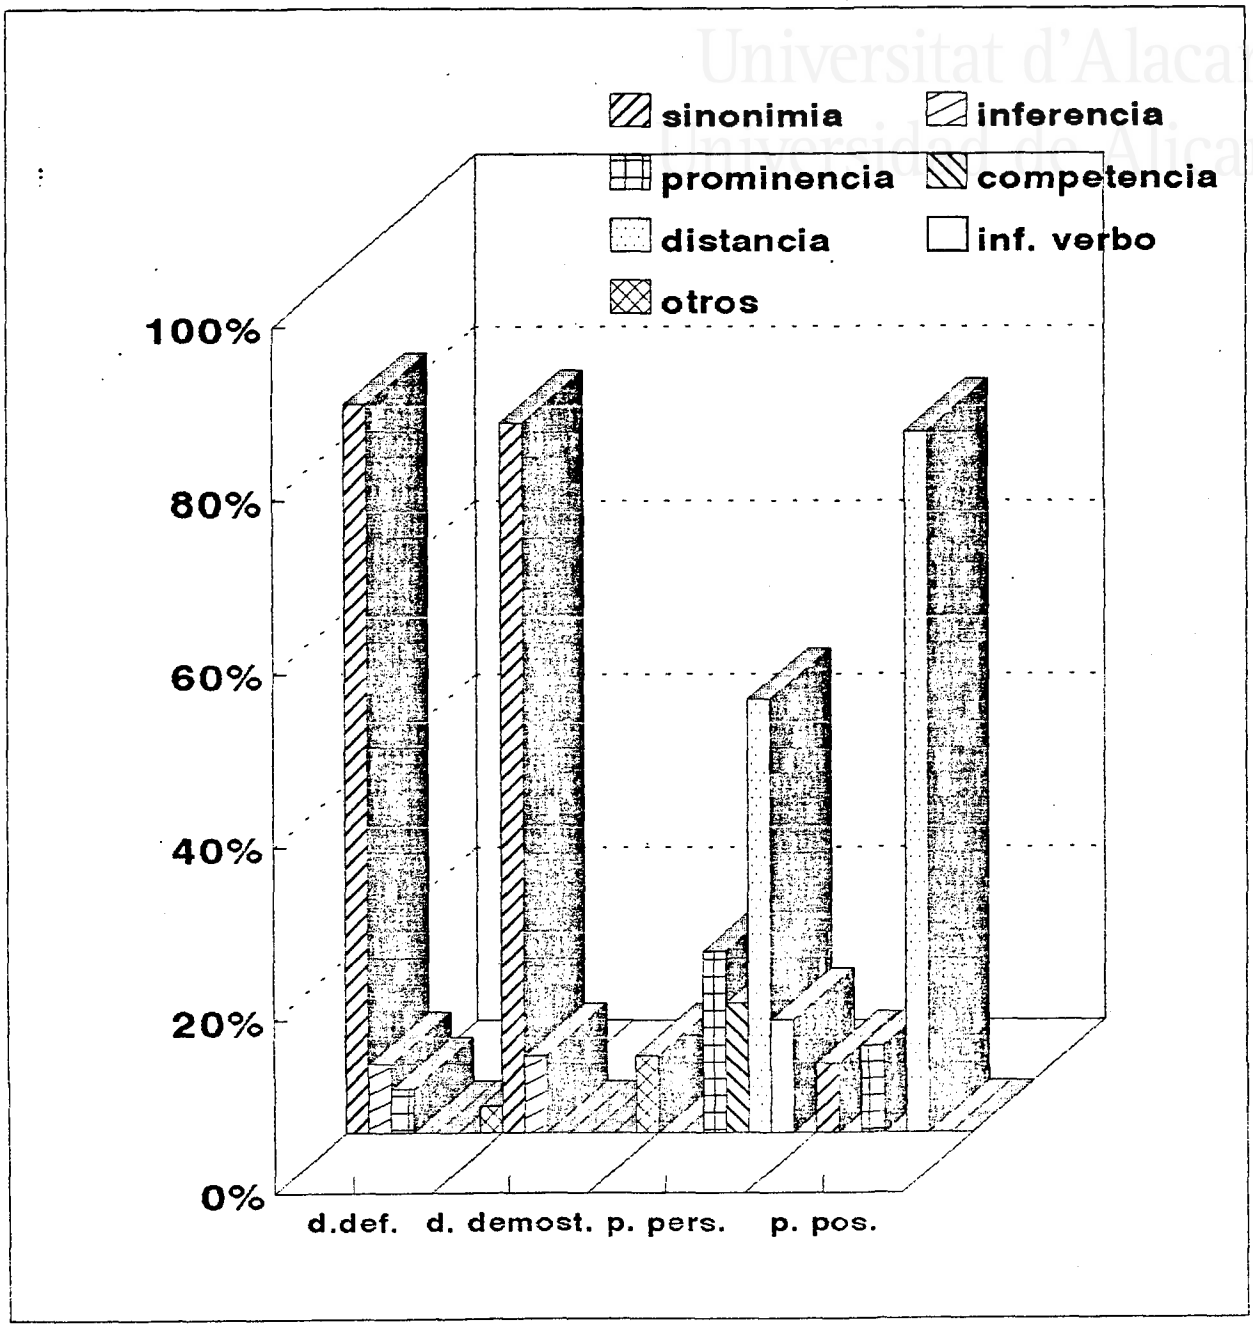
En los pronombres, sin embargo, el criterio con más influencia es el de distancia. Este rasgo de distancia actúa cuando ningún otro rasgo se impone con fuerza y selecciona como antecedente el que se encuentra a menos distancia de la expresión anafórica y mantiene la concordancia gramatical. Sin embargo, cuando hay más de un posible antecedente, el rasgo de distancia no es válido y es entonces cuando actúan rasgos como la prominencia o la información del verbo. Lo que ocurre realmente con los pronombres es que como expresiones anafóricas incorporan poca información sobre su potencial antecedente y, por tanto, cuando hay varios antecedentes posibles, necesitan otras fuentes de información que ayuden a la identificación del antecedente correcto.

Tipo de información	*Expresión anafórica*			
	Descripción definida	Descripción demostrativo	Pronombre personal	Pronombre posesivo
Sinonimia	84%	82%	0%	8%
Inferencia	8%	9%	0%	0%
Prominencia	5%	0%	21%	10%
Competencia	0%	0%	15%	0%
Distancia	0%	0%	50%	81%
Inf. verbo	0%	0%	13%	0%
Otros	3%	9%	0%	0%
TOTAL	100%	100%	99%	99.9%

Tabla V

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez



Incidencia de las fuentes de información

Gráfico 4

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

12. Conclusiones

El análisis del corpus de textos presentado en este capítulo nos ha permitido descubrir las fuentes de información necesarias para la identificación de antecedentes anafóricos así como su incidencia en las diferentes expresiones anafóricas. Los datos extraídos le dan a este estudio un carácter explicativo y predictivo al mismo tiempo. Gracias a este estudio podemos saber cuáles son las claves para la asignación de antecedentes anafóricos, cómo actúan estas claves, en qué casos y con qué incidencia, y de este modo, podemos explicar con detalle los mecanismos para el establecimiento de relaciones anafóricas. De igual manera, podemos predecir el tipo de expresión anafórica que se utilizará para determinados antecedentes, dependiendo del tipo de información con la que se cuente en cada caso.

Como hemos podido comprobar a lo largo del presente estudio, la tarea de asignación de antecedentes a las expresiones anafóricas es verdaderamente compleja. En efecto, para llegar a la identificación correcta de antecedentes son necesarias muchas y diversas fuentes de conocimiento y en cualquier caso, ninguna de ellas aporta información totalmente concluyente sobre el antecedente. En la valoración de los posibles candidatos a antecedente siempre actúan varios tipos de conocimiento y no puede decirse que exista un único criterio que supere en eficacia a los demás. Así pues, sólo mediante la coordinación de todas las fuentes de información es posible una aproximación real al problema de la anáfora. Por tanto, cualquier modelo que quiera explicar la anáfora en toda su extensión deberá tener en cuenta todas estas fuentes de conocimiento y conseguir integrarlas en una única estrategia. Sólo la conjunción de todos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

los rasgos estudiados permitirá una aproximación correcta al establecimiento de relaciones anafóricas.

Con relación al tipo de estrategia que debe utilizarse para coordinar todas estas fuentes, consideramos que la más adecuada es la «democrática» porque permite que todas la fuentes de conocimiento interactúen en la selección del antecedente, sin conceder mayor prominencia a ninguna en especial. Nuestra postura se justifica porque, tal como hemos visto a lo largo del presente capítulo, los valores que aporta cada fuente de información son siempre relativos y, por tanto, no podemos decidir de antemano qué fuente es la que aportará la información decisiva.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 5.
Coordinación de múltiples fuentes de información.

1. Introducción.

Hemos visto en el capítulo anterior que los tipos de conocimiento necesarios para identificar los antecedentes de las expresiones anafóricas son muchos y muy diversos. Hemos comprobado entonces que no puede predecirse el tipo de conocimiento que actúa en cada relación anafórica y que sólo podremos aproximarnos de manera real al problema de la identificación de antecedentes anafóricos si conseguimos coordinar dentro de un único modelo todas las fuentes de información.

En el presente capítulo describimos una estrategia de identificación y selección de antecedentes anafóricos que trata de coordinar todas las fuentes de información, y que utiliza para ello un modelo vectorial. Con el empleo de una estrategia de estas características queremos mostrar que es posible realizar un tratamiento simultáneo de la información lingüística (datos morfológicos, sintácticos, semánticos y pragmáticos), y al mismo tiempo dejar que cada fuente de información actúe en mayor o menor grado en función del tipo de relación anafórica tratada.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Así pues, describimos a continuación la estrategia adoptada para la identificación de antecedentes anafóricos. Tras apuntar los fundamentos teóricos sobre los que construímos ésta, la aplicaremos a una serie de casos reales y comprobaremos si los resultados obtenidos son los deseados.

2. La estrategia de identificación de antecedentes anafóricos.

Para coordinar todas las fuentes de información lingüística que intervienen en la identificación de antecedentes anafóricos diseñaremos un modelo de resolución anafórica en el que tengan lugar los siguientes procesos:

1- Tratamiento simultáneo de toda la información lingüística. Esta información es, como vimos, de tipo morfológico, sintáctico, semántico y pragmático.

2- Asignación de relevancia a cada fuente de información en función del contexto lingüístico. La estrategia que utilicemos no debe incidir de antemano sobre determinadas fuentes de información y debe evitar que otras fuentes queden relegadas a un segundo plano en la selección del candidato correcto.

3- Comparación en términos de igualdad de cada antecedente posible y su expresión anafórica. Nuestra intención es que todas las entidades discursivas tengan las mismas posibilidades de ser consideradas como antecedente, con lo cual evitaremos que se establezcan relaciones de preferencia *a priori* y no excluiremos ningún candidato.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los requisitos de los puntos 1 y 2, el tratamiento simultáneo de toda la información lingüística y la asignación de relevancia a las fuentes de información en función del contexto lingüístico están relacionados con el hecho de que, tal como mostramos anteriormente, no es posible predecir de manera general el tipo de información que se activa en el establecimiento de relaciones anafóricas.

En efecto, toda relación anafórica se construye en virtud de la incidencia de determinadas fuentes de información y puede ocurrir que aquellas fuentes que son válidas para un ejemplo concreto no lo sean para otro parecido. Esto es lo que sucede en los siguientes enunciados:

T1 It was *Mary* who told Jane to go to New York.
Why did *she* do it?

T2 It was Mary who told *Peter* to go to New York.
Why did *he* do it?

Comprobamos que en T1 es la información pragmática (prominencia de la entidad discursiva *Mary*) la que hace posible una relación anafórica entre *Mary* y *she*. Sin embargo, en T2, la información clave para asignar la entidad *Peter* como antecedente de *he* es la información morfológica (concordancia de género).

Con respecto al tercer punto, la comparación de los posibles antecedentes en términos de igualdad, se desprende de los puntos anteriores que no podemos pre-seleccionar ningún antecedente si no dejamos actuar ninguna fuente de información por encima de otras. Así, todas las entidades discursivas son válidas como posibles antecedentes de modo que sólo tras la aplicación de nuestra estrategia podremos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

determinar qué antecedente es el correcto.

Universitat d'Alacant
Universidad de Alicante

3. Selección de la estrategia: el producto escalar.

Se ha utilizado en los modelos *conexionistas*[1] una operación estándar, el llamado producto escalar, que nos ayudará a tratar la información en los términos expuestos. El producto escalar es una operación tomada del álgebra y se define como:

$$P1 \cdot P2 = \sum_{k=1}^{n} P1_k x P2_k$$

[1] El conexionismo es una disciplina próxima a la inteligencia artificial y la ciencia cognitiva que se ha desarrollado con éxito en los últimos años. En los sistemas conexionistas el tratamiento de la información se realiza mediante la utilización de grandes redes de unidades computacionales simples y el establecimiento de relaciones o «conexiones» entre estas unidades. La relación entre unidades se define por medio de los llamados «pesos» o patrones de actividad que se producen en el paso de una unidad a otra. Son estos patrones de actividad los que contienen la información que se obtiene como resultado final.

Los sistemas conexionistas se han utilizado para tratar problemas que exigen el procesamiento simultáneo de gran cantidad de información o en aquellos casos en que esta información no se acopla a patrones estándar, sino que corresponde a patrones similares pero nunca idénticos al estándar. Así pues, existen sistemas conexionistas que pueden reconocer y descifrar escritura manual, mientras que otros consiguen convertir texto en voz o incluso simular el comportamiento de la memoria humana para almacenar y reconocer palabras y datos relacionados entre sí pero no estructurados.

Puede encontrarse una introducción clara al conexionismo en Smith (1991). De igual modo, Fodor y Pylyshyn (1988) ofrecen una introducción crítica al tema comparándolo con las aproximaciones más «tradicionales» en inteligencia artificial.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

donde P1 y P2 son vectores[2] que tienen n elementos, $P1_k$ es el elemento k de P1 y $P2_k$ es el elemento k de P2.

Como vemos, el producto escalar opera con vectores y el resultado que se obtiene tras su aplicación es un número o escalar. Este número permite fijar la posición relativa de los dos vectores considerados, de manera que se lleve a efecto la comparación de ambos vectores.

Tomemos, por ejemplo, los vectores u y v definidos como:

u=(4,4,2)
v=(1,3,4)

El producto escalar de ambos es:

$$u \cdot v = (4x1)+(4x3)+(2x4)= 24$$

Representamos ahora los vectores u y v en un espacio de tres dimensiones:

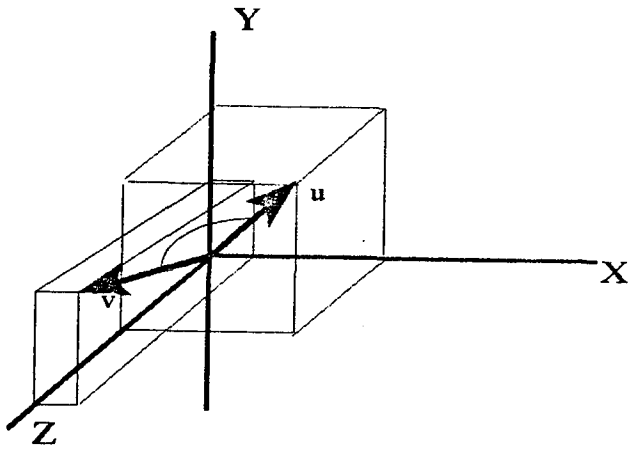


Gráfico 1

[2] Un vector es un segmento orientado que queda determinado por su magnitud, dirección y sentido AB; A origen, B extremo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para saber qué posición relativa tiene un vector respecto del otro, necesitamos conocer el ángulo θ que separa *u* de *v*. Calcularemos θ mediante la siguiente fórmula:

$$u \cdot v = \|u\| \|v\| \cos\theta$$

donde

|u| es el módulo[3] de *u*, esto es, su longitud
|v| es el módulo de *v*

Aplicamos ahora la citada fórmula y obtendremos que:

$$\cos\theta = \frac{u \cdot v}{\|u\| \|v\|} = \frac{24}{\sqrt{36} \cdot \sqrt{26}} = 0.78$$

A partir de cos θ = 0.78 podremos calcular θ y tendremos las posición del vector *u* con respecto a *v*.

---

[3] El módulo |*r*| de un vector *r* = *(x,y,z)* es:

$$\|r\| = (x^2 + y^2 + z^2)^{\frac{1}{2}}$$

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Comprobamos, entonces, que gracias al producto escalar podremos conocer el ángulo que separa un vector de otro, esto es, saber si ambos están más o menos próximos.

La pregunta que surge a continuación es la siguiente: ¿cómo podemos aprovechar esta propiedad del producto escalar para realizar un tratamiento automático del lenguaje natural? Para contestar a esta cuestión analizaremos ahora un sistema donde el producto escalar se ha utilizado como la operación básica.

El sistema al que nos referimos es PARROT, un prototipo construído por R. Sutcliffe con el objetivo de ensayar un mecanismo que produjera paráfrasis de historias o secuencias relacionadas con hechos y situaciones típicas de una casa (Sutcliffe, 1989).

En PARROT, el producto escalar es, como hemos dicho, la operación básica y se utiliza para comparar el significado de diferentes conceptos. Para ello, Sutcliffe parte de la idea de que los significados de las palabras pueden considerarse como vectores, de manera que dos palabras con el mismo significado corresponderán a vectores muy próximos y, por el contrario, dos palabras de significado diferente serán dos vectores muy distantes.

Supongamos, por ejemplo, que en el gráfico 1 el vector u define a la palabra *book*, mientras que el vector v representa a la palabra *house*. Según Sutcliffle, estas dos palabras-vectores estarían muy alejadas precisamente porque sus significados no tienen ningún rasgo en común. Sin embargo, si representáramos las palabras *book* y *magazine* con sus

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

vectores correspondientes, éstos estarían muy próximos en el espacio porque sus significados comparten muchos rasgos.

Universitat d'Alacant
Universidad de Alicante

El modo en que Sutcliffe define cada concepto consiste en atribuir a cada uno de ellos una serie de rasgos o atributos semánticos que denomina *microfeatures* (1992), y que representa como *is_edible, is_functional*, etc.

Estos atributos se aplican a cada concepto en mayor o menor medida, en función de los rasgos semánticos que lo componen y se codifican como valores numéricos. Así, por ejemplo, el concepto *book* queda definido como (Sutcliffe 111):

	book
small _size	5
made_of_paper	5
is_common	5
found_in_bookshops	10
found_in_offices	5
found_in_foodshops	0
found_in_kitchens	0
found_in_homes	5
is_functional	10
involves_information	15
is_edible	0

El conjunto de valores numéricos correspondientes a un concepto constituyen un vector, de manera que la comparación del significado de dos conceptos se puede llevar a cabo mediante el producto escalar. Así, Sutcliffe calcula la posición relativa que separa los vectores correspondientes a dos conceptos y considera que cuanto más próximos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

estén ambos, más próximos o similares son también sus significados.

Universitat d'Alacant
Universidad de Alicante

A la vista de los resultados obtenidos en la aplicación del producto escalar para el análisis semántico, pensamos que esta operación podía ser igualmente utilizada para la identificación de antecedentes en las relaciones anafóricas.

Al igual que Sutcliffe hace con las relaciones semánticas, nuestro modelo definiría las relaciones anafóricas en forma vectorial, de manera que las expresiones anafóricas y las entidades discursivas quedarían representadas por vectores. Así, para localizar el antecedente correspondiente a una determinada expresión anafórica tendríamos que examinar cada uno de los vectores de las entidades discursivas y seleccionaríamos el que estuviera más próximo.

Volvamos al gráfico 1 para ilustrar nuestra hipotesis. Consideremos que el vector u es la expresión *she*, mientras que el vector v es la entidad *peter*. Como sabemos, la referencia de *peter* a *she* es imposible y, por tanto, la distancia que separa sus vectores debe ser mucho mayor que la que exista entre el vector de *she* y el de, por ejemplo, *mary*.

Nuestra hipótesis parte, por tanto, de la suposición de que el producto escalar, por sus características y condiciones de aplicación para modelos semánticos, puede ser válido para el establecimiento de relaciones anafóricas.

Justificamos nuestra decisión porque el tipo de tratamiento de la información que se hace en PARROT es muy similar al tipo de tratamiento

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

de la información que necesita un modelo de interpretación anafórica.

Universitat d'Alacant
Universidad de Alicante

En efecto, la utilización del producto escalar como método de comparación entre los significados de dos palabras exige una descomposición de éstos en atributos que se aplican en mayor o menor grado a cada palabra. De igual modo, para la identificación de antecedentes es necesario, como vimos, una descomposición de la información lingüística en diferentes fuentes de información que se aplican en distintos grados según el contexto.

Podemos concluir, por tanto, que el producto escalar parece ser la operación adecuada para resolver el problema de la identificación del antecedente correcto en una relación anafórica. Debemos recordar, sin embargo, que la aplicación del producto escalar está condicionada por la necesidad de codificar entidades discursivas y expresiones anafóricas en forma de vectores.

4. Aplicación del producto escalar a la identificación de antecedentes anafóricos.

Tal como queda expuesto en el apartado anterior, la aplicación del producto escalar a la identificación de antecedentes anafóricos exige que tanto las entidades discursivas como las expresiones anafóricas sean consideradas como vectores. Sólo así será posible utilizar el producto escalar como método de comparación entre posibles candidatos a antecedente.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para hacer efectiva la codificación en vectores es necesario:

1- Definir un conjunto de atributos anafóricos aplicables de manera general tanto a entidades discursivas como a expresiones anafóricas. Este conjunto de atributos debe contener toda la información lingüística necesaria para consolidar una relación anafórica.

2- Establecer los grados de aplicación de cada atributo en función de la información lingüística que se extrae del antecedente y la expresión anafórica. Codificaremos los grados de aplicación mediante el empleo de valores numéricos, de manera que si un atributo se aplica en mayor grado que otro el valor correspondiente será más alto.

3- Considerar que el conjunto de atributos que definen una entidad discursiva concreta, es decir, los valores numéricos asignados, constituyen el vector que representa esa entidad. De igual modo, el conjunto de atributos y valores numéricos asignados a una expresión anafórica constituyen el vector de esa expresión anafórica. Así, el vector contendrá todas las fuentes de información codificadas con valores numéricos.

4- Comparar los vectores correspondientes a todas las entidades discursivas y el vector correspondiente a la expresión anafórica. Efectuaremos esta comparación mediante el producto escalar. El resultado que obtendremos será una lista de las entidades, ordenadas según su mayor o menor proximidad con el vector correspondiente a la expresión anafórica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5. Los atributos anafóricos.

La definición de un conjunto de atributos que contenga toda la información relevante para el establecimiento de relaciones anafóricas es uno de los pasos previos en el diseño de una estrategia que, como la que intentamos construir en el presente trabajo, efectúe un tratamiento automático de toda la información mediante el empleo de un modelo vectorial. Los requisitos que estos atributos deben cumplir, dada la función que posteriormente tendrán asignada, son los siguientes:

1- Posibilidad de codificación en forma de valores numéricos. Tal es así porque el tipo de estrategia que queremos desarrollar utiliza notación vectorial para la identificación de antecedentes y, como ya señalamos, es necesario que las entidades discursivas y las expresiones anafóricas se representen como vectores cuyos elementos son valores numéricos.

2- Uniformidad. El conjunto de atributos debe ser el mismo tanto para las expresiones anafóricas como para las entidades discursivas. Con este requisito pretendemos evitar la selección arbitraria de atributos.

3- Coherencia. La definición de los atributos anafóricos debe asegurar la consistencia en la aplicación de los mismos, con el fin de que los resultados obtenidos sean fiables. Así pues, debemos asignar los valores siguiendo siempre los mismos parámetros y criterios, independientemente de que estemos tratando con una expresión anafórica o con una entidad discursiva.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

4- Exhaustividad. El conjunto de atributos debe ser finito y abarcar todos los rasgos posibles.

5- Validez. El conjunto de atributos debe representar con exactitud el tipo de información necesaria para la identificación de antecedentes, y sólo dicha clase de información.

Para seleccionar los atributos en los términos expuestos, tomamos como base las fuentes de información extraídas del análisis del corpus, cuyos resultados quedan expuestos en el capítulo anterior. Allí explicamos cómo la coordinación de diferentes fuentes de información lingüística permite una aproximación real al problema de la identificación de antecedentes anafóricos, estudiamos estas fuentes a través de numerosos ejemplos extraídos del corpus y determinamos la influencia que cada una de estas fuentes tiene en el establecimiento de relaciones anafóricas.

Por tanto, escogimos los atributos pertinentes para la identificación de antecedentes según las fuentes de información lingüística localizadas en el corpus. Como veremos a continuación, cada fuente de información lingüística tendrá asociados una serie de atributos característicos, de manera que el conjunto de todos los atributos intenta representar el conocimiento necesario para el establecimiento de relaciones anafóricas.

Las fuentes de información lingüística y sus correspondientes atributos son:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

1- Información morfológica.

Como ya vimos en el capítulo anterior, la información de tipo morfológico tiene un papel fundamental en la selección del antecedente correcto, ya que nos ayudará a localizar como antecedente aquél cuyos rasgos morfológicos concuerdan con los de la expresión anafórica. Así pues, los atributos morfológicos que definimos son los siguientes:

género:
- neutro
- masculino
- femenino

número:
- singular
- plural

persona:
- primera
- segunda
- tercera

En general, estos atributos son suficientes para poder distinguir entre varias entidades discursivas aquélla que comparte rasgos con la expresión anafórica. Sin embargo, comprobamos en el capítulo cuarto que hay ocasiones en las que la concordancia no se mantiene y son necesarias, por tanto, otras fuentes de información para poder identificar el antecedente correcto.

Así ocurre, por ejemplo, cuando la entidad discursiva es un nombre colectivo y, por tanto, la expresión anafórica puede tener el atributo de número en singular o plural; también encontramos un problema similar

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

ante ejemplos de generalización e individualización, donde la expresión anafórica que se emplea no corresponde en número a la entidad discursiva con la que se relaciona; y, por último, cuando la suma de diferentes entidades discursivas en singular da lugar al empleo de una expresión anafórica en plural.

Comprobaremos más adelante, en el apartado 8, al probar la estrategia sobre ejemplos reales, cómo pueden solucionarse este tipo de problemas gracias a la integración de múltiples fuentes de información.

2- Información sintáctica.

La importancia de la definición de atributos sintácticos para la identificación de antecedentes viene dada por la necesidad de marcar (a) las posiciones paralelas entre entidad discursiva y expresión anafórica, y (b) las posiciones prominentes de determinadas entidades discursivas sobre otras entidades menos prominentes y, por tanto, con menos probabilidades de ser antecedente.

Ninguno de estos dos rasgos es totalmente concluyente a la hora de decidir qué antecedente le corresponde a una expresión anafórica concreta y es fácil encontrar ejemplos que contradigan lo expuesto en ambos puntos[4]. Sin embargo, recordemos que la estrategia que desarrollamos en

[4] En este sentido, Sidner (1983) apunta que el empleo de las estructuras sintácticas paralelas para la identificación de antecedentes anafóricos es un método condenado al fracaso por dos razones: «First [...] it happens at arbitrary levels of structure. Second ... recognition of parallelism is still beyond computational theory» (319). Recordemos, sin embargo, que en la presente investigación este método no se emplea aislado ya que se integra en una estrategia de coordinación de diferentes fuentes de información.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

esta investigación persigue la coordinación de diferentes fuentes de información en un único modelo sin definir *a priori* qué tipo de información es más importante en cada caso. En este sentido, la función sintáctica de entidad discursiva y expresión anafórica y la marca de posición prominente de determinadas entidades discursivas son dos tipos de información necesaria que, convenientemente relacionada con otras fuentes de información, ayuda al establecimiento satisfactorio de relaciones anafóricas.

De acuerdo con el análisis del corpus del capítulo cuarto definimos los siguientes atributos sintácticos:

sujeto

objeto:
- directo
- indirecto

complemento:
- circunstancial
- preposicional regido

3- Información semántica.

La regla fundamental que debemos tener en cuenta en la selección y definición de los atributos semánticos es la *consistencia semántica*. Como ya vimos en el capítulo anterior, la consistencia semántica puede

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

manifestarse de tres formas diferentes:

a) Entre el antecedente y la expresión anafórica. Este tipo de consistencia se mantiene mediante el empleo de sinónimos, hiperónimos, relaciones del todo a una parte, del grupo al individuo y de generalización, y asegura que los rasgos semánticos que definen a la expresión anafórica son también las mismas que caracterizan al antecedente.

b) Entre el verbo y la expresión anafórica. Se trata en este caso de mantener las restricciones de selección (*selectional restrictions*) en el establecimiento de relaciones anafóricas.

c) Consistencia semántica dentro de la oración en la que se encuentra la expresión anafórica. Este es el tipo de consistencia más difícil de formalizar, ya que obliga a tener en cuenta la información extraída del conocimiento del mundo.

El problema con el que nos encontramos a la hora de seleccionar los atributos semánticos estriba en cómo podemos definir una lista suficientemente exhaustiva de rasgos semánticos que incluya todas las relaciones semánticas posibles entre antecedente y expresión anafórica y que además tenga en cuenta los tres tipos de consistencia semántica definidos.

En efecto, la definición de estos atributos puede llegar a ser muy compleja en función del grado de profundidad que queramos alcanzar en el análisis semántico. Para evitar precisamente esta complejidad y dado

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

que el análisis semántico no es un objetivo prioritario de la presente investigación, hemos definido unos atributos mínimos de carácter general que son aplicables por igual a todas las entidades discursivas.

Así pues, los atributos definidos son los siguientes[5]:

a) Rasgos semánticos de carácter general que aseguran la consistencia entre antecedente y expresión anafórica:

humano / no humano
animado / no animado
abstracto / no abstracto
objeto / no objeto
contable / incontable
sinonimia
hiperonimia

b) Rasgos que aseguran las restricciones de selección[6].

4- Información pragmática.

La necesidad de codificar con valores numéricos la información lingüística obliga a seleccionar como atributos pragmáticos únicamente aquellos que puedan llegar a ser cuantitativamente observables y númericamente codificables. A este respecto, recordemos que en el corpus hemos estudiado la influencia de cuatro criterios pragmáticos: unidad, competencia,

[5] No se han definido atributos que aseguren la consistencia oracional porque éste es un campo todavía por explorar dentro de la lingüística computacional y, en consecuencia, no existen criterios claramente definidos que puedan ser computacionalmente válidos.

[6] Los rasgos que definen las restricciones de selección dependen del tipo de verbo con que tratemos. Por esta razón, no ofrecemos aquí ninguna lista de atributos. Sí puede encontrarse una lista de rasgos de selección en el listado del programa que aparece en el Apéndice 3.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

prominencia y distancia. Estos cuatro parámetros han sido propuestos por Ariel (1990) como base para desarrollar su teoría sobre la *accesibilidad* de las entidades discursivas y se utilizan en la presente investigación como punto de partida para descubrir los atributos pragmáticos pertinentes para la identificación de antecedentes.

Veamos, en primer lugar, los criterios de unidad y competencia. En el análisis de corpus expuesto en el capítulo cuarto se comprobó que el rasgo de unidad no es lo suficientemente significativo como para incluirlo entre los rasgos codificables. Recordemos, en este sentido, que la mayoría de las expresiones anafóricas se agrupaban dentro de los valores 0 (el antecedente se encuentra en el mismo párrafo) y 1 (el antecedente se encuentra en el párrafo anterior).

En cuanto al criterio de competencia, al igual que ocurre con el criterio de unidad, su aplicación no es relevante para la presente investigación ya que, si bien permite predecir el tipo de expresión anafórica que se utilizará dadas determinadas circunstancias, no es útil cuando se trata de seleccionar el antecedente correcto. En efecto, el hecho de que el número de posibles antecedentes sea mayor o menor no aporta información alguna acerca de cuál es el que corresponde a la expresión anafórica.

Trataremos, por último, los criterios de distancia y prominencia. Como queda expuesto en el capítulo anterior, la distancia que existe entre una expresión anafórica y su antecedente se mide por el número de oraciones que separan a la primera del segundo. Los resultados obtenidos tras el análisis del corpus son significativos y muestran una clara distribución de las expresiones anafóricas según su tendencia a encontrar

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

el antecedente en la misma oración, en una oración anterior o a una distancia mucho mayor.

Universitat d'Alacant
Universidad de Alicante

Podemos afirmar, por tanto, que la distancia es un mecanismo de control que impide que una expresión anafórica busque su antecedente más lejos de lo que le corresponde. Así ocurre, por ejemplo, en el caso de los pronombres reflexivos, cuyo alcance máximo de distancia es la cláusula en la que se encuentran.

Dividiremos el atributo de distancia en dos subatributos: distancia oracional y distancia clausal. La distancia oracional da cuenta de la posibilidad de que un antecedente se encuentre en la misma oración que su expresión anafórica correspondiente. De manera similar, la distancia clausal expresa en forma numérica la relación existente entre antecedentes y expresiones anafóricas dentro de una misma cláusula y fuera de ella.

Gracias a estos dos subatributos podemos identificar el antecedente correcto en enunciados como T3a, T3b y T4:

T3a *The teacher* thinks that Peter hates *him*.

T3b *John* is the new boy at school. The teacher thinks that Peter hates *him*.

T4 The teacher thinks that *Peter* hates *himself*.

El pronombre *him* en T3a y T3b debe tener asignado un valor de distancia que explique su necesidad de localizar un antecedente en una cláusula diferente, aunque no necesariamente en la misma oración, de modo que si marcamos *him* con estos valores conseguimos asignar el

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

antecedente correcto en ambos casos. Algo similar ocurre en T4 donde *himself* debe tener asignado un valor de distancia correspondiente a un antecedente en la misma cláusula.

Los atributos de distancia cumplen una doble función ya que, (a) por una parte indican las preferencias y requisitos de las expresiones anafóricas con respecto a sus antecedentes, y (b) por otra parte, permiten asignar las posiciones reales que ocupan las entidades discursivas en el texto.

Para ilustrar este punto, tomemos como ejemplo el texto *Mary played with the girl. She also played with Peter.* Los atributos correspondientes a la expresión anafórica *she* son, tal como los definimos en la página siguiente, «diferente oración» y «diferente cláusula». Gracias a tales atributos, conseguimos indicar que *she* prefiere un antecedente que se encuentre en una oración distinta y que, al mismo tiempo, necesita que su antecedente esté en una cláusula diferente. Estos valores serán siempre los mismos, independientemente de la posición que *she* adopte en la oración.

Con respecto a los atributos que la entidad discursiva *Mary* toma en este texto, comparamos la posición de *Mary* con la de *she* y asignamos los siguientes valores: «diferente oración» y «diferente cláusula». Sin embargo, si colocamos la misma entidad *Mary* en otro contexto sus valores de distancia cambiarán. Así, por ejemplo, en el texto *Mary thinks that she will see Peter*, mientras que *she* mantiene los mismos atributos para indicar sus restricciones y preferencias como expresión anafórica, *Mary* cambia sus valores a «misma oración» y «diferente cláusula» para mostrar su nueva

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

posición en la oración.

Por último, queda por ver el criterio de prominencia. En este sentido, apuntamos anteriormente al definir los atributos sintácticos que la identificación de antecedentes puede beneficiarse de la definición de posiciones prominentes en el discurso. Así, las entidades discursivas en posiciones prominentes serían las candidatas más claras a antecedente anafórico. Tal como queda expuesto en el capítulo anterior, las posiciones sintácticas que marcan mayor prominencia en inglés se ordenan del siguiente modo: en primer lugar el sujeto, a continuación el objeto directo y el indirecto, y en último lugar otros complementos subcategorizados por el verbo y los circunstanciales.

Una vez descritos los criterios pragmáticos de unidad, competencia, distancia y prominencia, y expuestas sus condiciones de aplicación para la investigación que nos ocupa, pasamos a definir los siguientes atributos pragmáticos:

prominencia:
alta
baja

distancia oracional:

misma oración
diferente oracion

distancia clausal:

misma cláusula
diferente cláusula

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

6. Asignación de valores numéricos a los atributos anafóricos.

Como ya apuntamos anteriormente, la aplicación del producto escalar a la identificación de antecedentes anafóricos necesita que tanto entidades discursivas como expresiones anafóricas sean consideradas como vectores. Para ello hemos descrito, en primer lugar, un conjunto de atributos anafóricos que recoge la información lingüística pertinente en el establecimiento de relaciones anafóricas. Una vez descrito este conjunto de atributos que definirá las entidades discursivas y las expresiones anafóricas, el paso siguiente consiste en conseguir codificar esta información en forma de vectores. Así pues, es necesario asignar valores numéricos a cada atributo y establecer los grados de aplicación de cada atributo con respecto a entidades discursivas y expresiones anafóricas.

Para llevar a cabo la asignación de valores numéricos a los atributos anafóricos clasificamos éstos en dos tipos dependiendo de si (a) su aplicación restringe las características que la entidad discursiva y la expresión anafórica pueden tener o si, por el contrario, (b) son atributos que no imponen ningún tipo de restricción en la relación que la entidad discursiva y la expresión anafórica puedan establecer.

Los atributos del tipo (a) se denominan *atributos restrictivos* y engloban los atributos morfológicos de género, número y persona, así como todos los atributos semánticos y el atributo pragmático de distancia clausal. Los atributos del tipo (b) reciben el nombre de *atributos no restrictivos* y pertenecen a este grupo los atributos sintácticos, la prominencia y la distancia oracional.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Gracias a esta distinción podremos dar cuenta del hecho de que, por ejemplo, una expresión anafórica cuyo género es femenino restringe su selección del antecedente a aquellas entidades discursivas cuyo género sea también femenino, mientras que la función sintáctica de esta expresión no impone ninguna restricción.

Así pues, definimos dos reglas para asignar los valores numéricos:

1- Regla de asignación de valores para los atributos restrictivos. Los atributos restrictivos pueden tomar dos valores diferentes dependiendo de si el atributo se aplica o no a la entidad en cuestión.

En general, cualquier valor superior a 0 indica que el atributo está presente en la entidad discursiva cuyo vector se está definiendo, mientras que el valor 0 se asigna a aquellos atributos que no pueden aplicarse a la entidad discursiva en cuestión.

Supongamos, por ejemplo, que estamos definiendo el vector correspondiente a la entidad *mary*. El único atributo de género que puede aplicarse a esta entidad es el de «femenino» y, por tanto, se le asignará un valor superior a 0, por ejemplo el valor 3. El resto de atributos morfológicos de género tendrán asignados, en este caso, el

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

valor 0 indicando que no se aplican a la entidad *mary*. De este modo, el vector correspondiente a *mary* tendría los siguientes valores en los atributos de género:

	mary
género	
neutro	0
masculino	0
femenino	3

Ahora bien, supongamos que queremos definir el vector correspondiente a la expresión anafórica *he*. Es necesario marcar de algún modo la diferencia que existe en la aplicación de los atributos de género de *he* con respecto a *mary* y evitar al mismo tiempo que entre la entidad *mary* y la expresión *he* pueda establecerse ningún tipo de relación anafórica. Para ello basta con asignar los valores numéricos correspondientes a cada atributo teniendo en cuenta que son atributos restrictivos y que, por tanto, debe seguirse el patrón de asignación ya expuesto. Así pues, el vector correspondiente a *he* en los atributos de género es:

	he
género	
neutro	0
masculino	3
femenino	0

De este modo se consigue, como veremos en los apartados siguientes, que al calcular el producto escalar de los vectores correspondientes a *mary* y *he*, el valor 3 del atributo femenino de *mary* quede anulado con el valor 0 del atributo femenino de *he*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2- Regla de asignación de valores para los atributos no restrictivos. Los atributos no restrictivos sólo tienen un valor posible, que será asignado sólo si se cumplen las condiciones necesarias para su aplicación y que no será asignado en caso contrario.

Tomemos, por ejemplo, la entidad discursiva *house* cuya función sintáctica es la de sujeto en el enunciado *The house is big*. Para definir el vector correspondiente a *house* es necesario dar cuenta de que su función sintáctica es la de sujeto y de que, al mismo tiempo, este hecho no restringe en modo alguno la función sintáctica de la expresión anafórica con la cual pueda establecer una relación de referencia. Así, por ejemplo, *house* puede ser antecedente del pronombre en T5 y T6:

T5 *It* is also very nice.
T6 Mary bought *it* five years ago.

La asignación de valores se realiza, por tanto, considerando un valor para cada atributo no restrictivo, de manera que este valor sea único y diferente para cada uno de los atributos. En el caso de los atributos sintácticos podrían considerarse los siguientes valores:

sujeto	4
objeto directo	3
objeto indirecto	2
complementos	1

o cualquier otro valor siempre que dentro de una misma clase de atributos no coincidiesen dos valores iguales.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volviendo ahora al ejemplo de la entidad *house*, seleccionaríamos como atributo sintáctico el valor 4 correspondiente a sujeto, y dejaríamos sin asignar el resto de atributos y sus valores puesto que no se aplican a *house* en esta ocasión. De igual modo, en T5 *it* tendría el valor 4 en su atributo sintáctico, y en T6 *it* tendría el valor 3.

A continuación, mostramos las tablas I a IV, donde definimos los valores numéricos que asignamos a los atributos restrictivos y no restrictivos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Información Gramatical		
Atributos gramaticales	**Valores correspondientes**	
Género	SI	NO
Neutro	3	0
Masculino	3	0
Femenino	3	0
Número		
Singular	2	0
Plural	2	0
Persona		
Primera	3	0
Segunda	3	0
Tercera	3	0

Tabla I
Atributos gramaticales

Información Sintáctica	
Atributos sintácticos	**Valores correspondientes**
Sujeto	4
Objeto directo	3
Objeto indirecto	2
Complementos	1

Tabla II
Atributos sintácticos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Información Semántica		
Atributos semánticos	**Valores correspondientes**	
	SI	NO
Animado	2	0
No animado	2	0
Humano	2	0
No humano	2	0
Contable	2	0
Incontable	2	0
Abstracto	2	0
No abstracto	2	0
Objeto	2	0
No objeto	2	0
Sinónimo	2	0
Restricciones selectivas (depende del tipo de verbo)	2	0

Tabla III: Atributos semánticos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Información Pragmática		
Atributos pragmáticos	**Valores correspondientes**	
Prominencia		
Alta	1	
Baja	0	
	SI	NO
Distancia clausal		
Misma cláusula	1	0
Diferente cláusula	1	0
Distancia oracional		
Misma oración	1	
Diferente oración	0	

Tabla IV: Atributos pragmáticos

7. Los vectores asociados a entidades discursivas y expresiones anafóricas.

Una vez que hemos asignado valores numéricos a los atributos anafóricos, la conversión en vectores de entidades discursivas y expresiones anafóricas es inmediata. En efecto, basta con que asignemos a cada entidad y expresión los valores correspondientes a cada atributo para que obtegamos un vector asociado a cada entidad y cada expresión. Es entonces cuando puede aplicarse el producto escalar como método de comparación y

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

selección de los candidatos a antecedente.

Sería deseable, sin embargo, que al emplear el producto escalar para comparar los vectores, los resultados obtenidos pudieran mantenerse siempre dentro de una escala fija. De este modo, conseguiríamos una comparación y contraste efectivos de los diferentes resultados, y evitaríamos que valores excesivamente altos en algunos de los elementos que componen el vector pudieran afectar al resultado final.

Es necesario, por tanto, efectuar una normalización de todos los vectores y así conseguir que el «peso» de los elementos que componen cada vector se pondere a una misma escala para todos los vectores. Los resultados obtenidos al normalizar nos permitirán disponer de vectores de igual longitud, de manera que el producto escalar de dos vectores cualquiera permanezca siempre dentro de un intervalo fijo.

La normalización de un vector se obtiene multiplicando todos sus elementos por un número determinado, de modo que el resultado de multiplicar el cuadrado de los elementos normalizados sea igual al cuadrado de una constante C, que se mantiene igual en todo el sistema.

Así pues, aplicaremos la siguiente fórmula:

$$sc=\left[\frac{C^2}{\Sigma(P_i)^2}\right]^{1/2}$$

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

donde *sc* es la constante por la que se deben multiplicar todos los elementos del vector P para normalizarlo, y C la constante del sistema.

Como resultado del proceso de normalización extraemos dos propiedades que son directamente aplicables al problema que nos ocupa. Estas propiedades son las siguientes:

a) el producto escalar de un vector consigo mismo es siempre 1.
b) el producto escalar de dos vectores es siempre menor que 1, a menos que los dos vectores sean idénticos[7].

---

[7] Ambas propiedades se demuestran del siguiente modo:

tomemos la fórmula

(1)

$$\cos\theta = \frac{v \cdot w}{\|v\|\|w\|}$$

como resulta que

$$\|v\| = \|w\| = C$$

podremos escribir la fórmula (1) como:

$$C^2 \cos\theta = v \cdot w$$

Por tanto, si tenemos que $v = w$, entonces el ángulo entre los vectores v y w será cero, de forma que *cos* θ será 1, y $v \cdot w = C^2$. Sin embargo, si $v \neq w$ entonces el ángulo entre v y w será distinto de cero y *cos* θ será menor que 1. Por tanto, $v \cdot w$ será menor que C^2.

Si suponemos que C es siempre 1, deducimos claramente las propiedades de (1) y (2).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Veamos ahora cómo influyen estas dos propiedades en la identificación de antecedentes anafóricos. Supongamos, en primer lugar, que tomamos el vector P_i asociado a la expresión anafórica a_i y calculamos el producto escalar de este vector consigo mismo, es decir, $P_i \cdot P_i$. El resultado obtenido será 1, según la propiedad (a).

Supongamos, de igual modo, que se calcula ahora el producto escalar de P_i y el vector P_k asociado a la entidad discursiva e_k , es decir $P_i \cdot P_k$. Si los vectores asociados a a_i y e_k son idénticos, el resultado del producto escalar será 1, en caso contrario , el resultado será menor que 1, tal como predice la propiedad (b), y más próximo a 1 cuanto más parecidos sean los vectores.

Así pues, la aplicación del producto escalar a la identificación de antecedentes anafóricos puede formularse del siguiente modo:

Estrategia de identificación de antecedentes anafóricos.

> La comparación de las diferentes entidades discursivas candidatas a antecedente se realizará mediante el cálculo del producto escalar de cada uno los vectores normalizados, correspondientes a cada una de las entidades, y el vector normalizado asociado a la expresión anafórica. Se seleccionará como antecedente correcto aquella entidad cuyo producto escalar esté más próximo a 1.

Veremos a continuación, en el apartado 8, la aplicación práctica del producto escalar a una serie de casos reales y comprobaremos si efectivamente esta estrategia produce los resultados deseados.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

8. Identificación de antecedentes mediante el producto escalar.

Una vez que hemos expuesto las bases teóricas sobre las que construimos la estrategia de identificación de antecedentes y hemos definido los atributos anafóricos y sus posibles valores, el paso siguiente es comprobar de manera empírica la operatividad de la estrategia. Con este fin, llevamos a cabo las siguientes operaciones:

a) Seleccionamos una serie de ejemplos típicos que representaran problemas concretos en la identificación del antecedente correcto.

b) Identificamos las entidades discursivas y expresiones anafóricas que aparecían en cada ejemplo, y asignamos los valores correspondientes a cada atributo anafórico.

c) Creamos los vectores correspondientes a cada entidad discursiva y a cada expresión anafórica.

d) Comparamos los vectores siguiendo la estrategia diseñada.

Es necesario apuntar que ejecutamos todo este proceso de manera manual ya que se consideramos que, en este primer estadio del diseño de la estrategia, debíamos comprobar su funcionamiento del modo más simple posible, antes de construir todo un programa informático para un tratamiento automático.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En efecto, la puesta en práctica de una estrategia como la que describimos aquí necesitaría acceso automático a todos los tipos de información lingüística para poder crear, también de modo automático, los vectores correspondientes a entidades discursivas y expresiones anafóricas. Sería indispensable, así pues, construir módulos de análisis morfológico, sintáctico, semántico y pragmático, sin los cuales no podríamos obtener la información necesaria para asignar valores a los atributos anafóricos y crear así los vectores correspondientes.

Ante la complejidad que el diseño de estos módulos puede suponer y dado que, como ya hemos apuntado, el objetivo principal en este momento era comprobar hasta qué punto la estrategia era válida, desarrollamos todo el proceso de modo manual, intentando evitar cualquier tipo de arbitrariedad, sobre todo en la definición de los vectores.

Para probar hasta qué punto la estrategia desarrollada es válida para identificar el antecedente correcto en una relación anafórica seleccionamos una serie de ejemplos que ilustraran la influencia de cada una de las fuentes de información en la selección del antecedente, así como la posibilidad de discriminar entre varios candidatos a antecedente gracias a la integración de estas fuentes en un único patrón.

Los ejemplos seleccionados pueden clasificarse, por tanto, en cuatro grupos en función del tipo de información que ejerce mayor influencia:

1- Influencia de la información morfológica. Tratamos ejemplos de distinción entre géneros y referencia a nombres colectivos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2- Influencia de la información sintáctica. Los ejemplos muestran la influencia de las estructuras sintácticas paralelas en el establecimiento de relaciones anafóricas.

3- Influencia de la información semántica. Tratamos ejemplos de consistencia semántica entre antecedente y expresión anafórica, consistencia verbal y sinonimia.

4- Influencia de la información pragmática. A través de los ejemplos seleccionados estudiamos la influencia de los atributos de prominencia y distancia.

8.1. Información morfológica.

a) Distinción entre entidades de diferente género. Probamos en este apartado si la aplicación de la estrategia descrita en el apartado 3 es válida para identificar el antecedente correcto, y si ayuda a seleccionar entre dos entidades discursivas aquella que concuerda en género con la expresión anafórica.

Tomemos como ejemplo T7:

T7 Mary was eating a cake. **It** was very good.

El primer paso es la conversión en vector de las entidades anafóricas *mary* y *cake* , así como de la expresión anafórica *it*, en los términos expuestos en el apartado 6. En la tabla V aparecen los valores correspondientes a estos vectores en las columnas e_1,e_2 y a . Una vez

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

obtenidos los vectores asociados a estas entidades y expresión, el paso siguiente es conseguir la normalización de los vectores. Para ello debe calcularse, tal como indicamos en el apartado 7, la constante *sc* por la cual deben multiplicarse todos los elementos de cada vector. En la tabla V aparecen las diferentes constantes obtenidas :

- la constante por la que deben multiplicarse los elementos de e_1 es

$$sc_1 = 0.15$$

- la constante por la que deben multiplicarse los elemento de e_2 es

$$sc_2 = 0.16$$

- la constante por la que deben multiplicarse los elementos de a es

$$sc_2 = 0.14$$

Los resultados obtenidos tras la normalización de e_1, e_2 y a aparecen en e_1' , e_2' y a'.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

	Entidad 1 *mary*		Entidad 2 *cake*		Anáfora *it*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a'
neutro	0	0	3	0.48	3	0.42
masculino	0	0	0	0	0	0
femenino	3	0.45	0	0	0	0
singular	2	0.3	2	0.32	2	0.28
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.45	3	0.48	3	0.42
función sintáctica	4	0.6	3	0.48	4	0.56
animado	2	0.3	0	0	2	0.28
no animado	0	0	2	0.32	2	0.28
prominencia	1	0.15	1	0.16	1	0.14
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.15	1	0.16	1	0.14
oración	0	0	0	0	0	0
	$sc_1 = 0.15$		$sc_2 = 0.16$		$sc_2 = 0.14$	

Tabla V

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Hallaremos ahora el producto escalar del vector correspondiente a la entidad *mary* y la expresión anafórica *it*, así como el producto escalar de *cake* e *it*. Los resultados son los siguientes:

$$mary \cdot it = 0.735$$
$$cake \cdot it = 0.896$$

Como podemos comprobar, los resultados indican que el vector asociado a *cake* está más próximo a *it* (valor 0.896) que el vector asociado a *mary* (valor 0.735). Podemos decir, por tanto, que el antecedente de la expresión anafórica *it* es la entidad *cake*.

Un tratamiento similar tendría T8, donde las entidades *john* y *mary* compiten como antecedentes de *he*.

T8 John and Mary went shopping. He bought a shirt.

La aplicación del producto escalar daría los siguientes resultados:

$$john \cdot he = 0.99$$
$$mary \cdot he = 0.7875$$

b) Referencia a un nombre colectivo. El problema principal con los nombres colectivos es que la expresión anafórica con la que establecen referencia puede estar tanto en singular como en plural. Por esta razón el atributo de número de un nombre colectivo tendrá que mostrar que éste puede ser tanto singular como plural.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Veamos en T9a cómo se selecciona el antecedente entre dos posibles candidatos: *Grand Jury* e *it*, de los cuales *Jury* es el nombre colectivo.

T9a The Grand Jury commented on a single topic. It also recommended to have these laws studied.

Los vectores asociados a las entidades *grand jury, single topic* y a la expresión anafórica *it* aparecen en la tabla VI.

Como puede comprobarse, los valores asignados a la entidad *grand jury* en el atributo de número son singular 2 y plural 2, consiguiendo así codificar el hecho de que esta entidad tiene número colectivo y, por tanto, acepta una expresión anafórica en singular o plural.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *grand jury*		Entidad 2 *single topic*		Anáfora *it*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	3	0.42	3	0.48	3	0.42
masculino	0	0	0	0	0	0
femenino	0	0	0	0	0	0
singular	2	0.28	2	0.32	2	0.28
plural	2	0.28	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.48	3	0.42
función sintáctica	4	0.56	3	0.48	4	0.56
animado	2	0.28	0	0	2	0.28
no animado	0	0	2	0.32	2	0.28
restricciones de selección[9]	2	0.28	0	0	2	0.28
prominencia	1	0.14	1	0.16	1	0.14
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.14	1	0.16	1	0.14
oración	0	0	0	0	0	0
	sc_1 = 0.14		sc_2 = 0.16		sc_3 = 0.14	

Tabla VI

[9] El valor 2 asignado al atributo correspondiente a las restriciones selectivas muestra la necesidad de que el sujeto del verbo *recommend*, es decir, la expresión anafórica *it*, comparta con su antecedente los mismos rasgos, en este caso el atributo de sujeto animado.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Una vez calculadas las constantes y normalizados los vectores, puede calcularse el producto escalar:

grand jury · *it* = 0.94
single topic · *it* = 0.896

Ante estos resultados, podemos afirmar que la entidad seleccionada como antecedente de *it* es, por tanto, *grand jury*.

Cambiaremos ahora la expresión anafórica utilizada en T9a por una que tiene el atributo de número plural. Comprobamos que la entidad *grand jury* sigue siendo el candidato seleccionado, a pesar de que hay otra entidad en plural (*other topics*).

T9b The Grand Jury commented on a number of other topics. They also recommended to have these laws studied.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *grand jury*		Entidad 2 *other topics*		Anáfora *they*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	3	0.42	3	0.48	3	0.36
masculino	0	0	0	0	3	0.36
femenino	0	0	0	0	3	0.36
singular	2	0.28	0	0	0	0
plural	2	0.28	2	0.32	2	0.24
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.48	3	0.36
función sintáctica	4	0.56	3	0.48	4	0.48
animado	2	0.28	0	0	2	0.24
no animado	0	0	2	0.32	2	0.24
restricciones de selección	2	0.28	0	0	2	0.24
prominencia	1	0.14	1	0.16	1	0.12
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.14	1	0.16	1	0.12
oración	0	0	0	0	0	0
	$sc_1 = 0.14$		$sc_2 = 0.16$		$sc_3 = 0.12$	

Tabla VII

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El resultado de calcular el producto escalar es:

grand jury · *they* = 0.8064
other topics · *they* = 0.768

Como conclusión de lo expuesto diremos que en T9a y T9b el atributo de número no aporta ninguna información importante para la selección del candidato puesto que tanto *grand jury* como *single topic* pueden ser antecedentes de *it* en T9a, del mismo modo que *grand jury* y *other topics* pueden ser antecedentes de *they* en T9b. En estos dos casos son otras fuentes de información las que actúan de manera decisiva: la prominencia de *grand jury* sobre *topic,* las estructuras sintácticas paralelas entre expresión anafórica y antecedente, y el atributo semántico impuesto por el verbo. Como vemos, es la integración de diferentes fuentes la que permite la selección del antecedente correcto.

8.2. Información sintáctica

En este apartado tratamos ejemplos donde la estructura sintáctica de las oraciones que contienen el antecedente y la expresión anafórica dan la clave para la identificación correcta del antecedente.

Tomemos como ejemplo T10a:

T10a Mary gave Susan an apple. John also gave her an orange.

Los valores asignados a los vectores correspondientes a *mary, susan* y *her*, y los vectores normalizados aparecen en la Tabla VIII.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *mary*		Entidad 2 *susan*		Anáfora *her*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	0	0	0	0
masculino	0	0	0	0	0	0
femenino	3	0.45	3	0.51	3	0.51
singular	2	0.3	2	0.34	2	0.34
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.45	3	0.51	3	0.51
función sintáctica	4	0.6	2	0.34	2	0.34
animado	2	0.3	2	0.34	2	0.34
no animado	0	0	0	0	0	0
restricciones de selección	0	0	0	0	0	0
prominencia	1	0.15	1	0.17	1	0.17
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.15	1	0.17	1	0.17
oración	0	0	0	0	0	0
	sc_1 = 0.15		sc_2 = 0.17		sc_3 = 0.17	

Tabla VIII

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los resultados que se obtienen al calcular el producto escalar son los siguientes:

$$mary \cdot her = 0.916$$
$$susan \cdot her = 0.922$$

El producto de *susan* y *her* está más próximo al valor 1 que el resultado del producto de *mary* y *her*. Afirmaremos, por tanto, que la entidad *susan* es el antecedente correcto para la expresión anafórica *her*.

Comparemos ahora los resultados de la identificación del antecedente en T10a con los de T10b:

T10b Mary gave Susan an apple. She also gave John an orange.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *mary*		Entidad 2 *susan*		Anáfora *she*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	0	0	0	0
masculino	0	0	0	0	0	0
femenino	3	0.45	3	0.51	3	0.45
singular	2	0.3	2	0.34	2	0.3
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.45	3	0.51	3	0.45
función sintáctica	4	0.6	2	0.34	4	0.6
animado	2	0.3	2	0.34	2	0.3
no animado	0	0	0	0	0	0
restricciones de selección	0	0	0	0	0	0
prominencia	1	0.15	1	0.17	1	0.15
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.15	1	0.17	1	0.15
oración	0	0	0	0	0	0
	$sc_1 =$ 0.15		$sc_2 =$ 0.17		$sc_1 =$ 0.15	

Tabla IX

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El producto escalar ofrece ahora los siguientes resultados:

mary · *she* = 0.99
susan · *she* = 0.916

En este caso el antecedente seleccionado es *mary*.

Como podemos observar, la estrategia diseñada consigue también identificar el antecedente correcto en aquellos casos en los que la información pertinente es la información sintáctica.

8.3. Información semántica.

La información semántica necesaria para establecer relaciones anafóricas correctas quedó resumida en el apartado 5 en tres tipos de consistencia: consistencia expresión anafórica - antecedente, consistencia verbo - expresión anafórica y consistencia oración - expresión anafórica. Trataremos aquí sólo los dos primeros tipos de consistencia y dejaremos sin estudiar el tercer tipo, ya que el estudio y formalización del conocimiento necesario para asegurar la consistencia semántica entre oración y expresión anafórica constituye en sí mismo un tema de gran complejidad que queda fuera de los objetivos marcados en la presente investigación.

a) Consistencia expresión anafórica - antecedente. La consistencia semántica entre una expresión anafórica y la entidad discursiva seleccionada como antecedente se mantiene siempre que los atributos semánticos de una y otra sean los mismos. Los atributos semánticos que hemos definido incluyen rasgos de caracter general (animado/no animado,

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

humano/no humano) y relaciones semánticas más complejas (sinonimia, hiperonimia...). Para probar si la estrategia diseñada es válida también en los casos de consistencia semántica entre una expresión anafórica y su antecedente tomaremos como ejemplo T11:

T11 Reverend Jason got an Indian, the Canadians the other. The clergyman knelt for a moment.

En la Tabla X aparecen los vectores correspondientes a las entidades discursivas identificadas y la expresión anafórica *the clergyman*, que es la que nos interesa en este caso.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *reverend jason*		Entidad 2 *indian*		Anáfora *clergyman*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	0	0	0	0
masculino	3	0.42	3	0.48	3	0.42
femenino	0	0	0	0	0	0
singular	2	0.28	2	0.32	2	0.28
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.48	3	0.42
función sintáctica	4	0.56	3	0.48	4	0.56
animado	2	0.28	2	0.32	2	0.28
no animado	0	0	0	0	0	0
sinónimo	2	0.28	0	0	2	0.28
restricciones de selección	2	0.28	2	0.32	2	0.28
prominencia	1	0.14	1	0.16	1	0.14
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.14	1	0.16	1	0.14
oración	0	0	0	0	0	0
	$sc_1 = 0.14$		$sc_2 = 0.16$		$sc_3 = 0.14$	

Tabla X

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Los resultados del producto escalar son los siguientes:

reverend jason · *the clergyman* = 1
indian clergyman = 0.9529

Como vemos, también en este caso la estrategia que hemos diseñado permite seleccionar el antecedente correcto.

b) Consistencia verbo-expresión anafórica. Este tipo de consistencia semántica se mantiene codificando en la tabla de atributos la información relativa a la restricciones de selección que impone el verbo sobre su sujeto y objeto y asignándole los valores que aseguren la consistencia.

Veamos a continuación algunos ejemplos de cómo puede tratarse este problema en el marco de la estrategia diseñada.

T12a Fulton legislators studied and revised these laws to the end of modernizing and improving them.

En T12a los verbos *modernize* e *improve* imponen la restricción de que su objeto directo sea un objeto físico y, por tanto, el único antecedente posible para la expresión anafórica *them* es *these laws*. Así lo muestra el resultado del producto escalar de los vectores correspondientes a *fulton legislators, these laws* y *them* (tabla XI).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *legislators*		Entidad 2 *laws*		Anáfora *them*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	2	0.328	2	0.28
masculino	2	0.3	0	0	2	0.28
femenino	2	0.3	0	0	2	0.28
singular	0	0	0	0	0	0
plural	2	0.3	2	0.328	2	0.28
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.45	3	0.492	3	0.42
función sintáctica	4	0.6	3	0.492	3	0.42
animado	2	0.3	0	0	2	0.28
no animado	0	0	2	0.328	2	0.28
restricciones de selección	0	0	2	0.328	2	0.28
prominencia	1	0.15	1	0.164	1	0.14
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.15	1	0.164	1	0.14
oración	1	0.15	1	0.164	0	0
	$sc_1 =$ 0.15		$sc_2 =$ 0.164		$sc_3 =$ 0.14	

Tabla XI

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los resultados del producto escalar son los siguientes:

Universitat d'Alacant
Universidad de Alicante

legislators · *them* = 0.819
laws · *them* = 0.826

Comparamos ahora T12a con T12b y comprobamos que en T12b la construcción *to assign a task* rige un complemento con el rasgo semántico de «persona». Por esta razón, limitamos la selección del antecedente a la única entidad discursiva que cumple las restricciones de selcción impuestas por el verbo, es decir, la entidad *fulton legislators* (Tabla XII).

T12b Fulton legislators studied and revised these laws studied and revised to the end of fulfilling the task assigned to them.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	Entidad 1 *legislators*		Entidad 2 *laws*		Anáfora *them*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	2	0.34	2	0.3
masculino	2	0.28	0	0	2	0.3
femenino	2	0.28	0	0	2	0.3
singular	0	0	0	0	0	0
plural	2	0.28	2	0.34	2	0.3
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.51	3	0.44
función sintáctica	4	0.56	3	0.51	1	0.15
animado	2	0.28	0	0	2	0.3
no animado	0	0	2	0.34	2	0.3
restricciones de selección	2	0.28	0	0	2	0.3
prominencia	1	0.14	1	0.17	1	0.15
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.14	1	0.17	1	0.15
oración	1	0.14	1	0.17	0	0
	sc_1 = 0.14		sc_2 = 0.17		sc_3 = 0.15	

Tabla XII

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Los resultados del producto escalar son los siguientes:

legislators · *them* = 0. 735
laws · *them* = 0. 636

Algo similar a lo que ocurre con los ejemplos T12a y T12b se encuentra en T13a y T13b:

T13a Alfred and Zohar had ice cream cones. They tasted really good.
T13b Alfred and Zohar had ice cream cones. They liked them a lot.

En ambos casos son los verbos *taste* y *like* los que imponen las restricciones de selección que fuerzan la elección del antecedente correcto (Tablas XIII y XIV).

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T13a Alfred and Zohar had ice cream cones. They tasted really good.

	Entidad 1 *alfred and zohar*		Entidad 2 *ice cream cones*		Anáfora *they*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	3	0.48	3	0.36
masculino	3	0.45	0	0	3	0.36
femenino	0	0	0	0	3	0.36
singular	0	0	0	0	0	0
plural	2	0.3	2	0.32	2	0.24
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.45	3	0.48	3	0.36
función sintáctica	4	0.6	3	0.48	4	0.48
animado	2	0.3	0	0	2	0.24
no animado	0	0	2	0.32	2	0.24
restricciones de selección	0	0	2	0.32	2	0.24
prominencia	1	0.15	1	0.16	1	0.12
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.15	1	0.16	1	0.12
oración	0	0	0	0	0	0
	sc_1 = 0.15		sc_2 = 0.16		sc_3 = 0.12	

Tabla XIII

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T13b Alfred and Zohar had ice cream cones. They liked them a lot.

	Entidad 1 *alfred and zohar*		Entidad 2 *ice cream cones*		Anáfora *they*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	3	0.492	3	0.36
masculino	3	0.42	0	0	3	0.36
femenino	0	0	0	0	3	0.36
singular	0	0	0	0	0	0
plural	2	0.28	2	0.328	2	0.24
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.492	3	0.36
función sintáctica	4	0.56	3	0.492	4	0.48
animado	2	0.28	0	0	2	0.24
no animado	0	0	2	0.328	2	0.24
restricciones de selección	2	0.28	0	0.328	2	0.24
prominencia	1	0.14	1	0.164	1	0.12
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.14	1	0.164	1	0.12
oración	0	0	0	0	0	0
	sc_1 = 0.14		sc_2 = 0.164		sc_3 = 0.12	

Tabla XIV

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Los resultados del producto escalar para el texto T13a son:

alfred and zohar · *they* = 0.813

ice cream cones · *they* = 0.8576

Para el texto T13b los resultados del producto escalar son los siguentes:

alfred and zohar · *they* = 0.8064

ice cream cones · *they* = 0.7869

8.4. Información pragmática.

Recordemos que los atributos que definimos como pertinentes para la codficación de la información pragmática son la prominencia y la distancia. Comprobaremos en este apartado hasta qué punto la estrategia diseñada es válida para tratar casos donde estos dos atributos contienen la información necesaria para identificar el antecedente correcto.

a) Prominencia. El ejemplo seleccionado para ilustrar cómo puede identificarse como antecedente la entidad discursiva que tiene la prominencia más alta es T14.

T14 Sandy walked her dog near a bull one day. It walked quietly along.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Gracias a la mayor prominencia de la entidad discursiva *her dog* es posible rechazar *a bull* como antecedente de *it* (Tabla XV).

	Entidad 1 *dog*		Entidad 2 *bull*		Anáfora *it*	
Atributos anafóricos	e_1	e_1' (e_1*sc_1)	e_2	e_2' (e_2*sc_2)	a	a_1
neutro	3	0.402	3	0.54	3	0.45
masculino	0	0	0	0	0	0
femenino	0	0	0	0	0	0
singular	2	0.328	2	0.36	2	0
plural	0	0	0	0	0	0.3
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.492	3	0.54	3	0.45
función sintáctica	3	0.492	1	0.36	4	0.6
animado	2	0.328	2	0.36	2	0.3
no animado	0	0	0	0	0	0
restricciones de selección	0	0	0	0	0	0
prominencia	1	0.164	0	0	1	0.15
distancia						
misma cláusula	0	0	0	0	0	0
dif. cláusula	1	0.164	1	0.18	1	0.15
oración	0	0	0	0	0	0
	sc_1 = 0.164		sc_2 = 0.18		sc_3 = 0.15	

Tabla XV

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Los resultados del producto escalar para el ejemplo T14 son:

$dog \cdot it = 0.984$

$bull \cdot it = 0.927$

b) Distancia. El atributo pragmático de distancia se divide, como vimos en el apartado 5, en dos subatributos: la distancia oracional y la distancia clausal. Como ya indicamos anteriormente estos dos subatributos son los que nos permitirán asignar los antecedentes correctos en las relaciones anafóricas que se dan en casos del tipo T15, T16a y T16c.

T15 The teacher thinks that Peter hates himself.

T16a The teacher thinks that Peter hates him.

T16b John is the new boy at school. The teacher thinks that Peter hates him.

El pronombre *him* en T16a y T16b debe tener asignado un valor de distancia que permita limitar la búsqueda del antecedente a las entidades dsicursivas que se encuentren en una cláusula diferente de la que contiene al propio pronombre. Por otra parte, el valor de distancia del pronombre *himself* de T16 debe marcar la necesidad de este pronombre de localizar su antecedente en la misma cláusula que lo contiene. Mostramos a continuación de qué manera se codifica esta información, cúales son los vectores correspondientes y qué resultados se obtienen al aplicar el producto escalar.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T15 The teacher thinks that Peter hates himself.

	Entidad 1 *teacher*		Entidad 2 *peter*		Anáfora *himself*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	0	0	0	0
masculino	3	0.42	3	0.42	3	0.45
femenino	0	0	0	0	0	0
singular	2	0.28	2	0.28	2	0.3
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.42	3	0.42	3	0.45
función sintáctica	4	0.56	4	0.56	3	0.45
animado	2	0.28	2	0.28	2	0.3
no animado	0	0	0	0	0	0
restricciones selectivas	2	0.28	2	0.28	2	0.3
prominencia	1	0.14	1	0.14	1	0.15
distancia						
misma cláusula	0	0	1	0.14	1	0.15
dif. cláusula	1	0.14	0	0	0	0
oración	1	0.14	1	0.14	1	0.15
	$sc_1 = 0.14$		$sc_2 = 0.14$		$sc_3 = 0.15$	

Tabla XVI

El producto escalar ofrece los resultados siguientes:

teacher · *himself*= 0.924

peter · *himself*= 0.945

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T16a The teacher thinks that Peter hates him.

	Entidad 1 *teacher*		Entidad 2 *peter*		Anáfora *him*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	a	a_1
neutro	0	0	0	0	0	0
masculino	3	0.426	3	0.426	3	0.468
femenino	0	0	0	0	0	0
singular	2	0.284	2	0.284	2	0.312
plural	0	0	0	0	0	0
primera	0	0	0	0	0	0
segunda	0	0	0	0	0	0
tercera	3	0.426	3	0.426	3	0.468
función sintáctica	4	0.568	4	0.568	3	0.468
animado	2	0.284	2	0.284	2	0.312
no animado	0	0	0	0	0	0
restricciones selectivas	2	0.284	2	0.284	2	0.312
prominencia	1	0.142	1	0.142	1	0.156
distancia						
misma cláusula	0	0	1	0.142	0	0
dif. cláusula	1	0.142	0	0	1	0.156
oración	1	0.142	1	0.142	1	0.156
	$sc_1 = 0.142$		$sc_2 = 0.142$		$sc_3 = 0.156$	

Tabla XVII

Los resultados del producto escalar son:

$$teacher \cdot him = 0.9965$$

$$peter \cdot him = 0.9744$$

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

T16b John is the new student at school. The teacher thinks that Peter hates him.

	Entidad 1 *john*		Entidad 2 *teacher*		Entidad 3 *peter*		Anáfora *him*	
Atributos anafóricos	e_1	e_1' $(e_1 x sc_1)$	e_2	e_2' $(e_2 x sc_2)$	e_3	e_3' $(e_3 x sc_3)$	a	a_1
neutro	0	0	0	0	0	0	0	0
masculino	3	0.45	3	0.447	3	0.447	3	0.492
femenino	0	0	0	0	0	0	0	0
singular	2	0.3	2	0.298	2	0.298	2	0.328
plural	0	0	0	0	0	0	0	0
primera	0	0	0	0	0	0	0	0
segunda	0	0	0	0	0	0	0	0
tercera	3	0.45	3	0.447	3	0.447	3	0.492
función sintáctica	4	0.6	4	0.596	4	0.596	3	0.492
animado	2	0.3	2	0.298	2	0.298	2	0.328
no animado	0	0	0	0	0	0	0	0
restricciones de selección	0	0	0	0	0	0	0	0
prominencia	1	0.15	1	0.149	1	0.149	1	0.164
distancia								
misma cláusula	0	0	0	0	1	0.149	0	0.164
dif. cláusula	1	0.15	1	0.149	0	0	1	0
oración	0	0	1	0.149	1	0.149	0	0
	$sc_1 = 0.15$		$sc_2 = 0.149$		$sc_3 = 0.149$		$sc_4 = 0.164$	

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

Universitat d'Alacant
Universidad de Alicante

Los resultados del producto escalar son:

$$john \cdot him = 0.984$$

$$teacher \cdot him = 0.9772$$

$$peter \cdot him = 0.9528$$

9. Conclusiones.

El objetivo principal que daba origen a este capítulo era el desarrollo de una estrategia de identificación y selección de antecedentes anafóricos que cumpliera una serie de requisitos. Estos requisitos son básicamente dos: (a) integrar todas las fuentes de información lingüística en un único patrón, (b) realizar un tratamiento simultáneo de toda la información.

Si tomamos como punto de partida estos dos aspectos, pensamos que la estrategia idónea consiste en reconstruir para nuestros fines un modelo utilizado con anterioridad para el tratamiento semántico. El método seleccionado es el *producto escalar*. Este método, como ya queda probado a lo largo del presente capítulo ha sido utilizado con éxito en el sistema PARROT.

Por lo que respecta a la operatividad del producto escalar como estrategia de identificación de antecedentes anafóricos, hemos podido comprobar que ha producido los resultados deseados al ser aplicado a casos de ambigüedad entre antecedentes, ambigüedad que hemos concentrado en cuatro tipos: morfológica, sintáctica, semántica y pragmática.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 6.
Automatización del proceso de identificación de antecedentes.

1. Introducción.

Como anticipamos en el capítulo quinto, el producto escalar se revela como una operación adecuada para identificar antecedentes anafóricos. En efecto, su operatividad ha quedado probada mediante el examen manual de diferentes ejemplos, y gracias a él hemos podido asignar el antecedente correcto en cada ocasión. Es necesario, a continuación, que experimentemos la posibilidad de automatizar todo el proceso de identificación de antecedentes, restringiendo al mínimo la intervención humana.

En este sentido, conviene recordar que el objetivo último de nuestra investigación es crear un mecanismo de identificación automática de antecedentes anafóricos, como ya quedó expuesto en el capítulo primero.

Así pues, describiremos a lo largo del presente capítulo la arquitectura general del sistema, dentro del cual destaca el producto escalar como estrategia básica de identificación de antecedentes anafóricos. El sistema consta de diferentes módulos, todos ellos independientes entre sí, que aportan la información lingüística necesaria para la localización de antecedentes. Asimismo, la operación básica, esto es, el producto escalar, queda incluído, como veremos, en otro módulo diferente.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Con relación a la citada independencia de cada módulo o componente del sistema, es fácilmente comprensible que éste sea uno de los requisitos fundamentales en cualquier sistema informático. Supongamos, por ejemplo, que el módulo sintáctico y el módulo semántico están completamente ligados el uno al otro, es decir, que no podemos hacer ningún cambio en uno de los dos sin que esta modificación afecte al otro. El resultado sería una arquitectura enmarañada, confusa, cuyos componentes no serían identificables.

A lo largo del presente capítulo mostraremos, en primer lugar, una síntesis de la estructura general del sistema. A continuación, describiremos en detalle cada uno de los módulos que contribuyen con su información a completar los rasgos lingüísticos que facilitan la localización de antecedentes. Estos módulos son los siguientes: el morfológico, el sintáctico, el semántico y el pragmático. Por último, centraremos nuestra atención en el módulo de identificación de relaciones anafóricas.

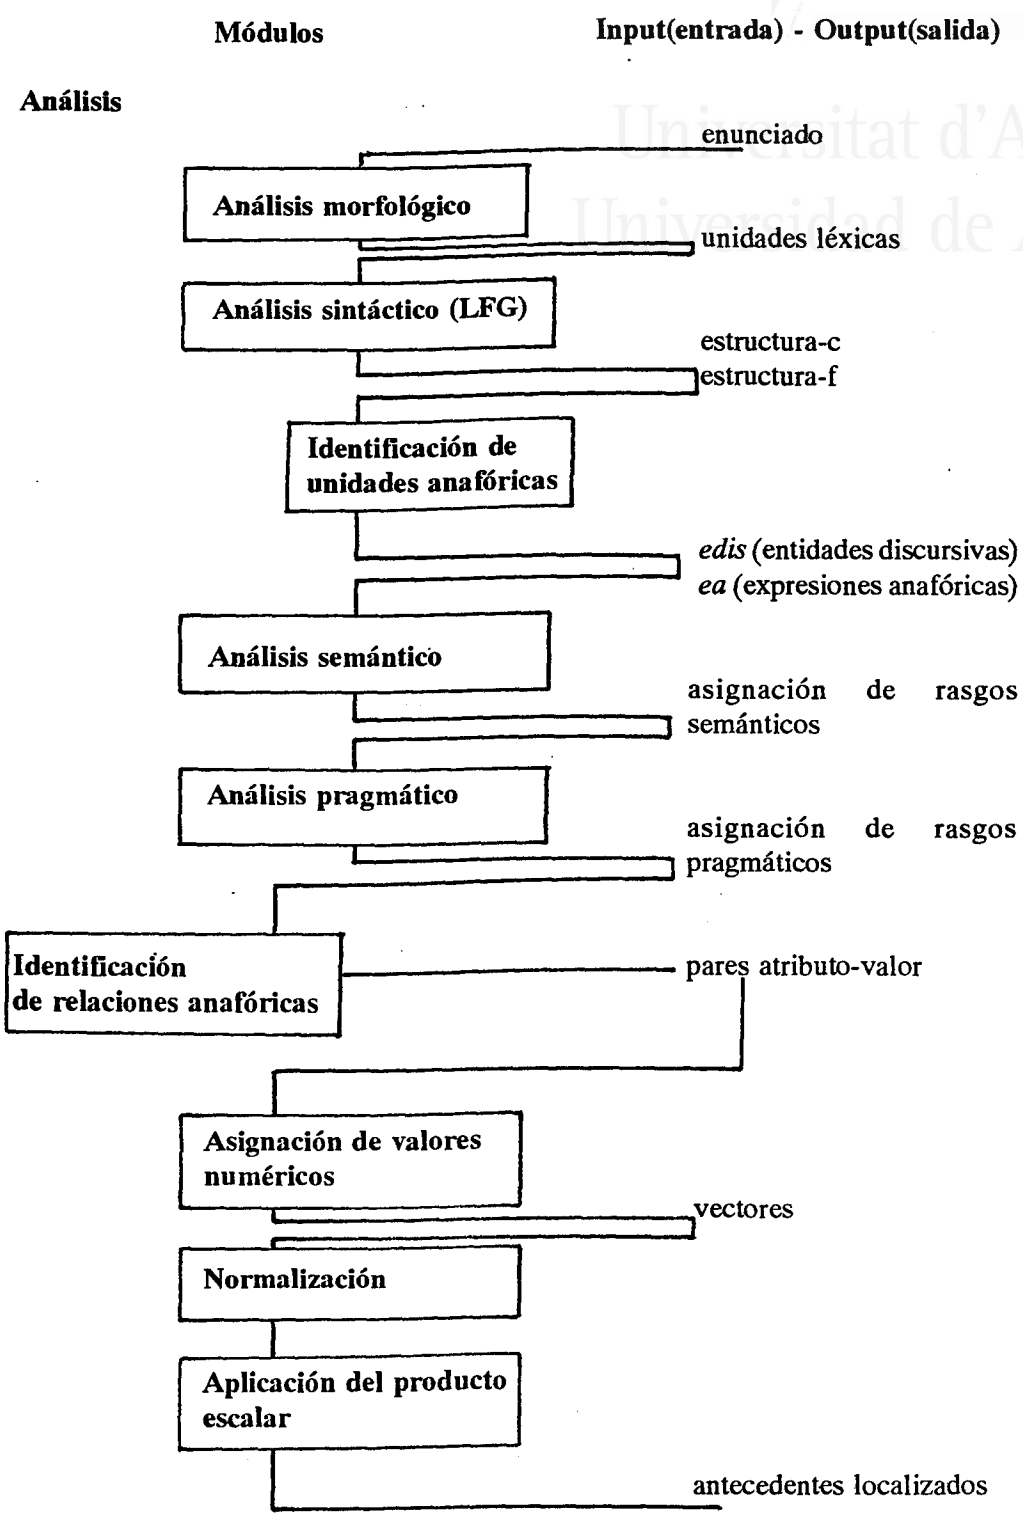
2. Estructura general.

La estructura general del sistema está formada, como ya hemos mencionado, por diferentes módulos independientes. Más adelante veremos que cada uno de ellos toma como datos de entrada los datos de salida del módulo anterior. De este modo, se consigue que, a pesar de su independencia, todos los módulos estén relacionados.

Mostramos en el Cuadro I la arquitectura general del sistema.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez



Cuadro I

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

3. Los módulos de análisis morfológico y sintáctico.

Los módulos de análisis morfológico y sintáctico que utilizamos en nuestro sistema son adaptaciones de los analizadores morfológico y sintáctico desarrollados por otros autores para aplicaciones diferentes. Así, en el caso del módulo morfológico nos basamos en el desarrollado por Gal *et al* (1991), y con respecto al módulo sintáctico adoptamos el desarrollado por Amores (1992).

Con relación a lo anterior, es preciso poner de relieve que la adopción de los citados módulos se hizo por razones de tipo práctico y teórico. En primer lugar, parece razonable utilizar elementos de otros sistemas si éstos están disponibles, y aprovechar así un trabajo investigador previo. A lo largo de nuestra investigación tuvimos acceso directo a los listados del código-fuente de los mencionados sistemas y contamos además con la información adicional facilitada por los propios autores. Por estas razones, consideramos adecuado utilizar ambos módulos para nuestros propósitos[1].

En segundo lugar, debemos considerar también la capacidad de adaptación de ambos componentes para el objetivo propuesto. A este respecto, comprobamos que éstos fueron construídos con total independencia de la aplicación en la cual se insertan y, por tanto, son módulos autónomos que pueden adaptarse fácilmente a otras aplicaciones computacionales.

[1] Queremos puntualizar que nuestro sistema contiene adaptaciones de ambos analizadores y, por tanto, existen algunas diferencias con los módulos originales. Así pues, cualquier deficiencia que pueda observarse debe atribuirse únicamente a nuestro trabajo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Junto a las razones eminentemente prácticas ya expuestas existen también motivaciones de tipo teórico que apoyan y refuerzan la selección de ambos módulos. Entre ellas destacaríamos la eficacia del tratamiento de la morfología y la sintaxis gracias a la teoría lingüística empleada. Expondremos estos puntos en detalle al tratar, por separado, los módulos morfológico y sintáctico.

Conviene ahora añadir que para constuir ambos módulos hemos empleado una DCG (*Definite Clause Grammar*), formalismo que se debe a Pereira y Warren (1980). Este formalismo permite construir gramáticas libres de contexto como código de Prolog[2] , que al mismo tiempo pueden ser compiladas como *parsers* o analizadores (Amores 113). Veremos más adelante, que en una DCG las reglas gramaticales están formadas por predicados y una serie de condiciones que deben cumplirse para que el predicado sea verdad. Al mismo tiempo, las reglas constan de unos nodos terminales y otros no terminales que expresan la información lingüística.

Para ilustrar en qué consiste una DCG tomemos, por ejemplo, la regla que dice que una oración está formada por un sintagma nominal y un sintagma verbal, esto es, O -> SN SV. Esta regla se escribiría en DCG como *o(SN,SV) --> sn(SN), sv(SV).* La parte de la izquierda establece que una oración se compone de un sintagma nominal y un sintagma verbal y esto es cierto siempre que se cumpla la condición de la parte derecha, la cual determina que debe existir un sintagma nominal así como un sintagma verbal. Comprobamos, entonces, que la codificación de reglas mediante una DCG se puede llevar a cabo de manera sencilla ya que la

[2] Prolog es un lenguaje de programación creado especialmente para el tratamiento del lenguaje natural. Fue desarrollado por Alain Colmerauer en los años setenta en la Universidad de Marsella.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

notación empleada es muy similar a la empleada en lingüística.

3.1. El módulo morfológico.

Este módulo utiliza reglas de DCG para identificar en el diccionario las palabras que corresponden a los nodos terminales de la gramática. Supongamos que estamos procesando la regla del sintagma nominal que establece que debe encontrarse un nombre propio, esto es, *np(np(NP)) --> pn(NP).* En este caso, el nodo terminal es el nombre propio (*pn*) y la regla que intenta localizarlo en el diccionario es *pn(pn(PN)) --> [PN],{lex(pn,PN)}.* El paso siguiente es identificar una entrada léxica del tipo *lex(pn,PN),* donde *pn* indica que estamos buscando un nombre propio.

Las entradas léxicas en el diccionario reciben un tratamiento diferente en función de si la palabra es flexiva o no. En el caso de que la palabra no sea flexiva, ésta se codifica con reglas del tipo:

```
lex(pn,peter).
lex(det,those).
lex(prep,with).
```

Sin embargo, para las palabras de morfología flexiva, como ocurre, por ejemplo, con los plurales de los nombres o las formas de pasado de los verbos, existen reglas que tratan estas formas sin necesidad de codificarlas directamente en el léxico. Así, para localizar la entrada *girls* basta con llamar a la regla que se encarga del tratamiento de los plurales de los nombres y se generará la palabra *girls* partiendo del singular *girl*. La regla que se emplea en este caso es:

```
lex(n,N):- plural(Sing,N),
           dic(Sing,n).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Del mismo modo, existen reglas similares para tratar la morfología de los verbos[3].

Con respecto a los rasgos morfológicos que influyen en la localización posterior de antecedentes, cada entrada léxica contiene, además de la categoría gramatical a la que pertenece, una lista con los atributos de género, número y persona así como sus valores correspondientes.

```
lex(pr,she,[pred:she,gen:femenino,pers:terc,num:sing]).

lex(pn,peter,[pred:peter,gen:masculino,
              pers:terc,num:sing]).
```

3.2. El analizador sintáctico.

Como ya apuntamos anteriormente, el módulo sintáctico que utilizamos es básicamente el que Amores (1992) construyó para su sistema de traducción automática. Además de las razones prácticas que nos movieron a adoptar este módulo y que quedan expuestas al comienzo de este apartado, existen otras de tipo teórico que contribuyen a nuestra elección.

En primer lugar, citaremos la teoría lingüística utilizada. Se trata de la gramática léxico funcional (LFG), teoría que constituye, como bien demuestra Amores, un paradigma adecuado para el tratamiento automático del lenguaje natural (94).

[3] El módulo de análisis morfológico construído en nuestro sistema no tiene la sofisticación del desarrollado por Amores (1992), quien crea un sistema morfológico completo tomando como punto de partida el trabajo de Gal *et al.* La razón que nos llevó a preferir un tratamiento sencillo por encima de uno más elaborado parte de la necesidad de centrar nuestra atención en la automatización del proceso de identificación de antecedentes.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La LFG se desarrolló a finales de los años 70 con los trabajos de J. Bresnan y R. Kaplan, quienes pretendían crear un modelo del lenguaje que fuera computacionalmente preciso y psicológicamente realista (Sells 1985: 129). En este sentido, la LFG se separa de la corriente principal de la gramática generativa al postular un modelo que aboga por una concepción según la cual en la sintaxis hay más de lo que cabe expresar mediante árboles de estructura sintagmática.

Para dar una visión general de los principios básicos de la LFG, diremos que en esta teoría se asignan dos niveles de descripción sintáctica: la estructura-c (estructura de constituyentes) y la estructura-f (estructura funcional).

La estructura-c se representa por medio de árboles de estructura sintagmática que indican la distribución superficial de una oración. Las estructuras-c se definen mediante categorías sintácticas, nodos terminales y relaciones de dominancia y precedencia, adoptando un conjunto de reglas de estructura sintagmática del tipo:

O -> SN SV

SN -> DET N

SV -> V NP NP

Estas reglas tienen asociadas las llamadas «anotaciones funcionales», que indican cómo puede construirse la estructura-f a partir de las reglas. Las anotaciones funcionales se asocian a algunos elementos de la parte derecha de las reglas y de ellos se derivan las estructuras-f. Así, por ejemplo, las reglas anteriores estarían anotadas del siguiente modo:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

O -> SN SV

(↑ SUJ)= ↓ ↑ = ↓

SV -> V NP NP

(↑ OBJ)= ↓ (↑ OBJ2)= ↓

Las metavariables hacia arriba y hacia abajo (↑ y ↓) se refieren a la estructura-f correspondiente al nudo de estructura-c construido por las reglas. El que mira hacia arriba alude a la estructura-f del nudo madre y el que mira hacia abajo alude a la estructura-f del propio nudo. Así, por ejemplo, leemos la regla para O como «el SUJeto de arriba está abajo» y «arriba está abajo», con lo que indicamos que toda la información funcional contenida en el SN va a la parte de SUJeto de la estructura-f de S, y que la información contenida en SV es información directa sobre S, es decir, que SN es el sujeto de O y que SV es la cabecera funcional.

En cuanto a la representación de las estructuras-f, éstas se construyen mediante conjuntos ordenados de pares atributo-valor, donde los atributos corresponden a las cabeceras de los constituyentes (SUBJ, OBJ, SCOMP...). Veamos, a modo de ilustración, la representación de la estructura-f para la oración *Tara paints Louise* (Sells: 137):

SUBJ [PRED 'Tara']

OBJ [PRED 'Louise']

TENSE PRES

PRED 'paint < (↑SUBJ) (↑OBJ)>'

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El objetivo de la LFG es construir representaciones de las estructuras-f de las oraciones utilizando para ello las estructuras-c y las anotaciones funcionales que éstas incluyen. Este proceso se lleva a cabo mediante la asignación de los valores que corresponden a las metavariables ↑ y ↓ y la resolución de ecuaciones funcionales. La asignación se hace de modo que las flechas que se señalan entre sí reciben la misma variable y así, mediante aproximaciones sucesivas se consiguen localizar y combinar las ecuaciones que darán lugar a las estructuras-f [4].

Amores desarrolla un analizador sintáctico que sigue los dictados de la LFG y que, por tanto, construye estructuras-c y estructuras-f de las oraciones analizadas. Para llevar a cabo esta tarea, Amores diseña dos estrategias diferentes, una para cada tipo de estructura. Así, para la estructura-c, emplea una DCG que efectúa el análisis de constituyentes, mientras que para la estructura-f, la estrategia consiste en asignar a cada constituyente una estructura de pares atributo-valor obtenida mediante un algoritmo de unificación[5].

Así, por ejemplo, para una regla como:

```
s(s(NP,VP),Fs) --> np(NP,Fnp),
                   vp(VP,Fvp), {
                   unify(Fvp,[Subj:Fnp],Fs)
                   }.
```

el proceso que se sigue consiste en encontrar una oración (s) que tenga dos

[4] No nos detenemos aquí en el desarrollo completo de todos los aspectos que componen la Gramática Léxico Funcional. Esbozamos únicamente algunas de las características básicas que facilitan la comprensión de las reglas incluídas en el analizador sintáctico que compone nuestro sistema. El lector interesado en profundizar en el estudio de la LFG encontrará una introducción en Sells (1985) y detalles más concretos en Kaplan (1982).

[5] El objetivo de la unificación es fusionar en una única estructura todos los elementos de dos expresiones, de manera que los rasgos que sean idénticos en ambas quedarán fusionados a un sólo rasgo y los que sean diferentes aparecerán como rasgos diferentes.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

constituyentes, NP y VP. A continuación, si éstos han sido identificados, se procede a la unificación de la estructura-f del sintagma verbal (Fvp) con la estructura-f del sintagma nominal (Fnp), tomado éste como el valor de sujeto (Subj) (Amores: 121).

Una vez que se ha realizado el análisis de la oración siguiendo el proceso expuesto, se obtiene como resultado una estructura de pares atributo-valor del tipo:

```
subj:'pred:'child
      gen:indefinido
      pers:terc
      num:plur
      det:num:plur
      semfeat:human
     num:plur
obj:'pred:'cake
     gen:neutro
     pers:terc
     num:plur
     det:num:plur
'pred:'buy(subj,obj)
tense:past
```

Esta estructura-f correspondería a la oración *The children bought the cakes* y en ella podemos observar dos aspectos que serán fundamentales para la posterior aplicación de nuestra estrategia de identificación de antecedentes y que constituyen dos razones más por las que adoptamos este analizador.

En primer lugar, podemos ver que en la estructura-f resultante del análisis sintáctico están presentes tanto los rasgos morfológicos que vienen del módulo anterior, como los rasgos sintácticos que ha originado el presente módulo. Todos estos rasgos serán decisivos más tarde cuando queramos seleccionar el antecedente correcto de cada expresión anafórica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En segundo lugar, la distribución ordenada de los pares atributo-valor facilitará después la asignación de valores numéricos correspondientes a cada par. Gracias a esta asignación numérica podremos convertir toda la información lingüística en vectores y aplicar el producto escalar en los términos expuestos en el capítulo quinto. Así pues, podemos pensar en estos pares atributo-valor como en un vector en potencia.

4. Identificación de unidades de análisis.

Hasta ahora sólo hemos realizado un análisis morfológico y sintáctico de la oración. El paso siguiente en nuestra estrategia es identificar las unidades de análisis con las que vamos a tratar. Estas unidades son dos: entidades discursivas (*edis*) y expresiones anafóricas (*ea*).

El predicado de Prolog que se encarga de llevar a cabo la identificación de las mencionadas unidades es **identifica/5**[6]. Este predicado toma la estructura funcional que se obtiene tras la fase de análisis sintáctico y localiza dentro de ella todas las entidades discursivas y expresiones anafóricas, y marca, al mismo tiempo, el número de oración y cláusula donde han sido localizadas.

Por ejemplo, ante las estructuras-f de los enunciados *The children bought the cakes* y *They ate them*, el predicado **identifica/5** descubriría las siguientes unidades de análisis:

[6] El valor 5 junto al predicado *identifica* indica el número de argumentos que tiene el predicado. Así, si la regla es *identifica(O,CLa,Fstructure,EDIS,EA)*, los argumentos son cinco: *O,CLA,Fstructure,EDIS* y *EA*.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
Entidades discursivas:

     [oracion : 1,clausula : 1,subj : [pred : child,
     gen:indefinido, pers : terc, num : plur]]


     [oracion : 1,clausula : 1,obj : [pred : cake,
     gen:neutro, pers : terc,num : plur]]


Expresiones anafóricas:

     [oracion : 2,clausula : 1,subj : [pred : they,
     gen : indefinido,pers : terc,num : plur]]


     [oracion : 2,clausula : 1,obj : [pred : them,
     gen : indefinido,pers : terc,num : plur]]
```

Cada una de las unidades identificadas está contenida dentro de una lista con sus rasgos correspondientes.

La estrategia de identificación recorre el enunciado de izquierda a derecha y anota en dos listas diferentes la aparición de una expresión anafórica o una entidad discursiva.

5. Extracción de información semántica.

Una vez que las entidades discursivas y las expresiones anafóricas han sido identificadas, el paso siguiente es asignar a cada una de ellas la información semántica que le corresponde.

El predicado encargado de esta tarea es **semantica/2**.

```
semantica([O,Cla,[H|T]],[X|Y]):-
     semfeat([O,Cla,H],X),
     semantica([O,Cla,T],Y).
```

En este predicado, el primer argumento, es decir, ([O,Cla,[H|T]),

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

representa la unidad anafórica a la que deben añadirse los rasgos semánticos, mientras que el segundo argumento, esto es, ([X|Y]), es la unidad anafórica más sus rasgos semánticos.

Universitat d'Alacant
Universidad de Alicante

El proceso de asignación de rasgos semánticos se lleva a cabo mediante la aplicación de una jerarquía semántica según la cual una entidad hereda todos los rasgos que le corresponden por pertenecer a un determinado grupo semántico (Amores: 54). Por ejemplo, la entidad *peter* pertenece al grupo de *humanos* y como tal le corresponde heredar las siguientes características semánticas: animado, contable, no abstracto, no objeto, no comestible.

Sin embargo, el tratamiento de los pronombres *it*, *they* y *them* es diferente debido a que no podemos determinar de antemano la pertenencia de estos pronombres a un grupo semántico concreto. Pensemos que, por ejemplo, *they* puede tener los rasgos animado, no animado, humano, no humano, objeto, no objeto y, por tanto, no podemos asignar uno u otros sin conocer antes los rasgos semánticos del antecedente con el que construye la referencia.

La solución adoptada para estos pronombres consiste en asignar los rasgos semánticos que el verbo imponga en sus restricciones de selección. La regla utilizada es la siguiente:

```
semfeat([N,Cla,Feature:Value],
      [oracion:N,clausula:Cla,Feature:T]):-
      in(pred:P,Value),
      (P==it;
       P==they;
       P==them),!,
      (in(semfeat:SF,Value),
      assert(P isa SF:yes);
      not in(semfeat:SF,Value),
      assert(P isa default:yes)),
      jerarquía_semantica(Value,P,T),retract(P isa SF:yes).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Supongamos, por ejemplo, que debemos asignar los valores semánticos al pronombre *it* en el enunciado *The dog ate it.*

Como ya hemos apuntado, el pronombre *it* necesita la información proporcionada por el verbo para saber qué rasgos semánticos le corresponden. En este caso el verbo *eat* obliga a que *it* sea comestible. Así, una vez que el primer rasgo semántico ha sido asignado, el resto de rasgos se asignan por herencia en la jerarquía semántica. El resultado que obtenemos entonces es:

```
[oracion:1,clausula:1,obj:[pred:it,gen:neutro, pers:terc,
num:sing,abstract:no,animate:no,count:yes,edible:yes,
human:no,object:no]
```

En ocasiones, sin embargo el verbo no impone ningún tipo de restricción semántica, como ocurre, por ejemplo, con el verbo *like*, cuyo objeto puede tener cualquier rasgo semántico. Para este tipo de verbos, se reserva un valor por defecto que asigna al pronombre rasgos no determinados. Así, en el enunciado *Mary likes it*, no es posible predecir qué rasgos semánticos puede tener el pronombre.

Lo que ocurre entonces es que la regla le asigna los valores por defecto. Así, cuando llegue el momento de identificar el antecedente, los valores semánticos no forzarán ninguna interpretación en especial y, por tanto, serán otras fuentes de información las que deban decidir sobre el antecedente correcto.

El resultado de aplicar esta estrategia al pronombre *it* en la oración anterior sería:

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
[oracion:1,clausula:1,obj:[pred:it,gen:neutro,pers:terc,
num:sing,abstract:yes_no,animate:yes_no,count:yes_no,
edible:yes_no,human:yes_no,object:yes_no]
```

Universitat d'Alacant
Universidad de Alicante

6. Asignación de rasgos pragmáticos.

El módulo de asignación de rasgos pragmáticos actúa inmediatamente después de la asignación semántica.

Los rasgos pragmáticos que aplicamos en nuestro sistema son dos: la distancia clausal y la distancia oracional. En el capítulo quinto apuntamos que estos dos rasgos pragmáticos nos ayudan a establecer dos restricciones: por una parte, la restricción de los pronombres reflexivos para seleccionar como antecedente únicamente entidades discursivas que se encuentren dentro de la misma cláusula que el pronombre; por otra, la necesidad de buscar el antecedente de un pronombre no reflexivo fuera de la cláusula donde aparece este último.

El predicado que lleva a cabo esta tarea es **rasgos_pragmaticos/1** y se aplica únicamente a las expresiones anafóricas. Esto es así porque el valor de distancia que tiene asignado la expresión anafórica es siempre fijo dentro de la oración o la cláusula, mientras que el valor de distancia que lleve asignado la entidad discursiva dependerá de la expresión anafórica con la que se le compare. Para llegar a la asignación de rasgos pragmáticos a las entidades discursivas tendremos que esperar al siguiente módulo, identificación de relaciones anafóricas.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

7. Identificación de relaciones anafóricas.

Llegamos con este módulo a la parte central de todo el proceso de resolución anafórica. Para explicar cómo se lleva a cabo la identificación de relaciones anafóricas analizaremos a modo de ejemplo los enunciados *The children bought the cakes* y *They ate them*, y examinaremos cada uno de los pasos que intervienen en el proceso mediante su aplicación a estos ejemplos.

En primer lugar, tomamos la primera expresión anafórica localizada por el predicado **identifica/5**. En este momento, la expresión anafórica tiene codificados como una lista de pares atributo-valor todos sus rasgos morfológicos, sintácticos, semánticos y pragmáticos. En los enunciados seleccionados, la expresión anafórica *they* obtendrá la siguiente representación:

```
[oracion : 2,clausula : 1,subj : [pred : they,
gen : indefinido,pers : terc,num : plur,
abstract:no,animate:yes, count:yes,edible:no,
human:yes,object:no,distancia1:dif_cla,
distanci2:dif_orac]]
```

A continuación, convertimos toda esta información en un vector. El predicado encargado de realizar esta tarea es **convierte/2**.

```
convierte(Expresion(N,[H|T]),Expresion(E,[V1|V2])):-
     inlist(pred:E,[H|T]),
     convierte_valor([H|T],[V1|V2]).
```

El primer argumento de este predicado, (Expresion(N,[H|T])) es la expresión anafórica con todos sus rasgos y el segundo argumento, (Expresion(E,[V1|V2]), es el vector resultante.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

La conversión en vectores se realiza mediante la asignación de valores numéricos, consultando para ello unas tablas que contienen las correspondencias numéricas para cada par atributo-valor. Mostramos aquí la tabla correspondiente a los valores para la información morfológica (el resto de tablas pueden verse en el Apéndice 3):

```
valor(restrictivo,gen:neutro,[3,0,0]).
valor(restrictivo,gen:masculino,[0,3,0]).
valor(restrictivo,gen:femenino,[0,0,3]).
valor(restrictivo,gen:indefinido,[3,3,3]).
valor(restrictivo,num:sing,[3,0]).
valor(restrictivo,num:plur,[0,3]).
valor(restrictivo,num:colectivo,[3,3]).
valor(restrictivo,pers:prim,[3,0,0]).
valor(restrictivo,pers:seg,[0,3,0]).
valor(restrictivo,pers:terc,[0,0,3]).
```

Así pues, el vector que corresponde a la expresión anafórica anterior es:

```
ea(they,[0,0,4,0,3,3,3,0,0,3,0,3,0,2,2,0,2,0,0,2,2,0,0,2,0,1,0]
```

El siguiente paso consiste en normalizar el vector resultante y de ello se ocupa el predicado **normaliza/1**. El único argumento de este predicado es el vector construído en el paso anterior y el resultado que se obtiene es un vector normalizado que se registra en la base de datos interna de Prolog para usarlo más tarde.

Una vez que hemos seleccionado la primera expresión anafórica, hemos asignado los valores numéricos correspondientes para construir su vector y éste ha sido normalizado, debemos identificar el antecedente correcto para la expresión anafórica.

Para llevar a cado esta tarea, el programa considera una por una todas la entidades discursivas y calcula la distancia real que las separa de

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

la expresión anafórica que se está tratando en ese momento. Esto se consigue gracias al predicado **calcula_distancia/1**.

```
calcula_distancia(ea(_,[O,Cla|_])):-
      call(edis(N1,[O2,Cla2|T2])),
      oracion(O,O2,O3),
      clausula(Cla,Cla2,Cla3),
      append(Cla3,O3,Dist),
      append([O2,Cla2|T2],Dist,T3),
      convierte(edis(N1,T3),edis(n2,T4)),
      normaliza(edis(N2,T4), fail.
```

Calcula_distancia/1 toma la primera entidad discursiva que existe en la base de datos interna de Prolog y a continuación comprueba cuál es la distancia oracional y clausal de la entidad discursiva con respecto a la expresión anafórica. Después convierte la entidad discursiva en un vector y lo normaliza.

Una vez que la distancia ya ha sido asignada a todas las entidades discursivas, los pares atributo- valor de todas ellas están ya completos y se puede proceder a la comparación de estas entidades con la expresión anafórica para así localizar el antecedete correcto. Esta comparación se lleva a cabo mediante el producto escalar que, como ya definimos en el capítulo quinto, constituye la base central de la estrategia de identificación de antecedentes.

El resultado final es una lista ordenada de las entidades discursivas en función de si el valor obtenido al aplicar el producto escalar es más o menos próximo al valor 1. En este sentido, recordaremos que, según la estrategia desarrollada en el capítulo quinto, consideramos como antecedente correcto de una expresión anafórica áquel cuyo producto escalar esté más próximo a 1.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

En los enunciados que tomamos como ejemplo el resultado final sería el siguiente:

Universitat d'Alacant
Universidad de Alicante

```
ANTECEDENTE DE   pred:them
      pred:cake (0.8643)
  Antecedentes rechazados:
      pred:child (0.8371)

ANTECEDENTE DE   pred:they
      pred:child (0.9883)
  Antecedentes rechazados:
      pred:cake (0.7041)
```

8. Conclusiones.

La automatización del proceso de identificación de antecedentes es una tarea compleja, tal como hemos podido comprobar a lo largo de la presente tesis. Sin embargo, no es una empresa impracticable y así lo hemos mostrado en este capítulo.

En efecto, es posible acceder automáticamente a las fuentes de información gramatical, sintáctica, semántica y pragmática, construir vectores a partir de la información obtenida y, por último, identificar el antecedente correcto en una relación anafórica. Para conseguir los resultados deseados, hemos construido diferentes módulos para cada fase del proceso.

En primer lugar, adaptamos un analizador morfológico (Gal *et al*, 1991) que nos permitiera el acceso a la información sobre género, número

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

y caso de las palabras codificadas en el diccionario. A continuación, adaptamos también un *parser* o analizador sintáctico (Amores, 1992) para poder asignar funciones gramaticales dentro de la oración. El siguiente módulo es el semántico, cuya función es determinar los rasgos semánticos de las entidades discursivas identificadas en la oración. En cuanto al conocimiento pragmático, existe, como vimos, un módulo diferente para este tipo de información, cuya tarea es determinar la distancia y prominencia de las entidades discursivas.

Una vez que las fuentes de información lingüística han aportado todos los datos requeridos, el proceso de identificación de antecedentes anafóricos se centra en la aplicación del producto escalar como estrategia de selección de candidatos. Así pues, construímos también un nuevo módulo que realizase este trabajo y que ofreciera como resultado el antecedente correcto.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Capítulo 7.
Evaluación del producto escalar como estrategia de identificación de antecedentes.

1. Introducción.

La aplicación del producto escalar tenía como objetivo fundamental la coordinación de las múltiples fuentes de información lingüística que intervienen en la localización de relaciones anafóricas.

Con el empleo de una estrategia de estas características pretendíamos mostrar la posibilidad de llevar a cabo un tratamiento simultáneo de toda la información lingüística necesaria para identificar correctamente un antecedente. En este sentido, hemos visto en el capítulo anterior, que efectivamente es posible construir un sistema de resolución anafórica tomando como núcleo central el producto escalar.

Llegado este punto, se plantea la cuestión de determinar la validez del modelo propuesto.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Para ello, realizaremos, a lo largo de este capítulo, una evaluación de aquél según los siguiente criterios:

a) Estudio y justificación de la aproximación computacional adoptada. En este apartado comprobaremos si la adopción de un enfoque democrático, frente a los enfoques tradicional y consultivo (véase capítulo 3), está justificada.

b) Alcance lingüístico. Se trata, en este caso, de conocer los tipos de anáfora que pueden ser resueltos por el sistema.

c) Precisión. Analizaremos aquí la exactitud de los resultados obtenidos en la localización de antecedentes.

d) Posibilidad de valorar los resultados con mayor o menor dificultad.

e) Sencillez de las estructuras y mecanismos empleados.

f) Poder explicativo. Comprobaremos hasta qué punto la estrategia diseñada permite relacionar la anáfora con otros aspectos de la lengua, o si, por el contrario, se limita a utilizar conceptos relevantes sólo para este fenómeno.

g) Limitaciones.

h) Posibilidad de actualización y ampliación.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

2. Estudio y justificación de la aproximación computacional adoptada.

Universitat d'Alacant
Universidad de Alicante

Como recordaremos, en el capítulo tercero habíamos descrito algunas de las principales aproximaciones computacionales al problema de la anáfora. Éstas se clasificaban en tres tipos: el tradicional, el «consultivo» y el «democrático». Tras el análisis de las relaciones anafóricas contenidas en un corpus, concluimos que el enfoque más adecuado parecía ser el democrático ya que ofrecía la posibilidad coordinar todas las fuentes de conocimiento necesarias para la identificación de antecedentes.

Así pues, decidimos adoptar una aproximación democrática para el diseño de nuestra estrategia. El paso siguiente, entonces, era encontrar el modo de coordinar múltiples fuentes de información lingüística de modo que todas ellas pudieran intervenir por igual en la selección del antecedente correcto. Para ello, tomamos como punto de referencia la construcción de un modelo de inspiración vectorial cuya operación central es el producto escalar.

Ahora bien, ¿es realmente cierto que esta operación permite un tratamiento democrático de la información lingüística? La respuesta parece ser afirmativa ya que el producto escalar no impone por sí mismo ninguna restricción o preferencia a la hora de seleccionar el antecedente.

En efecto, gracias a la aplicación del producto escalar podemos comparar en términos de igualdad los vectores asociados a las entidades discursivas y las expresiones anafóricas sin influir de antemano en la selección final. En este sentido, podemos pensar en el producto escalar

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

como en una operación independiente de la aplicación para la que se utiliza.

Universitat d'Alacant
Universidad de Alicante

Donde sí puede surgir, sin embargo, alguna duda, es en el proceso de asignación de valores numéricos a los atributos anafóricos. Como vimos, es necesario realizar esta asignación para que la información lingüística pueda ser tratada como un vector. A este respecto, recordemos que habíamos definido una serie de tablas con los valores numéricos que cada atributo debía recibir.

A diferencia de otros sistemas democráticos (Carbonell y Brown, 1988) donde las preferencias y restricciones se codifican como reglas independientes, en nuestro sistema las preferencias están codificadas directamente en las tablas de valores, por ejemplo, en las funciones sintácticas donde se otorga mayor prominencia a la posición de sujeto. Es en este punto donde pueden aparecer las mayores críticas puesto que la obtención de resultados satisfactorios depende de la codificación de los valores en las tablas y éstas han sido construidas de manera manual. Así pues, este tipo de codificación puede inducir a la sospecha de que fijamos los valores de manera arbitraria con la intención de obtener los resultados deseados.

Con relación a esta cuestión, apuntaremos que, si bien los valores se han determinado manualmente, no existe arbitrariedad en ello puesto que su asignación es el fruto de un trabajo exhaustivo sobre el corpus descrito en el capítulo cuarto. El método empleado consistía en asignar unos valores originales, experimentar los resultados obtenidos con ellos y ajustar cada valor en función de los errores cometidos en la selección del

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

antecedente. Sería deseable sin embargo, que en versiones posteriores del sistema, se probara con métodos conexionistas que asignaran automáticamente estos valores[1].

Universitat d'Alacant
Universidad de Alicante

3. Alcance lingüístico.

A la hora de analizar el alcance lingüístico de la estrategia propuesta debemos distinguir entre las pruebas manuales realizadas en el capítulo quinto y la implementación computacional del capítulo sexto.

En el primer caso, las pruebas contenían pronombres personales, pronombres reflexivos y sintagmas nominales introducidos por el artículo *the* (descripciones definidas). En todos los ejemplos, los resultados obtenidos fueron correctos, como puede comprobarse en el capítulo quinto.

Con respecto a la implementación computacional, las expresiones anafóricas tratadas se restringieron a los pronombres personales y reflexivos por razones teóricas y prácticas. Así, en el ámbito teórico, consideramos que los pronombres, al tener menor carga léxica que las descripciones definidas, ofrecen mayores posibilidades de ambigüedad a la hora de localizar su antecedente y, por tanto, mayores problemas para su resolución.

Las descripciones definidas, sin embargo, necesitan fundamentalmente información semántica sobre su antecedente y, en

[1] Agredecemos, en este sentido, las sugerencias de Julio Gonzalo, del Instituto de Ingeniería del Conocimiento de la Universidad Autónoma de Madrid así como los comentarios del Dr. Gabriel Amores, del Departamento de Lengua Inglesa de la Universidad de Sevilla.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

muchas ocasiones, conocimiento de inferencias sobre el mundo. Como sabemos, toda la información semántica que contiene nuestro módulo semántico queda limitada a la jerarquía semántica descrita en el capítulo sexto.

En cuanto a las razones prácticas que nos llevaron a eliminar las citadas descripciones de la implementación computacional, nos pareció oportuno centrar nuestra atención en los pronombres, debido a la complejidad que puede suponer la construcción de un módulo semántico que construya inferencias sobre conocimiento del mundo.

4. Precisión.

Una vez seleccionadas las expresiones anafóricas sobre las que se probaría la estrategia de identificación de antecedentes, definimos una serie de casos típicos que ayudaran a determinar la precisión de los resultados obtenidos.

Así pues, seleccionamos una serie de ejemplos que respondieran a los siguientes problemas:

a) Selección del antecedente correcto por concordancia en los rasgos gramaticales de la entidad discursiva y la expresión anfórica.

b) Selección del antecedente correcto por posiciones sintácticas paralelas de la entidad discursiva y el antecedente.

c) Selección del antecedente correcto por consistencia semántica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

d) Selección del antecedente correcto por aplicación de rasgos pragmáticos de distancia.

Universitat d'Alacant
Universidad de Alicante

4.1. Selección del antecedente por concordancia gramatical.

Queremos probar que mediante la aplicación de la estrategia descrita podemos localizar el antecedente que concuerda en género, número y persona con la expresión anafórica. El ejemplo seleccionado es:

T1 Peter bought the fish with Mary.
She ate it.

El resultado obtenido es el siguiente:

Enunciado: Peter bought the fish.

[2]

```
Estructura-c

      s(np(pn(peter)),
        vph(vp(v(bought),
               np(det(the),
                  n(fish)),
               prepp(prep(with),
                     np(pn(mary))))))
```

[2] Con este tipo de letra representaremos los resultados que se obtienen directamente en la pantalla del ordenador. El hecho de que las palabras no estén acentuadas se debe a que no definimos acentos en nuestro programa.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Estructura-f

```
subj:'pred:'peter
     gen:masculino
     pers:terc
     num:sing
     semfeat:human
 num:sing
 prepp:'pred:'mary
      gen:femenino
      pers:terc
      num:sing
      pcase:'pred:'with
  obj:'pred:'fish
    gen:neutro
    pers:terc
    num:sing
    det:num:sing
 'pred:'buy(subj,obj)
 tense:past
```

Entidades discursivas:

```
[oracion : 1,clausula : 1,subj : [pred :
peter,gen : masculino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]

[oracion : 1,clausula : 1,prepp : [pred :
mary,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]

[oracion : 1,clausula : 1,obj : [pred : fish,
gen : neutro,pers : terc,num : sing,abstract :
no,animate : yes,count : yes,edible : yes,human
: no,object : no]]
```

Enunciado: She ate it.

Estructura-c

```
s(np(pr(she)),
  vph(vp(v(ate),
         np(pr(it)))))
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

```
Estructura-f

     subj:'pred:'she
          gen:femenino
          pers:terc
          num:sing
          semfeat:human
      num:sing
      obj:'pred:'it
         gen:neutro
         pers:terc
         num:sing
         semfeat:edible
      'pred:'eat(subj,opt(obj))
      tense:past

Expresiones anafóricas

     [oracion : 2,clausula : 1,subj : [pred : she,gen
     : femenino,pers : terc,num : sing,abstract :
     no,animate : yes,count : yes,edible : no,human
     : yes,object : no,distancia1 : dif_cla,
     distancia2 : dif_orac]]

     [oracion : 2,clausula : 1,obj : [pred : it,gen
     : neutro,pers : terc,num : sing,abstract :
     no,animate : no,count : yes,edible : yes,human
     : no,object : no,distancia1 : dif_cla,
     distancia2 : dif_orac]]
```

Al aplicar el producto escalar como estrategia para comparar los vectores resultantes de las entidades discursivas y las expresiones anafóricas, conseguimos los siguientes valores:

```
ANTECEDENTE DE pred:it
     pred:fish (0.852459016393443)
  Antecedentes rechazados:
     pred:peter (0.652123598746764)
     pred:mary (0.61594731974624)
```

Como vemos, el producto escalar ha seleccionado como antecedente del pronombre *it* el candidato cuyo valor está más próximo a 1, y la

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

elección ha sido correcta.

Universitat d'Alacant
Universidad de Alicante

4.2. Selección del antecedente por posiciones sintácticas paralelas.

Los ejemplos que mostramos en este apartado contienen relaciones anafóricas donde el antecedente se localiza gracias a que ocupa la misma posición sintáctica que su expresión anfórica.

T2a Mary played with the girl.
Peter also played with her.

T2b Mary played with the girl.
She also played with Peter.

Los resultados que obtenemos para T2a son los siguientes:

Enunciado: Mary played with the girl.

```
Estructura-c

     s(np(pn(mary)),
       vph(vp(v(played),
              prepp(prep(with),
                    np(det(the),
                       n(girl))))))
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Estructura-f

```
subj:'pred:'mary
     gen:femenino
     pers:terc
     num:sing
     semfeat:animate
 num:sing
 prepp:'pred:'girl
      gen:femenino
      pers:terc
      num:sing
      det:num:sing
      pcase:'pred:'with
  'pred:'play(subj,opt(obj))
```

Entidades discursivas

```
[oracion : 1,clausula : 1,subj : [pred :
mary,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]

[oracion : 1,clausula : 1,prepp : [pred :
girl,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]
```

Enunciado: Peter also played with her.

Estructura-c

```
s(np(pn(peter)),
  vph(advp(also),
      vp(v(played),
         prepp(prep(with),
               np(pr(her))))))
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

```
Estructura-f

     subj:'pred:'peter
          gen:masculino
          pers:terc
          num:sing
          semfeat:animate
      num:sing
      advp:adv:also
      prepp:'pred:'her
           gen:femenino
           pers:terc
           num:sing
           pcase:'pred:'with
       'pred:'play(subj,opt(obj))

Entidades discursivas

     [oracion : 2,clausula : 1,subj : [pred :
     peter,gen : masculino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object : no]]

Expresiones anafóricas

     [oracion : 2,clausula : 1,prepp : [pred :
     her,gen : femenino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object : no,
     distancia1 : dif_cla,distancia2 : dif_orac]]
```

El resultado del producto escalar es:

```
ANTECEDENTE DE pred:her

     pred:girl (0.982142857142857)

   Antecedentes rechazados:

     pred:mary (0.956100492239443)
     pred:peter (0.804361815109743)
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Así pues, nuestra estrategia localiza correctamente *girl* como antecedente de *her* en el texto *Mary played with the girl. Peter also played with her.*

Veamos ahora qué ocurre cuando cambiamos la segunda oración y el texto es *Mary played with the girl. She also played with Peter.* Obviamente, debemos esperar que el antecedente seleccionado para el pronombre *she* sea *Mary*.

Enunciado: She also played with Peter[3].

```
Estructura-c

        s(np(pr(she)),
          vph(advp(also),
              vp(v(played),
                 prepp(prep(with),
                       np(pn(peter))))))

Estructura-f

        subj:'pred:'she
             gen:femenino
             pers:terc
             num:sing
             semfeat:animate
         num:sing
         advp:adv:also
         prepp:'pred:'peter
               gen:masculino
               pers:terc
               num:sing
               pcase:'pred:'with
          'pred:'play(subj,opt(obj))
```

[3] No repetimos el análisis de la oración *Mary played with the girl* porque es el mismo del ejemplo anterior.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
Entidades discursivas

     [oracion : 2,clausula : 1,prepp : [pred :
     peter,gen : masculino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object : no]]

Expresiones anafóricas

     [oracion : 2,clausula : 1,subj : [pred :
     she,gen : femenino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object :no,
     distancia1 : dif_cla,distancia2 : dif_orac]]
```

Y el resultado de aplicar el producto escalar es el siguiente:

```
ANTECEDENTE DE pred:she

     pred:mary (0.98529411764706)

   Antecedentes rechazados:

     pred:girl (0.956100492239443)
     pred:peter (0.803115707754045)
```

Ahora, el antecedente seleccionado es *Mary*, exactamente el que esperábamos.

Así pues, a la vista de los resultados obtenidos, podemos afirmar que nuestra estrategia es también válida para localizar antecedentes anafóricos en función de la posición sintáctica que éstos mantienen con la expresión anafórica.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

4.3. Selección del antecedente por consistencia semántica.

Comprobaremos aquí si nuestra estrategia puede decidir qué antecedente es el correcto cuando el verbo impone restricciones de selección.

Los ejemplos que analizaremos son los siguientes:

T3a A cake was on the table.
Mary ate it.

T3b A cake was on the table.
Mary had painted it.

En T3a el verbo, *ate*, impone la restricción de que su objeto directo debe tener el rasgo semántico de «comestible» y, por tanto, sólo *cake* puede ser antecedente ya que *table* no tiene este rasgo.

En T3b el verbo, *had painted*, necesita un objeto directo que tenga el rasgo semántico de «cosa» y, por tanto, sólo *table* puede ser antecedente ya que *cake* no tiene este rasgo.

Veamos cómo se resuelve esta situación aplicando el producto escalar.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Enunciado: A cake was on the table[4].

Entidades discursivas

```
[oracion : 1,clausula : 1,prepp : [pred :
table,gen : neutro,pers : terc,num :
sing,abstract : no,animate : no,count :
yes,edible : no,human : no,object : yes]]

[oracion : 1,clausula : 1,subj: [pred :
cake,gen : neutro,pers : terc,num :
sing,abstract : no,animate : no,count :
yes,edible : yes,human : no,object : no]]
```

Enunciado: Mary ate it.

Entidades discursivas

```
[oracion : 2,clausula : 1,subj : [pred :
mary,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]
```

Expresiones anafóricas

```
[oracion : 2,clausula : 1,obj : [pred : it,gen
: neutro,pers : terc,num : sing,abstract :
no,animate : no,count :yes,edible : yes,human
: no,object : no,distancia1 :
dif_cla,distancia2 : dif_orac]]
```

[4] A partir de ahora, el análisis de las oraciones mostrará unicamente las entidades discursivas, las expresiones anafóricas y el resultado del producto escalar.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Resultado del producto escalar:

```
ANTECEDENTE DE pred:it

     pred:cake (0.983606557377705)

   Antecedentes rechazados:

     pred:table (0.838372740765715)
     pred:mary (0.6473808187208)
```

Comprobamos, entonces, que efectivamente nuestra estrategia ha señalado *cake* como antecedente de *it*.

Probaremos ahora el texto T3b, *A cake was on the table. Mary had painted it.*

Enunciado: Mary had painted it[5].

```
Entidades discursivas

     [oracion : 2,clausula : 1,subj : [pred :
     mary,gen : femenino,pers : terc,num :
     sing,abstract : no,animate :yes,count :
     yes,edible : no,human : yes,object : no]]

Expresiones anafóricas

     [oracion : 2,clausula : 1,obj : [pred : it,gen
     :neutro,pers : terc,num : sing,abstract :
     no,animate : no,count : yes,edible : no,human
     : no,object : yes,distancia1 : dif_cla,
     distancia2 : dif_orac]]
```

[5] Las entidades discursivas localizadas para *A cake was on the table* son las mismas que en T3a.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

El resultado del producto escalar es:

```
ANTECEDENTE DE pred:it

    pred:table (0.975249922931546)

  Antecedentes rechazados:

    pred:cake (0.852459016393443)
    pred:mary (0.6473808187208)
```

4.4. Selección del antecedente correcto por rasgos pragmáticos de distancia.

En este apartado, vamos a comprobar si tras aplicar el producto escalar podemos discriminar entre varios candidatos gracias al empleo de los rasgos pragmáticos de distancia oracional y distancia clausal. Para ello, tomaremos como ejemplos los siguientes textos:

T4a Mary thinks that the woman likes her.

T4b Mary thinks that the woman likes herself.

T4c The girl plays with Mary.
Mary thinks that the woman likes her.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Enunciado: Mary thinks that the woman likes her.

```
Entidades discursivas

    [oracion : 1,clausula : 1,subj : [pred :
    mary,gen : femenino,pers : terc,num :
    sing,abstract : no,animate : yes,count :
    yes,edible : no,human : yes,object : no]]

    [oracion : 1,clausula : 2,subj : [pred :
    woman,gen : femenino,pers : terc,num :
    sing,abstract : no,animate : yes,count :
    yes,edible : no,human : yes,object : no]]

Expresiones anafóricas

    [oracion : 1,clausula : 2,obj : [pred : her,gen
    : femenino,pers : terc,num : sing,abstract :
    no,animate : yes,count : yes,edible : no,human
    : yes,object : no,distancia1 : dif_cla,
    distancia2 : dif_orac]]
```

El resultado del producto escalar es:

```
ANTECEDENTE DE pred:her

    pred:mary (0.986485057098362)

  Antecedentes rechazados:

    pred:woman (0.9710712280812)
```

Como vemos, el producto escalar ha identificado correctamente la entidad *Mary* como antecedente de *her*. Veamos, ahora, si también puede identificarse el antecedente correcto en el siguiente enunciado.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Enunciado: Mary thinks that the woman likes herself.

```
Entidades discursivas

     [oracion : 1,clausula : 1,subj : [pred :
     mary,gen : femenino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object : no]]

     [oracion : 1,clausula : 2,subj : [pred :
     woman,gen : femenino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object : no]]


Expresiones anafóricas


     [oracion : 1,clausula : 2,obj : [pred :
     herself,gen : femenino,pers : terc,num :
     sing,abstract : no,animate : yes,count :
     yes,edible : no,human : yes,object :
     no,distancia1 : misma_cla,distancia2 :
     misma_orac]]


     ANTECEDENTE DE pred:her

          pred:woman (0.993786211009733)

        Antecedentes rechazados:

          pred:mary (0.97849792378814)
```

Efectivamente, al cambiar el pronombre y utilizar *herself*, la referencia cambia también y localizamos como antecedente la entidad dicursiva *woman*.

Probaremos todavía un último ejemplo en el que la referencia cambia al añadir un nuevo contexto.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Enunciado: The girl plays with Mary.
Mary thinks that the woman likes her.

Entidades discursivas

```
[oracion : 1,clausula : 1,prepp : [pred :
mary,gen :femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]

[oracion : 1,clausula : 1,subj : [pred :
girl,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes, count :
yes,edible : no,human : yes,object : no]]

[oracion : 2,clausula : 1,subj : [pred :
mary,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]

[oracion : 2,clausula : 2,subj : [pred :
woman,gen : femenino,pers : terc,num :
sing,abstract : no,animate : yes,count :
yes,edible : no,human : yes,object : no]]
```

Expresiones anafóricas

```
[oracion : 2,clausula : 2,obj : [pred : her,gen
: femenino,pers : terc,num : sing,abstract :
no,animate : yes,count : yes,edible : no,human
: yes,object : no,distancia1 : dif_cla,
distancia2 : dif_orac]]


ANTECEDENTE DE  pred:her

     pred:girl (1)

   Antecedentes rechazados:

     pred:mary (0.99239570702275)
     pred: woman (0.9710712280812)
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Una vez analizados todos los ejemplos, podemos afirmar que nuestra estrategia muestra gran eficacia a la hora de tratar las relaciones anafóricas descritas.

Universitat d'Alacant
Universidad de Alicante

5. Dificultad en la valoración de los datos.

En nuestra opinión, la valoración de los datos que maneja el sistema así como de los resultados que éste produce no conlleva gran dificultad puesto que la información queda siempre disponible en un archivo que almacena cada uno de los resultados parciales.

Así, como hemos visto en los ejemplos anteriores, es posible recuperar el resultado del análisis sintáctico y saber qué estructura-c y estructura-f tiene cada oración. Del mismo modo, podemos acceder a los resultados del módulo de identificación de unidades de análisis y comprobar si el programa localiza correctamente las entidades discursivas y expresiones anafóricas, y sus rasgos morfológicos, sintácticos, semánticos y pragmáticos son los adecuados.

Por último, cuando el antecedente ha sido seleccionado, el sistema nos ofrece también los antecedentes rechazados y los valores numéricos que éstos han obtenido, de manera que puede contrastarse la información fácilmente.

Con todo lo dicho, podemos concluir que nuestra estrategia es en todo momento transparente y que, por tanto, la valoración de los datos es siempre posible.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

6. Sencillez de las estructuras y mecanismos empleados.

Universitat d'Alacant
Universidad de Alicante

En general, los mecanismos utilizados no son excesivamente complejos gracias a que el lenguaje de programación empleado, Prolog, permite gran claridad explicativa así como el empleo de notación muy próxima a la lingüística.

En este sentido, el sistema cuenta con un mecanismo para el análisis morfológico de las palabras contenidas en el léxico, otro módulo diferente que asigna funciones sintácticas y cuya teoría central es la LFG, un tercer módulo semántico basado en una jerarquía semántica, y un último módulo de análisis pragmático.

Junto a los mecanismos de análisis, encontramos un módulo de identificación de relaciones anafóricas que ejecuta una serie de operaciones matemáticas como la codificación en vectores de los rasgos lingüísticos, la normalización de los vectores y la aplicación del producto escalar.

Por último, y como ya apuntamos en el capítulo sexto, es necesario señalar que todos estos módulos mantienen su independencia, evitando, así, que el proceso de identificación de antecedentes resulte confuso.

7. Poder explicativo.

La cuestión principal que queremos tratar en este apartado consiste en descubrir hasta qué punto el tratamiento de la anáfora propuesto relaciona este fenómeno con otros aspectos del lenguaje, esto es, si la estrategia diseñada considera la anáfora dentro de un marco lingüístico amplio o si,

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

por el contrario, restringe su interpretación aislándola de otros problemas.

Para responder a esta interrogación citaremos a Hobbs (1986: 339) cuando afirma que «Charniak (1972) demonstrated rather convincingly that in order to do pronoun resolution, one had to be able to do everything else ... once everything is done, pronoun resolution comes free». En efecto, como ya apuntamos en los capítulo segundo y cuarto, no podemos pensar en la anáfora como en un problema aislado.

A este respecto, quedó demostrado que las fuentes de información que intervienen en el establecimiento de relaciones anafóricas son varias, de manera que no podemos restringir ninguna de ellas sin limitar tambien el alcance del tratamiento de la anáfora.

La estrategia que hemos diseñado reconoce la necesidad de coordinar todas estas fuentes de conocimiento y asegura que la anáfora se beneficie de ellas en la localización de antecedentes. Al mismo tiempo, toda la información empleada puede ser utilizada para tratar otros problemas como, por ejemplo, la selección del foco del discurso o la resolución de ambigüedades léxicas y estructurales (Carter, 1990).

8. Limitaciones.

Al llegar al capítulo de las limitaciones que tiene nuestro sistema debemos reconocer que éstas son varias si se considera que los tipos de anáfora que quedan por tratar son muchos, que no se ha implementado un módulo de gestión de la estructura discursiva y que tampoco existe un mecanismo de generación de inferencias sobre el conocimiento del mundo.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

Sin embargo, no debemos olvidar que el objetivo de la presente tesis era, como señalamos en el capítulo primero, llegar a automatizar el proceso de identificación de antecedentes anafóricos utilizando para ello un modelo de inspiración vectorial y, en este sentido, no podemos negar que nuestra meta se ha cumplido.

9. Actualización y ampliación.

Gracias a la modularidad del sistema, las posibilidades de ampliación y actualización del sistema son grandes. En efecto, los módulos léxico, sintáctico, semántico y pragmático pueden aumentarse con nuevas reglas y datos sin que sea necesario alterar la estructura general del sistema.

En este sentido, recordemos que lo que realmente se ha hecho para construir nuestro sistema es precisamente el proceso inverso, es decir, se han tomado módulos completos de otras aplicaciones y se han seleccionado las funciones y datos básicos necesarios para aplicar la estrategia diseñada. Así pues, la ampliación de estos mismos módulos es casi inmediata.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

Conclusiones.

Nuestra preocupación básica al empezar esta tesis era conseguir la automatización del proceso de identificación de relaciones anafóricas. Con este fin, nos habíamos marcado una serie de objetivos secundarios que hemos ido desarrollando a lo largo de los diferentes capítulos que componen la presente investigación.

Ahora es el momento de reflexionar sobre nuestro propio trabajo y comprobar si todas las metas que establecimos al principio han sido satisfechas. Al mismo tiempo, intentaremos precisar cuál ha sido nuestra contribución al estudio de la anáfora.

Con el fin de exponer nuestras conclusiones de manera ordenada, enumeraremos a continuación cada uno de los mencionados subobjetivos y analizaremos, asimismo, su contribución al objetivo principal.

1- La primera meta propuesta era la formulación de una tipología de la anáfora discursiva que sirviera para centrar nuestro análisis dentro de un paradigma concreto. En este sentido, hemos elaboramos una clasificación que relaciona los siguientes aspectos de la anáfora: el tipo de antecedente, el tipo de relación anafórica y la función discursiva de la misma.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Como pudimos comprobar, toda esta información sirvió para construir las bases teóricas sobre las que fundamentamos nuestra investigación.

2- Una vez que el marco teórico fue delimitado, el siguiente paso consistió en elaborar un estudio crítico de las aproximaciones computacionales más significativas en el campo de la anáfora. Este análisis cumplía una doble finalidad. Por una parte, pretendíamos componer el marco general en el que se insertaba nuestra investigación y, por otra, determinar qué enfoque podía ser más adecuado para nuestros propósitos.

A este respecto, hemos realizado un recorrido por algunos de los trabajos más destacados dentro de la lingüística computacional, analizando sus características principales y apuntando sus ventajas y desventajas. El estudio se realizó considerando tres grupos distintos de aproximación: la tradicional, la «democrática» y la «consultiva».

Tras el análisis crítico, parecía que el enfoque más adecuado era el «democrático» puesto que gracias a él podíamos integrar en un único modelo las diferentes fuentes de información necesarias para localizar los antecedentes anafóricos y dejar que todas ellas actuasen por igual en la selección de éstos.

Sin embargo, el modelo de interpretación anafórica que posteriormente desarrolláramos debía compartir con los métodos tradicionales la restriccion de los posibles antecedentes a aquellos

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

mencionados de manera explícita en el discurso. Del mismo modo, tendría en común con los metodos más avanzados las siguientes características: el tratamiento de relaciones anafóricas más allá de la oracion, y la necesidad de incorporar información sobre el foco del discurso.

3- Un tercer objetivo en nuestra investigación era comprobar hasta qué punto la elección de la aproximación democrática era válida para llevar a cabo nuestro proyecto.

Con este fin, estudiamos de manera empírica las relaciones anafóricas contenidas en un corpus y obtuvimos los siguientes resultados:

a) La información lingüística necesaria para identificar los antecedentes anafóricos agrupa, por igual, rasgos morfológicos, sintácticos, semánticos y pragmáticos. En este sentido, podemos afirmar que la exclusión de alguno de estos rasgos puede llevar a la localización del antecedente erróneo.

b) La influencia que ejercen las diferentes fuentes de información no puede predecirse de antemano y no puede decirse que exista un único criterio que supere en eficacia a los demás.

Por tanto, extraemos como conclusión lo siguiente: primero, que sólo es posible una aproximación real al problema de la anáfora cuando

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

se consiguen integrar en un mismo modelo todas las fuentes de información; y segundo, que el modelo más adecuado parece ser el democrático ya que permite que todas las fuentes aporten sus criterios en términos de igualdad, sin conceder mayor prominencia a ninguna de ellas.

4- A continuación, nuestra investigación entró en una fase práctica, que se centró en desarrollar la estrategia que permitiera automatizar el proceso de identificación de antecedentes.

Para ello adoptamos como operación básica el producto escalar, decisión que está fundada en dos puntos básicos: en primer lugar, el éxito obtenido con anterioridad al aplicar el producto escalar para el tratamiento de la información semántica; y, en segundo lugar, la posiblidad de tratar la información en los términos expuestos anteriormente ya que esta operación integra en un único patrón todos los rasgos lingüísticos y concede la misma importancia a todos ellos.

A fin de comprobar si nuestra estrategia producía los resultados deseados aplicamos el producto escalar a una serie de ejemplos concretos. Localizamos, entonces, los antecedentes correctos en enunciados que contenían diferentes candidatos y conseguimos discriminar entre ellos en función de criterios morfológicos, sintácticos, semánticos y discursivos.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5- La siguiente etapa de nuestra investigación quedó centrada en la construcción de un programa informático que efectuara de modo automático todos los análisis y operaciones efectuadas previamente de manera manual.

A este respecto, es necesario mencionar que el objetivo principal en esta etapa era verificar la posibilidad de automatizar todo el proceso de identificación de antecedentes limitando la intervención humana.

Teniendo en cuenta este objetivo, creamos diferentes módulos independientes para las diferentes tareas. Así, tomamos de otras aplicaciones los módulos de análisis morfológico y sintáctico, y se adaptaron a nuestro propio programa. Construímos además, módulos de análisis semántico y de asignación de rasgos discursivos, así como un módulo encargado de la identificación de antecedentes anafóricos.

Este último módulo tiene como operación central el producto escalar y como rutinas complementarias la identificación de unidades de análisis, la asignación de valores numéricos para cada rasgo lingüístico, la conversión en vector de cada unidad de análisis y, por último, la selección del antecedente correcto.

6- Con respecto a la validez de nuestra aproximación al problema de la identificación de antecedentes, expusimos en el capitulo séptimo los datos obtenidos en relación con la precisión de los resultados, la sencillez de las estructuras construidas y el poder explicativo de aquélla. Mencionamos, asimismo, sus limitaciones y sus

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

posibilidades de ampliación.

A la vista de estos datos, llegamos a la conclusión de que nuestra estrategia consigue un tratamiento de las relaciones anafóricas en los términos expuestos en el punto 4, esto es, permite coordinar todas las fuentes de información en un único modelo y gestionarlas en condiciones de igualdad.

Queda, por último, mencionar la posible contribución de la tesis que aquí presentamos al campo de la lingüística computacional. En este sentido, pensamos que tanto en los aspectos prácticos como en los teóricos, nuestra tesis, a pesar de sus limitaciones, puede ser de utilidad en la realización de trabajos posteriores.

En efecto, no debemos olvidar que la anáfora es un fenómeno central en todo proceso comunicativo y, por tanto, cualquier sistema que busque un tratamiento automático del lenguaje natural deberá contar con un módulo de identificación de antecedentes y es precisamente aquí donde nuestra investigación cobra mayor importancia.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

BIBLIOGRAFÍA

Universitat d'Alacant
Universidad de Alicante

Aijmer, K. y B. Altenberg, eds. (1991): *English Corpus Linguistics*. Londres: Longman.

Alcaraz Varó, E. (1983): «De la lingüística oracional a la supraoracional» en *Anales de Lingüística*. Alicante: Universidad de Alicante.

_____ (1990): *3 Paradigmas de la investigación lingüística*. Alcoy: Marfil.

Allen, J. (1987): *Natural Language Understanding*. California: The Benjamin/Cummings Publishing Company Inc..

Alshawi, H. (1987): *Memory and Context for Language Interpretation*. Cambridge: Cambridge University Press.

Alshawi, H. y J. Van Eijck (1989): «Logical forms in the Core Language Engine» en *ACL Proceedings, 27th Annual Meeting*.

Alshawi, H. (1990): «Resolving quasi logical forms» en *Computational Linguistics* 16 (3): 133-144.

_____ (1992): *The Core Language Engine*. Cambridge: MIT Press.

Amores Carredano, J. G. (1992): *A Lexical-Functional Grammar Machine Translation System for Medical Abstracts*. Tesis doctoral. Universidad de Sevilla.

Appelt, D. (1985): «Some pragmatic issues in the planning of definite and indefinite noun phrases» en *Proc. of the 23th Annual Meeting of the ACL*: 198-203.

Ariel, M. (1990): *Accessing Noun-phrase Antecedents*. Londres: Routledge.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Atkins, S., J.Clear y N. Ostler (1992): «Corpus design criteria» en *Literary and Linguistic Computing 7 (1)*: 1-16.

Ayuso, D. (1989): «Discourse entitites in JANUS» en *Proc. of the 27th Annual Meeting of the ACL*: 243-250.

Bentivoglio, P. (1983): «Topic continuity and discontinuity in discourse: a study of spoken latin-american Spanish» en T. Givón, ed. *Topic Continuity in Discourse: a Quantitative Cross-language Study*. Amsterdam: John Benjamins.

Betts, A. (1988): «Anaphora in V.3» en *Eurotra-Essex Internal Memoranda*. Essex: University of Essex, Department of Language and Linguistics.

Boguraev, B.K. (1979): *Automatic Resolution of Linguistic Ambiguities*. University of Cambridge Computer Laboratory TR-11: .

Bosch, P. (1983): *Agreement and Anaphora. A study of the Role of Pronouns in Syntax and Discourse*. Londres: Academic Press.

Brady, M. y R. C. Berwick, eds. (1989): *Computational Models of Discourse*. Cambridge, Mass: MIT Press.

Brennan, S., M. Friedman y C. Pollard (1987): «A centering approach to pronouns» en *Proc. of the 25th Annual Meeting of the ACL*: 155-162.

Brown, C. (1983): «Topic continuity in written English narrative» en T. Givón , ed. *Topic Continuity in Discourse: A Quantitative Cross-Language Study*. Amsterdam: John Benjamins. 317-341.

Carbonell, J. G. y R. D. Brown, (1988): «Anaphora resolution: a multy-strategy approach» en *COLING 1*: 96-101.

Carter, D. M. (1987): *Interpreting Anaphors in Natural Language*. Chichester, UK: Ellis Horwood.

Carter, D. M. (1990): «Control issues in anaphor resolution» en *Journal of Semantics 7*: 435-454.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Clark, H. y C. J. Sengul (1979): «In search of referents for nouns and pronouns» en *Memory and Cognition* 7 (1): 35-41.

Clancy, P.M. (1980): «Referential choice in English and Japanese narrative discourse» en Chafe, ed. *The Pear Stories, vol.III* Norwood: Ablex. 127-202.

Clocksin, W. F. y C. S. Mellish (1987): *Programación en Prolog.* Barcelona: Editorial Gustavo Gili.

Cohen, P. (1984): «Referring as requesting» en *COLING*: 207-211.

Cornish, F. (1986): *Anaphoric Relations in English and French. A Discourse Perspective.* Londres: Croom Helm.

Charniak, E. (1972): *Toward a Model of Children's Story Comprehension.* Cambridge, Mass: MIT A.I. Lab TR-266.

Charniak, E. (1986): «Jack and Janet in search of a theory of knowledge» en Grosz *et al*, eds. *Readings in NLP.* California: Morgan Kaufmann.

Chomsky, N. (1965): *Aspects of the Theory of Syntax.* Cambridge, Mass: MIT Press.

_____ (1981): *Lectures on Government and Binding.* Dordrecht: Foris.

D'Introno, F. (1983): «Teoría lingüística» en López Morales, H. *Introducción a la lingüística actual.* Madrid: Playor.

Dahlbäck, N. (1991): *Representations of Discourse. Cognitive and Computational Aspects.* Linköping: Linköping Studies in Arts and Sciences.

Dale, R. (1989): «Cooking up referring expressions» en *Proc. of the 27th Annual Meeting of the ACL:* 68-75.

Demonte, V. (1983): «Principios y representaciones en sintaxis: la teoría de la rección y el ligamiento» en *Verba 10*: 5-42.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Dik, S. M. (1992): *Functional Grammar in Prolog*. Berlin: Mouton de Gruyter.

Donnellan, K.S. (1978): «Speaker reference, descriptions and anaphora» en P. Cole, ed. *Syntax and Semantics, vol9: Pragmatics*. Nueva York: Academic Press, Inc. 47-68.

Dowty, D., R.E. Wall y S. Peters (1981): *Introduction to Montague Semantics*. Dordrecht: Reidel.

Erman, L., P. London y S. Fickas (1981): «The desing and an example use of Hearsay III» en *Proc. IJCAI 7*.

Ferrari, G. (1991): «Towards a realistic dialogue model» en *Actas del congreso de la SEPLN*. Valencia: 11-22.

Fodor, J.A. y Pylyshyn,Z.W. (1988): «Connectionism and cognitive architecture: a critical analysis» en *Cognition 28*: 3-71.

Fraser, B. (1990): «An approach to discourse markers» en *Journal of Pragmatics* 14: 383-395.

Gal, A., G. Lapalme, P. Saint-Dizier y H. Somers (1991): *Prolog for Natural Language Processing*. Chichester: J. Wiley & Sons Ltd.

Garnham, A. (1989): «Integrating information in text comprehension: the interpretation of anaphoric noun phrases» en Carlson, G. N. y Tanenhaus, M. K., eds. *Linguistic Structure in Language Processing*. Londres: Kluwer Academic Publishers.

Garside, R., G. Leech y G. Sampson (1987): *The Computational Analysis of English*. Londres: Longman.

Gazdar, G. y C. Mellish (1989): *Natural Processing in Prolog*. Wokinggham: Addison-Wesley.

Gernsbacher, M. A. (1989): «Mechanisms that improve referential access» en *Cognition 32*: 99-156.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Goodman, B. A. (1986): «Reference identification and reference identification failure» en *Computational Linguistics, 12 (4)*: 273- 305.

Grice, P. (1975): «Logic and conversation» en Cole, P. y J. Morgan, eds. *Syntax and Semantics 3: Speech Acts*, Nueva York: Academic Press.

Grice, P. (1978): «Further notes on logic and conversation» en P. Cole y J. Morgan, eds. *Syntax and Semantics 9: Pragmatics*. Nueva York: Academic Press.

Grishman, R. (1989): *Computational Linguistics. An Introduction*. Cambridge: Cambridge University Press.

Grosz, B. (1977): «The representation and use of focus in a system for understanding dialogs» en *IJCAI 5*.

_____ (1981): «Focusing and description in Natural Language Dialogues» en Joshi, A. K., B. Webber, B. e I. Sag, eds. *Elements of Dicourse Understanding*. Cambridge: Cambridge University Press.

Grosz, B., A. Joshi y S. Weinstein (1983): «Providing a unified account of definite noun phrases in discourse» en *Proc. of the 21st Annual Meeting of the Association for Computational Linguistics*: 44-50.

Grosz, B. y C. Sidner (1986): «Attentions, intentions and the structure of discourse» en *Computational Linguistics 12 (3)*: 175-204.

Grosz, B., K. S. Jones y B. L. Webber, eds. (1986): *Readings in Natural Language Processing*. California: Morgan Kaufmann Publishers.

Guindon, R. (1986): «The structure of user-adviser dialogues: is there method in their madness?» en *24th Annual Meeting of the ACL*: 224- 230.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Halliday, M.A.K. y Hasan, R. (1976): *Cohesion in English*. Londres: Longman.

Hintikka, J. y J. Kulas (1985): *Anaphora and Definite Descriptions*. Dordrecht: Reidel.

Hirst, G. (1981): *Anaphora in Natural Language Understanding: A Survey*. Berlin: Springer.

_____ (1987): *Semantic Interpretation and the Resolution of Ambiguity*. Cambridge: Cambridge University Press.

_____ (1991): «Does conversational analysis have a role in computational linguistics?» en *Computational Linguistics* 17 (2): 211-229.

Hobbs, J. (1976): *Pronoun Resolution*. Nueva York: Research Report # 76-1, City College, City University of New York.

Hobbs, J. (1979): «Coherence and co-reference» en *Cognitive Science 3 (1)*: 67-90.

Hobbs, J. (1986): «Resolving pronoun references» en Grosz *et al*, eds. *Readings in Natural Language Processing*. California: Morgan Kaufmann Publishing.

Horrocks, G. (1987): *Generative Grammar*. Londres: Longman.

Kucera, H., y W. N. Francis (1967): *Computational Analysis of Present-Day American English*. Providence: Brown University Press.

Joly, A. (1989): *Essais de systématique énonciative*. Lille: Presses Universitaires de Lille.

Joshi, A. K., B. Webber e I. Sag, eds. (1981):*Elements of Discourse Understanding*. Cambridge: Cambridge University Press.

Kaplan, R. y J. Bresnan (1982): «Lexical-Functional Grammar: a formal system for grammatical representation» en J. Bresnan, ed. *The Mental Representation of Grammatical Relations*. Cambridge, Mass: MIT Press.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Kronfeld, A. (1986): «Donnellan's distinction and a computational model of reference» en *Proc. of the 24th Anual Meeting of the ACL*: 186-191.

_____ (1989): «Conversationally relevant descriptions» en *Proc. of the 27th Annual Meeting of the ACL*: 60-27.

_____ (1990): *Reference and Computation*. Cambridge: Cambridge University Press.

Lappin, S. y McCord, M. (1990): «Anaphora resolution in slot grammar» en *Computational Linguistics 16 (4)*: 197-212.

Leech, G. (1993): «Corpus annotation schemes» en *Literary and Linguistic Computing* 8 (4): 275-281.

Lesgold, A., S. Forth y M. Curtis (1979): «Foregrounding effects in discourse comprehension» en *Journal of Verbal Learning and Verbal Behavior* 18: 291-308.

Levinson, S. C. (1983): *Pragmatics*. Cambridge: Cambridge University Press.

_____ (1987): «Pragmatics and the grammar of anaphora: a partial reduction of binding and control phenomena» en *Journal of Linguistics, 23*: 379-434.

Lockman, A. y A. D. Klappholz (1980): «Towards a procedural model of contextual reference resolution» en *Discourse Processes* 3: 25-71.

Marslen-Wilson, W., E. Levy y L. K. Tyler (1982): «Producing interpretable discourse: the establishment and maintenance of reference» en R.J. Jarvella y W. Klein, eds. *Speech, Place and Action*. John Wiley.

Mellish, C. S. (1985): *Computer Interpretation of Natural Language Descriptions*. Chichester: Ellis Horwood.

Meya Llopart, M. y W. Hubert (1986): *Lingüística computacional*. Barcelona: Teide.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Otero, C.P. (1984): *La revolución de Chomsky*. Madrid: Tecnos.

Partee, B. (1984): «Nominal ant temporal anaphora» en *Linguistic and Philosophy* 7: 243-286.

Paskiewicz, T.M. (1989): *Anaphoric Pronouns. MSc Dissertation*. University of Manchester Institute of Science and Technology.

Passonneau, R. (1991): «Some facts about centers, indexical, and demonstratives» en *Proc. of the 29th Annual Meeting of the ACL*: 63- 70.

Pereira, F. y D. Warren (1980): «Definite Clause Grammars for language analysis» en *Artificial Intelligence 13*: 231-278.

Pereira, F. y S. Shieber (1987): *Prolog and Natural Language Analysis*. Stanford, CA: CSLI.

Posner, M. ed. (1993): *The Foundations of Cognitive Science*. John Wiley & Sons.

Radford, A. (1988): *Introducción a la sintaxis transformativa*. Barcelona: Teide.

Redeker, G. (1990): «Ideational and pragmatic markers of discourse structure» en *Journal of Pragmatics* 14: 367-381.

Reinhart, T. (1983): *Anaphora and Semantic Interpretation*. Londres: Croom Helm.

Rice, G. M. (1989): *The Role of Focus in Discourse. MSc Thesis.*. University of Manchester Institute of Science and Technology.

Rich, E. y LuperFoy, S. (1988): «An architecture for anaphora resolution» en *Proceedings of the Second Conference on Applied NLP*: 18-24.

Rigler, E. (1988): «Discourse approaches to nominal and temporal anaphora» en *Eurotra Essex Internal Memoranda*. Essex: University of Essex, Department of Language and Linguistics.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Robins, R. H. (1951): *Ancient and Mediaeval Grammatical Theory in Europe*. Londres: Longman.

Robinson, A. (1981): «Determining verb phrase referents in dialogues» en *American Journal of Computational Linguistics 7 (1)*: 1-16.

Sampson, G. (1993): «The need for grammatical stocktaking» en *Literary and Linguistic Computing* 8 (4): 267-273.

Sells, P. (1985): *Lectures on Comtemporary Syntactic Theories*. Stanford: CSLI.

Schuster, E. (1988): «Anaphoric reference to events and actions» en *COLING*.

Sharkey, N. (1990): «Connectionist representations for natural language» en *Procesamiento del lenguage natural 8* : 1-17.

Sidner, C. (1979): «Towards a computational theory of definite anaphora comprehension in English discourse» en *Technical Report 537*. Cambridge, Mass: MIT Artificial Intelligence Laboratory.

_____ (1983): «Focusing in the comprehension of definite anaphora» en Brady y Berwick, eds. *Computational Models of Dicourse*. MIT.

Smith, G.W. (1991): *Computers and Human Language*. Nueva York: Oxford University Press.

Sutcliffe, R. (1989): *A Parallel Distributed Processing Approach to the Representation of Knowledge for Natural Language Understanding*. Tesis doctoral. Universidad de Essex.

_____ (1990): «Distributed subsymbolic representations for natural language: how many features do you need» en *Proceedings of the 3rd Irish Conference on Artificial Intelligence and Cognitive Science*. University of Ulster at Jordanstown, Northern Ireland: Springer Verlag.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Sutcliffe, R. (1991): «Distributed representations in a text based information retrieval system: a new way of using the vector space model» en *Proceedings of the Fourteenth Annual International ACM/SIGIR Conference on Research and Development in Information Retrieval*. Chicago: ACM Press.

_____ (1992): «Representing meaning using microfeatures» en Reilly, R. y N. Sharkey, eds. *Connectionists Approaches to Natural Language Processing*. Lawrence Erlbaum.

Swartz, S. (1987): *Applied Natural Language Processing*. Nueva York: Petrocelli.

Tennant, H. (1981): *Natural Language Processing*. Nueva York: Petrocelli.

Velthuijsen,H. (1993): *The Nature and Applicability of the Blackboard Architecture*. Tesis doctoral. Dept. of computer science, Universidad de Limburg, Holanda.

Walker, M. A. (1989): «Evaluating discourse processing algorithms» en *ACL Proceedings, 27th Annual Meeting*: 251-261.

Webber, B.L. (1986): «So what can we talk about now» en Grosz *et al*, eds. *Readings in Natural Language Processing*. California: Morgan Kaufmann Publishers.

_____ (1988): «Tense as discourse anaphor» en *Computational Linguistics 14 (2)*: 395-414.

Weizenbaum, J. (1966): «ELIZA: a computer program for the study of natural language communication between man and machine» en *Communications of the ACM* 9: 36-45.

Wilks, Y. (1975): «A preferential pattern-seeking semantics for natural language inference» en *Artificial Intelligence 6*: 53-74.

_____ (1986): «An intelligent analyzer and understander of English» en Grosz *et al*, eds. *Readings in Natural Language Processing*. California: Morgan Kaufman.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

Winograd, T. (1972): *Understanding Natural Language*. Nueva York: Academic Press.

_____ (1986): «A procedural model of language understanding» en Grosz *et al*, eds. *Readings in Natural Language*. California: Morgan Kaufman.

Woods, A., P. Fletcher y A. Hughes (1986): *Statistics in Language Studies*. Cambridge: Cambridge University Press.

Woods, W. A., M. Kaplan y B. Nash-Webber (1972): *The Lunar Sciences Information System: Final Report, BBN Report 2378*. Cambridge, Mass: Bolt, Beranek y Newman Inc.

Woods, W. A. (1977): «Lunar rocks in natural English: Explorations in natural language question answering» en A. Zampolli, ed. *Linguistic Structures Processing*. Nueva York: Elsevier.

Zadrozny, W. y K. Jansen (1991): «Semantics of Paragraphs» en *Computational Linguistics 17, 2*: 171-209.

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

APÉNDICE 1

Ejemplo de un texto de SUSANNE con las unidades de análisis identificadas

```
N07:0970c -    YIL  <ldquo>    -        .
N07:0970d -    RRQq +How how   [Q[S?[Rq:e.Rq:e]
N07:0970e -    VD0  do    do    [Vo.Vo]
N07:0970f -    AT   the   the   [N:s.
N07:0970g -    NNL1c      valley    valley     .
N07:0970h -    NNc  people     people     .N:s]
N07:0970i -    VV0v feel  feel  [Vr.Vr]S?]Q]
N07:0970j -    YIR  +<rdquo>   -        .
N07:0970k -    YQ   +?    -        .Q]
N07:0970m -    YB   <minbrk>   -     [Oh.Oh]
N07:0970n -    YIL  <ldquo>    -     [Q.
N07:0970p -    RGa  +As   as    [Q[J.
N07:0970q -    JJ   mad   mad   .J]
N07:0970r -    CSA  as    as    [Fc.
N07:0970s -    RR   ever  ever  [R:t.R:t]Fc]
N07:0970t -    YF   +.    -     .
N07:0980a -    CCB  But   but   [S+.
N07:0980b -    NP1s Kruger     Kruger     [Np:s[G[Nns.Nns]
N07:0980c -    GG   +<apos>s   -     .G]
N07:0980d -    NN2  men   man   .Np:s]
N07:0980e -    VV0v keep  keep  [V.V]
N07:0980f -    PPHO2      them  they  [Nop:o.Nop:o]
N07:0980g -    II   off   off   [P:j.
N07:0980h -    NN1n balance    balance    .P:j]
N07:0980i -    YC   +,    -     .
N07:0980j -    CC   and   and   [S+.
N07:0980k -    PPHS2      they  they  [Nap:s.Nap:s]
N07:0980m -    VD0  do    do    [Ve.
N07:0980n -    XX   +n<apos>t  not   .
N07:0980p -    VV0v trust      trust      .Ve]
N07:0990a -    PPIO1      me    I     [Neo:o.Neo:o]S+]S+]
N07:0990b -    YF   +.    -     .
N07:0990c -    PPIS1      I     I     [S[Nea:s.Nea:s]
N07:0990d -    VBM  +<apos>m   be    [Vmb.Vmb]
N07:0990e -    AT1  an    an    [Ns:e.
N07:0990f -    NN1c outsider   outsider   .Ns:e]S]
N07:0990g -    YF   +.    -     .
N07:0990h -    CSn  When  when  [S[Fa:t[Rq:t.Rq:t]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:0990i -    PPHS2     they they [Nap:s.Nap:s]
N07:0990j -    VV0v learn     learn     [V.V]
N07:0990k -    PPY  you  you  [Fn:o[Ny:s.Ny:s]
N07:0990m -    VBR  +<apos>re be   [Vab.Vab]
N07:0990n -    II   in   in   [P:p.
N07:0990p -    AT   the  the  [Np.
N07:0990q -    NNL2 hills     hill .Np]P:p]
N07:0990r -    RR   though    though    [R:c.R:c]Fn:o]Fa:t]
N07:0990s -    YC   +,   -    .
N07:1000a -    PPHS2     they they [Nap:s.Nap:s]
N07:1000b -    VMo  +<apos>ll will [Vc.
N07:1000c -    VV0v rally     rally     .Vc]
N07:1000d -    YC   +,   -    .
N07:1000e -    VD0  do   do   [S*@[Ve.
N07:1000f -    XX   +n<apos>t not  .
N07:1000g -    VV0v worry     worry     .Ve]
N07:1000h -    II   about     about     [P:u.
N07:1000i -    DD1a that that .P:u]S*@]S]Q]
N07:1000j -    YIR  +<rdquo>  -    .
N07:1000k -    YF   +.   -    .O]
N07:1000m -    YB   <minbrk>  -    [Oh.Oh]
N07:1000n -    NP1s Barton    Barton    [O[S[Nns:s.Nns:s]
N07:1000p -    VVDv waited    wait [Vd.Vd]
N07:1010a -    IF   for  for  [P:t.
N07:1010b -    AT1  a    a    [Ns.
N07:1010c -    JJ   long long .
N07:1010d -    NNT1c     moment    moment    .Ns]P:t]
N07:1010e -    YC   +,   -    .
N07:1010f -    RTn  then then [S-[Rsw:t.Rsw:t]
N07:1010g -    VVDv asked     ask  [Vd.Vd]
N07:1010h -    AT   the  the  [Ns:o155.
N07:1010i -    NN1n question  question  .
N07:1010j -    DDQr which     which
[Fr[Dq:s155.Dq:s155]
N07:1010k -    VVDi lay  lie  [Vd.Vd]
N07:1010m -    RR   always    always    [R:t.R:t]
N07:1010n -    JJs  uppermost uppermost [Jh:p.
N07:1020a -    II   in   in   [P.
N07:1020b -    APPGm     his  his  [Ns.
N07:1020c -    NN1n mind mind .Ns]P]Jh:p]Fr]Ns:o155]S-]S]
N07:1020d -    YF   +.   -    .O]
N07:1020e -    YB   <minbrk>  -    [Oh.Oh]
N07:1020f -    YIL  <ldquo>   -    [O.
N07:1020g -    APPGi1    +My  my   [Q[Ns.
N07:1020h -    NN1c boy  boy  .Ns]
N07:1020i -    YF   +.   -    .
N07:1020j -    VDD  Did  do   [S?[Vod.Vod]
N07:1020k -    PPY  you  you  [Ny:s.Ny:s]
N07:1020m -    VV0t find find [Vr.Vr]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1020n -    PPHO1m    him  he    [Nos:o.Nos:o]S?]Q]
N07:1020p -    YIR  +<rdquo>  -     .
N07:1020q -    YQ   +?   -     .O]
N07:1020r -    YB   <minbrk>  -     [Oh.Oh]
N07:1020s -    NP1s Dill Dill [O[S[Nns:s.Nns:s]
N07:1030a -    VBDZ was  be   [Vsb.Vsb]
N07:1030b -    JJ   silent    silent    [J:e.J:e]
N07:1030c -    CSk21     as   as    [Fa:h[CSk=.
N07:1030d -    CSk22     if   if    .CSk=]
N07:1030e -    PPHS1m    he   he    [Nas:s157.Nas:s157]
N07:1030f -    VVDt hated     hate  [Vd.Vd]
N07:1030g -    YG   -    -    [Ti:o<s157.s157>
N07:1030h -    TO   to   to   [Vi.
N07:1030i -    VV0v answer    answer     .Vi]Ti:o]Fa:h]
N07:1030j -    YC   +,   -    .
N07:1030k -    CC   and  and  [S+.
N07:1030m -    NP1s Barton    Barton     [Nns:s.Nns:s]
N07:1030n -    VHD  had  have [Vd.Vd]
N07:1030p -    AT1  a    a    [Ns:o.
N07:1030q -    JJ   cold cold [JJ&.
N07:1030r -    YC   +,   -    .
N07:1030s -    JJ   sick sick [JJ-.JJ-]JJ&]
N07:1030t -    NN1n feeling   feeling    .
N07:1040a -    IO   of   of   [Po.
N07:1040b -    NN1n apprehension   apprehension
.Po]Ns:o]S+]S]
N07:1040c -    YF   +.   -    .O]
N07:1040d -    YB   <minbrk>  -     [Oh.Oh]
N07:1040e -    YIL  <ldquo>   -     [O.
N07:1040f -    PPHS1m    +He  he    [Q[S[Nas:s.Nas:s]
N07:1040g -    VBZ  +<apos>s  be    [Vzb.Vzb]
N07:1040h -    II   in   in   [P:p.
N07:1040i -    NP1s Morgan    Morgan     [Nns[G[Nns.Nns]
N07:1040j -    GG   +<apos>s  -     .G]
N07:1040k -    NN1c Ferry     ferry      .Nns]P:p]S]Q]
N07:1040m -    YIR  +<rdquo>  -     .
N07:1040n -    YF   +.   -    .O]
N07:1050a -    YB   <minbrk>  -     [Oh.Oh]
N07:1050b -    NP1s Barton    Barton     [O[S[Nns:s.Nns:s]
N07:1050c -    RR   half half [Vd.
N07:1050d -    YH   +<hyphen> -     .
N07:1050e -    VVDv +straightened  straighten      .Vd]
N07:1050f -    II   in   in   [P:h.
N07:1050g -    NN1n surprise  surprise   .P:h]S]
N07:1050h -    YF   +.   -    .O]
N07:1050i -    YB   <minbrk>  -     [Oh.Oh]
N07:1050j -    YIL  <ldquo>   -     [O.
N07:1050k -    DDQ  +What     what  [Q[S?[Dq:o.Dq:o]
N07:1050m -    VBZ  +<apos>s  be    [Vozb.Vozb]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1050n -    PPHS1m    he     he     [Nas:s.Nas:s]
N07:1050p -    VDG  doing      do     [Vrg.Vrg]
N07:1060a -    RLh  there      there       [Rw:p.Rw:p]S?]Q]
N07:1060b -    YIR  +<rdquo>   -      .
N07:1060c -    YQ   +?   -     .O]
N07:1060d -    YB   <minbrk>   -      [Oh.Oh]
N07:1060e -    RT   Again      again       [O[S[R:t.R:t]
N07:1060f -    NP1s Dill Dill [Nns:s.Nns:s]
N07:1060g -    VVDi hesitated hesitate   [Vd.Vd]S]
N07:1060h -    YF   +.   -     .
N07:1060i -    YIL  <ldquo>    -      .
N07:1060j -    VVGv +Dealing   deal   [Q[Tg[Vg.Vg]
N07:1060k -    NN1n faro faro [Ns:o.Ns:o]Tg]Q]
N07:1060m -    YIR  +<rdquo>   -      .
N07:1060n -    YF   +.   -     .
N07:1070a -    YIL  <ldquo>    -      .
N07:1070b -    VVGv +Dealing   deal   [Q[Tg?[Vg.Vg]
N07:1070c -    NN1n faro faro [Ns:o.Ns:o]Tg?]
N07:1070d -    YQ   +?   -     .
N07:1070e -    RRQq How  how   [S?[Rq:h.Rq:h]
N07:1070f -    VV0i come come  [V.V]S?]Q]
N07:1070g -    YIR  +<rdquo>   -      .
N07:1070h -    YQ   +?   -     .O]
N07:1070i -    YB   <minbrk>   -      [Oh.Oh]
N07:1070j -    YIL  <ldquo>    -      [O.
N07:1070k -    APPGy     +Your      your [Q[S[Ns:s.
N07:1070m -    NNS1c     sister     sister     .
N07:1070n -    YH   +<hyphen>  -      .
N07:1070p -    II   +in  in    [P.
N07:1070q -    YH   +<hyphen>  -      .
N07:1070r -    NN1n +law law   .P]Ns:s]
N07:1070s -    VHZ  has  have  [Vz.Vz]
N07:1080a -    AT   the  the   [Ns:o.
N07:1080b -    NN1n faro faro  .
N07:1080c -    NNJ1c     bank  bank .Ns:o]
N07:1080d -    II   in   in    [P:p.
N07:1080e -    NP1m Cap  Cap   [Ns[G[Nns.
N07:1080f -    NP1s Ayres      Ayres      .Nns]
N07:1080g -    GG   +<apos>    -      .G]
N07:1080h -    NN1c saloon     saloon     .Ns]P:p]S]Q]
N07:1080i -    YIR  +<rdquo>   -      .
N07:1080j -    YF   +.   -     .O]
N07:1080k -    YB   <minbrk>   -      [Oh.Oh]
N07:1080m -    NP1s Barton     Barton     [O[S[Nns:s.Nns:s]
N07:1080n -    VVDv cursed     curse      [Vd.Vd]
N07:1080p -    II   under      under      [P:h.
N07:1090a -    APPGm     his   his   [Ns.
N07:1090b -    NN1n breath     breath     .Ns]P:h]S]
N07:1090c -    YF   +.   -     .
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
N07:1090d -    ICSt After     after     [S[P:t.
N07:1090e -    DD1q another    another   [Ns.
N07:1090f -    JJ   long long .
N07:1090g -    NN1c pause     pause     .Ns]P:t]
N07:1090h -    PPHS1m    he   he    [Nas:s.Nas:s]
N07:1090i -    VVDv asked     ask  [Vd.Vd]
N07:1090j -    YC   +,   -    .
N07:1090k -    YIL  <ldquo>   -    .
N07:1090m -    RGQq +How how  [Q:o[S?[Np:s[Dqp.
N07:1090n -    DA2  many many .Dqp]
N07:1090p -    NNc  people    people    .Np:s]
N07:1100a -    VV0v know know [V.V]
N07:1100b -    PNQSq     who  who  [Fn?:o[Nq:e.Nq:e]
N07:1100c -    PPHS2     they they [Nap:s.Nap:s]
N07:1100d -    VBR  are  be   [Vab.Vab]Fn?:o]S?]Q:o]
N07:1100e -    YIR  +<rdquo>  -    .S]
N07:1100f -    YQ   +?   -    .O]
N07:1100g -    YB   <minbrk>  -    [Oh.Oh]
N07:1100h -    YIL  <ldquo>   -    [O.
N07:1100i -    PN1  +Everyone everyone  [Q[Ns.Ns]
N07:1100j -    YF   +.   -    .
N07:1100k -    APPGy     Your your [S[Nns:s.
N07:1100m -    NNS1c     cousin    cousin    .
N07:1100n -    NP1s Finley    Finley    .Nns:s]
N07:1100p -    VVDv saw  see  [Vd.Vd]
N07:1110a -    IIt  to   to   [P:u.
N07:1110b -    DD1a that that .P:u]S]
N07:1110c -    YF   +.   -    .
N07:1110d -    PPHS1m    He   he   [S[Nas:s.Nas:s]
N07:1110e -    VBZ  +<apos>s  be   [Vzb.Vzb]
N07:1110f -    RGb  quite     quite     [Ns:e.
N07:1110g -    AT1  a    a    .
N07:1110h -    NN1c rat  rat  .Ns:e]S]
N07:1110i -    YC   +,   -    .
N07:1110j -    PPY  you  you  [S![Ny:s.Ny:s]
N07:1110k -    VV0v know know [V.V]S!]
N07:1110m -    YF   +.   -    .
N07:1110n -    PPHS1m    He   he   [S[Nas:s.Nas:s]
N07:1110p -    VVDv sold sell [Vd.Vd]
N07:1110q -    RP   out  out  [R:n.R:n]
N07:1110r -    IIt  to   to   [P:u.
N07:1110s -    NP1s Kruger    Kruger    [Np[G[Nns.Nns]
N07:1110t -    GG   +<apos>s  -    .G]
N07:1110u -    NN2  men  man  .Np]P:u]S]
N07:1110v -    YF   +.   -    .
N07:1120a -    PPHS1m    He   he   [S[Nas:s.Nas:s]
N07:1120b -    VHZ  +<apos>s  have [Vzf.
N07:1120c -    VVNv informed  inform    .Vzf]
N07:1120d -    PPHO2     them they [Nop:i.Nop:i]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1120e -    IO   of    of    [Po:u.
N07:1120f -    PN1  everything    everything    [Ns:159.
N07:1120g -    YG   -     -     [Fr<o159.o159>
N07:1120h -    PPY  you   you   [Ny:s.Ny:s]
N07:1120i -    YG   -     -     <t161.t161>
N07:1120j -    VH0  +<apos>ve have [Vf.
N07:1120k -    RR   ever  ever  [R:G161.R:G161]
N07:1120m -    VVNv written   write     .Vf]
N07:1120n -    PPHO1m     him   he
[Nos:i.Nos:i]Fr]Ns:159]Po:u]S]
N07:1120p -    YF   +.    -     .
N07:1120q -    PPHS1m     He    he    [S[Nas:s.Nas:s]
N07:1130a -    VVZv wants     want  [Vz.Vz]
N07:1130b -    APPGy      your  your  [Ns:o.
N07:1130c -    NN1c ranch     ranch     .Ns:o]S]Q]
N07:1130d -    YIR  +<rdquo>  -     .
N07:1130e -    YF   +.    -     .O]
N07:1130f -    YB   <minbrk>  -     [Oh.Oh]
N07:1130g -    NP1s Barton    Barton    [O[S[Nns:s.Nns:s]
N07:1130h -    VVDv stood     stand     [Vd.Vd]
N07:1130i -    RP   up    up    [R:n.R:n]S]
N07:1130j -    YF   +.    -     .
N07:1130k -    PPHS1m     He    he    [S[Nas:s.Nas:s]
N07:1130m -    VVDv said  say   [Vd.Vd]
N07:1130n -    RR   tensely   tensely   [R:h.R:h]
N07:1130p -    YC   +,    -     .
N07:1130q -    YIL  <ldquo>   -     .
N07:1130r -    JA21 +All  all   [Q:o[J![JA=.
N07:1140a -    JA22 right     right     .JA=]J!]
N07:1140b -    YF   +.    -     .
N07:1140c -    VV0v Let   let   [S*[V.V]
N07:1140d -    PPIO2      +<apos>s  we    [Nop:O162.Nop:O162]
N07:1140e -    YG   -     -     [Tb:o<s162.s162>
N07:1140f -    VV0i go    go    [V.V]
N07:1140g -    VV0v get   get   [Tb:c[V.V]
N07:1140h -    AT   the   the   [Ns:o.
N07:1140i -    NN1c boy   boy   .Ns:o]Tb:c]Tb:o]S*]Q:o]
N07:1140j -    YIR  +<rdquo>  -     .S]
N07:1140k -    YF   +.    -     .O]
N07:1140m -    YB   <minbrk>  -     [Oh.Oh]
N07:1140n -    NP1s Dill  Dill  [O[S[Nns:s.Nns:s]
N07:1140p -    VHD  had   have  [Vdf.
N07:1140q -    VVNi come  come  .Vdf]
N07:1140r -    RP   up    up    [R:q.R:q]
N07:1140s -    RR   also  also  [R:m.R:m]S]
N07:1140t -    YF   +.    -     .
N07:1140u -    YIL  <ldquo>   -     .
N07:1140v -    PPIS1      +I    I     [Q[S[Nea:s.Nea:s]
N07:1150a -    VBDZ was   be    [Vsb.Vsb]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1150b -    JJ    afraid    afraid     [Jh:e.
N07:1150c -    IO    of    of    [Po.
N07:1150d -    DD1i  this  this  .Po]Jh:e]S]
N07:1150e -    YF    +.    -     .
N07:1150f -    PPIS1       I     I     [S[Nea:s.Nea:s]
N07:1150g -    RR    almost      almost      [R:h.R:h]
N07:1150h -    VDD   did   do    [Vde.
N07:1150i -    XX    +n<apos>t   not   .
N07:1150j -    VV0v  tell  tell  .Vde]
N07:1150k -    PPY   you   you   [Ny:i.Ny:i]S]Q]
N07:1150m -    YIR   +<rdquo>    -     .
N07:1150n -    YF    +.    -     .O]
N07:1150p -    YB    <minbrk>    -     [Oh.Oh]
N07:1150q -    YIL   <ldquo>     -     [O.
N07:1150r -    CSi   +If   if    [Q[S[Fa:c.
N07:1160a -    PPY   you   you   [Ny:s.Ny:s]
N07:1160b -    VHD   had   have  [Vdex.
N07:1160c -    XX    +n<apos>t   not   .Vdex]Fa:c]
N07:1160d -    PPIS1       I     I     [Nea:s.Nea:s]
N07:1160e -    VMd   +<apos>d    will  [Vdcf.
N07:1160f -    VH0   have  have  .
N07:1160g -    VVNv  killed      kill  .Vdcf]
N07:1160h -    PPY   you   you   [Ny:o.Ny:o]S]Q]
N07:1160i -    YIR   +<rdquo>    -     .
N07:1160j -    YF    +.    -     .O]
N07:1160k -    YB    <minbrk>    -     [Oh.Oh]
N07:1160m -    NP1s  Dill  Dill  [O[S[Ns:s[G[Nns.Nns]
N07:1160n -    GG    +<apos>s    -     .G]
N07:1160p -    NN1n  voice       voice       .Ns:s]
N07:1160q -    VVDv  tightened   tighten     [Vd.Vd]S]
N07:1160r -    YF    +.    -     .
N07:1170a -    YIL   <ldquo>     -     .
N07:1170b -    CCB   +But  but   [Q[S+.
N07:1170c -    PPY   you   you   [Ny:s.Ny:s]
N07:1170d -    VMo   ca    can   [Vce.
N07:1170e -    XX    +n<apos>t   not   .
N07:1170f -    VV0v  ride  ride  .Vce]
N07:1170g -    II    into  into  [P:q.
N07:1170h -    AT    the   the   [Ns.
N07:1170i -    NN1c  Ferry       ferry       .Ns]P:q]S+]
N07:1170j -    YF    +.    -     .
N07:1170k -    DD1a  That  that  [S[Ds:s.Ds:s]
N07:1170m -    VBZ   +<apos>s    be    [Vzb.Vzb]
N07:1170n -    DDQ   what  what  [Ff:e[Dq:G163.Dq:G163]
N07:1170p -    PPHS2       they  they  [Nap:s.Nap:s]
N07:1170q -    VMo   +<apos>ll   will  [Vc.
N07:1180a -    VV0t  expect      expect      .Vc]
N07:1180b -    PPY   you   you   [Ny:O165.Ny:O165]
N07:1180c -    YG    -     -     [Ti:o<s165.s165>
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1180d -    TO   to    to    [Vi.
N07:1180e -    VD0  do    do    .Vi]
N07:1180f -    YG   -     -     <o163.o163>Ti:o]Ff:e]S]
N07:1180g -    YF   +.    -     .
N07:1180h -    PPHS2      They  they [S[Nap:s.Nap:s]
N07:1180i -    VMo  +<apos>ll   will [Vcb.
N07:1180j -    VB0  be    be    .Vcb]
N07:1180k -    RLh  there       there      [Rw:p.Rw:p]
N07:1180m -    VVGv waiting     wait [Tg:b[Vg.Vg]
N07:1180n -    IF   for   for   [P:u.
N07:1180p -    PPY  you   you   .P:u]Tg:b]S]
N07:1180q -    YF   +.    -     .
N07:1180r -    PPIS1      I     I     [S[Nea:s.Nea:s]
N07:1180s -    VV0v understand      understand      [V.V]
N07:1190a -    RGQq how   how   [Fn?:o[Rq:h.Rq:h]
N07:1190b -    PPY  you   you   [Ny:s.Ny:s]
N07:1190c -    VV0v feel  feel  [V.V]
N07:1190d -    II   about       about      [P:u.
N07:1190e -    AT   the   the   [Ns.
N07:1190f -    NN1c child       child      .Ns]P:u]
N07:1190g -    YE   ...   -     .Fn?:o]S]Q]
N07:1190h -    YIR  +<rdquo>    -     .
N07:1190i -    YF   +.    -     .O]
N07:1190j -    YB   <minbrk>    -     [Oh.Oh]
N07:1190k -    YIL  <ldquo>     -     [O.
N07:1190m -    AT   +The  the   [Q[S[Ns!.
N07:1190n -    NN1c hell  hell  .Ns!]
N07:1190p -    PPY  you   you   [Ny:s.Ny:s]
N07:1190q -    VD0  do    do    [Vx.Vx]S]Q]
N07:1190r -    YIR  +<rdquo>    -     .
N07:1190s -    YF   +.    -     .
N07:1190t -    NP1s Barton      Barton     [S[Ns:s[G[Nns.Nns]
N07:1190u -    GG   +<apos>s    -     .G]
N07:1200a -    NN1n voice       voice      .Ns:s]
N07:1200b -    VBDZ was   be    [Vsb.Vsb]
N07:1200c -    JJR  rougher     rough      [Jh:e.
N07:1200d -    CSN  than  than  [Fc.
N07:1200e -    NP1s Dill  Dill  [Nns:s.Nns:s]
N07:1200f -    YG   -     -     <t167.t167>
N07:1200g -    VHD  had   have  [Vdf.
N07:1200h -    RR   ever  ever  [R:G167.R:G167]
N07:1200i -    VVNv heard       hear .Vdf]
N07:1200j -    PPH1 it    it    [Ni:o.Ni:o]Fc]Jh:e]S]
N07:1200k -    YF   +.    -     .
N07:1200m -    YIL  <ldquo>     -     .
N07:1200n -    PPIS1      +I    I     [Q[S[Nea:s.Nea:s]
N07:1200p -    RR   never       never      [R:t.R:t]
N07:1210a -    VVDv saw   see   [Vd.Vd]
N07:1210b -    PPHO1m     him   he    [Nos:o.Nos:o]S]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1210c -    YF   +.   -    .
N07:1210d -    APPGi1    My   my   [S[Ns:s.
N07:1210e -    NN1c wife wife .Ns:s]
N07:1210f -    VVDi died die  [Vd.Vd]
N07:1210g -    II   in   in   [P:t.
N07:1210h -    NN1u childbirth   childbirth   .P:t]
N07:1210i -    ICSt after     after     [Fa:t.
N07:1210j -    PPIS1     I    I    [Nea:S.Nea:S]
N07:1210k -    VBDZ was  be   [Vsp.
N07:1210m -    VVNv sent send .Vsp]
N07:1210n -    RL   away away [R:q.R:q]Fa:t]S]Q]
N07:1210p -    YF   +.   -    .O]
N07:1210q -    YB   <minbrk>  -    [Oh.Oh]
N07:1210r -    YIL  <ldquo>   -    [O.
N07:1210s -    PPIS1     +I   I    [Q[S[Nea:s.Nea:s]
N07:1220a -    VMo  ca   can  [Vce.
N07:1220b -    XX   +n<apos>t not  .
N07:1220c -    VV0v leave     leave     .Vce]
N07:1220d -    PPHO1m    him  he   [Nos:o.Nos:o]
N07:1220e -    RLh  there     there     [Rw:p.Rw:p]S]
N07:1220f -    YF   +.   -    .
N07:1220g -    NP1m Donald    Donald    [S[Nns:s.
N07:1220h -    NP1s Kruger    Kruger    .Nns:s]
N07:1220i -    VMd  would     will [Vdc.
N07:1220j -    VV0t like like .Vdc]
N07:1220k -    PN1  nothing   nothing   [Ns:o.Ns:o]
N07:1220m -    JJR  better    good [Jh:h.
N07:1230a -    CSN  than than [Fc.
N07:1230b -    TO   to   to   [Vi.
N07:1230c -    VV0v hold hold .Vi]
N07:1230d -    PPHO1m    him  he   [Nos:o.Nos:o]
N07:1230e -    IIa  as   as   [P:h.
N07:1230f -    NN1c hostage   hostage   .P:h]Fc]Jh:h]
N07:1230g -    YC   +,   -    .
N07:1230h -    CC   and  and  [S+.
N07:1230i -    PPIS1     I    I    [Nea:s.Nea:s]
N07:1230j -    VMd  would     will [Vdce.
N07:1230k -    XX   +n<apos>t not  .
N07:1230m -    VV0t entrust   entrust   .Vdce]
N07:1230n -    AT1  a    a    [Ns:o.
N07:1230p -    NN1c snake     snake     .Ns:o]
N07:1230q -    IIt  to   to   [P:u.
N07:1230r -    APPGm     his  his  [Ns.
N07:1240a -    JJ   tender    tender    .
N07:1240b -    NN1n care care .Ns]P:u]S+]S]
N07:1240c -    YF   +.   -    .
N07:1240d -    PPIS1     I    I    [S[Nea:s.Nea:s]
N07:1240e -    VH0  +<apos>ve have [Vf.
N07:1240f -    VVNv got  get  .Vf]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1240g -     TO    to    to    [Ti:z[Vi.
N07:1240h -     VV0v  get   get   .Vi]
N07:1240i -     AT    the   the   [Ns:o.
N07:1240j -     NN1c  boy   boy   .Ns:o]Ti:z]S]
N07:1240k -     YF    +.    -     .
N07:1240m -     VV0v  Let   let   [S*[V.V]
N07:1240n -     PPIO2       +<apos>s  we    [Nop:O170.Nop:O170]
N07:1240p -     YG    -     -     [Tb:o<s170.s170>
N07:1240q -     VV0v  ride  ride  [V.V]Tb:o]S*]Q]
N07:1240r -     YIR   +<rdquo>    -     .
N07:1240s -     YF    +.    -     .O]
N07:1240t -     YBL   <bmajhd>    -     [Oh.
N07:1240u -     NNJ1c       CHAPTER   chapter   [Nns.
N07:1250a -     MC    TWO   two   .Nns]
N07:1250b -     YBR   <emajhd>    -     .Oh]
N07:1250c -     NP1s  BARTON      Barton
[O[S[Np:s[G[Nns.Nns]
N07:1250d -     GG    +<apos>S    -     .G]
N07:1250e -     NN2   MEN   man   .Np:s]
N07:1250f -     VVDv  CUT   cut   [Vd.Vd]
N07:1250g -     AT    the   the   [Np:o.
N07:1250h -     NN1c  telegraph   telegraph .
N07:1250i -     NN2   wires       wire .Np:o]
N07:1250j -     II    in    in    [P:p.
N07:1250k -     NN1c  half  half  [Np[M.
N07:1250m -     AT1   a     a     .
N07:1250n -     NNOc  dozen       dozen       .M]
N07:1260a -     NN2   places      place       .Np]P:p]
N07:1260b -     YC    +,    -     .
N07:1260c -     VVGv  carrying    carry       [Tg:b[Vg.Vg]
N07:1260d -     RL    away  away  [R:q.R:q]
N07:1260e -     JJ    whole       whole       [Np:o.
N07:1260f -     NN2   sections    section     .Np:o]
N07:1260g -     TO    to    to    [Ti:c[Vi.
N07:1260h -     VV0v  make  make  .Vi]
N07:1260i -     NN2   repairs     repair      [Np:o.Np:o]
N07:1260j -     DAR   more  more  [J:j.
N07:1260k -     JJ    difficult   difficult .J:j]Ti:c]Tg:b]S]
N07:1260m -     YF    +.    -     .
N07:1260n -     PPH1  It    it    [S[Ni:s.Ni:s]
N07:1270a -     VBDZ  was   be    [Vsb.Vsb]
N07:1270b -     II    over  over  [P:e.
N07:1270c -     AT1   an    an    [Ns.
N07:1270d -     NNT1c       hour  hour .Ns]P:e]
N07:1270e -     ICSt  before      before      [Fa:t.
N07:1270f -     APPGh2      their       their       [Ns:S.
N07:1270g -     NN1n  escape      escape      .Ns:S]
N07:1270h -     VBDZ  was   be    [Vsp.
N07:1270i -     VVNt  discovered      discover    .Vsp]Fa:t]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
N07:1270j -     YC    +,    -      .
N07:1270k -     CCB   but   but    [S+.
N07:1270m -     RR    still       still       [R:c.R:c]
N07:1270n -     AT    the   the    [Ns:s.
N07:1280a -     NN1u  news  news   .
N07:1280b -     CST   that  that   [Fn.
N07:1280c -     NP1s  Barton      Barton       [Nns:s.Nns:s]
N07:1280d -     VBDZ  was   be     [Vsb.Vsb]
N07:1280e -     JJ    free  free   [J:e.J:e]Fn]Ns:s]
N07:1280f -     VVDv  flashed     flash        [Vd.Vd]
N07:1280g -     II    across      across       [P:q.
N07:1280h -     AT    the   the    [Ns.
N07:1280i -     JJ    central     central      .
N07:1280j -     NN1c  portion     portion      .
N07:1280k -     IO    of    of     [Po.
N07:1280m -     AT    the   the    [Ns.
N07:1280n -     NNL1n       state       state
.Ns]Po]Ns]P:q]S+]S]
N07:1280p -     YF    +.    -.     .O]
N07:1290a -     YB    <minbrk>    -      [Oh.Oh]
N07:1290b -     PPH1  It    it     [O[S[Ni:s.Ni:s]
N07:1290c -     VVDv  reached     reach        [Vd.Vd]
N07:1290d -     NP1m  Donald      Donald       [Nns:o.
N07:1290e -     NP1s  Kruger      Kruger       .Nns:o]
N07:1290f -     II    in    in     [P:p.
N07:1290g -     APPGm       his   his  [Ns.
N07:1290h -     JJ    massive     massive      .
N07:1290i -     NN1c  home  home   .
N07:1290j -     II    in    in     [P.
N07:1290k -     NP1t  Burlingame        Burlingame
[Nns.Nns]P]Ns]P:p]S]
N07:1290m -     YF    +.    -      .
N07:1300a -     PPH1  It    it     [S[Ni:s.Ni:s]
N07:1300b -     VVDv  reached     reach        [Vd.Vd]
N07:1300c -     AT    the   the    [Np:o.
N07:1300d -     NN2   mines       mine .
N07:1300e -     II    at    at     [P.
N07:1300f -     ND1   North       north        [Nns.
N07:1300g -     NNS   San   San    [Nns.
N07:1300h -     NP1m  Juan  Juan   .Nns]
N07:1300i -     CC    and   and    [Nns+.
N07:1300j -     NP1s  Bloomfield        Bloomfield
.Nns+]Nns]P]Np:o]S]
N07:1300k -     YF    +.    -      .
N07:1300m -     PPH1  It    it     [S[Ni:s.Ni:s]
N07:1310a -     VVDt  brought     bring        [Vd.Vd]
N07:1310b -     NN2   men   man    [Np:o.Np:o]
N07:1310c -     II21  out   out    [P:q[II=.
N07:1310d -     II22  of    of     .II=]
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Volver al índice/Tornar a l'índex


```
N07:1310e -     NN1c bed  bed  .P:q]
N07:1310f -     CC   and  and  [S+.
N07:1310g -     VVDv sent send [Vd.Vd]
N07:1310h -     PPHO2     them they [Nop:o.Nop:o]
N07:1310i -     II   into into [P:q.
N07:1310j -     JJ   hurried   hurried   [Np.
N07:1310k -     NN2  conferences    conference
.Np]P:q]S+]S]
N07:1310m -     YF   +.   -    .
N07:1320a -     CSf  For  for  [Fa.
N07:1320b -     PN1  everyone  everyone  [Ns:s168.
N07:1320c -     YG   -    -    [Tn<S168.S168>
N07:1320d -     VVNt involved  involve   [Vn.Vn]Tn]Ns:s168]
N07:1320e -     VVDv knew know [Vd.Vd]
N07:1320f -     CST  that that [Fn:o.
N07:1320g -     AT   the  the  [Ns:s.
N07:1320h -     JJ   whole     whole     .
N07:1320i -     NNL1c     valley    valley    .Ns:s]
N07:1320j -     VBDZ was  be   [Vsb.Vsb]
N07:1320k -     AT1  a    a    [Ns:e.
N07:1320m -     NN1n powder    powder    .
N07:1320n -     NN1c keg  keg  .Ns:e]
N07:1320p -     YC   +,   -    .
N07:1320q -     CC   and  and  [Fn+.
N07:1330a -     NP1m Mitchell  Mitchell  [Nns:s.
N07:1330b -     NP1s Barton    Barton    .Nns:s]
N07:1330c -     AT   the  the  [Ns:e169.
N07:1330d -     NN1c fuse fuse .
N07:1330e -     DDQr which     which
[Fr[Dq:s169.Dq:s169]
N07:1330f -     VMd  could     can  [Vdc.
N07:1330g -     VV0v send send .Vdc]
N07:1330h -     PPH1 it   it   [Ni:o.Ni:o]
N07:1330i -     II   into into [P:q.
N07:1330j -     JJ   explosive explosive [Ns.
N07:1330k -     NN1u violence  violence
.Ns]P:q]Fr]Ns:e169]Fn+]Fn:o]Fa]
N07:1330m -     YF   +.   -    .O]
N07:1340a -     YB   <minbrk>  -    [Oh.Oh]
```

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

APÉNDICE 2

Ejemplo de texto con las unidades identificadas y numeradas

Universitat d'Alacant
Universidad de Alicante

DOCUMENTO N07-1.ANA

Análisis desde N07:0970c hasta N07:1340a

1.DATOS

Número frase	Entidades introducidas	Referencia a
1	0	
2	2.1. Kruger's	
	2.1. men	
	2.2. **them**	
	2.3. **they**	(2.1.)
	2.4. **me**	
3	3.1. **I**	(2.4.)
	3.2. an outsider	
4	4.1. **they**	(2.3.)
	4.2. **you**	
	4.3. **the hills**	
	4.4. **they**	(4.1.)
	4.5. **that**	4

********** nuevo párrafo **********

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

5	5.1. Barton	
	5.2. a long moment	
	5.3. the question	
	5.4. **his mind**	(5.1.)

********** nuevo párrafo **********

6	6.1. **My boy**	(5.1.)
7	7.1. **you**	(6.1.)
	7.2. **him**	
8	8.1. **Dill**	(6.1.)
	8.2. **he**	(8.1.)
	8.3. **Barton**	(5.1.)
	8.4. a cold sick feeling	
	8.4. of apprehension	

********** nuevo párrafo**********

9	9.1. **He**	(7.2.)
	9.2. Morgan's	
	9.2. ferry	

********** nuevo párrafo **********

10	10.1. **Barton**	(8.3.)
	10.2. surprise	

********** nuevo párrafo **********

11	11.1 **he**	(9.1.)

********** nuevo párrafo **********

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

12	12.1. **Dill**	(8.1.)
13	13.1. faro	
14	14.1. **faro**	(13.1.)

********** nuevo párrafo **********

15	15.1. **Your sister**	(10.1.)
	15.2. **the faro**	(14.1.)
	15.3. Cap Ayres saloon	

********** nuevo párrafo **********

16	16.1 **Barton**	10.1.
	16.2. **his breath**	(16.1.)
17	17.1. another pause	
	17.2. **he**	(16.1.)
	17.3. people	
	17.4. they	

********** nuevo párrafo **********

18	18.1. everyone	
19	19.1. **your cousin Finley**	(16.1.)
	19.2. **that**	17
20	20.1. **he**	(19.1.)
	20.2. a rat	
	20.3. **you**	(12.1.)
21	21.1. **he**	(20.1.)
	21.2. **Kruger' men**	(2.1.)

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

22	22.1. **he**	(21.1.)
	22.2. **them**	(21.2.)
	22.3. everything	
	22.4. **you**	(16.1.)
	22.5. **him**	(22.1.)
23	23.1. **He**	(22.5.)
	23.2. **your ranch**	(22.4.)

********** nuevo párrafo **********

24	24.1. **Barton**	(16.1.)
25	25.1. **He**	(24.1.)
26	26.1. the boy	
27	27.1. **Dill**	(12.1.)
28	28.1. **I**	(24.1.)
	28.2. **this**	
29	29.1. **I**	(27.1.)
	29.2. **you**	(24.1.)

********** nuevo párrafo **********

30	30.1.**you**	(29.1.)
	30.2. **I**	(29.2.)
	30.3. **you**	(30.1.)

********** nuevo párrafo **********

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

31	31.1. **Dill's**	(27.1.)
	31.1. voice	
32	32.1. **you**	(30.2.)
	32.2. **the ferry**	(9.2.)
33	33.1. **that**	32
	33.2. **they**	(22.2.)
	33.3. **you**	(32.1.)
34	34.1. **they**	(33.2.)
	34.2. **you**	(33.3.)
35	35.1. **I**	(34.2.)
	35.2. **you**	(31.1.)
	35.3. **the child**	(26.2.)

********** nuevo párrafo **********

36	36.1. the hell	
	36.2. **you**	(35.1.)
37	37.1. **Barton's**	(24.1.)
	37.1. voice	
	37.2. **Dill**	(31.1.)
	37.3. **it**	(37.1.)
38	38.1. **I**	(37.1.)
	38.2. **him**	(35.3.)
39	39.1. **my wife**	(38.1.)

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

	39.2. childbirth	
	39.3. **I**	(38.1.)
********** nuevo párrafo **********		
40	40.1. **I**	(39.3.)
	40.2. **him**	(38.2.)
41	41.1. **Donald Kruger**	(2.1.)
	41.2. nothing	
	41.3. **him**	(40.2.)
	41.4. hostage	
	41.5. **I**	(39.3.)
	41.6. a snake	
	41.7. **his** tender care	(41.1.)
42	42.1. **I**	(41.5.)
	42.2. **the boy**	(41.3.)
43	0	
44	44.1. **Barton's**	(37.1.)
	44.2. the telegraph wires	
	44.3. half a dozen places	
	44.4. whole sections	
	44.5. repairs	
45	45.1 It	
	45.2. an hour	

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Volver al índice/Tornar a l'índex

45.3. **their escape** (44.1.)

45.4. the news

45.5. **Barton** (44.1.)

45.6. the central portion

45.6[1]. of the state

********** nuevo párrafo **********

Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

APÉNDICE 3

Listado completo del programa de resolución anafórica.

Universitat d'Alacant
Universidad de Alicante

```
                                /* LFG.DEC*/



:- consult('unify.dec').
:- consult('iden.dec').
:- consult('ira.dec').
:- consult('conv.dec').
:- consult('seman.dec').
:- consult('prag.dec').
:- consult('output.dec').
:- consult('input.dec').


%%% RUTINAS DE INPUT %%%

try:- abolish(vedis),
      abolish(vea),
      abolish(ea),
      abolish(edis),
      try(1,1).

try(O,Cla):-
      tell('out.dec'),
      read_in(Text),
      s(Sstructure,Fstructure,Text,[Punc]),
      in(Punc,[.,?,!]),
      pp(Sstructure),nl,nl,
      rearrange(Fstructure,NewFstructure),
      printout(0,NewFstructure),nl,nl,
      identifica(O,Cla,NewFstructure,EDIS,EA),
      rasgos_semanticos(EDIS,EA,EA2),
      rasgos_pragmaticos(EA2),
      told,
      write('¿Introducir nuevas oraciones? (s/n)'),nl,
      get(Y),
           ((Y=110,!,
           relaciones_anaforicas);
           (Y=115),!,nl,
              NewO is O+1,
        try(NewO,Cla)).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
%%% REGLAS DE ESTRUCTURA DE FRASE %%%
   % adaptación de Amores (1992) %

% Oración

      s(s(NP,VP),Fs) -->
 np(NP,Fnp),{unify([],[subj:Fnp,num:Num],F1),
                  extract(Fnp,num:Num)},
                     vph(VP,Fvp), {unify(Fvp,F1,Fs),
                        extract(Fvp,pred:Pred),
                          complete(Fs,Pred)}.

% Sintagma nominal

      np(np(NP),Fnp) -->pn(NP,Fnp).

      np(np(NP),Fnp) --> pr(NP,Fnp).

      np(np(Det,N),Fnp) --> det(Det,Fdet),
                            {unify([],[num:Num,det:Fdet],F1),
                            extract(Fdet,num:Num)},
                            n(N,Fn), {unify(F1,Fn,Fnp)}.

% Sintagma verbal

      vph(vp(Adv,Vp),Fs) --> advp(Adv,Fadv),
                  vp(Vp,Fvp),
                  {unify(Fvp,[advp:Fadv]),Fs)}.

      vph(vp(Vp),Fs) --> vp(Vp,Fs).

      vp(vp(V,NP),Fvp) --> v(V,Fv),
                           {extract(Fv,pred:Pred),
                           allows(Pred,obj)},
                          np(NP,Fnp), {unify(Fv,[obj:Fnp],Fvp)}.

      vp(vp(V,NP,PP),Fvp) --> v(V,Fv),
                     np(NP,Fnp),
                        {unify(Fv,[obj:Fnp],F1)},
                        prepp(PP,Fpp),
                          {unify(F1,[prepp:Fpp],Fvp)}.

      vp(vp(V),Fvp) --> v(V,Fvp).

      vp(vp(V,PP),Fvp) --> v(V,Fv),
                  prepp(PP,Fpp),
                       {unify(Fv,[prepp:Fpp],Fvp)}.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
vp(vp(V,ADJ),Fvp) --> v(V,Fv),
                {extract(Fv,pred:Pred),
                     allows(Pred,adjp)},
                     adjp(ADJ,Fadj),
                   {unify(Fv,[adjp:Fadj],Fvp)}.

vp(vp(V,VP),Fvp) --> v(V,Fv),
                sbar(VP,Fsbar),
                     {unify(Fv,[scomp:Fsbar],Fvp)}.


vp(vp(Aux,VP),Fvp) --> aux(Aux,Fv),
                vp(VP,Fvpp),
                {unify(Fv,Fvpp,Fvp)}.



% Sintagma preposicional

     prepp(prepp(Prep,NP),Fpp) --> prep(Prep,Fp),
                    np(NP,Fnp),
                       {unify([pcase:Fp],Fnp,Fpp)}.

% Oración subordinada

     sbar(sbar(C,S),Fsbar) --> sc(C,F),
                s(S,Fs),
                {unify(F,Fs,Fsbar)}.


%%% REGLAS PARA LOS SIMBOLOS TERMINALES %%%

% Nombre común

     n(n(N),F) --> [N], {lex(n,N,F)}.

% Nombre propio

     pn(pn(PN),F) --> [PN], {lex(pn,PN,F)}.

% Pronombre

     pr(pr(PR),F) --> [PR], {lex(pr,PR,F)}.

% Verbo

     v(v(V),F) --> [V], {lex(v,V,F)}.

% Determinante

     det(det(Det),F) --> [Det], {lex(det,Det,F)}.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
% Adjetivo

     adjp(adjp(ADJ),F) --> [ADJ], {lex(adj,ADJ,F)}.

% Preposición

     prep(prep(Prep),F) --> [Prep], {lex(prep,Prep,F)}.

% Conjunción

     sc(sc(C),F) --> [C], {suc(C,F)}.

% Adverbio

     advp(advp(Adv),F) --> [Adv], {av(Adv,F)}.


% Auxiliares

     aux(aux(A),F) --> [A], {auxi(A,F)}.



%%% PREDICADOS AUXILIARES %%%

extract([],Feature:Value):-!,fail.
extract([Feature:Value|_],Feature:Value).
extract([F1:V1|Rest],F2:V2):- extract(Rest,F2:V2).

allows(Pred,Case) :- Pred=..[_|Frame], in(Case,Frame).
allows(Pred,Case) :- Pred=..[_|Frame],in(opt(Case),Frame).

in(X,[X|Rest]).
in(X,[_|Rest]):- in(X,Rest).

complete(F,Pred) :- Pred=..[_|Frame],satisfied(Frame,F).

satisfied([],_).
satisfied([opt(_)],F).
satisfied([opt(_)|Rest],F):- satisfied(Rest,F).
satisfied([Case],F):- unify([Case:[pred:_]],F,F).
satisfied([Case1|Rest],F):- unify([Case1:[pred:_]],F,F),
                    satisfied(Rest,F).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez

Universitat d'Alacant
Universidad de Alicante

```
%%% MORFOLOGIA %%%
 % adaptación de Gal et al (1991) %

:- consult('list.dec').


test(Sing,Astring,Condition,Bstring,Plur):-
     not var(Sing),
     convert(Sing,Singlist),
     append(Base,Astring,Singlist),
     call(Condition),
     append(Base,Bstring,Plurlist),
     convert(Plur,Plurlist).

test(Sing,Astring,Condition,Bstrign,Plur):-
     not var(Plur),
     convert(Plur,Plurlist),
     append(Base,Bstring,Plurlist),
     call(Condition),
     append(Base,Astring,Singlist),
     convert(Sing,Singlist).

% Reglas específicas de morfología

% Plurales irregulares

     plural(child,children):-!.
     plural(mouse,mice):-!.
     plural(sheep,sheep):-!.
     plural(fish,fish).

% Tiempo pasado de los verbos

     plural(X,X):- dic(X,v,[tense:past|_]).

% y -> ies, excepto tras vocal

     plural(Sing,Plur) :-
          test(Sing,[C,y],not(vowel(C)),[C,i,e,s],Plur).

% s,x,z -> es

     plural(Sing,Plur) :-
          test(Sing,[C],in(C,[o,s,x,z]),[C,e,s],Plur).

% ch,sh -> es

     plural(Sing,Plur) :-
          test(Sing,[C,h],in(C,[c,s]),[C,h,e,s],Plur).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
% casos por defecto

      plural(Sing,Plur) :-
            test(Sing,[],true,[s],Plur).

      plural(Sing,PLur) :-
            test(Sing,[],true,[ed],Plur).

      vowel(C) :- in(C,[a,e,i,o,u]).


% Reglas de diccionario

% Nombres

      lex(n,N,Features) :- dic(N,n,NFeatures),
                  unify([num:sing],NFeatures,Features).

      lex(n,N,Features) :- plural(Sing,N),
                  dic(Sing,n,Fs),
                  unify([num:plur],Fs,Features).

% Verbos

      lex(v,V,Features) :- dic(V,v,Features),
                  extract(Features,tense:past).

      lex(v,V,Features) :- dic(V,v,VFeatures),
                  unify([num:plur],VFeatures,Features).

      lex(v,V,[num:sing|Features]):- plural(Basic,V),
                  dic(Basic,v,Features).


%%% DICCIONARIO %%%


% Artículos y demostrativos

      lex(det,those,[num:plur]).
      lex(det,that,[num:sing]).
      lex(det,the,[num:_]).
      lex(det,a,[num:sing]).

% Adjetivos

      lex(adj,good,[pred:good]).

% Preposiciones

      lex(prep,with,[pred:with]).
      lex(prep,in,[pred:in]).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
      lex(prep,on,[pred:on]).

% Conjunciones

      suc(that,[compl:that]).

% Adverbios

      av(also,[adv:also]).

% Nombres propios

      lex(pn,peter,[pred:peter,gen:masculino,pers:terc,
            num:sing]).
      lex(pn,mary,[pred:mary,gen:femenino,pers:terc,num:sing]).

% Pronombres

      lex(pr,she,[pred:she,gen:femenino,pers:terc,num:sing]).
      lex(pr,her,[pred:her,gen:femenino,pers:terc,num:sing]).
      lex(pr,herself,[pred:herself,gen:femenino,pers:terc,
            num:sing]).
      lex(pr,he,[pred:he,gen:masculino,pers:terc,num:sing]).
      lex(pr,him,[pred:him,gen:masculino,pers:terc,num:sing]).
      lex(pr,himself,[pred:himself,gen:masculino,pers:terc,
            num:sing]).
      lex(pr,they,[pred:they,gen:indefinido,pers:terc,num:plur]).
      lex(pr,them,[pred:them,gen:indefinido,pers:terc,num:plur]).
      lex(pr,themselves,[pred:themselves,gen:indefinido,
            pers:terc,num:plur]).
      lex(pr,there,[pred:there,gen:indefinido,pers:terc,
            num:sing]).
      lex(pr,it,[pred:it,gen:neutro,pers:terc,num:sing]).
      lex(pr,itself,[pred:itself,gen:neutro,pers:terc,num:sing]).

% Nombres

      dic(child,n,[pred:child,gen:indefinido,pers:terc]).
      dic(mouse,n,[pred:mouse,gen:neutro,pers:terc]).
      dic(sheep,n,[pred:sheep,gen:neutro,pers:terc]).
      dic(boy,n,[pred:boy,gen:masculino,pers:terc]).
      dic(man,n,[pred:man,gen:masculino,pers:terc]).
      dic(girl,n,[pred:girl,gen:femenino,pers:terc]).
      dic(cake,n,[pred:cake,gen:neutro,pers:terc]).
      dic(fish,n,[pred:fish,gen:neutro,pers:terc]).
      dic(table,n,[pred:table,gen:neutro,pers:terc]).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
% Verbos

     dic(buy,v,[subj:[semfeat:human],pred:buy(subj,obj)]).
     dic(die,v,[subj:[semfeat:animate],pred:die(subj)]).
     dic(eat,v,[pred:eat(subj,opt(obj)),subj:[semfeat:human],
          obj:[semfeat:edible]]).
     dic(paint,v,[pred:paint(subj,opt(obj)),
          subj:[semfeat:human],obj:[semfeat:object]]).
     dic(like,v,[pred:like(subj,obj),subj:[semfeat:animate]]).
     dic(play,v,[pred:play(subj,opt(obj)),
          subj:[semfeat:animate]]).
     dic(sleep,v,[subj:[semfeat:animate],pred:sleep(subj)]).
     dic(see,v,[pred:see(subj,obj),subj:[semfeat:animate]]).
     dic(taste,v,[pred:taste(subj,obj),subj:[semfeat:human],
          obj:[semfeat:edible]]).
     dic(taste,v,[pred:taste(subj,adjp),subj:[semfeat:edible]]).
     dic(think,v,[pred:think(subj,scomp),subj:[semfeat:human]]).
     dic(are,v,[pred:there_be(subj,obj),num:plur]).
     dic(is,v,[pred:there_be(subj,obj),num:sing]).
     dic(ate,v,Vfeats):- dic(eat,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(bought,v,Vfeats):- dic(buy,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(died,v,Vfeats):- dic(die,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(slept,v,Vfeats):- dic(sleep,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(saw,v,Vfeats):- dic(see,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(thought,v,Vfeats):- dic(think,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).
     dic(was,v,Vfeats):- dic(is,v,Rootfeats),
                unify([tense:past],Rootfeats,Vfeats).

     auxi(had,[tense:past]).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
          /* UNIFY.DEC */

% Reglas de unificación adaptadas de Gal et al. (1991) %

:-op(600,xfy,':').

unify(Fset,Fset,Fset):-!.
unify(Anything,[],Anything) :-!.
unify([],Anything,Anything) :-!.

% atributos idénticos y valores idénticos

    unify([F1:V1|R1],[F1:V1|R2],[F1:V1|R]) :- !,
                          unify(R1,R2,R).

% atributos idénticos

     unify([Feature1:SetValue1|Rest1],
               [Feature1:SetValue2|Rest2],
               [Feature1:Result1|Result]):-
          not(atom(SetValue1)),
          not(atom(SetValue2)),
          unify(SetValue1,SetValue2,Result1),
          unify(Rest1,Rest2,Result),!.

% atributos idénticos y valores diferentes

     unify([Feature1:Value1|Rest1],
               [Feature1:Value2|Rest2],Result):-
          !,fail.

% atributos diferentes

     unify([Feature1:Value1|Rest1],
               [Feature2:Value2|Rest2],Result):-
          unify([Feature1:Value1],Rest2,NewRest2),
          unify(Rest1,[Feature2:Value2|NewRest2],Result),!.

% cuando tres grupos de atributos se especifican parcialmente,
% el resultado de unificar los dos primeros puede ser compatible
% con el tercer, pero no necesariamente en el mismo orden.
% perm permite todas las permutaciones posibles de un conjunto.

     unify(X,Y,Z) :- not(var(Z)), unify(X,Y,ZZ), perm(Z,ZZ).


     perm([],[]):-!.
     perm([H],[H]):-!.
     perm([H|T],L):-
          perm(T,T1), list_delete(L,T1,H).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
                    /* IDEN.DEC */

/* Identificación de entidades discursivas, EDIS, y expresiones
   anafóricas, EA.*/


% identifica/5
% localiza en el discurso (D) todas las entidades discursivas
% (edis) así como las expresiones anafóricas (ea) y las guarda
% en dos listas diferentes, marcando al mismo tiempo, el número
% de oración (O) y el número de cláusula (Cla).

      identifica(O,Cla,D,[O,Cla,Edis],[O,Cla,Ea]):-
            ident0(O,Cla,D,Edis,Ea).

      ident0(O,Cla,[],[],[]).

      ident0(O,Cla,[D1|D2],[Edis1|Edis2],[Ea1|Ea2]):-
            ident1(O,Cla,D1,Edis1,Ea1),
            ident0(O,Cla,D2,Edis2,Ea2).


      ident1(O,Cla,Funcion:[pred:EA|Resto],0,
            Funcion:[pred:EA|Resto]):-
            expresion_anaforica:EA.

      ident1(O,Cla,Funcion:Valores,Funcion:Valores,0):-
            entidad_discursiva:Funcion.

      ident1(O,Cla,scomp:Valores,Edis,Ea):-
            NewCla is Cla+1,
            identifica(O,NewCla,Valores,Edis,Ea).

      ident1(O,Cla,Funcion:Valores,0,0).


% definición de las funciones sintácticas de las entidades
% discursivas.

      entidad_discursiva:subj.
      entidad_discursiva:obj.
      entidad_discursiva:prepp.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
% definición de las expresiones anafóricas.

      expresion_anaforica:he.
      expresion_anaforica:him.
      expresion_anaforica:himself.
      expresion_anaforica:it.
      expresion_anaforica:itself.
      expresion_anaforica:she.
      expresion_anaforica:her.
      expresion_anaforica:herself.
      expresion_anaforica:they.
      expresion_anaforica:them.
      expresion_anaforica:themselves.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
                              /* SEMAN.DEC */

                    /* Módulo de análisis semántico */

:- op(600,xfy,['isa']).

      rasgos_semanticos(EDIS,EA,EA2):-
            semantica(EDIS,EDIS2),!,
            write('Entidades discursivas:'),nl,
            store(edis,EDIS2),!,
            semantica(EA,EA2).


      semantica([O,Cla,[]],[]):-!.

      semantica([O,Cla,[0|T]],L):-!,
            semantica([O,Cla,T],L).

      semantica([O,Cla,[H|T]],[X|Y]):-
            semfeat([O,Cla,H],X),
            semantica([O,Cla,T],Y).


      semfeat([O,Cla,[H|T]],L):-
            integer(H),
            semantica([H|T],L).



% reglas de asignación de rasgos semánticos para los pronombres
% "it", "they" y  "them" en función de las restricciones de
% selección impuestas por el verbo

      semfeat([N,Cla,Feature:Value],
            [oracion:N,clausula:Cla,Feature:T]):-
         in(pred:P,Value),
                  (P == it;
                   P == they;
                   P == them),!,
                        (in(semfeat:SF,Value),
                        assert(P isa SF:yes);
                        not in(semfeat:SF,Value),
                        assert(P isa default:yes)),
            jerarquia_semantica(Value,P,T),
               retract(P isa SF:yes).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
% reglas de asignación de rasgos semánticos para el resto de
% pronombres y entidades discursivas

     semfeat([N,Cla,Feature:Value],
          [oracion:N,clausula:Cla,Feature:T]):-!,
        in(pred:P,Value),
             jerarquia_semantica(Value,P,T).


% reglas para establecer la jerarquía semántica

     jerarquia_semantica(Value,P,T):-
             findall(I,inheritance(P,I),Semfeat),
          sort(Semfeat,Semfeat2,[2]),
          append(Value,Semfeat2,Value2),
          delfeat_all([det:D,semfeat:SF,default:X,pcase:PC],
               Value2,T).


     inheritance(Item,Feature):-
          Item isa Feature.


% jerarquía semántica


     Item isa animate:yes:- Item isa human:yes.

     Item isa animate:no:-  not Item isa animate:yes,
                            not Item isa default:yes.

     Item isa animate:yes_no:- Item isa default:yes.

     Item isa count:yes:-   Item isa animate:yes;
                            Item isa object:yes;
                           Item isa edible:yes.

     Item isa count:no:-    not Item isa count:yes,
                           not Item isa default:yes.

     Item isa count:yes_no:- Item isa default:yes.

     Item isa abstract:yes:- Item isa feeling.

     Item isa abstract:no:-  not Item isa abstract:yes,
                            not Item isa default:yes.

     Item isa abstract:yes_no:- Item isa default:yes.

     Item isa object:no:-    not Item isa object:yes,
                            not Item isa default:yes.

     Item isa object:yes_no:- Item isa default:yes.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
      Item isa human:no:-      not Item isa human:yes,
                              not Item isa default:yes.

      Item isa human:yes_no:- Item isa default:yes.


      peter isa human:yes.
      mary isa human:yes.
      he isa human:yes.
      him isa human:yes.
      himself isa human:yes.
      she isa human:yes.
      her isa human:yes.
      herself isa human:yes.
      child isa human:yes.
      boy isa human:yes.
      man isa human:yes.
      woman isa human:yes.
      girl isa human:yes.
      cake isa edible:yes.
      fish isa edible:yes.
      mouse isa animate:yes.
      sheep isa animate:yes.
      table isa object:yes.


store(N,[]):-!,
      nl.

store(N,[oracion:O|T]):-!,
      nl,
      tab(5),
      write([oracion:O|T]),
      nl,
      recorda(N,[oracion:O|T],R).

store(N,[H|T]):-!,
  store(N,H),
  store(N,T).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
                /* PRAG.DEC */

/*  Rasgos_pragmaticos/1  asigna  el  valor  de  distancia
correspondiente a cada una de la expresiones anafóricas en
función de si se trata de un pronombre reflexivo o no. De este
modo puede indicarse si el pronombre prefiere un antecedente
dentro de su misma oración o de su misma cláusula */

    rasgos_pragmaticos(EA):-
          distancia(EA,EAP),
          write('Expresiones anafóricas:'),nl,
          store(ea,EAP).


    distancia([],[]).

    distancia([H|T],[X|Y]):-
          dist(H,X),
          distancia(T,Y).

    dist([],[]).

    dist([oracion:O,clausula:Cla,F:Ea1],
                [oracion:O,clausula:Cla,F:EAP]):-
          in(pred:P,Ea1),
          (reflexivo(P),
          append(Ea1,
                [distancia1:misma_cla,distancia2:misma_orac],
                EAP);
          not reflexivo(P),
          append(Ea1,
                [distancia1:dif_cla,distancia2:dif_orac],
                EAP)).

    dist([H|T],[X|Y]):-
          distancia([H|T],[X|Y]).


    reflexivo(P):-
          convert(P,PList),
          (append(X,[s,e,l,f],PList);
           append(X,[s,e,l,v,e,s],PList)).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
                /* IRA.DEC */

      /* Módulo de identificación de relaciones anafóricas */


% relaciones_anaforicas/0
% determina la relación anafórica correcta entre una entidad
% discursiva y una expresión anafórica.

     relaciones_anaforicas :-
          call(ea(N,V)),
          convierte(ea(N,V),ea(E,[V1|V2])),
          normaliza(ea(E,[V1|V2])),
          calcula_distancia(ea(_,V)),
          compara,
          abolish(vean),
          abolish(vedn),
          fail.

     relaciones_anaforicas.


% normaliza/1
% normaliza los vectores correspondientes a las expresiones
% anafóricas, VEA (vector expresión anafórica) y las
% entidades discursivas, VEDIS (vector entidad discursiva).

     normaliza(Expresion(E,V1)):-
          normal(Expresion(E,V1),Expresion(E,V2)),!,
          ((Expresion == ea,!,
               recorda(vean,Expresion(E,V2),X));
          Expresion == edis,!,
               recorda(vedn,Expresion(E,V2),Y)).

     normal(Expresion(E,V1),Expresion(E,V2)):-
          calcula(P,V1,V12),
          sc(P,SC),
          norm(SC,V1,V2).


% norm/3
% normaliza V1

     norm(SC,[],[]).
          norm(SC,[X|Y],[H|T]) :-
          H is SC * X,
          norm(SC,Y,T).




% calcula_distancia/2
% calcula la distancia que existe entre una expresión
% anafórica,EA, y una entidad discursiva,EDIS.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
      calcula_distancia(ea(_,[O,Cla|_])):-
                  call(edis(N1,[O2,Cla2|T2])),
            oracion(O,O2,O3),
            clausula(Cla,Cla2,Cla3),
            append(Cla3,O3,Dist),
            append([O2,Cla2|T2],Dist,T3),
            convierte(edis(N1,T3),edis(N2,T4)),
            normaliza(edis(N2,T4)),
            fail.

      calcula_distancia(ea(_,[H|_])).

      oracion(O,O,[distancia2:misma_orac]):-!.
      oracion(O,O2,[distancia2:dif_orac]):-!.

      clausula(Cla,Cla,[distancia1:misma_cla]):-!.
      clausula(Cla,Cla2,[distancia1:dif_cla]):-!.


% compara/0
% compara cada una de las expresiones anafóricas con cada una
% de las entidades discursivas buscando el antecedente
% correcto.

      compara:-
                  call(vean(_,ea(pred:P,L))),
                  findall(Res,prodes(vedn(VEDN),
                        vean(_,ea(pred:P,L)),Res),Prodes),
                  sort(Prodes,[H|T],[2],1),
                  write('ANTECEDENTE DE '),
                  write(P),
                  write(:),nl,tab(5),
                  write(H),nl,nl,tab(3),
                  write('Antecedentes rechazados:'),nl,tab(5),
                  ar(T).


% prodes/3
% halla el producto escalar de dos vectores, en este caso
% los vectores normalizados de las EDIS y las EA: VEDN (vector
% entidad discursiva normalizado), VEAN (vector de expresión
% anafórica normalizado).

      prodes(vedn(E),vean(_,ea(VEAN,[H|T])),R) :-
            vedn(_,edis(VEDN,[X|Y])),
            prodes2([X|Y],[H|T],[VEDN,R2]),
            R =.. [VEDN,R2].

      prodes2([0],[],[EDN,0]).
      prodes2([],[],[EDN,0]).
      prodes2([X|Y],[H|T],[EDN,R]) :-
            R1 is X * H,
            prodes2(Y,T,[EDN,R3]),
            R is R1 + R3.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
% calcula/3
% calcula P = Σ(V1)^2

      calcula(P,V1,V12) :-
            cuadrado(V1,V12),
            suma(V12,P).

      cuadrado([],[]).
      cuadrado([X|Y],[H|T]) :-
            cuad(X,H),
            !,
            cuadrado(Y,T).


      cuad(0,0) :-!.

      cuad(X,H) :-
            H is X ^ 2.


% suma/2
% calcula el sumatorio de V12

      suma([],0).
      suma([X|Y],P) :-
            suma1(X,Y,P).

      suma1(X,[],X).
      suma1(X,[H|T],P) :-
            N is X + H,
            suma(T,O),
            P is N + O.


% sc/2
% calcula la constante por la que deben multiplicarse los
% elementos de V1 para normalizarlos

      sc(0,0) :-!.
      sc(P,SC) :-
            SC is (1 / P) ^ (1 / 2).


      ar([]) :-
            nl,
            nl.
      ar([H|T]) :-
            write(H),
            nl,
            tab(5),
            ar(T).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
                    /* CONV.DEC */

          /* Módulo para la conversión en vectores */

% Cada uno de los rasgos lingüísticos acumulados durante las
% fases de análisis, esto es, rasgos morfológicos, sintácticos,
% semánticos y pragmáticos, tiene asignado un valor numérico que
% se utiliza para construir un vector.
% Cada vector representa, por tanto, una expresión anafórica o
% una entidad discursiva.


     convierte(Expresion(N,[H|T]),Expresion(E,[V1|V2])):-
               inlist(pred:E,[H|T]),
               convierte_valor([H|T],[V1|V2]).


     convierte_valor([],[]).

     convierte_valor([Feature:Value|L],[V1|V4]):-
          lst(Value),
          valor(no_restrictivo,Feature,V1),
          convierte_valor(Value,V2),
          convierte_valor(L,V3),
          concat(V2,V3,V4).

     convierte_valor([H|T],[V1|V2]):-
               valor(no_restrictivo,H,V1),
               convierte_valor(T,V2).

     convierte_valor([H|T],[V1|V2]):-
               valor(restrictivo,H,[V1|V3]),
               convierte_valor(T,V4),
               concat(V3,V4,V2).

     inlist(pred:X,[F:V|T]):-
          lst(V),
          in(pred:X,V).

     inlist(pred:X,[H|T]):-
          inlist(X,T).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
% valores correspondientes a la información morfológica

      valor(restrictivo,gen:neutro,[3,0,0]).
      valor(restrictivo,gen:masculino,[0,3,0]).
      valor(restrictivo,gen:femenino,[0,0,3]).
      valor(restrictivo,gen:indefinido,[3,3,3]).
      valor(restrictivo,num:sing,[3,0]).
      valor(restrictivo,num:plur,[0,3]).
      valor(restrictivo,num:colectivo,[3,3]).
      valor(restrictivo,pers:prim,[3,0,0]).
      valor(restrictivo,pers:seg,[0,3,0]).
      valor(restrictivo,pers:terc,[0,0,3]).


% valores correspondientes a la información sintáctica

      valor(no_restrictivo,subj,4).
      valor(no_restrictivo,obj,3).
      valor(no_restrictivo,prepp,1).
      valor(no_restrictivo,adjunct,1).

% valores correspondientes a la información semántica

      valor(restrictivo,edible:yes,[2,0]).
      valor(restrictivo,edible:no,[0,2]).
      valor(restrictivo,edible:yes_no,[2,2]).
      valor(restrictivo,count:yes,[2,0]).
      valor(restrictivo,count:no,[0,2]).
      valor(restrictivo,count:yes_no,[2,2]).
      valor(restrictivo,human:yes,[2,0]).
      valor(restrictivo,human:no,[0,2]).
      valor(restrictivo,human:yes_no,[2,2]).
      valor(restrictivo,animate:yes,[2,0]).
      valor(restrictivo,animate:no,[0,2]).
      valor(restrictivo,animate:yes_no,[2,2]).
      valor(restrictivo,abstract:yes,[2,0]).
      valor(restrictivo,abstract:no,[0,2]).
      valor(restrictivo,abstract:yes_no,[2,2]).
      valor(restrictivo,object:yes,[2,0]).
      valor(restrictivo,object:no,[0,2]).
      valor(restrictivo,object:yes_no,[2,2]).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
% valores correspondientes a la información pragmática

      valor(no_restrictivo,prominencia:subj,2).
      valor(no_restrictivo,prominencia:obj,2).
      valor(no_restrictivo,prominencia:prepp,1).
      valor(restrictivo,distancia1:misma_cla,[1,0]).
      valor(restrictivo,distancia1:dif_cla,[0,1]).
      valor(no_restrictivo,distancia2:misma_orac,1).
      valor(no_restrictivo,distancia2:dif_orac,0).

% otros valores

      valor(no_restrictivo,oracion:N,0).
      valor(no_restrictivo,clausula:N,0).
      valor(no_restrictivo,pred:X,0).
      valor(no_restrictivo,[],0).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
                        /* OUTPUT.DEC */

% mostrar de manera ordenada los pares atributo-valor

      show(Features):- rearrange(Features,Newfeatures),
            printout(0, Newfeatures).

      printout(Tab,[]) :- !.
      printout(Tab,Value) :- atom(Value), !, print(Value),nl.
      printout(Tab,[pred:Pred|Rest]):-    !,    print('pred:'),
            print(Pred),
            nl, tab(Tab), printout(Tab,Rest).
      printout(Tab,[Feature:Value])   :-   !,   print(Feature),
            print(':'),
            namelength(Feature,Len),
            Newtab is Tab+Len+1,
            printout(Newtab,Value).
      printout(Tab,[Feature:Value|Rest]) :- !, print(Feature),
            print(':'),
            namelength(Feature,Len), Newtab is Tab+Len+1,
            printout(Newtab,Value), tab(Tab),
            printout(Tab,Rest).

      namelength(Name,Length) :- name(Name,X), length(X,Length).


% ordenar del siguiente modo: pre, atributos atómicos, grupos de
% atributos

      rearrange(Featset,[pred:Val|Rest]):-
            perm(Featset,[pred:Val|Others]),    !,
            internal(Others,Rest).
            rearrange(F,F).

      internal([],[]):-!.
      internal([Feat:Val|Tail],[Feat:Val|Newtail]):-
              atom(Val),!,internal(Tail,Newtail).
      internal([Feat:Val|Tail],[Feat:Val|Newtail]):-
              Val=..[_,_],!,internal(Tail,Newtail).
      internal([Feat:Val|Tail],Result):- rearrange(Val,Newval),
              internal(Tail,Newtail),
              concat(Newtail,[Feat:Newval],Result).


% mostrar las palabras separadas por espacios en blanco y
% acabando en una nueva línea

      write_word([Head|Tail]):- write(Head), write(' '),
            write_word(Tail).

      write_word([]):- nl.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
% mostrar las expresiones de Prolog en varias líneas con
% sangrado

      pp(X):- pp(X,0).
      pp(X,I):-var(X),!,write('_').
      pp(X,I):- X=..[Y,Y1|Ys], whoof(Y,Length),!,
           write(Y), write('('),
        pp(Y1,I+Length),
           pp1(Ys,I+Length),
           write(')').
       pp(X,I):- write(X).

      pp1([],I) :- !.
      pp1([X],I) :- !, write(','),nl,tab(I),pp(X,I).
      pp1([X|Xs],I) :- !,write(','),nl,tab(I),pp(X,I),pp1(Xs,I).

      whoof(s,2).
      whoof(np,3).
      whoof(vp,3).
      whoof(rel,4).
      whoof(int,4).

      whoof(I,L):- convert(I,List), length(List,LI),
           L is LI + 1.
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

```
                        /* INPUT.DEC */

read_in([Word|Words]):- get0(Char1), readword(Char1,Word,Char2),
                restsent(Word,Char2,Words).

restsent(Word,Char,[]):- lastword(Word),!.
restsent(Word1,Char1,[Word2|Words]):-
readword(Char1,Word2,Char2),
                            restsent(Word2,Char2,Words).

readword(10,'.',10):-!.
readword(Char1,Word,Char2):- single_char(Char1),!,
                    name(Word,[Char1]),get0(Char2).
readword(Char1,Word,Char2):- alpha(Char1,Char3),!,get0(Char4),
                    restword(Char4,Chars,Char2),
                    name(Word,[Char3|Chars]).
readword(Char1,Word,Char2):- get0(Char3),
                    readword(Char3,Word,Char2).

restword(Char1,[Char2|Chars],Char3) :- alpha(Char1,Char2),!,
                    get0(Char4),
                    restword(Char4,Chars,Char3).

restword(Char,[],Char).

single_char(X):- in(X,[10,33,44,46,58,59,63]).


alpha(Char,Char):- Char > 96, Char < 123.     % a - z
alpha(Char,Char):- Char > 47, Char < 58.      % 1 - 9
alpha(Char1,Char2):- Char1 > 64, Char1 < 91, % A - Z
                Char2 is Char1 + 32.
alpha(39,39).
alpha(45,45).
alpha(43,43).

lastword('.').
lastword('!').
lastword('?').
lastword([]).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Aproximación estadístico-algebraica al problema de la resolución de la anáfora en el discurso. Celia Rico Pérez


```
                    /* LIST.DEC */

          /* Herramientas para la manipulación de listas */

% append

     append([],L,L).
     append([X|Rest],Y,[X|Z]):- append(Rest,Y,Z).

% pertenencia a una lista

     in(X,[X|Rest]).
     in(X,[_|Rest]):- in(X,Rest).

% localizar el elemento 'n' en una lista

     nth(List,N,Element) :- nth_member(List,N,Element,1).

     nth_member([H|T],N,H,N).
     nth_member([H|T],N,X,C) :- C1 is C+1,
                nth_member(T,N,X,C1).

% dar la vuelta a los elementos de una lista

     reverse(Left,Right) :- var(Left), !, not var(Right),
                reverse(Right,Left).
     reverse(Left,Right) :- reverse(Left,[],Right).
     reverse([Head|Tail],List,Left)    :-
     reverse(Tail,[Head|List],Left).
     reverse([],List,List).

% borrar los elementos de una lista

     list_delete0(Discurso,Discurso,[]).
     list_delete0(Discurso,Y,[[]|T]):-!,
                list_delete0(Discurso,Y,T).
     list_delete0(Discurso,Y,[[H]|T]):-
                list_delete(Discurso,X,H),
           list_delete0(X,Y,T).

     list_delete(L,L,[]).
     list_delete([],[],H).
     list_delete([H|T],T,H):-!.
     list_delete([H|T],[H|TT],X):- list_delete(T,TT,X).

% conversión de átomos a cadenas y vice versa

     convert(X,X1):- % atom -> string
           var(X1), !, name(X,Codes),
                name1(Codes,X1).
     convert(X,X1):- % string -> atom
           var(X), !, name1(Codes,X1),
                name(X,Codes).

     name1([],[]).
     name1([X|Xs],[X1|X1s]):- name(X1,[X]), name1(Xs,X1s).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994

Volver al índice/Tornar a l'índex


```
% borra todos los elementos contenidos en una lista de la lista
L2
% y el resultado aparece en L3

      delfeat_all([],L,L).

      delfeat_all([H|T],L2,L3):- delfeat(H,L2,Temp),!,
              delfeat_all(T,Temp,L3).

      delfeat(_,[],[]).

      delfeat(X,[X|T],T):-!.

      delfeat(X,[Y|Z],[Y|Result]):- delfeat(X,Z,Result).
```


Tesis doctoral de la Universidad de Alicante. Tesi doctoral de la Universitat d'Alacant. 1994